
ESTATÍSTICA

Uma introdução à teoria e à prática

J. P. S. DE SOUSA

Visão Geral da Estatística e Análise de Dados

Uma Breve História da Estatística

A palavra estatística deriva dos termos neolatim *statisticum collegium* e italiano *statista*, que significam Colégio de Estado e Estadista respectivamente. A palavra alemã *Statistik* foi usada modernamente por Gottfried Achenwall em meados do século XVIII para designar a coleta de dados políticos, econômicos e sociais de um país, cujo equivalente em inglês era *political arithmetic*. Posteriormente, através de Sir John Sinclair e seus trabalhos no *Statistical Accounts of Scotland*, a palavra ganhou uma conotação mais ampla sobre coleta e classificação de dados.

Como vistos pelas suas raízes etimológicas, a estatística surgiu enquanto a disciplina que se preocupava com a coleta, tratamento, classificação e análise de dados sobre características político-sócio-econômicas de um país a fim de apoiar a formulação de políticas públicas.

A Estatística Matemática tem seus fundamentos no desenvolvimento da Teoria das Probabilidades, antes, com tratamento mais informal, nos trabalhos de Pierre de Fermat, Blaise Pascal e Christian Huygens no século XVII e Thomas Bayes no século XVIII. O rigor matemático também se expandiu no século XVIII com as obras *Ars Conjectandi* (1713) de Jakob Bernoulli e *The Doctrine of Chances* de Abraham Moivre (1718). A formalização matemática rigorosa das probabilidades veio ao auge com Andrei Kolmogorov no século XIX.

A disciplina estatística também tem laços com a Teoria de Erros, cujas origens remontam a *Opera Miscellanea* de Roger Cotes de 1772, e sua reedição por Thomas Simpson em 1755, que aplicou a teoria a erros de observação. A Teoria de Erros ganhou um aspecto mais analítico ainda no final do século XVIII e ao longo do XIX nas mãos de Pierre-Simon de Laplace, Joseph Louis Lagrange e Daniel Bernoulli. O seminal Método dos Mínimos Quadrados (MMQ) foi desenvolvido e publicado independentemente por Adrien-Marie Legendre, Carl Friedrich Gauss e Robert Adrain.

Com o desenvolvimento e sofisticação das técnicas estatísticas, como a amostragem, modelagem e inferência, a estatística na virada do século XIX para o XX, expandiu-se da esfera do Estado para se tornar uma disciplina aplicada em ciências naturais, sociais, administração pública e privada. Neste contexto, figuram nomes George Box, Pafnuty Chebyshev, Gertrude Cox, George Dantzig, Edward Deming, Bruno de Finetti, Sir Ronald Fisher, Sir Francis Galton, Aleksandr Lyapunov, Karl Pearson, Charles Spearman e John Tukey.

Atualmente a estatística é a disciplina central em qualquer outra área para lidar com dados e incertezas. O avanço das técnicas computacionais viabilizaram o desenvolvimento de técnicas e aplicações estatísticas cada vez mais robustas e complexas para lidar com quantidades massivas de dados e geração de conhecimento e compreensão para diversas áreas, como economia, ciências sociais, computação, inteligência de negócios, saúde, etc.

Modelos Estatísticos

A estatística é um ramo da matemática aplicada e da metodologia científica que busca extrair, reduzir, analisar e modelar um conjunto de dados que amostram uma população. Para isso, são usadas principalmente as ferramentas teóricas providas pela Teoria das Probabilidades, pois entende-se que os dados originam-se de fenômenos aleatórios, e, uma vez modelados, geralmente dois objetivos visam ser cumpridos: estimar ou prever o comportamento dos dados no futuro, ou realizar inferência, que consiste em detectar os padrões embutidos. A inferência pode ser feita por duas abordagens: a inferência dedutiva, que aceita determinadas premissas para chegar às conclusões, ou a inferência indutiva, que parte de casos particulares para generalizar.

Ainda sobre a inferência estatística, quando tenta-se modelar um determinado conjunto de dados, tentamos identificar padrões e tendências de comportamento através de modelos estatísticos. Supondo que temos um conjunto de dados D , e identificamos que conseguimos ajustar a eles um modelo M , teremos então que

$$D = M + R$$

onde R descreve a parte aleatória dos dados que não pode ser capturada pelo modelo, chamada de resíduos. Normalmente, busca-se que resíduos não devam conter nenhuma suavidade, pois isso implicaria em padrões que o modelo falhou em capturar, e mais suavização por parte de M será necessária.

Análise de Dados

A Análise de Dados consiste na inspeção, limpeza, transformação e modelagem de dados com o objetivo claro de obter informações úteis, informar conclusões ou apoiar a tomada de decisão. Em resumo, ela é o processo de extração de dados brutos para geração de conhecimento acionável, geralmente feito num ciclo iterativo. As fases desse processo podem ser divididas em:

1. **Requisitos de Dados:** a escolha de dados a serem extraídos dependem das análises que se deseja realizar. Aqui define-se a **unidade experimental**, que pode consistir de um indivíduo ou uma população deles, e as **variáveis** específicas dessa unidade, como idade e renda para uma população de pessoas.
2. **Coleta de Dados:** consiste na tarefa de obter os dados de diferentes fontes, como bancos de dados estruturados ou não-estruturados, sensores físicos, formulários, uma interface de programação de aplicação (API), arquivos binários ou de textos, entre muitas outras fontes.
3. **Processamento e Limpeza:** inclui tarefas de organizar os dados em formatos estruturados, identificar tipos, deduplicar, tratar valores faltantes, incorretos e desviantes e transformar o formato de dados para outros mais convenientes.
4. **Análise Exploratória:** compreende uma gama de técnicas para descrever e resumir os dados obtidos à procura de informações que ajudem entender relações entre

as variáveis e guie às técnicas a serem aplicadas nas fases posteriores. Aqui é comumente aplicadas técnicas da Estatística Descritiva e métodos gráficos.

5. Modelagem: são usados algoritmos e modelos estatísticos para extrair padrões latentes nos dados, muitas vezes não triviais de serem identificados. As técnicas de aprendizado estatístico são especialmente úteis nessa etapa.
6. Comunicação e Produto de Dados: a depender do contexto e das finalidades definidas a priori, busca-se maneiras de comunicar esses dados aos atores interessados na forma de visualizações e relatórios. Nos últimos anos, a disciplina de **Narrativa de Dados** tem se destacado para realizar essa comunicação.

A Análise de Dados, do ponto de vista da Estatística, poderia ser dividida em

1. Estatística Descritiva: utilizar medidas de resumo numéricas para os dados a fim de descrever padrões visíveis, geralmente respondendo perguntas do tipo “o que aconteceu?”.
2. Análise Exploratória: semelhante a anterior, porém empregando métodos mais flexíveis e visuais que permitam identificar padrões mais ocultos, correlações e anomalias. Ocorre num processo iterativo de formulação de perguntas, exploração e descobertas.
3. Análise Confirmatória: aplica as técnicas da inferência estatística para confirmar ou rejeitar hipóteses existentes das etapas anteriores

Sumário

I	Distribuições	1
1	Probabilidades	2
1.1	Noções de Medida	3
1.1.1	Análise	3
1.1.2	Introdução à Medida	4
1.1.3	Integral de Lebesgue	7
1.1.4	Espaços L^p	9
1.2	Cálculo das Probabilidades	11
1.3	Probabilidade Condicional e Independência	14
1.4	Teorema de Bayes	16
2	Variáveis Aleatórias	18
2.1	Variáveis Aleatórias	18
2.2	Função de Distribuição Acumulada	20
2.3	Variáveis Aleatórias Discretas	22
2.4	Variáveis Aleatórias Contínuas	25
2.5	Transformações	28
2.5.1	Transformação de Variáveis Discretas	29
2.5.2	Transformação de Variáveis Contínuas	30
2.6	Esperança e Momentos	32
3	Modelos de Distribuição de Probabilidade	35
3.1	Modelos de Distribuição Discreta	35
3.1.1	Distribuição Bernoulli	35
3.1.2	Distribuição Binomial	36
3.1.3	Distribuição Geométrica	37
3.1.4	Distribuição Binomial Negativa	38
3.1.5	Distribuição Hipergeométrica	39

3.1.6	Distribuição de Poisson	40
4	Variáveis Aleatórias Multidimensionais	42
5	Simulação	43
II	Análise Exploratória	44
6	Modelos e Descrição de Dados	45
6.1	Tipos de Dados	45
6.2	Escala de Dados	46
6.3	Tabelas de Frequência	46
6.4	Gráficos	47
7	Medidas de Resumo	48
7.1	Medidas de Posição	48
7.2	Medidas de Dispersão	49
8	Análise de Dados de Duas Variáveis	50
III	Inferência Clássica	51
9	Amostragem	52
10	Estimação de Parâmetros	53
11	Testes de Hipóteses	54
12	Inferência Multipopulacional	55
13	Análise de Aderência e Adesão	56
14	Teste de Hipótese Não Paramétricos	57
IV	Regressão	58
15	Covariância e Correlação	59
16	Regressão Linear	60
17	Regressão Linear Generalizada	61
V	Inferência Bayesiana	62
18	Paradigma Bayesiano	63

19	Inferência e Decisão	64
20	Computação Bayesiana	65
VI	Séries Temporais	66
21	Fundamentos de Séries Temporais	67
22	Modelagem e Previsão	68

PARTE I

DISTRIBUIÇÕES

Probabilidades

Ao observar, registrar ou extrair uma amostra de dados a partir de um fenômeno aleatório, isto é, cujo resultado não pode ser deterministicamente previsto, a Estatística, dentre outras coisas, procura entender o comportamento das frequências de ocorrência dos valores amostrados. Essas frequências são estimativas das **probabilidades** dos eventos observados. A partir de hipóteses adequadas, podemos modelar as frequências por modelos probabilísticos que, por sua vez, são objetos de estudo da Teoria das Probabilidades.

Probabilidades são frequentemente representadas como porcentagens e são muitas vezes entendidas como a frequência de um evento quando se repete o experimento um número suficiente de vezes. Por exemplo, dizer que 16% da população possui diploma de graduação significaria que se escolhermos aleatoriamente 100 pessoas dessa população, cerca de 16 delas teriam diploma de graduação. Essa abordagem é chamada de **frequentista**, sendo a mais amplamente adotada em aplicações estatísticas clássicas.

Outra abordagem para compreender probabilidades é enquanto o grau de crença numa hipótese, como ao dizer que se tem 80% de certeza em dizer que irá chover, visto as evidências do céu nublado e ventos frios. Essa é uma visão mais intuitiva e moderna de probabilidades, sendo chamada de **Bayesiana**, sendo a base da Inferência Bayesiana.

A moderna Teoria das Probabilidades é fundamenta utilizando-se conceitos da Teoria da Medida, um ramo da Análise que generaliza as noções de comprimento, área e volume para espaços abstratos associando-os a uma “medida”, a partir da qual também estende-se uma Teoria de Integração para esses espaços. Probabilidades são vistas, portanto, como medidas das chances de ocorrência de um subconjunto de eventos dentro de um universo de resultados possíveis.

1.1 Noções de Medida

Nesta seção, será realizada uma breve exposição dos principais enunciados sobre a Teoria da Medida a fim de fundamentar o desenvolvimento posterior dos conceitos associados à Teoria de Probabilidades, que, por sua vez, garante a fundamentação da teoria estatística.

1.1.1 Análise

O conceito de continuidade, estudado dentro da Análise, está atrelado à ideia de poder aproximar uma função real a um determinado valor variando suavemente seu argumento.

Definição 1.1. *Um função $f : \mathbb{R} \rightarrow \mathbb{R}$ é uniformemente contínua em $a \in \mathbb{R}$ se*

$$\forall \epsilon > 0 \exists \delta \in \mathbb{R} \forall x \in \mathbb{R}, |x - a| < \delta \rightarrow |f(x) - f(a)| < \epsilon$$

Outra forma equivalente de definição de continuidade é

$$\lim_{x \rightarrow a} f(x) = \lim_{x \rightarrow a^+} f(x) = \lim_{x \rightarrow a^-} f(x) = f(a).$$

Funções que não são contínuas em determinado ponto significa que, a depender de onde nos aproximamos, o valor para o qual a função converge se diferencia.

Exemplo 1.1. *A função $f(x) = x^2$ é contínua em todo ponto de seu domínio, já que*

$$\lim_{x \rightarrow a} x^2 = a^2$$

Exemplo 1.2. *Funções escadas são exemplo de funções não contínuas.*

A próxima definição é uma versão mais forte da anterior. A continuidade uniforme significa que, independente da escolha de limite de erro ϵ para o valor da função, há um único δ tal que em qualquer lugar observa-se que, se $|x - a| < \delta$, então $|f(x) - f(a)| < \epsilon$.

Definição 1.2. *Uma função $f : \mathbb{R} \rightarrow \mathbb{R}$ é uniformemente contínua se*

$$\forall \epsilon > 0 \exists \delta \in \mathbb{R} \forall x, a \in \mathbb{R}, |x - a| < \delta \rightarrow |f(x) - f(a)| < \epsilon$$

Uma função que não é uniformemente contínua pode ter variações muita abruptas em alguns intervalos, e mais suaves em outros.

Exemplo 1.3. *As funções $\sin x$, $\cos x$ e funções lineares são exemplos de absolutamente contínuas, pois suas taxas de variação não se tornam infinitamente grandes conforme a função se aproxima de qualquer ponto.*

Exemplo 1.4. *A função $f(x) = 1/x$ não é uniformemente contínua, pois conforme se aproxima de 0, a sua variação se torna infinitamente grande.*

Conjuntos que podem ser inteiramente contidos em um aberto e que possuem todos os seus pontos de acumulação são ditos compactos. Quando uma função é contínua em cada ponto de um compacto, então é seguro dizer que ela será uniformemente contínuo ao longo de todo o conjunto.

Teorema 1.1. *Seja f uma função pontualmente contínua em X . Se X é compacto (fechado e limitado), então f é uniformemente contínua em X .*

A continuidade uniforme é uma restrição avaliada a cada par de pontos dentro de um intervalo. Já a continuidade absoluta significa que podemos tomar tantos intervalos quanto pudermos enumerar e somar seus comprimentos de forma que, a soma dos comprimentos dos intervalos no domínio levam a pequenas somas de intervalos na imagem, não estando mais estrita a pontos somente.

Definição 1.3. *Uma função f é absolutamente contínua em $[a, b]$ se para todo $\epsilon > 0$ existe $\delta \in \mathbb{R}$ tal que, para quaisquer intervalos disjuntos*

$$(a_k, b_k) \subset [a, b]$$

tem-se

$$\sum_k (b_k - a_k) < \delta \implies \sum_k |f(b_k) - f(a_k)| < \epsilon$$

1.1.2 Introdução à Medida

Antes de podermos medir determinados conjuntos, precisamos entender que tipos de conjuntos podem ser medidos. Com esse propósito, introduz-se o conceito de σ -álgebras, que define uma álgebra sobre uma coleção de partes de um conjunto cujas operações definem conjuntos **mensuráveis**, i.e., que podem ser medidos em certo sentido.

Definição 1.4. *Seja Ω um conjunto e $\mathcal{B} \subset \mathcal{P}(\Omega)$. O conjunto $\mathcal{B}$ é uma σ -álgebra de Ω se, e somente se,*

$$i \quad \emptyset \in \mathcal{B}.$$

$$ii \quad \forall A \in \mathcal{B}, A^c \in \mathcal{B}.$$

$$iii \quad \forall A \in \mathcal{B}, \bigcup_{i=1}^{\infty} A_i \in \mathcal{B}.$$

Se Ω é um espaço amostral, então $A \in \mathcal{B}$ é denominado evento de Ω .

O caso dos números reais será especial a nós. Comumente, nos referimos à **topologia usual** dos reais como a coleção de todos os intervalos – abertos e fechados – e conjuntos enumeráveis de números reais. A σ -álgebra de Borel para $\mathbb{R}$ é aquela que, a partir de um conjunto de geradores na forma $(-\infty, x]$, com $x \in \mathbb{R}$, consegue criar a topologia usual dos reais.

Definição 1.5. *Seja $\mathcal{G} = \{(-\infty, x] \mid x \in \mathbb{R}\}$. A σ -álgebra gerada por $\mathcal{G}$ é chamada σ -álgebra de Borel em $\mathbb{R}$ e é denotada por $\mathcal{B}(\mathbb{R})$.*

Definição 1.6. *Um conjunto é dito de medida nula se para todo $\epsilon > 0$ existe uma cobertura enumerável $\{I_k\}_1^n$ tal que a soma dos comprimentos de cada intervalo I_k é menor que ϵ .*

Ao especificar um universo de elementos e as suas partes que podem ser “medidas”, então chegamos a um espaço mensurável. Se encontrarmos uma função, chamada de **medida**, que satisfaça hipóteses de o vazio tem medida 0 e que a medida da soma de partes disjuntas é a soma das medidas, então essa medida, junto com o universo e a sua σ -álgebra, formam um espaço de medida.

Definição 1.7. O par $(\Omega, \mathcal{B})$ é dito mensurável se $\mathcal{B}$ for uma σ -álgebra de Ω . A função $\mu : \mathcal{B} \rightarrow \mathbb{R}_+$ é uma medida para $(\Omega, \mathcal{B})$ se satisfaz

$$i. \mu(\emptyset) = 0$$

$$ii. \sigma\text{-aditividade: } \mu\left(\bigsqcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i)$$

A tripla $(\Omega, \mathcal{B}, \mu)$ é chamado de espaço de medida.

Sem a restrição sobre a pré-imagem de f , haveriam conjuntos na imagem que podem ser medidos cujas contrapartes não o poderiam.

Dentre todas as medidas, a de maior destaque é a de Lebesgue, que define uma forma “canônica” de medir intervalos reais, podendo ser generalizada para medir retângulos em qualquer dimensão. Essa medida se comporta analogamente a uma régua, pois ela satisfaz que a medida do intervalo é o comprimento dele.

Definição 1.8. A medida λ de Lebesgue para $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ satisfaz

$$\lambda((a, b]) = b - a$$

Outra medida importante é a de contagem, que associa cada conjunto à sua cardinalidade. Em especial, para conjunto finitos, isso representa a quantidade de elementos no conjunto.

Definição 1.9. Se a medida μ satisfaz

$$\mu(A) = \begin{cases} |A|, & \text{se } A \text{ for finito} \\ |\infty|, & \text{caso contrário} \end{cases}$$

então μ é medida de contagem.

Teorema 1.2. Se $(\Omega, \mathcal{B}, \mu)$ é uma espaço de medida e $\{A_n\}$ é uma família enumerável de elementos de $\mathcal{B}$, então

i. continuidade por baixo: Se $A_1 \subset A_2 \subset \dots$, então

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow \infty} \mu(A_n)$$

ii. continuidade por cima: Se $A_1 \supset A_2 \supset \dots$, então

$$\mu\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow \infty} \mu(A_n)$$

iii. Sub-aditividade

$$\mu \left(\bigcup_{n=1}^{\infty} A_n \right) \leq \sum_{n=1}^{\infty} \mu(A_n)$$

Desejamos que, quando um conjunto está contido em outro, então sua medida deve ser menor ou igual ao do conjunto que contém. Isso expressa-se no próximo Teorema.

Teorema 1.3. *Seja $(\Omega, \mathcal{B}, \mu)$ espaço de medida, e A e B elemetos de $\mathcal{B}$.*

$$A \subset B \rightarrow \mu(A) \leq \mu(B)$$

Há dois tipos de medida que valem serem citadas. As medidas completas são aquelas que qualquer subconjunto de um outro que tenha medida nula também terá medida nula. Por sua vez, as σ -finitas são aquelas que permite particionar o universo em enumeráveis partes de medida finita.

Definição 1.10. *Uma medida μ para $(\Omega, \mathcal{B})$ é dita completa se*

$$\forall S \in \mathcal{B} \forall A, \mu(S) = 0 \wedge (A \subset S \rightarrow A \in \mathcal{B})$$

A medida μ é dita σ -finita se

$$\Omega = \bigcup_{n=1}^{\infty} A_n$$

com $\mu(A_n) < \infty$ para todo $n \in \mathbb{N}$.

Teorema 1.4. *A medida de Lebesgue e de contagem são σ -finitas.*

Definição 1.11. *Seja $(\Omega, \mathcal{B})$ um espaço mensurável por medidas ν e μ . Dizemos que ν é absolutamente contínua em relação a μ , denotado por $\nu \ll \mu$, se*

$$\forall A \in \mathcal{B}, \mu(A) = 0 \implies \nu(A) = 0.$$

Funções, sob certas circunstâncias apropriadas, podem ser compreendidas como transformações de um espaço. Quando aplicamos uma função f com domínio no universo Ω de um espaço mensurável e obtemos um novo universo que pode ser medido, então essa função será mensurável caso, para todo conjunto “medível” na imagem, sua contraparte no domínio também é um conjunto que pode ser medido.

Definição 1.12. *Sejam $(\Omega, \mathcal{B})$ e $(\Omega', \mathcal{B}')$ espaços de medida. Uma função $f : \Omega \rightarrow \Omega'$ é mensurável – ou $(\mathcal{B}, \mathcal{B}')$ -mensurável – se*

$$\forall B \in \mathcal{B}', f^{-1}(B) \in \mathcal{B}$$

onde f^{-1} denota a pré-imagem de f .

Teorema 1.5. *São verdadeiras as seguintes afirmações:*

- i. Toda função contínua é mensurável.*
- ii. Se f e g são funções mensuráveis, então são mensuráveis*

$$f \circ g, \quad f \cdot g, \quad \frac{f}{g}, g \neq 0$$

iii. Se $\{f_n\}$ é uma sequência de funções mensuráveis, então são mensuráveis

$$\limsup f_n, \quad \liminf f_n, \quad \sup f_n, \quad \inf f_n$$

iv. O limite pontual de uma função mensurável é mensurável.

Quando temos uma função f mensurável, pode ser desejável trabalhar como uma versão dela que se comporte tal como uma medida, mas especialmente como a medida de Lebesgue. Com esse fim, defini-se a medida de Stieltjes, que mede intervalos como, por exemplo, a distância vertical entre dois pontos no gráfico de uma função real.

Definição 1.13. Se $f : \mathbb{R} \rightarrow \mathbb{R}$ é uma função mensurável monótona crescente e contínua à direita, então a medida induzida de Stieltjes por f , denotada por μ_f , satisfaz

$$\mu_f((a, b]) = f(b) - f(a)$$

O próximo resultado mostra uma propriedade fundamental das medidas de Stieltjes.

Teorema 1.6. Seja μ_f a medida de Stieltjes induzida por f . A função f é absolutamente contínua se, e somente se, $\mu_f \ll \lambda$, onde λ é a medida de Lebesgue.

1.1.3 Integral de Lebesgue

A integral de Riemann falha ao tentarmos integrar a maioria das funções. A fim de estender a integração para uma classe maior de funções, a Teoria da Medida expandiu o conceito de integral enquanto uma generalização da medida de comprimentos de comprimentos, áreas, volumes, etc. Esse desenvolvimento culminou na própria moderna Teoria de Medida, tendo como uma de suas bases a integração de Lebesgue.

Definição 1.14. A aplicação $\phi : \Omega \rightarrow \mathbb{R}$ é uma função simples se pode ser expressa com

$$\phi(x) = \sum_{i=1}^n a_i \cdot I_{A_i}(x)$$

onde $a_i \in \mathbb{R}$ e $\{A_i\}_{i=1}^n \subset \mathcal{B}(\mathbb{R})$ são dois a dois disjuntos.

As funções simples designam uma classe de funções que assumem um conjunto finito de valores. Sua importância encontra-se no Teorema a seguir, o qual enuncia que qualquer função não negativa pode ser aproximado por uma seqência de funções simples.

Teorema 1.7. Para toda função $f \geq 0$ há uma sequência $\{\phi_i\}_{i \in \mathbb{N}}$ não negativa e crescente de funções simples tal que $\phi \rightarrow f$ pontualmente, e uniformemente se f for limitada.

Com isso, estamos prontos para definir a importante Integral de Lebesgue,

Definição 1.15. Dada a medida λ de Lebesgue, a integral de Lebesgue, denotada por

$$\int f d\lambda$$

satisfaz

i. Se f é simples, então

$$\int f d\lambda = \sum_{i=1}^n a_i \cdot \lambda(A_i)$$

ii. sendo f é mensurável e $\{\phi\}_{\mathbb{N}}$ tal que $\phi_n \rightarrow f$, então

$$\int f d\lambda = \lim_{n \rightarrow \infty} \int \phi_n d\lambda$$

e o limite existe e não depende da sequência $\{\phi\}_{\mathbb{N}}$.

iii. Se $f = f^+ - f^-$, onde $f^+ = \max(0, f)$ e $f^- = \max(0, -f)$, então

$$\int f d\lambda = \int f^+ d\lambda + \int f^- d\lambda$$

desde que $\int |f| d\lambda < \infty$.

Teorema 1.8. A integral de Lebesgue satisfaz

i. **Linearidade:**

$$\int (af + bg) d\lambda = a \int f d\lambda + b \int g d\lambda$$

ii. **Monotonicidade:**

$$f \leq g \text{ q.s.} \rightarrow \int f d\lambda \leq \int g d\lambda$$

iii. **Aditividade:** Se $A \cap B = \emptyset$, então

$$\int_{A \cup B} f d\lambda = \int_A f d\lambda + \int_B f d\lambda$$

iv. **Nulidade:** Se $f \geq 0$ mensurável,

$$\forall A \in \mathcal{B}(\mathbb{R}), \int_A f d\lambda = 0 \leftrightarrow f = 0 \text{ q.s. em } A$$

v. **Desigualdade de Módulo:**

$$\left| \int f d\lambda \right| \leq \int |f| d\lambda$$

vi. **Riemann:**

$$\int_{[a,b]} f d\lambda = \int_a^b f(x) dx$$

Teorema 1.9 (Convergência Monótona). Se $\{f_n\}_{\mathbb{N}}$ é uma sequência não negativa e crescente de funções mensuráveis e $f_n \rightarrow f$ q.s., então

$$\lim_{n \rightarrow \infty} \int f_n d\lambda = \int f d\lambda$$

Lema 1.1 (de Fatou). Se $f_n \geq 0$ são mensuráveis, então

$$\int \liminf f_n d\lambda \leq \liminf \int f_n d\lambda$$

Teorema 1.10. *Se $f_n \rightarrow f$ q.s. e existe $g \in L^1(\lambda)$ tal que $|f_n| \leq g$ q.s. para todo n , então*

$$\lim_{n \rightarrow \infty} \int f_n d\lambda = \int f d\lambda$$

O Teorema de Toneli é um importante resultado do cálculo integral. Ele enuncia que dada uma função não negativa e desejamos integrá-la num espaço de medida dado como produto de outros dois, podemos integrar individualmente em relação a cada espaço individualmente de forma iterada.

Teorema 1.11. *Para $f \geq 0$ mensurável em*

$$(\Omega_1 \times \Omega_2, \mathcal{A}_1 \otimes \mathcal{A}_2, \mu_1 \otimes \mu_2)$$

vale que

$$\int \int f d(\mu_1 \otimes \mu_2) = \int (f d\mu_1) d\mu_2 = \int (f d\mu_2) d\mu_1$$

No cálculo integral multivariável tradicional, esse resulta se torna especialmente útil, pois justifica a integração iterada em cada variável de forma independente. Desse modo, enuncia-se o Teorema de Fubini:

Teorema 1.12. *Se*

$$\int |f| d(\mu_1 \otimes \mu_2) < \infty$$

então as integrais iteradas existem q.s. e são iguais às integrais duplas.

Logo, toda função integrável permite a integração (quase sempre) iterada de cada variável.

Teorema 1.13. *Seja $(\Omega, \mathcal{A}, \mu)$ espaço mensurável onde μ é de contagem, e f uma função não negativa mensurável. Para todo mensurável $A \in \mathcal{A}$,*

$$\int_A f d\mu = \sup \left\{ \sum_{x \in F} f(x) \mid F \subseteq A, F \text{ finito} \right\}$$

Em especial, se

$$\int_A |f| d\mu < \infty$$

então

$$\int_A f d\mu = \sum_{x \in A} f(x)$$

tal que a série à direita é absolutamente convergente.

1.1.4 Espaços L^p

Os espaços L^p são espaços funcionais de aplicações mensuráveis e integráveis. Através deles, podemos definir noção de “norma” para funções, a qual utiliza a integração em relação a uma medida.

Definição 1.16. Para $1 \leq p \leq \infty$,

$$L^p(\mu) = \left\{ f \text{ mensurável} \mid \int |f|^p d\mu < \infty \right\}$$

e

$$\|f\|_p = \left(\int |f|^p d\mu \right)^{\frac{1}{p}}$$

Se $p = \infty$,

$$\|f\|_\infty = \text{ess sup } |f|$$

O Teorema de Hölder é uma generalização da famosa Desigualdade Cauchy-Schwartz para funções em espaços L^p distos conjugados.

Teorema 1.14 (de Hölder).

$$\int (fg) d\mu = \|f\|_p \cdot \|g\|_q$$

onde

$$\frac{1}{p} + \frac{1}{q} = 1.$$

Se $p = q = 2$, então o Teorema de Hölder equivale à Desigualdade de Cauchy-Schwartz. O próximo teorema generaliza a desigualdade triangular para espaços L^p .

Teorema 1.15.

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p$$

Logo, todos os espaços L^p são normados e completos (de Banach). Em especial, L^2 é um espaço de Hilbert.

Teorema 1.16. Se $\mu(\Omega) < \infty$ e $p \leq q$, então $L^p(\Omega) \subset L^q(\Omega)$

Teorema 1.17 (de Radon-Nikodym). Seja $(S, \mathcal{B})$ um espaço mensurável por medidas μ e ν . Se μ é σ -finita e $\nu \ll \mu$, então existe uma função mensurável não negativa $f \in L^1(\mu)$ tal que

$$f = \frac{d\nu}{d\mu} \iff \forall A \in \mathcal{B}, \nu(A) = \int_A f d\mu$$

Ademais, se a função g satisfaz a expressão anterior, então

$$g = \frac{d\nu}{d\mu} \iff f = g \text{ q.s.}$$

Teorema 1.18. Se F é uma função absolutamente contínua, então existe $f \in L^1(\lambda)$ tal que

$$F(x) = F(a) + \int_a^x f d\lambda$$

onde dizemos que $f = F'$ q.s.

Teorema 1.19. Se $f = F'$ q.s. e f é contínua em x , então $f(x) = F'(x)$.

Definição 1.17. *Sejam $(\Omega, \mathcal{B}, \mu)$ um espaço de medida, $(\Omega', \mathcal{B}')$ um espaço mensurável e $T : \Omega \rightarrow \Omega'$ uma função mensurável. Dizemos que ν é a medida imagem obtida ao impulsionar μ por T , denotado por*

$$\nu = T \cdot \mu,$$

se

$$\forall B \in \mathcal{B}', \nu(B) = \mu(T^{-1}(B))$$

onde T^{-1} denota a pré-imagem de T .

Teorema 1.20. *Sejam $(\Omega, \mathcal{B}, \mu)$ e $(\Omega', \mathcal{B}', \nu)$ espaços de medida, onde ν é a medida imagem de μ impulsionada por $T : \Omega \rightarrow \Omega'$ mensurável. Se $f : \Omega' \rightarrow \mathbb{R}$ é mensurável e não negativa, então*

$$\int_{\Omega'} f d\nu = \int_{\Omega} (f \circ T) d\mu$$

1.2 Cálculo das Probabilidades

A Teoria de Probabilidades fundamenta-se em três princípios primitivos conhecidos como Axiomas de Kolmogorov. Dado um universo de possibilidades Ω , chamado de espaço amostral, e cujas partes são chamadas de eventos, enuncia-se que

Axioma 1. A probabilidade é uma função não negativa

Axioma 2. A probabilidade do espaço amostral é 1.

Axioma 3. A probabilidade de eventos disjuntos é a soma de suas respectivas probabilidades.

Podemos traduzir esses axiomas na nomenclatura de medida. O espaço amostral trata-se do universo de um espaço de medida, de sorte que os eventos são os elementos de uma σ -álgebra desse universo. A função de probabilidade é, portanto, uma medida para os eventos que pode ser interpretada como o quão provável é obter os elementos do evento num experimento aleatório. Uma vez que medidas satisfazem não negatividade e σ -aditividade por definição, para resumir os axiomas basta então impor que a medida aplicada a totalidade do universo é igual a 1.

Definição 1.18. *Um espaço de medida $\Omega, \mathcal{F}, P$ é um espaço de probabilidade se é satisfeito que*

$$P(\Omega) = 1.$$

Os elementos $A \in \mathcal{F}$ são chamados de eventos. O conjunto Ω é denominado espaço amostral.

Os Teoremas 1.21 e 1.22 nos ajudarão a facilitar a avaliação e, futuramente, a computação de probabilidades

Teorema 1.21. *Se $(\Omega, \mathcal{F}, P)$ é espaço de probabilidade, então*

$$i. P(A^c) = 1 - P(A)$$

ii. $P(A) \leq 1$

Demonstração. Para (i), temos que $A \cup A^c = \Omega$, então por σ -aditividade,

$$\begin{aligned} P(A) + P(A^c) &= P(\Omega) \\ P(A^c) &= P(\Omega) - P(A) = 1 - P(A) \end{aligned}$$

A afirmação (ii) segue de (i) e da propriedade de imagem não negativade de medida:

$$P(A^c) \geq 0 \implies 1 - P(A) \geq 0 \implies P(A) \leq 1.$$

■

Teorema 1.22. *Se $(\Omega, \mathcal{F}, P)$ é espaço de probabilidade, e A e B são eventos, então*

$$i \quad P(B \cap A^c) = P(B) - P(B \cap A).$$

$$ii \quad P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Demonstração. Para (i), considere primeiramente que

$$(B \cap A) \cup (B \cap A^c) = B$$

e como $(B \cap A) \cap (B \cap A^c) = \emptyset$, então podemos usar aditividade de medidas:

$$\begin{aligned} P(B \cap A) + P(B \cap A^c) &= P(B) \\ P(B \cap A^c) &= P(B) - P(B \cap A). \end{aligned}$$

Para provar (ii), usaremos a probabilidade do complementar e a afirmação (i):

$$\begin{aligned} P(A \cup B) &= 1 - P(A^c \cap B^c) \\ &= 1 - [P(A^c) - P(A^c \cap B)] \\ &= P(A) + P(A^c \cap B) \\ &= P(A) + P(B) - P(A \cap B). \end{aligned}$$

■

Para espaços amostrais enumeráveis, ao associar a cada resultado individual um número em $[0, 1]$, de modo que a soma dos pesos resulte em 1, a soma dos pesos dos resultados presentes num evento será a probabilidade desse evento.

Teorema 1.23. *Seja $\Omega = \{\omega_i\}_{\mathbb{N}}$ um conjunto enumerável, e $\mathcal{F}$ uma σ -Álgebra de Ω . Seja $\delta : \Omega \rightarrow [0, 1]$ função tal que*

$$\sum_{\omega \in \Omega} \delta(\omega) = 1.$$

Presuma também que, se $A \in \mathcal{F}$, então

$$P(A) = \sum_{\omega \in A} \delta(\omega)$$

A tripla $(\Omega, \mathcal{F}, P)$ é um espaço de probabilidade.

Demonstração. Precisamos provar que P é uma medida de probabilidade que satisfaz os Axiomas de Medida.

Não negatividade Como $\delta \geq 0$, então para todo A em $\mathcal{F}$ vale que $P(A) \geq 0$.

Probabilidade do espaço amostral satisfeito por hipótese.

Soma de eventos disjuntos seja $\{A_j\}_{j \in \mathbb{N}}$ uma família disjunta de eventos de $\mathcal{F}$ tal que

$$A_j = \{\omega_i \mid i \in I_j\}$$

em que I_j é um conjunto de índices. Desenvolvendo,

$$P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} \sum_{i \in I_j} \delta(\omega_i) = \sum_{j=1}^{\infty} P(A_j)$$

■

Esse resultado é útil para computar a probabilidade de uma vasta gama de experimentos aleatórios na prática. Um exemplo é o lançamento de um dado de 6 faces; se acreditamos que o dado é honesto, isto é, que o dado não é viciado em nenhuma de suas faces, então podemos associar $1/6$ a cada face do dado. Se por exemplo, deseja-se saber a probabilidade de obtermos um número menor ou igual a 3, basta somar as faces que satisfazem essa condição, obtendo uma probabilidade de 0.5. Experimentos os quais acreditamos não conterem vícios são chamados de equiprováveis.

As σ -Álgebras que equivalem ao conjunto das partes do espaço amostral são chamadas de σ -Álgebra potência. Quando o espaço amostral do experimento é enumerável e a sua σ -álgebra é a potência, ocorre que cada subconjunto unitário do espaço amostral – um resultado individual – é um evento do experimento. Se o experimento é equiprovável, então todos os resultados são eventos de mesma probabilidade.

Definição 1.19. *Seja o espaço $(\Omega, \mathcal{B}, P)$ com Ω finito, $\mathcal{B} = \mathcal{P}(\Omega)$ e P definido como no Teorema 1.23. Chama-se esse espaço de equiprovável se, e somente se,*

$$\forall \omega \in \Omega, P(\omega) = \frac{1}{|\Omega|}.$$

A probabilidade de eventos em experimentos com resultados equiprováveis destaca-se por ser intuitiva de calcular. A probabilidade de evento será, simplesmente, a fração dos resultados presentes nele. Esse resultado será enunciado como Corolário do Teorema 1.23.

Corolário 1.1. *A probabilidade de um evento $A \in \mathcal{P}(\Omega)$ num espaço $(\Omega, \mathcal{P}(\Omega), P)$ equiprovável é igual a*

$$\frac{|A|}{|\Omega|}$$

Demonstração.

$$P(A) = |A| \cdot \frac{1}{|\Omega|} = \frac{|A|}{|\Omega|}$$

■

1.3 Probabilidade Condicional e Independência

Em experimentos aleatórios, um determinado evento pode ser mais ou menos frequente a depender do conhecimento da ocorrência de outro evento. Nesse caso, dizemos que um evento está condicionado a outro.

Definição 1.20. *Seja $(\Omega, \mathcal{B}, P)$ um espaço de probabilidade. Sejam E e F eventos de $\mathcal{B}$ com $P(F) \neq 0$. A probabilidade condicional do evento E dado F , denotada por $P(E|F)$, é dada por*

$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

Quando a interseção entre dois eventos é vazia, então teremos que a probabilidade condicional será 0. A probabilidade condicional induz uma forma de determinar a probabilidade do evento dado como interseção de vários outros.

Proposição 1.1 (Regra do Produto). *Seja $\mathcal{F} = \{E_i\}_n$ uma família de eventos disjuntos de um espaço de probabilidade $(\Omega, \mathcal{B}, P)$.*

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = \prod_{i=1}^n P\left(E_i \mid \bigcap_{j < i} E_j\right)$$

Demonstração. A prova será por indução em n

Base: $n = 1$ é trivial.

Hipótese de Indução: admita que o resultado vale para uma família de n eventos. Se $|\mathcal{F}| = n + 1$, então façamos

$$\bigcap_{j < n+1} E_j = E'$$

e obtemos que

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P(E' \cap E_n) = P(E_n|E')P(E').$$

Como a hipótese de indução vale para E' , então

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P\left(E_n \mid \bigcap_{j < n+1} E_j\right) \cdot \prod_{i=1}^n P\left(E_i \mid \bigcap_{j < i} E_j\right) = \prod_{i=1}^{n+1} P\left(E_i \mid \bigcap_{j < i} E_j\right)$$

Uma vez que a proposição vale para $n + 1$, então vale para todo $n \in \mathbb{N}$ pelo princípio de indução. ■

Eventos independentes são aqueles cuja probabilidade de ocorrência não depende da ocorrência de outro. Isso equivale a dizer que, o conhecimento do acontecimento de um evento não muda a crença na ocorrência de outro.

Definição 1.21. *Dois eventos E e F de um espaço $(\Omega, \mathcal{B}, P)$ são independentes se, e somente se*

$$P(E \cap F) = P(E) \cdot P(F)$$

Proposição 1.2. Se E e F são eventos independentes de $(\Omega, \mathcal{B}, P)$, então

$$P(E|F) = P(E) \quad e \quad P(F|E) = P(F)$$

Demonstração. Por definição de probabilidade condicional,

$$P(E \cap F) = P(E|F) \cdot P(F)$$

mas como E e F são independentes por hipótese,

$$\begin{aligned} P(E) \cdot P(F) &= P(E|F) \cdot P(F) \\ P(E) &= P(E|F) \end{aligned}$$

e o mesmo pode ser mostrado analogamente para $P(F)$. ■

Proposição 1.3. Sejam E e F eventos em $(\Omega, \mathcal{B}, P)$. Se eles são independentes, então os seguintes eventos também o são:

1. E e F^c
2. E^c e F
3. E^c e F^c

Demonstração. Para (1), é verdade que

$$\begin{aligned} P(E \cap F^c) &= P(E) - P(E \cap F) \\ &= P(E)[1 - P(F)] \\ &= P(E)P(F^c) \end{aligned}$$

A expressão (2) é análoga a (1). Por fim, para expressão (3), conclua que

$$\begin{aligned} P(E^c \cap F^c) &= P((E \cup F)^c) = 1 - P(E \cup F) \\ &= 1 - P(E) - P(F) + P(E \cap F) \\ &= P(E^c) - P(F) + P(E) \cdot P(F) \\ &= P(E^c) - P(F)[1 - P(E)] \\ &= P(E^c) - P(F) \cdot P(E^c) \\ &= P(E^c)[1 - P(F)] \\ &= P(E^c) \cdot P(F^c) \end{aligned}$$

■

Teorema 1.24 (Teorema de Probabilidade Total). Seja o espaço de probabilidade $(\Omega, \mathcal{B}, P)$. Seja $\mathcal{F} = \{F_i\}_{i \in \mathbb{N}}$, com $\mathcal{F} \subset \mathcal{B}$, uma partição de Ω . Se $E \in \mathcal{B}$, então

$$P(E) = \sum_{F \in \mathcal{F}} P(E|F) \cdot P(F)$$

Demonstração. Para quaisquer $i, j \in \mathbb{N}$ temos que

$$(E \cap F_i) \cap (E \cap F_j) = \emptyset.$$

Com isso, podemos usar aditividade enumerável disjunta,

$$P\left(\bigcup_{F \in \mathcal{F}} (E \cap F)\right) = \sum_{F \in \mathcal{F}} P(E \cap F).$$

Em vista de que

$$\bigcup_{F \in \mathcal{F}} (E \cap F) = E \cap \Omega = E,$$

então

$$P(E) = \sum_{F \in \mathcal{F}} P(E \cap F),$$

e pela definição de probabilidade condicional,

$$P(E) = \sum_{F \in \mathcal{F}} P(E|F) \cdot P(F).$$

■

1.4 Teorema de Bayes

Teorema 1.25 (Teorema de Bayes). *Seja $(\Omega, \mathcal{B}, P)$ um espaço de probabilidade. Se E e F são eventos, então*

$$P(E|F) = P(F|E) \frac{P(E)}{P(F)}$$

Demonstração.

$$P(E|F) \cdot P(F) = P(E \cap F) = P(F|E)P(E)$$

$$P(E|F) = P(F|E) \frac{P(E)}{P(F)}$$

■

Uma interpretação para o teorema é a atualização na crença $P(E)$, chamada de **prior**, numa hipótese E dada uma nova evidência F para ela, obtendo um novo grau de crença $P(E|F)$ chamado de **posterior**. A probabilidade $P(F|E)$ é chamada de **verossimilhança**, denotando o quão verossímil é observar a evidência F considerando a hipótese E verdadeira. Por sua vez, $P(F)$ é a crença na ocorrência de F tendo em vista todas as hipóteses, que, junto com a verossimilhança, ajusta o novo grau de crença em E .

Se num dado experimento aleatório consideramos hipóteses $E_1, \dots, E_n$ e obtemos uma evidência F , é plausível questionar em qual hipótese deveríamos depositar maior crença visto a evidência. Consideremos então o corolário:

Corolário 1.2 (Fórmula de Bayes). *Seja $\mathcal{E} = \{E_i\}_{i \in \mathbb{N}}$ uma partição de eventos de um espaço amostral Ω . Se F é um evento de Ω , então*

$$P(E_i|F) = \frac{P(F|E_i)P(E_i)}{\sum_{E \in \mathcal{E}} P(E)P(F|E)}$$

Demonstração. Segue do Teorema de Bayes e do Teorema da Probabilidade Total. ■

Logo, para cada hipótese, poderíamos utilizar a Fórmula de Bayes para computar a crença *a posteriori* nela após a evidência F , e selecionar aquela que tivesse maior probabilidade.

Variáveis Aleatórias

Variáveis aleatórias (v.a.) são representações de características numéricas de experimentos aleatórios. Exemplos são a quantidade de caras obtidas no lançamento de uma moeda, a soma dos lados de um dado, número de erros num livro, tempo até a um equipamento apresentar falha, entre muitos outros.

2.1 Variáveis Aleatórias

Apesar do nome, a definição formal desse conceito não os trata como variáveis, mas sim como funções mensuráveis (ver Definição 1.12). Logo, a variável consiste numa associação de eventos às realizações de grandezas numéricas, de modo que todo conjunto de valores pode ter a sua probabilidade medida.

Definição 2.1. *Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade. A aplicação $X : \Omega \rightarrow \mathbb{R}$ é uma variável aleatória se for $(\mathcal{F}, \mathcal{B}(\mathbb{R}))$ -mensurável, i.e.,*

$$\forall A \in \mathcal{B}(\mathbb{R}), (X^{-1}(A) \in \mathcal{F})$$

A fim de facilitar o tratamento de variáveis aleatórias, iremos introduzir uma notação para denotar eventos de um espaço amostral a partir da variável

Definição 2.2. *Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade e $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. Se $A \in \mathcal{B}(\mathbb{R})$, então o evento denotado por $\{X \in A\}$ é equivalente a $X^{-1}(A) \in \mathcal{B}$.*

Perceba que se $A \in \mathcal{B}(\mathbb{R})$, então temos três formas de denotar o mesmo evento de $\mathcal{F}$.

$$X^{-1}(A) = \{X \in A\} = \{\omega \in \Omega \mid X(\omega) \in A\}$$

Mais do que associações a características numéricas, as variáveis aleatórias transportam um espaço de probabilidade para o espaço de medida dos reais e sua topologia usual. Logo, para medir a probabilidade de obter um conjunto de valores num experimento aleatório, não necessariamente precisamos explicitar a função de probabilidade

do espaço de origem, pois podemos induzir uma nova medida de probabilidade para $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, obtendo, então, um novo espaço de probabilidade que consiste no espaço de resultados do experimento.

Definição 2.3. *Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade e $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. A tripla $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_X)$ é o espaço de probabilidade induzido por X se para todo $A \in \mathcal{B}(\mathbb{R})$ é satisfeito*

$$P_X(A) = P(X \in A) \iff \forall A \in \mathcal{B}(\mathbb{R}), P_X(A) = P(X^{-1}(A))$$

Em outras palavras, P_X é a medida imagem de P impulsionada por X no espaço $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ (ver Definição 1.17).

A especificação de variáveis aleatórias costuma vir acompanhada de um conjunto de valores chamado **suporte**, que modela a noção de valores possíveis que a variável pode assumir no experimento. Um determinado valor x está no suporte de X se um conjunto quaisquer conjuntos de valores suficientemente próximos de x tem probabilidade não nula.

Definição 2.4. *O suporte de uma variável aleatória X é o conjunto*

$$\Omega_X = \{x \in \mathbb{R} \mid \forall \epsilon > 0, P(x - \epsilon < X < x + \epsilon) > 0\}$$

Se o suporte modela os valores possíveis, é razoável considerar que a probabilidade do próprio deve ser igual a 1.

Teorema 2.1. *Se X é uma variável aleatória com suporte Ω_X , então $P_X(\Omega_X) = 1$.*

Demonstração. Se $S = \mathbb{R} \setminus \Omega_X$, então

$$x \in S \iff \exists a, b \in \mathbb{R}, x \in (a, b) \wedge P_X((a, b)) = 0.$$

Pelo fato de $\mathbb{Q}$ ser denso em $\mathbb{R}$, existem $p, q \in \mathbb{Q}$ tais que

- i. $x \in (p, q)$
- ii. $(p, q) \subset (a, b)$
- iii. $P_X((p, q)) = 0$

De (i) segue que

$$S \subset \bigcup_{(p,q) \in I} (p, q),$$

onde $I \subset \mathbb{Q}^2$ é uma família enumerável de intervalos. Por (ii) e (iii) tem-se

$$P_X(S) \leq P_X\left(\bigcup_{(p,q) \in I} (p, q)\right) \leq \sum_{(p,q) \in I} P_X((p, q)) = 0.$$

Se $0 \leq P_X(S) \leq 0$, então $P_X(S) = 0$. Conclui-se que $P_X(\Omega_X) = 1$. ■

Com isso, quando for conveniente, podemos, em vez de trabalhar com $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, usar o espaço $(\Omega_X, \mathcal{A})$, onde

$$\mathcal{A} = \{\Omega_X \cap B \mid B \in \mathcal{B}(\mathbb{R})\}$$

que é chamada de σ -álgebra traço de $\mathcal{B}(\mathbb{R})$.

Outro resultado interessante é que todo evento no espaço de resultados com probabilidade não nula contém pelo menos um elemento do suporte.

Proposição 2.1. *Seja X uma variável aleatória e $S \in \mathcal{B}(\mathbb{R})$ com $P_X(S) = 1$. Se $A \in \mathcal{B}(\mathbb{R})$ e $P(X \in A) \neq 0$, então $A \cap S \neq \emptyset$.*

Demonstração. Suponha que $A \cap S = \emptyset$, e por σ -aditividade,

$$P(A \cup S) = P(A) + P(S) = P(A) + 1$$

Mas pelo Teorema 1.21,

$$P(A) + 1 \leq 1$$

$$P(A) \leq 0$$

Por não negatividade,

$$0 \leq P(A) \leq 0$$

$$P(A) = 0$$

■

2.2 Função de Distribuição Acumulada

Se para cada ponto da reta real conseguimos informar qual a probabilidade de uma variável ter realização menor ou igual a esse ponto, então temos de informações de como está distribuída a probabilidade da variável. Essa função especial ajuda a caracterizar a variável e é chamada de Função de Distribuição Acumulada, ou distribuição apenas.

Definição 2.5. *Sejam Ω um espaço amostral e P uma medida de um espaço de probabilidade e X uma variável aleatória. A função $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de distribuição acumulada para X se, e somente se,*

$$F(x) = P(X \leq x)$$

Um consequência imediata da definição é que se P_X é a medida do espaço induzido por X , então

$$F(x) = P_X((-\infty, x]).$$

Outros fatos devem ser satisfeitos para determinada função ser uma distribuição. Primeiro, ela deve ser limitada superiormente por 1 e inferiormente por 0, já que são os valores máximo e mínimo de probabilidade que um ponto pode assumir. Pelo princípio de que $A \subset B$ implica $P(A) \leq P(B)$, então se $x < y$, teríamos $P(X \leq x) \leq P(X \leq y)$,

e a distribuição é monótona. Por fim, se a partir de um ponto x nos aproximamos de um ponto a pela direita, então estamos aproximando o evento $(-\infty, x]$ do evento $(-\infty, a]$, o que significa que essa a distribuição acumulada deve ser contínua à direita, visto que o primeiro evento inclui o segundo.

Teorema 2.2. *Se $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de distribuição acumulada de uma variável aleatória X , então*

1. $\forall x_1, x_2 \in \mathbb{R}, (x_1 \leq x_2 \rightarrow F(x_1) \leq F(x_2))$
2. $\forall x, a \in \mathbb{R}, (\lim_{x \rightarrow a^+} F(x) = F(a))$
3. $\lim_{x \rightarrow \infty} F(x) = 1$
4. $\lim_{x \rightarrow -\infty} F(x) = 0$

Demonstração. A afirmação (1) segue do fato de que, se $x_1 \leq x_2$, então

$$(X \leq x_1) \subset (X \leq x_2),$$

e pelo Teorema 1.3,

$$P(X \leq x_1) \leq P(X \leq x_2) \implies F(x_1) \leq F(x_2).$$

Seguindo para a afirmação (2),

$$\lim_{x \rightarrow a^+} F(x) = \lim_{x \rightarrow a^+} P(X \leq x)$$

Se x decresce até a , então os eventos $\{X \leq x\}$, para $x > a$, formam uma sequência decrescente de eventos cuja interseção é $\{X \leq a\}$. Pela continuidade de probabilidades, temos que

$$\lim_{x \rightarrow a^+} P(X \leq x) = P\left(\lim_{x \rightarrow a^+} X \leq x\right) = P(X \leq a) = F(a)$$

Para as afirmações (3) e (4), considere a sequência de intervalos encaixados

$$I_1 \subset I_2 \subset \dots$$

com extremos inferiores e superiores a_i e b_i respectivamente com $i \in \mathbb{N}$. Os eventos $\{X \leq b_i\}$ formam uma sequência crescente de eventos encaixados tal que

$$\lim_{n \rightarrow \infty} \{X \leq b_n\} = \{X \leq \infty\}$$

Novamente, pela continuidade da probabilidade,

$$\lim_{x \rightarrow \infty} F(x) = \lim_{x \rightarrow \infty} P(X \leq x) = P(X \leq \infty) = P(\mathbb{R}) = 1$$

O mesmo argumento é replicável para (4): a sequência de eventos $\{X \leq a_i\}$ converge para $\{X \leq -\infty\}$, de sorte que

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{x \rightarrow -\infty} P(X \leq x) = P(X \leq -\infty) = P(\emptyset) = 0$$

■

Portanto, o Teorema 2.2 garante que há uma medida induzida de Steljes para a distribuição F (ver Definição 1.13). Sendo μ_F a medida de Steljes induzida por F , então essa equivale a medida imagem P_X .

Proposição 2.2. *Se X é variável aleatória e μ_F é a medida de Steljes induzida por F , então $P_X = \mu_F$.*

Demonstração. Para quaisquer $a, b \in \mathbb{R}$, temos

$$(-\infty, a] \cup (a, b] = (-\infty, b] \quad (-\infty, a] \cap (a, b] = \emptyset$$

e por σ -aditividade

$$\begin{aligned} P_X((-\infty, a]) + P_X((a, b]) &= P_X((-\infty, b]) \\ P_X((a, b]) &= P_X((-\infty, b]) - P_X((-\infty, a]) \\ P_X((a, b]) &= F(b) - F(a) \end{aligned}$$

Logo,

$$P_X((a, b]) = \mu_F((a, b])$$

■

2.3 Variáveis Aleatórias Discretas

Definição 2.6. *Se X é uma variável aleatória, então X é discreta se, e somente se, existe um conjunto $S \subset \mathbb{R}$ enumerável tal que*

$$P(X \in S) = 1$$

Sob essa definição, existe um conjunto enumerável de valores cujas probabilidades pontuais são suficiente para obter a probabilidade total do espaço de probabilidade. Como vimos no Teorema 2.1, com o suporte reunindo os valores possíveis da variável, então os valores pontuais que acumulam massas de probabilidade devem estar todos reunidos nele. Isso sugere que o suporte é possivelmente um conjunto enumerável, o que é provado no Teorema a seguir.

Teorema 2.3. *O suporte Ω_X de uma variável aleatória X é enumerável se, e somente se, X é discreta.*

Demonstração. Sendo Ω_X enumerável, então pelo Teorema 2.1 segue que X é discreta. Por outro lado, supondo X discreta, então seja S tal que $P_X(S) = 1$. Sendo $x \in \Omega_X$, então

$$\forall \epsilon > 0, P(|X - x| < \epsilon) > 0$$

mas se $x \notin S$, segue da Proposição 2.1 que

$$\forall \epsilon > 0, S \cap (x - \epsilon, x + \epsilon) \neq \emptyset,$$

concluindo-se que todo ponto em $\Omega_X \setminus S$ é de acumulação em S . Definamos

$$A = S \cup \{x \in \mathbb{R} \setminus S \mid x \text{ é ponto de acumulação de } S\}$$

donde teremos $\Omega_X \subset A$. Como S é enumerável, então o conjunto de seus pontos de acumulação também será, assim como A . Uma vez que Ω_X é subconjunto de um enumerável, então ele próprio é enumerável. ■

Proposição 2.3. *Toda variável discreta X com medida induzida P_X admite uma função $p_X \in L^1(\mu)$ com contradomínio em $[0, 1]$ satisfazendo*

$$p_X = \frac{d}{d\mu}P_X \iff P_X(A) = \sum_{x \in A} p_X(x)$$

onde μ é a medida de contagem.

Demonstração. A medida de contagem, pelo Teorema 1.4, é σ -finita. Ademais,

$$\forall B \in \mathcal{B}(\mathbb{R}), \mu(B) = 0 \iff B = \emptyset,$$

implicando que P_X é absolutamente contínua em relação a μ pela Definição 1.11. Pelo Teorema de Radon-Nikodym, segue que existe $p_X \in L^1(\mu)$ tal que

$$p_X = \frac{d}{d\mu}P_X \iff P_X = \int p_X d\mu$$

o que equivale a, pelo Teorema 1.13,

$$\forall A \in \mathcal{B}(\mathbb{R}), P_X(A) = \sum_{x \in A} p_X(x).$$

Uma vez que para todo $x \in \mathbb{R}$, tem-se $0 < P(X = x) < 1$, e

$$P(X = x) = P_X(\{x\}) = \sum_{a \in \{x\}} p_X(a) = p_X(x)$$

então $p_X \in [0, 1]$. ■

Temos então que toda a massa de probabilidade de realizações de uma variável discreta está concentrada num conjunto enumerável de pontos. Para essas variáveis será garantida a existência de uma função que associa a cada um desses a probabilidade concentrada nele. A essa função damos o nome de **função de massa de probabilidade**.

Definição 2.7. *Seja $X : \Omega \rightarrow \mathbb{R}$ uma v.a. discreta. A função $p_X : \mathbb{R} \rightarrow [0, 1]$ é a função de massa de probabilidade de X se, e somente se,*

$$P(X = x) = p_X(x)$$

Enunciemos agora como obter a distribuição F de uma variável aleatória discreta.

Proposição 2.4. *Se $X : \Omega \rightarrow \mathbb{R}$ é uma v.a. discreta com função de massa igual a p_X e suporte Ω_X , então a distribuição de X é*

$$F_X(x) = \sum_{\substack{a \in \Omega_X \\ a \leq x}} p_X(a)$$

Demonstração. Suponha $A = \{a \in \Omega_X \mid a \leq x\}$ e $I = (-\infty, x]$. Observe que,

$$P(X \leq x) = P(X \in I)$$

e como $A \subset I$, então por σ -aditividade,

$$P(X \leq x) = P(X \in A) + P(X \in I \setminus A)$$

Suponha por contradição que $P(X \in I \setminus A) \neq 0$, e pela proposição 2.1, $(I \setminus A) \cap \Omega_X \neq \emptyset$, o que equivale a

$$I \cap (\Omega_X \setminus A) \neq \emptyset$$

mas $\Omega_X \setminus A = \{a \in \Omega_X \mid a > x\}$, o que contradiz a hipótese anterior. Portanto,

$$P(X \leq x) = P(X \in A),$$

e pela Proposição 2.3,

$$F_X(x) = \sum_{x \in A} p_X(x),$$

que equivale a

$$F_X(x) = \sum_{\substack{a \in \Omega_X \\ a \leq x}} p_X(a).$$

■

Com isso, se $S = \{x \in \mathbb{R} \mid p_X(x) > 0\} \subseteq \Omega_X$, então seja $\{x_i\}_{\mathbb{N}}$ uma ordenação de S de tal modo

$$F(x) = \begin{cases} 0, & \text{se } x < x_1 \\ F(x_1), & \text{se } x_1 \leq x < x_2 \\ \vdots & \\ F(x_i), & \text{se } x_i \leq x < x_{i+1} \\ \vdots & \end{cases}.$$

A função F é, pois, uma função constante por partes que sempre incluem a extremidade esquerda de seu domínio devido à propriedade necessária de uma distribuição sempre ser contínua à direita. Uma vez que

$$\begin{aligned} P(X = x_i) &= P(X \leq x_i) - P(X < x_i) \\ P(X = x_i) &= F(x_i) - \lim_{x \rightarrow x_i^-} F(x) \\ P(X = x_i) &= F(x_i) - F(x_{i-1}), \end{aligned}$$

então $p_X(x_i)$ é o salto entre duas partes consecutivas da distribuição de X .

2.4 Variáveis Aleatórias Contínuas

Variáveis aleatórias discretas caracterizam-se por uma lista enumerável de pontos concentrarem massas probabilidades. Outrossim, variáveis aleatórias contínuas são aquelas em que nenhum ponto real acumula qualquer massa de probabilidade, estando essa distribuída ao longo de suas vizinhanças. Formalmente, teremos que qualquer conjunto de pontos de medida nula (como pontos contáveis) terá probabilidade desprezível, caracterizando a medida de probabilidade da variável como absolutamente contínua em relação a medida de Lebesgue (ver Definição 1.11).

Definição 2.8. *A variável aleatória X será contínua se $P_X \ll \lambda$.*

O Teorema de Radon-Nikodym garante a existência de uma função especial – mensurável, não negativa e Lebesgue-integrável – associada a medida de probabilidade induzida P_X de X .

Proposição 2.5. *Toda variável aleatória contínua X admite uma função real mensurável não negativa $f \in L^1(\lambda)$ tal que*

$$f = \frac{d}{d\lambda} P_X$$

Demonstração. Se X é contínua, então $P_X \ll \lambda$. Como λ é σ -finita, então pelo Teorema de Radon-Nikodym existe $f \in L^1(\lambda)$ não negativa tal que

$$f = \frac{d}{d\lambda} P_X$$

■

Se interpretarmos a probabilidade como uma massa distribuída em espaço (neste caso, em $\mathbb{R}$) e que quanto maior a extensão do intervalo avaliado, maior a probabilidade da variável assumir realizações nele, então podemos interpretar a função f como uma **densidade** de probabilidade.

Definição 2.9. *Seja X uma variável aleatória contínua com medida induzida P_X . A função f que satisfaz*

$$f = \frac{d}{d\lambda} P_X \iff P_X = \int f d\lambda$$

é chamada de densidade de probabilidade de X .

A função de densidade pode ser então usada para medir a probabilidade de uma variável contínua assumir realizações num intervalo de valores reais. Isso é feito avaliando a integral da função sobre o intervalo desejado. A relação mais direta entre as funções de distribuição e de densidade é dada pela Proposição a seguir.

Proposição 2.6. *Se X é uma variável contínua com densidade f e distribuição F , então*

$$F(x) = \int_{-\infty}^x f(t) dt$$

Demonstração.

$$F(x) = P_X((-\infty, x]) = \int_{(-\infty, x]} f d\lambda = \int_{-\infty}^x f(t) dt$$

■

A distribuições de variáveis discretas tem a forma de uma função constante por partes, pois entre um ponto e outro temos um “salto” que representa a probabilidade acumulada por um dos pontos. Em contraste, como para variáveis contínuas nenhum ponto acumula massa de probabilidade, a sua distribuição deve variar suavemente ao longo de qualquer intervalo, ou de maneira mais forte, em qualquer conjunto disjunto de intervalo Isso caracteriza a distribuição como absolutamente contínua (ver Definição 1.3).

Proposição 2.7. *A variável X é contínua se, e somente se, sua distribuição F é absolutamente contínua.*

Demonstração. Supondo que X é contínua, então $P_X \ll \lambda$. Pela Proposição 2.2 e pelo Teorema 1.6, concluiremos que F é absolutamente contínua. Por outro lado, se F é absolutamente contínua, então $\mu_F = P_X \ll \lambda$ e, por definição, a variável X será contínua. ■

Como qualquer conjunto de pontos isolados terá probabilidade nula, então é intuitivo pensar que o intervalo $(a, b]$ terá a mesma probabilidade do que (a, b) . A formalização dessas ideias é dada pelo Teorema a seguir.

Teorema 2.4. *Se X é uma variável aleatória contínua com densidade f , então para todo $x, a, b \in \mathbb{R}$*

$$i. P(a < X \leq b) = \int_a^b f(t) dt$$

$$ii. P(X = x) = 0$$

$$iii. P(X \leq x) = P(X < x)$$

$$iv. P(X \geq x) = P(X > x)$$

Demonstração.

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$$

e pela Proposição 2.6

$$P(a < X \leq b) = \int_{-\infty}^b f(t) dt - \int_{-\infty}^a f(t) dt = \int_a^b f(t) dt$$

provando (i).

Observemos agora que

$$\lambda(\{x\}) = 0 \implies \int_{\{x\}} f d\lambda = 0 \implies P(X = x) = 0$$

provando (ii).

Uma vez que

$$P(X \leq x) = P(X = x) + P(X < x) \quad \text{e} \quad P(X \geq x) = P(X = x) + P(X > x)$$

então (iii) e (iv) são consequências de (ii). ■

Proposição 2.8. *Se X é uma variável aleatória contínua com densidade f e suporte Ω_X , então*

$$\int_{\Omega_X} f \, d\lambda = \int_{\mathbb{R}} f \, d\lambda = 1$$

Demonstração. Com efeito,

$$P_X(\Omega_X) = 1 \implies \int_{\Omega_X} f \, d\lambda = 1.$$

Ademais, se $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_X)$ é o espaço de probabilidade induzido por X , então

$$P_X(\mathbb{R}) = P(\Omega) = 1 \implies \int_{\mathbb{R}} f \, d\lambda = 1$$

■

Proposição 2.9. *Se X é uma variável contínua com densidade f e suporte Ω_X , então*

$$f = 0 \quad \text{q.s. em } \mathbb{R} \setminus \Omega_X$$

Demonstração. Seja $A = \mathbb{R} \setminus \Omega_X$. Observe que

$$\int_A f \, d\lambda + \int_{\Omega_X} f \, d\lambda = \int_{\mathbb{R}} f \, d\lambda$$

e pela Proposição 2.8, conclui-se

$$\int_A f \, d\lambda = 0.$$

Como uma função de densidade é mensurável e não negativa, então por nulidade da integral de Lebesgue, obtém-se que $f = 0$ q.s. em A . ■

Lema 2.1. *Seja X variável contínua com densidade f e suporte Ω_X . Se f é contínua em $x \in \mathbb{R}$, então $x \in \Omega_X$.*

Demonstração. Suponha que $0 < \epsilon < f(x)$. Por continuidade em x , existe $\delta > 0$ tal que

$$\forall a \in \mathbb{R}, |x - a| < \delta \implies |f(x) - f(a)| < \epsilon$$

Suponha por contradição que $x \notin \Omega_X$. Com efeito, exista uma vizinhança $V = (x - \nu, x + \nu)$, com $\nu > 0$ tal que $P(X \in V) = 0$, que equivale a $f = 0$ q.s. em V . Existe, pois, $y \in V$ tal que

$$|x - y| < \delta \quad \text{e} \quad f(y) = 0$$

de modo que

$$|f(x) - f(y)| < \epsilon \implies |f(x)| < \epsilon,$$

e sendo f densidade, $f > 0$ e $|f(x)| = f(x)$. Por conseguinte,

$$f(x) < \epsilon$$

contradizendo a afirmação que $\epsilon < f(x)$. Conclui-se que $x \in \Omega_X$. ■

Teorema 2.5. *Se X é variável aleatória densidade f contínua em*

$$\{x \in \mathbb{R} \mid f(x) > 0\}$$

então

$$\Omega_X = \overline{\{x \in \mathbb{R} \mid f(x) > 0\}}$$

Demonstração. Seja

$$E = \{x \in \mathbb{R} \mid f(x) > 0\}.$$

Mostremos que $\Omega_X \subset \overline{E}$. Para tanto, suponha que $x \notin \overline{E}$. Existe, então, vizinhança $V = (x - \delta, x + \delta)$, com $\delta > 0$, tal que

$$V \cap E = \emptyset$$

Então para todo $a \in V$, $f(a) = 0$, o que equivale a dizer que $f = 0$ q.s. em V . Por consequência, $P(X \in V) = 0$, e $x \notin \Omega_X$.

Demonstremos agora que $\overline{E} \subset \Omega_X$. Do Lema 2.1, temos que $E \subset \Omega_X$. Resta mostrar que todo ponto de acumulação $x \notin E$ é membro de Ω_X . Se $x \in \overline{E}$, então

$$\forall \nu > 0, (x - \nu, x + \nu) \cap E \neq \emptyset.$$

Isso equivale a dizer que para toda vizinhança V de x contém pelo menos um ponto com densidade positiva e, por consequência do Lema 2.1, que é membro do suporte. Se tivéssemos $x \notin \Omega_X$, então haveria uma vizinhança U centrada em x tal que $P(X \in U) = 0$, e teríamos

$$\forall a \in U, a \notin \Omega_X$$

contradizendo a afirmação que toda vizinhança de x tem um membro do suporte. Portanto, $\overline{E} \subset \Omega_X$. ■

2.5 Transformações

Definição 2.10. *Uma transformação de uma variável aleatória X é toda função $g : \mathbb{R} \rightarrow \mathbb{R}$.*

Em experimentos aleatórios, comumente defini-se variáveis aleatórias a partir de outras variáveis. Dizemos então que a variável derivada é obtida por uma transformação da variável original, consistindo da composição de uma função real mensurável, essa que, pelo Teorema 1.5, também será mensurável, sendo, então, uma variável aleatória.

Definição 2.11. *Seja X uma variável aleatória. Se g for uma transformação mensurável, então $g(X)$ é a variável aleatória definida por $g \circ X$.*

Da nossa definição, a probabilidade de uma variável $g(X)$ assumir valores num conjunto A deve ser o mesmo da imagem de valores de g aplicada sobre realizações de X pertencerem a A . De outro modo, podemos dizer que $P(g(X) \in A)$ é igual a probabilidade da pré-imagem de g em relação a A .

Proposição 2.10. *Se X é uma variável aleatória e g uma transformação mensurável, então*

$$P_X(g(X) \in A) = P(X \in g^{-1}(A))$$

Demonstração.

$$\begin{aligned} P_X(g(X) \in A) &= P_X(\{x \in \mathbb{R} \mid g(x) \in A\}) \\ &= P(X \in g^{-1}(A)) \end{aligned}$$

■

Com essa proposição, uma transformação induz um novo espaço de probabilidade $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_g)$ onde

$$P_g(A) = P_X(g^{-1}(A)) = P(X \in g^{-1}(A))$$

2.5.1 Transformação de Variáveis Discretas

Teorema 2.6. *Seja X uma variável discreta com suporte Ω_X , função de massa igual a p_X e g uma transformação mensurável de X tal que $Y = g(X)$. A variável Y é discreta e sua função de massa é dada por*

$$p_Y(y) = \sum_{x \in g^{-1}(y)} p_X(x)$$

Demonstração. Para Y ser discreto, seu suporte Ω_Y deve ser enumerável. Da Proposição 2.10 sabemos que

$$P_Y(A) > 0 \Leftrightarrow P(X \in g^{-1}(A)) > 0,$$

e pela Proposição 2.1,

$$g^{-1}(A) \cap \Omega_X \neq \emptyset.$$

donde segue

$$\forall y \in \Omega_Y \exists x \in \Omega_X, (g(x) = y \wedge y \in A)$$

Logo, Ω_Y é a imagem de Ω_X sobre g , sendo, pois, enumerável.

Para a afirmação sobre a função de massa de Y , a Proposição 2.10 mostra que

$$p_Y(y) = P_X(Y = y) = P(X \in g^{-1}(y)),$$

e, pelo Lema

$$p_Y(y) = \sum_{x \in g^{-1}(y)} p_X(x).$$

■

2.5.2 Transformação de Variáveis Contínuas

Para transformações de variáveis contínuas, concentramos-nos, primeiramente, nas transformações monótonas, pois essas compõem uma classe mais fácil de se analisar.

Teorema 2.7. *Seja X uma variável aleatória contínua com distribuição F_X e suporte Ω_X . Seja também $Y = g(X)$ com suporte Ω_Y , em que g é uma transformação monótona. Se g for crescente, então*

$$F_Y(y) = F_X(g^{-1}(y)).$$

Caso contrário,

$$F_Y(y) = 1 - F_X(g^{-1}(y)).$$

Demonstração. Com efeito, da Proposição 2.10 segue que,

$$F_Y(y) = P_X(Y \leq y) = P(X \leq g^{-1}((-\infty, y])).$$

A função g^{-1} tem a mesma monotonicidade de g . Se g for crescente, então

$$\{X \in g^{-1}((-\infty, y])\} = \{X \leq g^{-1}(y)\}$$

implicando em

$$F_Y(y) = F_X(g^{-1}(y)).$$

Se g for decrescente, obtém-se

$$\{X \in g^{-1}((-\infty, y])\} = \{X \geq g^{-1}(y)\}$$

e

$$F_Y(y) = P(X \geq g^{-1}(y))$$

mas pelo Teorema 2.4,

$$\begin{aligned} F_Y(y) &= P(X > g^{-1}(y)) \\ &= 1 - P(X \leq g^{-1}(y)) \\ &= 1 - F_X(g^{-1}(y)) \end{aligned}$$

■

Por sua vez, a densidade de transformações $Y = g(X)$ em casos em que a densidade de X é contínua, pode ser obtidas via a Regra da Cadeia do Cálculo Diferencial, com a condição de que a inversa de g seja também contínua em Ω_Y . Caso a densidade de X nem a inversa da transformação sejam contínuas em Ω_X e Ω_Y respectivamente, a regra da cadeia não poderia ser aplicada, complexificando a determinação da densidade de Y .

Teorema 2.8. *Seja X uma variável aleatória com f.d.p. igual a f_X . Seja $Y = g(X)$ uma variável obtida pela transformação g e com suporte Ω_Y . Se g é monótona, f_X é contínua em Ω_X e g^{-1} tem derivada contínua em Ω_Y , então a densidade f_Y de Y é dada por*

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, & \text{caso contrário.} \end{cases}$$

Demonstração. Do Teorema 1.18,

$$f_Y(y) = F'_Y(y) \text{ q.s.}$$

Se g é crescente, então

$$F_Y(y) = F_X(g^{-1}(y))$$

e, por consequência,

$$f_Y(y) = [F_X(g^{-1}(y))]' \text{ q.s.}$$

Por hipótese, g^{-1} ter derivada contínua em Ω_Y implica que g^{-1} é contínua em Ω_Y . Ademais, toda distribuição é absolutamente contínua. Pela Regra da Cadeia, obtemos então

$$f_Y(y) = F'_X(g^{-1}(y)) \cdot \frac{d}{dy}g^{-1}(y) \text{ q.s. se } y \in \Omega_Y$$

Por outro lado, se g é decrescente, então por um desenvolvimento análogo chega-se a

$$f_Y(y) = -F'_X(g^{-1}(y)) \cdot \frac{d}{dy}g^{-1}(y) \text{ q.s. se } y \in \Omega_Y$$

Como $\frac{d}{dy}g^{-1} \leq 0$ nesse caso, então podemos sintetizar esse e o caso anterior em

$$f_Y(y) = F'_X(g^{-1}(y)) \cdot \left| \frac{d}{dy}g^{-1}(y) \right| \text{ q.s. se } y \in \Omega_Y$$

Se $y \in \Omega_Y \implies g^{-1}(y) \in \Omega_X$ e f_X é contínua em Ω_X por hipótese, então f_X é contínua em $g^{-1}(y)$. Além disso, pela hipótese de g^{-1} ter derivada contínua em Ω_Y , então f_Y será contínua em Ω_Y , e pelo Teorema 1.19,

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy}g^{-1}(y) \right| \text{ se } y \in \Omega_Y$$

Se $y \notin \Omega_Y$, então, pelo Teorema 2.5, $f_Y(y) = 0$. ■

O teorema 2.8 permite-nos a generalizar a obtenção da densidade de probabilidade de transformações não monótonas que podem ser decompostas em partes monótonas. Um exemplo clássico é a função $g(x) = x^2$ definida em $\mathbb{R}$. Essa função não é monótona, porém suas partes definidas separadamente em $(-\infty, 0)$ e $[0, \infty)$ serão. A densidade da variável definida pela transformação poderá, portanto, ser obtida pelo resultado a seguir

Teorema 2.9. *Seja X uma variável aleatória com densidade igual a f_X contínua em Ω_X . Seja $Y = g(X)$ a variável obtida pela transformação g e com suporte Ω_Y . Se Ω_X admite uma partição em intervalos $\{A_i\}_{i=1}^n$ que torne possível definir a família de funções $\{g_i : A_i \rightarrow \mathbb{R}\}_{i=1}^n$ tal que*

$$i \quad g_i(x) = g(x)$$

$$ii \quad g_i(x) \text{ é monótona em } A_i$$

$$iii \quad g_i(A_i) = \Omega_Y \text{ para todo } i \in [n].$$

iv g_i^{-1} tem derivada contínua em Ω_Y para todo $i \in [n]$.

então a densidade f_Y de Y é dada por

$$f_Y(y) = \begin{cases} \sum_{i=1}^n f_X(g_i^{-1}(y)) \cdot \left| \frac{d}{dy} g_i^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, & \text{caso contrário.} \end{cases}$$

Demonstração. Com efeito, $f_Y = F'_Y$ e também

$$F_Y(y) = P(Y \leq y) = P(X \leq g^{-1}((-\infty, y]))$$

Mas pelo Teorema de Probabilidade Total,

$$F_Y(y) = \sum_{i=1}^n P(X \leq g^{-1}((-\infty, y]) \mid X \in A_i) \cdot P(X \in A_i)$$

e tomando $f(y) = F'_Y(y)$ q.s. ,

$$f_Y(y) = \sum_{i=1}^n \frac{d}{dy} F_X(g_i^{-1}(y)) + \sum_{i=1}^n \frac{d}{dy} P(X \in A_i) \text{ q.s.}$$

como $P(X \in A_i)$ não depende de y , $\frac{d}{dy} P(X \in A_i) = 0$ para todo $i \in [n]$. Além disso, pela hipótese (iv.) e o fato de que F_X é absolutamente contínua, se $y \in \Omega_Y$, então a equação $F_X(g_i^{-1}(y))$ será contínua em y . Da Regra da Cadeia obtemos,

$$f_Y(y) = \sum_{i=1}^n f_X(g_i^{-1}(y)) \cdot \left| \frac{d}{dy} g_i^{-1}(y) \right| \text{ q.s. se } y \in \Omega_Y$$

Pelos Teoremas 1.19 e 2.8, seguirá então,

$$f_Y(y) = \sum_{i=1}^n f_X(g_i^{-1}(y)) \cdot \left| \frac{d}{dy} g_i^{-1}(y) \right| \text{ se } y \in \Omega_Y$$

Noutro caso de $y \notin \Omega_Y$, o Teorema 2.5 implicará que $f_Y(y) = 0$. ■

2.6 Esperança e Momentos

Definição 2.12. *Seja X uma variável aleatória e $(\Omega, \mathcal{F}, P)$ espaço de probabilidade. Defini-se esperança de X , ou valor esperado, denotada por $E[X]$, como*

$$E[X] = \int_{\Omega} X dP$$

Teorema 2.10. *Seja X variável aleatória e $g : \mathbb{R} \rightarrow \mathbb{R}$ uma transformação mensurável. A esperança da variável $g(X)$ é dada por*

$$E[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f(x) dx, & \text{se } X \text{ é contínua} \\ \sum_{x \in \Omega_X} g(x) P(X = x), & \text{se } X \text{ é discreta} \end{cases}$$

Demonstração. Considere o espaço de medida $(\Omega, \mathcal{F}, P)$, tal que $g(X) : \Omega \rightarrow \mathbb{R}$ e

$$E[g(X)] = \int_{\Omega} g(X) dP$$

mas pelo Teorema 1.20, uma vez que $g(X) = g \circ X$, então

$$E[g(X)] = \int_{\mathbb{R}} g(x) dP_x$$

Se X for contínua, então $f(x) = \frac{d}{d\lambda} P_X$ é densidade de X e fazendo a substituição $dP_X = f(x)d\lambda$, obtemos

$$E[g(X)] = \int_{\mathbb{R}} g(x)f(x) d\lambda = \int_{-\infty}^{\infty} g(x)f(x) dx$$

■

Teorema 2.11. *Seja X variável aleatória, e g_1 e g_2 transformações mensuráveis. O operador de esperança satisfaz:*

1. $E[ag_1(X) + bg_2(X)] = aE[g_1(X)] + bE[g_2(X)]$
2. $\forall x \in \Omega_X, (g_1(x) \geq 0) \rightarrow E[g_1(X)] \geq 0$
3. $\forall x \in \Omega_X, (g_1(x) \geq g_2(x)) \rightarrow E[g_1(X)] \geq E[g_2(X)]$
4. $\forall x \in \Omega_X, (a \leq g_1(x) \leq b) \rightarrow a \leq E[g_1(X)] \leq b$

Demonstração. A propriedade 1 segue da linearidade dos operadores de integral, no caso contínuo, e de somatório no caso discreto. A propriedade 2 advém da nulidade para o contínuo e do fechamento dos reais não negativos sob adição nos discretos. As propriedades 3 e 4 vêm da monotonicidade das integrais e da propriedade aditiva das desigualdades. ■

Definição 2.13. *Seja $n \in \mathbb{N}$ e X variável aleatória com esperança μ . O n ésimo momento de X , denotado $m_n(\mu)'$, é definido como*

$$m_n(\mu)' = E[X^n]$$

O n ésimo momento central, denotado $m_n(\mu)$, é dado por

$$m_n(\mu) = E[(X - \mu)^n]$$

onde $\mu = E[X]$.

Definição 2.14. *Se X uma variável aleatória com esperança μ , então estão definidos:*

1. *Variância:* $\text{Var}(X) = m_2(\mu)$
2. *Desvio-padrão:* $\text{dp}(X) = \sqrt{\text{Var}(X)}$
3. *Assimetria:* $\frac{m_3(\mu)}{\text{dp}(X)^3}$

4. *Curtose*: $\frac{m_4(\mu)}{dp(X)^4} - 3$

Teorema 2.12. *Seja X variável aleatória com esperança μ e $a \in \mathbb{R}$. Vale que*

1. $\text{Var}(X) = E[X]^2 - \mu^2$
2. $\text{Var}(aX) = a^2 \text{Var}(X)$
3. $\text{Var}(X + a) = \text{Var}(X)$

Demonstração. Com efeito, do Teorema 2.11 segue que

$$\begin{aligned} \text{Var}(X) &= E[(X - \mu)^2] \\ &= E[X^2 - 2X\mu + \mu^2] \\ &= E[X^2] - 2\mu E[X] + \mu^2 \\ &= E[X^2] - 2\mu^2 + \mu^2 \\ &= E[X]^2 - \mu^2 \end{aligned}$$

provando 1. Usando isso para 2,

$$\begin{aligned} \text{Var}(aX) &= E[(aX)^2] - E[aX]^2 \\ &= E[a^2 X^2] - E[aX] \cdot E[aX] \\ &= a^2 E[X^2] - a^2 E[X]^2 \\ &= a^2 \text{Var}(X) \end{aligned}$$

E a aquela ainda pode ser usada para obter 3:

$$\begin{aligned} \text{Var}(X + a) &= E[(X + a)^2] - E[X + a]^2 \\ &= E[X^2] + 2aE[X] + a^2 - (E[X] + a)(E[X] + a) \\ &= E[X^2] + 2aE[X] + a^2 - E[X]^2 - 2aE[X] - a^2 \\ &= E[X^2] - E[X]^2 \\ &= \text{Var}(X) \end{aligned}$$

■

Definição 2.15. *A função geradora de momentos (mgf) da variável X é*

$$\begin{aligned} M_X &: \mathbb{N} \rightarrow \mathbb{R} \\ M_X(t) &= E[e^{tX}] \end{aligned}$$

Modelos de Distribuição de Probabilidade

3.1 Modelos de Distribuição Discreta

Muitas características de fenômenos aleatórios podem ser modelados como variáveis aleatórias discretas, como determinar se o lançamento de uma moeda deu cara, quantas pessoas possuem diploma numa população de tamanho conhecido, quantas bolas devemos sortear de uma urna até que obtenhamos a que contém a cor desejada, etc.

3.1.1 Distribuição Bernoulli

A distribuição Bernoulli modela experimentos que só podem ter dois resultados possíveis: *sucesso* ou *fracasso*. Seu único parâmetro é a probabilidade p de obter *sucesso* no experimento. Dessa forma, podemos particionar o espaço amostral em dois eventos disjuntos: $X = 0$ e $X = 1$. O primeiro é aquele cujos resultados são *fracassos*, obtidos com probabilidade $1 - p$, enquanto que no segundo são aqueles cujos resultados são *sucessos*, que ocorre com probabilidade p .

Definição 3.1. *Suponha que Ω seja um espaço amostral e $\mathcal{P} = \{F, S\}$ uma partição de Ω . A variável X tem distribuição Bernoulli de parâmetro p , denotado por $X \sim \text{Bernoulli}(p)$, se, e somente se, X é a função indicadora de um membro de $\mathcal{P}$ e*

$$P(X = 1) = p.$$

Da definição formal de uma distribuição Bernoulli, segue que seu suporte é o conjunto $\{0, 1\}$. Se $S \subset \Omega$ reúne os *sucessos*, então podemos escrever

$$P(S) = p \quad \text{e} \quad P(F) = 1 - p$$

e, caso Ω seja equiprovável, então

$$p = \frac{|S|}{|\Omega|}$$

Proposição 3.2. *A f.m.p. da distribuição Bernoulli de parâmetro p é dada por*

$$p_X(x) = p^x(1 - p)^{1-x}$$

Demonstração. Temos que

$$P(X = x) = \begin{cases} p, & \text{se } x = 1 \\ 1 - p, & \text{se } x = 0 \end{cases}$$

que equivale à fórmula desejada. ■

A esperança de uma Bernoulli é dada como

$$E[X] = 1 \cdot p + 0 \cdot (1 - p) = p.$$

Conclui-se que a taxa de sucessos é a própria probabilidade de obter um sucesso no experimento.

3.1.2 Distribuição Binomial

A distribuição binomial é uma versão mais generalizada da Bernoulli, modelando quantos sucessos são obtidos num experimento que consiste de n tentativas Bernoulli independentes, isto é, uma tentativa não altera no resultado da outra. Exemplo inclui quantas caras obtemos ao lançar uma moeda 10 vezes. Os parâmetros dessa distribuição são o número de tentativas n e o número de sucessos p . Seu suporte será igual aos inteiros de 0 a n .

Cada uma das n tentativas Bernoulli são v.a.'s $X_k \sim \text{Bernoulli}(p)$, com $k \in [n]$, independentes. Logo, a probabilidade de um evento $(X_k = x_k)_{k \in [n]}$ com a sucessos, tendo fixado o valor de cada x_k , deve ser igual a

$$P((X_k = x_k)_{k \in [n]}) = \prod_{k=1}^n P(X_k = x_k),$$

mas como há a resultados $x_k = 1$, e $n - a$ resultados $x_k = 0$, então

$$P((X_k = x_k)_{k \in [n]}) = \prod_{k=1}^n P(X_k = x_k) = p^a (1 - p)^{n-a}$$

Como cada uma das sequências de resultados com a sucessos são mutuamente exclusivas, então

$$P(X = a) = m \cdot p^a (1 - p)^{n-a},$$

onde m é o número de sequências com a sucessos dentre n , que equivale a escolher a tentativas para serem sucessos dentre n possíveis, logo

$$P(X = a) = \binom{n}{a} \cdot p^a (1 - p)^{n-a}$$

Definição 3.3. $X \sim \text{Binomial}(n, p) \iff p_X(a) = \binom{n}{a} p^a (1 - p)^{n-a}$

Se a taxa de sucesso de cada ensaio Bernoulli é p , então podemos intuir que o número esperado de sucessos em n ensaios deverá ser a fração p do total dos ensaios, ou seja que o valor esperado seja np .

Proposição 3.4. Se $X \sim \text{Binomial}(n, p)$, então $E[x] = np$.

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^n k \cdot \binom{n}{k} p^k (1-p)^{n-k}.$$

Utilizando o fato de que

$$\binom{n}{k} = \frac{n}{k} \binom{n-1}{k-1},$$

reduzimos então a

$$E[X] = n \sum_{k=0}^n \binom{n-1}{k-1} p^k (1-p)^{n-k},$$

o que nos sugere realizar uma troca de variável em k para que consigamos usar o Teorema Binomial. Para tanto, realizemos que

$$n \sum_{k=0}^n \binom{n-1}{k-1} p^k (1-p)^{n-k} = np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} (1-p)^{n-k}$$

já que somar o termo $k = 0$ equivale a somar 0. Fazendo então a troca $j = k - 1$, obtemos

$$E[X] = np \sum_{j=0}^n \binom{n-1}{j} p^j (1-p)^{(n-1)-j},$$

e pelo Teorema Binomial,

$$E[X] = np \cdot (p + 1 - p)^{n-1} = np$$

■

3.1.3 Distribuição Geométrica

Uma variável geométrica modela experimentos que consistem na repetição de ensaios Bernoulli independentes até que se obtenha o primeiro sucesso. Um exemplo é repetir o lançamento de uma moeda até obter coroa. Para obter a função de massa de probabilidade dessa variável para uma realização n , basta encontrar a probabilidade de obter $n - 1$ fracassos consecutivos seguidos de um sucesso. Desse modo, se $(X_k = x_k)_{k \in [n]}$ é uma sucessão de n ensaios Bernoulli independentes com parâmetro p , então

$$P((X_k = x_k)_{k \in \mathbb{N}}) = \prod_{k=1}^n P(X_k = x_k),$$

mas como os $n - 1$ valores de x_k são fracassos (iguais a 0) obtidos com probabilidade $1 - p$, e $x_n = 1$ é obtido com probabilidade p , então

$$P((X_k = x_k)_{k \in \mathbb{N}}) = (1 - p)^{n-1} p$$

Definição 3.5.

$$X \sim \text{Geo}(p) \longleftrightarrow p_X(n) = (1 - p)^{n-1} p$$

O número esperada de ensaios realizados num experimento até obter o primeiro sucesso é o valor esperado da variável geométrica.

Proposição 3.6. *Se $X \sim \text{Geo}(p)$, então*

$$E[X] = \frac{1}{p}$$

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^{\infty} k(1-p)^{k-1}p = p \sum_{k=0}^{\infty} k(1-p)^{k-1}.$$

O somatório à esquerda é a derivada de uma série geométrica de razão $q = 1 - p$, tal que $q < 1$. Observemos que

$$\begin{aligned} \frac{d}{dq} \left(\sum_{k=0}^{\infty} q^k \right) &= \frac{d}{dq} \left(\frac{1}{1-q} \right) \\ \sum_{k=0}^{\infty} k(1-p)^{k-1} &= \frac{1}{(1-q)^2} \end{aligned}$$

donde conclui-se

$$E[X] = \frac{p}{(1-1+p)^2} = \frac{1}{p}$$

■

3.1.4 Distribuição Binomial Negativa

A distribuição binomial negativa é similar à geométrica: invés de repetir os ensaios Bernoulli independentes até o obter o primeiro sucesso, os ensaios são repetidos até que se acumulem r sucessos, sendo esse total um novo parâmetro da distribuição. A dedução da f.m.p. para esse modelo de probabilidade é análogo ao da Binomial e da Geométrica; fixando uma sequência $((X_k = x_k)_{k \in [n]}$ de ensaios Bernoulli independentes com parâmetro p , temos que a probabilidade de uma sequência será

$$\prod_{k=1}^n P(X_k = x_k),$$

de sorte que, sendo r ensaios com $x_k = 1$ e $n - r$ ensaios com $x_k = 0$, então

$$\prod_{k=1}^n P(X_k = x_k) = (1-p)^{n-r} p^r.$$

Visto que cada sequência de ensaios é mutualmente exclusiva, então a probabilidade de obter acumular n ensaios até obter r tentativas equivale ao total de escolhas de r ensaios para fixar $x_k = 1$ dentre n possíveis, logo

$$\binom{n}{r} (1-p)^{n-r} p^r$$

Definição 3.7.

$$X \sim \text{BinNeg}(r, p) \longleftrightarrow p_X(n) = \binom{n}{r} (1-p)^{n-r} p^r$$

Uma binomial negativa pode ser vista como a sucessão de várias geométricas. Desse modo, o valor esperado de uma binomial negativa deve ser igual ao valor esperado da soma das geométricas que a compõe.

Proposição 3.8. *Se $X \sim \text{BinNeg}(r, p)$, então*

$$E[X] = \frac{r}{p}$$

Demonstração. Suponha que $(X_i)_{i \in [r]}$ denote a variável que determina quantos ensaios Bernoulli foram realizados até se obter um sucesso desde o último. Com efeito, a variável $X_i \sim \text{Geo}(p)$ para todo $i \in [r]$. Além disso, temos que

$$X = \sum_{i=1}^r X_i$$

Pela linearidade da esperança, conclui-se que

$$E[X] = \sum_{i=1}^r E[X_i] = \sum_{i=1}^r \frac{1}{p} = \frac{r}{p}$$

■

3.1.5 Distribuição Hipergeométrica

A distribuição hipergeométrica modela amostragens de tamanho n de um espaço amostral equiprovável de tamanho N , em que m dos resultados possíveis são considerados sucessos. Um exemplo clássico são bolas numa urna, das quais m são azuis, e as demais vermelhas. A urna é nosso espaço amostral, as m bolas azuis são os resultados que representam sucessos possíveis, caso realizássemos um sorteio de n bolas da urna, a variável que nos dá o número de bolas azuis sorteadas é hipergeométrica.

Para obter a função de distribuição para a situação sendo modelada, considere uma população de tamanho N , com m indivíduos pertencentes ao evento de sucessos, e uma amostra de tamanho n dessa população. Para obter a probabilidade de obter k indivíduos na amostra que sejam sucessos, supondo que os indivíduos na população são equiprováveis, podemos utilizar a proposição 1.1, considerando Ω como o universo das amostras, e E as amostras que possuem k indivíduos considerados sucessos. O número de amostras possíveis equivale a selecionar n indivíduos de N possíveis

$$|\Omega| = \binom{N}{n}.$$

Por sua vez, o número de amostras com k sucessos equivale ao selecionar k indivíduos dos m que são sucessos e selecionar outros $n - k$ com que não pertencem a esse grupo dos $N - m$ restantes. Por conseguinte

$$|E| = \binom{m}{k} \cdot \binom{N-m}{n-k}$$

e a probabilidade de uma amostra conter k sucessos será

$$\frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

Definição 3.9.

$$X \sim \text{HG}(N, m, n) \longleftrightarrow p_X(k) = \frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

A média de uma hipergeométrica pode ser facilmente obtida pelo seguinte raciocínio: suponha que já tenhamos selecionado a amostra de tamanho n e temos o conhecimento *a priori* de que a população N continha m sucessos, implicando que a probabilidade que cada indivíduo da amostra selecionada tenha probabilidade m/N de ser um sucesso. Considerando que cada indivíduo na amostra é um ensaio Bernoulli de parâmetro m/N , então a média de sucessos deve ser igual a $\frac{nm}{N}$.

Proposição 3.10. Se $X \sim \text{HG}(N, m, n)$, então

$$E[X] = n \frac{m}{N}$$

Demonstração. Presuma que a amostra de tamanho n obtida seja a sequência de eventos $(X_k = x_k)_{k \in [n]}$, em que $X_k : \Omega \rightarrow \{0, 1\}$ é a variável indicadora do conjunto dos sucessos S . Como $|S| = m$ e $|\Omega| = N$, então

$$P(S) = \frac{m}{N}$$

e X_k equivale a uma v.a. Bernoulli de parâmetro m/N . Logo, o número de sucessos na amostra é uma variável binomial com parâmetros n e n/N , e sua média será

$$E[X] = n \frac{m}{N}$$

■

3.1.6 Distribuição de Poisson

A distribuição de Poisson modela contagem de eventos que ocorrem dentro de um intervalo contínuo – como o tempo, uma superfície ou volume – com probabilidade praticamente desprezível. Essa distribuição pode ser compreendida como a uma aproximação da Binomial quando $n \rightarrow \infty$.

Considere que $X \sim \text{Binomial}(n, p)$, logo

$$p_X(a) = \binom{n}{a} (1-p)^{n-a} p^a$$

Se tomarmos o limite da f.m.p. de X quando $n \rightarrow \infty$ e denotamos np por λ , então

$$\begin{aligned} \lim_{n \rightarrow \infty} p_X(a) &= \lim_{n \rightarrow \infty} \binom{n}{a} \left(\frac{\lambda}{n}\right)^a \left(1 - \frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n \rightarrow \infty} \frac{n(n-1) \dots (n-a+1)}{a!} \left(\frac{\lambda}{n}\right)^a \left(1 - \frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n \rightarrow \infty} \prod_{k=1}^{a-1} \left(1 - \frac{k}{n}\right) \cdot \lim_{n \rightarrow \infty} \frac{\lambda^a (1 - \lambda/n)^n}{a! (1 - \lambda/n)^a} \end{aligned}$$

Como

$$\lim_{n \rightarrow \infty} \prod_{k=1}^{a-1} \left(1 - \frac{k}{n}\right) = 1 \quad \text{e} \quad \lim_{n \rightarrow \infty} 1 - (\lambda/n)^a = 1$$

então,

$$\lim_{n \rightarrow \infty} p_X(a) = \lim_{n \rightarrow \infty} \frac{\lambda^a}{a!} \left(1 - \frac{\lambda}{n}\right)^n$$

Usando o limite exponencial fundamental

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

obtemos, por fim,

$$\lim_{n \rightarrow \infty} p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Definição 3.11.

$$X \sim \text{Poisson}(\lambda) \iff p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Proposição 3.12. *Se $X \sim \text{Poisson}(\lambda)$, então*

$$E[X] = \lambda$$

Demonstração. Com efeito,

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \end{aligned}$$

O somatório equivale ao Polinômio de Taylor de e^λ , portanto

$$E[X] = \lambda e^{-\lambda} e^\lambda = \lambda$$

■

Variáveis Aleatórias Multidimensionais

Simulação

PARTE II

ANÁLISE EXPLORATÓRIA

Modelos e Descrição de Dados

6.1 Tipos de Dados

A forma comum em estatística de representar dados é por meio de matrizes retangulares chamadas de **tabelas** ou também, modernamente devido aos softwares usados para tratá-las, **quadro de dados** (*Dataframe*). Por padrão, sendo D um quadro de dados de dimensões $m \times n$, cada coluna de D corresponde a um **atributo**, também chamado de variável ou *feature*, e cada linha corresponde a um registro, que representa um indivíduo na amostra na amostra coletada.

Cada atributo possui um domínio de valores possíveis, que embora possam ser os mais variados possíveis, podem ser organizados numa taxonomia simples. Os tipos de atributos podem ser divididos em dois grande grupos: quantitativos ou qualitativos. O primeiro refere-se a dados com domínio num conjunto numérico, sendo dividido em

Discretos: São atributos que assumem valores em subconjuntos dos números inteiros $\mathbb{Z}$, sendo que na maioria dos contextos são não negativos. Representam contagens, como número de filhos e idades.

Contínuos: O domínio do atributo é um intervalo dos números reais $\mathbb{R}$. Na prática, pelas limitações ontológicas de representar um número real, a realização desses valores se limita a valores aproximados. A diferença fundamental para os discretos é que o conjunto de valores possíveis é não enumerável. Exemplos incluem principalmente medidas, como preços, alturas e pesos.

Os dados qualitativos representam uma qualidade dentro de um conjunto finito de possibilidades chamadas de fatores, sendo divididos em

Ordinais: os fatores possuem uma ordem natural. Exemplos são graus de uma qualidade, como classe social (baixa, média e alta) ou severidade de um exame médico.

Nominais: os fatores não possuem ordem natural, sendo também chamados de categóricos, pois representam categorias. Exemplos são grupos, como sexo ou estado civil. Um tipo especial de variáveis nominais são as dicotômicas, cujos valores possíveis são apenas dois: sucesso ou fracasso, positivo ou negativo, sim ou não, 0 ou 1.

6.2 Escala de Dados

Alternativamente às classificações apresentadas, podemos tipificar atributos através de escalas de medição de seus valores. As classes são similares às classificações apresentadas anteriormente, sendo elas:

- Escala Nominal – para dados nessa escala, só podemos dizer que seus valores são diferentes de outros, sendo usada para categorizar indivíduos. Um exemplo simples é o sexo de uma pessoa: feminino ou masculino. Essa escala não suporta operações matemáticas, e uma medida de centralidade comum para resumir dados nessa escala é a moda.
- Escala Ordinal – nessa escala, os valores podem ser ordenados, e podemos então dizer que, além de diferentes, um valor é maior do que o outro. Essa escala tem sua estrutura preservada por operações que preservem a ordem. Um exemplo de variável ordinal é o nível de escolaridade: fundamental, médio e superior. Medidas de tendência central comuns para dados nessa escala são a moda e a mediana.
- Escala Intervalar - essa escala possui uma origem arbitrária e necessita de uma unidade de medida, sendo um exemplo a temperatura de um ambiente. Podemos afirmar que valores são diferentes, maiores e quão maior em relação a outro, e transformações afim – do tipo $ax + b$ – não alteram a estrutura dessa escala. Podemos utilizar medidas como média, moda e mediana.
- Escala Razão – nessa escala, existe uma origem absoluta, e podemos dizer que um valor é o quão maior do que outro através de razões. Um exemplo de variável nessa escala é o peso de um indivíduo. Transformações do tipo ax preservam a estrutura dessa escala, e podemos utilizar medidas como média, moda e mediana.

6.3 Tabelas de Frequência

Um procedimento para entender o comportamento e distribuição dos dados é por meio de tabelas de frequência, especialmente para variáveis qualitativas, que não podem ser resumidas por ser resumidas por medidas de estatística descritiva a serem vistas mais adiante. Nas tabelas de frequência constam, geralmente, três colunas: a primeira é de categorias ou intervalos de uma classe d_i , a segunda a frequência absoluta n_i de d_i , enquanto a terceira é a frequência relativa $f_i = n_i/n$, onde n é o tamanho da amostra.

Quando lidamos com intervalos de dados numéricos, a amplitude precisa ser definido a priori, e amplitudes diferentes de cada classe pode levar a visualizações distintas. Muitas classes podem levar a perda de informação, enquanto que poucas podem

prejudica a tarefa de resumo. O recomendado é a criação de 5 a 15 classes de mesma amplitude.

Para dados contínuos discretizados em intervalos de amplitude Δ_i para a classe d_i , a tabela pode conter também: a densidade na classe, dada por n_i/Δ_i , a densidade de frequência, obtida por f_i/Δ_i , e a frequência acumulada, dado por

$$\sum_{k=1}^i f_k$$

Essas novas colunas podem ser usadas para construir gráficos que permitam analisar distribuição dos valores de uma variável numérica.

6.4 Gráficos

Nesta seção iremos descrever brevemente gráficos para realizar análise univariada de variáveis de acordo com o seu tipo. Para variáveis qualitativas, os gráficos são basicamente construídos com base na tabela de frequência de cada classe, mostrando a contagem ou a frequência relativa em cada classe. Alguns exemplos incluem:

- Gráfico de Barras – o tamanho da barra é proporcional a contagem ou frequência de registros na classe
- Gráfico de Setores – construído com um círculo de raio arbitrário em que a contagem ou frequência de registros é proporcional à área do setor circular que o representa
- Gráfico de Pirulito – mesmo princípio que o de barras, mas com aspecto mais simples, em que o tamanho é proporcional a uma linha tracejada vertical com um ponto no valor da contagem ou frequência.

Para variáveis numéricas discretas, barras e pirulito também podem funcionar se houver um número não muito grande de realizações distintas no conjunto de dados. Para variáveis contínuas, a discretização em intervalos permite gerar vários tipos de gráficos que ajudam a entender a distribuição de valores da variável, como

- Histogramas – construído também com barras com tamanho proporcional densidade – de registros ou frequência – em cada intervalo. Há várias fórmulas para determinar o número de intervalos (*bins*), como a de Sturges, dada por $k = 1 + 3.3 \log_{10}(n)$, da raiz quadrada, com $k = \sqrt{n}$, de Scott, com $k = \frac{3.5\sigma}{\sqrt[3]{n}}$, onde σ é o desvio-padrão, ou a de Freedman-Diaconis, dada por $k = \frac{2 \cdot \text{IQR}}{\sqrt[3]{n}}$.
- Ramo-e-folha – os ramos são uma coluna vertical com os valores inteiros distintos assumidos pelas realizações. As folhas são as partes fracionárias, empilhadas verticalmente ou horizontalmente em seus ramos.
- Gráfico Dispersão Unidimensional – os dados são mapeados a pontos na reta correspondentes a seus valores. Valores repetidos podem ser empilhados, de modo a dar uma melhor visualização à distribuição dos dados.

Medidas de Resumo

7.1 Medidas de Posição

Um grau maior de resumo dos dados pode ser obtido ao se computar determinadas estatísticas numéricas que sejam representativas de todo o conjunto, e não somente de agrupamentos deles, como é o caso das frequências absolutas e relativas. As medidas a serem apresentadas são usualmente usadas em conjunto para evitar uma redução muito drástica dos dados. Em especial, as medidas de posição nos dão uma ideia de centralidade dos dados.

A primeira delas, é a moda, definida simplesmente como o valor mais frequente na distribuição. Ela pode ser facilmente estimada contando-se o valor mais frequente. Se $x_1, \dots, x_n$ são realizações de uma variável X , então a moda é dada como

$$\text{moda}(X) = \arg \max_x f(x),$$

onde $f(x)$ é a frequência de x em X . A moda é adequada para atributos qualitativos e quantitativos discretos, ao passo que para quantitativos contínuos ela pode ser pouco representativa devido ao grande número de possibilidades de realizações, apesar de ter uma definição satisfatória para esse caso.

A segunda medida é a mediana, que o valor que acumula 50% da frequência acumulada da distribuição de um atributo. Para determinar a mediana de um vetor de dados X , basta ordenar as realizações do vetor; caso sua dimensão seja ímpar, então a mediana é o valor do índice $\frac{n}{2}$, ao passo que, caso seja par, a mediana é obtida como a média entre as realizações de índice $\frac{n}{2}$ e $\frac{n+1}{2}$.

Por fim, a média de um vetor de dados X é o valor $\bar{x}$ dado como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

que é equivalente também a

$$\bar{x} = \sum_{i=1}^n x_i f(x_i).$$

Tanto a média quanto a mediana são apropriadas apenas à atributos quantitativos. Caso estejamos lidando com intervalos discretizados desses valores, então a forma de computar essas medidas é por estimativa.

7.2 Medidas de Dispersão

Além de ver onde nossos dados estão centrados, é desejável saber o quanto eles variam, geralmente entorno do próprio centro citado. Para esse fim, utiliza-se as medidas de dispersão. Como exemplo dessas medidas, poderíamos ter a soma dos desvios entorno da média, ou do quadrado deles para acentuar desvios maiores. No entanto, o sinal dos desvios pode ocultar sua variabilidade real, pois eles podem somar zero, além também de dificultar a comparação da variação entre dois conjuntos de dados distintos. Uma alternativa para isso, seria consederar a soma dos desvios absolutos entorno da média, apesar dessa medida ser sensível ao tamanho do próprio conjunto.

As medidas de dispersão mais simples que contornam os problemas ditos anteriormente são o desvio médio e a variância, dados como

$$\text{dm}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad e \quad \text{Var}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|^2.$$

Como a variância possui unidade igual ao quadrado da unidade do atributo original, então sua interpretação pode ser prejudicada. Dessa forma, define-se o desvio padrão:

$$\text{dp}(X) = \sqrt{\text{Var}(X)},$$

que é equivalente ao “erro” cometido ao se substituir cada observação pela média.

Análise de Dados de Duas Variáveis

PARTE III

INFERÊNCIA CLÁSSICA

Amostragem

Estimação de Parâmetros

Testes de Hipóteses

Inferência Multipopulacional

Análise de Aderência e Adesão

Teste de Hipótese Não Paramétricos

PARTE IV

REGRESSÃO

Covariância e Correlação

Regressão Linear

Regressão Linear Generalizada

PARTE V

INFERÊNCIA BAYESIANA

Paradigma Bayesiano

Inferência e Decisão

Computação Bayesiana

PARTE VI

SÉRIES TEMPORAIS

Fundamentos de Séries Temporais

Modelagem e Previsão
