Estatística

Uma introdução à teoria e à prática

J. P. S. de Sousa

Rio de Janeiro — 2026

Sumário

I Distribuições **7**

1 Probabilidades **8**
1.1 Noções de Medida . . . 8
1.1.1 Análise . . . 9
1.1.2 Introdução à Medida . . . 10
1.1.3 Integral de Lebesgue . . . 13
1.1.4 Espaços L^p . . . 15
1.2 Cálculo das Probabilidades . . . 17
1.3 Probabilidade Condicional e Independência . . . 19
1.4 Teorema de Bayes . . . 22

2 Variáveis Aleatórias **24**
2.1 Variáveis Aleatórias . . . 24
2.2 Função de Distribuição Acumulada . . . 26
2.3 Variáveis Aleatórias Discretas . . . 28
2.4 Variáveis Aleatórias Contínuas . . . 30
2.5 Transformações . . . 33
2.5.1 Transformação de Variáveis Discretas . . . 34
2.5.2 Transformação de Variáveis Contínuas . . . 35
2.6 Esperança e Momentos . . . 37
2.7 Simetria . . . 44

3 Modelos de Distribuição de Probabilidade **49**
3.1 Modelos Discretos . . . 49
3.1.1 Distribuição Uniforme Discreta . . . 49
3.1.2 Distribuição Bernoulli . . . 50
3.1.3 Distribuição Binomial . . . 51
3.1.4 Distribuição Hipergeométrica . . . 52

3.1.5 Distribuição Geométrica 54
3.1.6 Distribuição Binomial Negativa 55
3.1.7 Distribuição Poisson 56
3.1.8 Distribuição Zeta 59
3.2 Distribuição Normal 59
3.3 Outros Modelos Contínuos 64
3.3.1 Uniforme Contínua 64
3.3.2 Exponencial 65
3.3.3 Distribuição Gama 66
3.3.4 Distribuição χ^2 67
3.3.5 Distribuição de Cauchy 67
3.3.6 Distribuição de Weibull 68
3.3.7 Distribuição Beta 69
3.3.8 Distribuição log-normal 69
3.3.9 Distribuição de Laplace 70

4 Variáveis Aleatórias Multidimensionais **71**

5 Simulação **72**

II Análise Exploratória **73**

6 Tipos de Dados e Gráficos **74**
6.1 Tipos e Escala de Dados 74
6.2 Tabelas de Frequência 76
6.3 Gráficos 77

7 Medidas de Resumo **80**
7.1 Medidas de Posição 80
7.2 Medidas de Dispersão 81
7.3 Quantis 82
7.4 Simetria e Assimetria 84
7.5 Medidas Robustas 86
7.6 Implementação em R 87
7.6.1 Medidas de Posição 87
7.6.2 Medidas de Dispersão 88
7.6.3 Quantis 89
7.6.4 Simetria e Assimetria 90
7.6.5 Medidas Robustas 91
7.6.6 Resumo por Grupos 92

8 Transformações de Dados **93**
8.1 Transformações Lineares 93

9 Análise de Dados de Duas Variáveis **98**

III Inferência Clássica 99

10 Amostragem 100

11 Estimação de Parâmetros 101

12 Testes de Hipóteses 102

13 Inferência Multipopulacional 103

14 Análise de Aderência e Associação 104

15 Testes de Hipóteses Não Paramétricos 105

IV Regressão 106

16 Covariância e Correlação 107

17 Regressão Linear 108

18 Regressão Linear Generalizada 109

V Inferência Bayesiana 110

19 Paradigma Bayesiano 111

20 Inferência e Decisão 112

21 Computação Bayesiana 113

VI Processos Estocásticos 114

22 Introdução aos Processos Estocásticos 115

23 Cadeias de Markov 116

24 Ergodicidade 117

25 Processos de Contagem 118

26 Simulação por Processos Estocásticos 119

VII Séries Temporais 120

27 Fundamentos de Séries Temporais 121

28 Modelos Lineares de Séries Temporais 122

29 Modelos Integrados e Sazonais **123**

30 Previsão **124**

31 Métodos de Suavização **125**

32 Tópicos Avançados **126**

Visão Geral da Estatística e Análise de Dados

O que é Estatística

A estatística é a ciência matemática – e parte da metodologia científica – que busca extrair, reduzir, analisar e modelar um conjunto de dados. Seu principal objetivo é encontrar padrões em dados e possibilitar a tomada de conclusões e decisões bem informadas sob incerteza. A Teoria das Probabilidades, que estuda os eventos e as variáveis aleatórias, é a principal base matemática dos conhecimentos estatísticos, conferindo-lhes rigor e confiabilidade.

Para encontrar tais padrões num conjunto de dados, a estatística faz o uso de modelos estatísticos. Esses modelos tentam descrever o dado em duas partes: a parte suave, onde se encontram os padrões, e a parte ruidosa, que corresponde ao fator aleatório inerente a fonte de extração do conjunto. A formulação dos modelos estatísticos ainda pode ser realizada visando-se dois fins, sendo o primeiro o de predizer o comportamento de dados não observados, enquanto que o segundo consiste na inferência, isto é, tomar conclusões sobre os parâmetros encontrados.

A inferência estatística possui um lugar de centralidade no ramo estatístico, pois é sua abordagem que permite generalizar as conclusões sobre os parâmetros dos modelos ajustados sobre uma amostra para uma população, ao mesmo tempo que quantifica a incerteza dessas conclusões. Há duas grandes escolas de inferência estatística, que se diferenciam quanto a interpretação do que é uma probabilidade e, consequentemente, como tratar a incerteza. A primeira é a clássica ou frequentista, que entende probabilidades como frequências relativas obtidas na observação a longo prazo, enquanto os parâmetros são considerados fixos e desconhecidos, com a incerteza vindo da distribuição dos valores dados pelos estimadores. A segunda é a bayesiana, que interpreta probabilidade como o grau de crença num evento ocorrer e vê os parâmetros como variáveis aleatórias, possuindo estes uma distribuição própria atualizada pelas observações via o famoso Teorema de Bayes.

Uma Breve História da Estatística

A palavra estatística deriva dos termos neolatim *statisticum collegium* e italiano *statista*, que significam Colégio de Estado e Estadista respectivamente. A palavra alemã *Statistik* foi usada modernamente por Gottfried Achenwall (1719–1772) em meados do século XVIII para designar a coleta de dados políticos, econômicos e sociais de um país, cujo equivalente em inglês era *political arithmetic*. Posteriormente, através de Sir John Sinclair (1754–1835) e seus trabalhos no *Statistical Accounts of Scotland*, a palavra ganhou uma conotação mais ampla sobre coleta e classificação de dados.

Como vistos pelas suas raízes etimológicas, a estatística surgiu enquanto a disciplina que se preocupava com a coleta, tratamento, classificação e análise de dados sobre características político-sócio-econômicas de um país a fim de apoiar a formulação de políticas pelos seus governos. Dado isso, a prática estatística apareceu, provavelmente, há milhares de anos atrás, quando foram realizados os primeiros censos e contagens de recursos pelos povos. No entanto, enquanto disciplina científica, a estatística desenvolve-

se a partir do século XIX, apoiada pelas ferramentas matemáticas estudadas em séculos anteriores, especialmente por aquelas da Teoria das Probabilidades.

O estudo moderno e documentado de probabilidades inicia-se no século XVI com Girolamo Cardano (1501–1576), um polimata italiano que, motivado pelo seu hábito de apostar, escreveu o livro "*Liber de ludo aleae*" (O livro dos jogos de azar) entre 1550 e 1564. Nesse trabalho, ele documenta a técnica de computar probabilidades como razões de resultados favoráveis sobre o número total de resultados possíveis, desde que todas as conclusões possíveis sejam equiprováveis. Entretanto, o livro não foi devidamente publicado até 1663, quando cálculos sobre jogos de azar simples já estavam amplamente disseminados pela Europa.

O estudo de jogos de azar e, consequentemente, de probabilidades foi também realizado ao longo das correspondências entre os franceses Pierre de Fermat (1601–1665) e Blaise Pascal (1623–1662) em meados do século XVII, principalmente em apoio aos jogos do nobre Chevalier de Méré (1607–1684). Suas contribuições consistiram no uso de técnicas combinatórias para resolver diversos tipos jogos, essas que se tornaram amplamente difundidas e compuseram as bases da moderna Teoria de Probabilidades.

A influência dos estudiosos franceses estendeu-se ao holandês Christiaan Huygens (1629–1695), que sistematizou os conhecimentos desenvolvidos naquele considerado o primeiro tratado sistemático sobre Probabilidades: "*Van Rekeningh in Spelen van Geluck*" (Sobre o Cálculo em Jogos de Azar), introduzindo conceitos como a esperança matemática e registrando a resolução do "Problema dos Pontos". Os trabalhos de Huygens também encontraram aplicações nos cálculos de taxas de anuidades financeiras na Holanda, sobre as quais também publicou um tratado em 1671. O uso vasto e sofisticado de probabilidades para cálculos de riscos, taxas de empréstimos e de seguros se deu mais futuramente em meados do século XVIII na Grã-Bretanha.

Em 1713, é publicada postumamente a célebre obra *Ars conjectandi*, de Jakob Bernoulli (1655–1705), reunindo e aprofundando ideias dos autores anteriormente citados e dando a primeira formulação da Lei dos Grandes Números. No ano de 1718, Abraham de Moivre (1667–1754) publica *The Doctrine of Chances*, outro marco para a Teoria de Probabilidades, trazendo uma definição formal de independência estatística. Em 1733, de Moivre obteve a primeira formulação do Teorema Central do Limite, a qual consistia no caso limite da distribuição binomial, e a incorporou à segunda edição da obra, de 1738. Já em 1763, é enviado, postumamente, um ensaio de Thomas Bayes (1701–1761) à *Royal Society* britânica que discutia o hoje conhecido Teorema de Bayes, que introduz o conceito de probabilidade inversa e atualização de probabilidades à luz de novas evidências.

Na França, a probabilidade ainda encontrou aplicações nas chamadas ciências morais, no sistema judiciário e em eleições de cargos. Pierre de Laplace (1749–1827) e o Marquês de Condorcet (1743–1794) usaram as probabilidades para calcular as chances de um veredito de um júri ou um grupo de eleitores tomarem a decisão "correta". Em 1812, Laplace publica *Théorie analytique des probabilités*, um clássico tratado que expandia o estudo das probabilidades por meio das técnicas do Cálculo Diferencial e Integral desenvolvidas no século anterior. Uma das contribuições desse trabalho é a formulação e prova clássica do Teorema Central do Limite para variáveis independentes

e identicamente distribuídas.

Paralelamente ao intenso desenvolvimento da Teoria de Probabilidades, a estatística moderna começava a ganhar forma ao longo dos séculos XVII e XVIII através do nome de **aritmética política**. Dado o contexto do Iluminismo e o interesse em generalizar o comportamento social por meio de leis universais, assim como a física fizera com a natureza, houve um crescimento nos estudos sobre população, doenças e renda. Exemplos desses estudos incluem os de John Graunt (1620–1674) e William Petty (1623–1687), que publicaram, respectivamente, registros de mortalidade da população londrina e da renda irlandesa, lançando as bases da estatística empírica. O pastor prussiano Johann Peter Süssmilch (1707–1767) também publicou dados sobre proporções de nascimentos e mortes, atrelados a ideia da manifestação da Divina Providência na regularidade demográfica mostrada pelos dados. Todavia, a aritmética política ainda carecia de métodos de coleta mais gerais sobre as populações.

Em 1749, a Suécia torna-se a primeira a nação a realizar a coleta regular e contínua de dados demográficos, primeiramente através de dados providos pela Igreja Luterana e depois por meio de um instituto nacional em 1858, sendo motivada por razões militares e econômicas. A constituição dos Estados Unidos inova ao trazer no seu texto a obrigatoriedade da promoção de censos demográficos a cada 10 anos a partir de 1790, cuja motivação era de atualizar o número de deputados para o Congresso e a distribuição dos impostos federais. Muitas nações europeias também vieram a adotar a prática dos censos em meados do século XIX.

Com as novas demandas criadas pelos censos e a maior oferta de dados para análise, a estatística cresceu e floresceu ao longo do século XIX, sendo aplicada nos mais diversos campos: dados territoriais, produção agrícola, renda, nascimentos, mortes, criminalidade, suicídios, entre outros. Um dos principais nomes desse movimento foi Adolphe Quetelet (1796–1874), que cunhou o conceito do "Homem Médio" para descrever centralidade e variações de características físicas e morais, demonstrando também a regularidade estatística de fenômenos sociais quando observados para uma grande população. Quetelet também articulou o Primeiro Congresso Internacional de Estatística de 1853 em Bruxelas, o qual presidiu e onde advogou pela uniformização, modernização e integração da nova ciência estatística.

Concomitantemente ao desenvolvimento da aritmética política, outras ciências matemáticas contribuiram para a formação da disciplina estatística. Roger Cotes (1682–1716) publicou *Opera Miscellanea* em 1722, inaugurando a Teoria de Erros através da análise astronômica e o uso da média para combinar observações. Thomas Simpson (1710–1761) aplica a análise probabilística aos erros de observação em 1755, argumentando formalmente o porquê a média é mais confiável que um dado isolado.

Adrien-Marie Legendre (1752–1833) publica o Método dos Mínimos Quadrados em 1805, utilizando-o na geodésia para estimar o comprimento do meridiano da Terra e determinar a unidade do metro. Carl Friedrich Gauss (1777–1855) desenvolve e aplica a técnica de forma independente para traçar a órbita de Ceres em 1809, constatando também que ela encontrava o parâmetro ótimo sob a hipótese dos erros seguirem a hoje denominada distribuição Normal ou Gaussiana. Adiante, o Método dos Mínimos Quadrados tornou-se amplamente difundido para obter estimativas de parâmetros de

populações a partir de amostras em várias disciplinas quantitativas.

Na Teoria Cinética dos Gases, a regularidade nas estatísticas sociais inspirou modelos termodinâmicos desenvolvidos nos trabalhos de Rudolf Clausius (1822–1888), James Clerk Maxwell (1831–1879) e Ludwig Boltzmann (1844–1906). Nesses trabalhos, é inaugurada a moderna Mecânica Estatística, que usa modelos probabilísticos para explicar propriedades macroscópicas de um sistema a partir da observação do comportamento geral de suas partes microscópicas.

A biologia também trouxe grandes contribuições à estatística na forma da biometria. Sir Francis Galton (1822–1911) utilizou os conhecimentos estatísticos desenvolvidos até meados do século XIX para analisar a diversidade biológica implicada pela Teoria da Evolução de Charles Darwin (1809–1882). Ele também foi um dos primeiros a desenvolver os métodos de regressões à média e correlação, os quais aplicou à análise de hereditariedade. Os trabalhos de Galton também influenciaram Karl Pearson (1857–1936), cujo nome batiza um dos principais testes e medidas de associação em análise de dados, além de introduzir o método dos momentos para estimação de parâmetros. Pearson também funda o primeiro departamento universitário de estatística do mundo no University College London em 1911, além da influente revista *Biometrika*, que durante muito tempo foi a principal difusora de novos métodos estatísticos e de suas aplicações.

No início do século XX, observou-se a necessidade de métodos sistemáticos de planejamento de experimentos e coleta de amostras que garantissem a eliminação de vieses e a representatividade da população amostrada em várias variáveis. Com esse fim, o estatístico polonês Jerzy Neyman (1894–1981) introduz o método de amostragem estratificada em 1934. O método ganha fama com George Gallup (1901–1984) em 1936, o qual previu a reeleição de Franklin D. Roosevelt (1882–1945) à presidência dos Estados Unidos, em oposição a previsão feita pela grande revista da época *Literary Digest*, que apesar de coletar um número maior de observações, o fez de forma a coletar apenas a opinião de americanos de classe média alta, os quais tendiam a votar no candidato republicano Alfred Landon (1887–1987). A anedota mudou para sempre as noções do que seria uma amostragem aleatória e o design de experimentos que necessitam de amostras representativas de populações.

Ainda na primeira metade e meados do século XX, o nome do biólogo e estatístico Ronald Fisher (1890–1962) ganha destaque ao inaugurar a inferência estatística contemporânea. Fisher expande o projeto e delineamento de experimentos, sistematiza o uso do valor-p para significância estatística, cria o método ANOVA para estudos multipopulacionais e introduz o método da Máxima Verossimilhança para estimação de parâmetros. Fisher é um dos grandes nomes na sistematização de estudos quantitativos, contribuindo para que a estatística não se prendesse somente a mera identificação de correlações, mas indo também em direção às causas dos fenômenos, tendo contribuições na ecologia, psicologia e pesquisas clínicas.

A Inferência Estatística ainda ganha diversas contribuições ao longo do século XX. Em 1908, William Sealy Gosset (1876–1937), sob o pseudônimo de Student, publica, na *Biometrika*, a distribuição e o teste t, que permitiam inferência confiável a partir de amostras pequenas, úteis à análise de dados na agricultura, indústria e pesquisa clínica.

Jerzy Neyman e Egon Pearson (1895–1980), alternativamente à abordagem de Fisher, desenvolvem a inferência a partir da formalização dos testes de hipótese, introduzindo conceitos como erros do Tipo I e II, poder do teste e intervalos de confiança.

Na segunda metade do século XX, com o advento dos computadores, a estatística ganhou novas fronteiras visto ao enorme poder de cálculo adquirido. Nesse contexto, John Tukey (1915–2000) advoga por métodos mais flexíveis e visuais aliados aos algoritmos computacionais para descobrir padrões ocultos e formular, num processo iterativo, hipóteses sobre os dados, em oposição aos modelos estatísticos pré-concebidos antes da análise. Assim, Tukey inaugura a Análise Exploratória de Dados, a partir da qual também se desenvolve a moderna Ciência de Dados do século XXI.

Atualmente a estatística é a disciplina central em qualquer outra área para lidar com dados quantitativos e incertezas, enquanto que o profissional de estatística é a principal referência para coleta, modelagem e análise de dados. O avanço da tecnologia computacional viabilizou o desenvolvimento de técnicas e aplicações estatísticas cada vez mais robustas e complexas para lidar com quantidades massivas de dados e geração de conhecimento e compreensão em praticamente todas as ciências: físicas, biológicas, sociais e humanas. Muitas outras áreas também utilizam amplamente a estatística em suas práticas, como engenharia, negócios, medicina, direito e atuária, por exemplo.

Visto seu desenvolvimento, conclui-se que a estatística permitiu a nós encontrar padrões e regularidade onde, à primeira vista, só há desordem e ruído. Ela representa o triunfo da humanidade sobre a incerteza acerca dos fatos mundanos.

Análise de Dados

A Análise de Dados consiste na inspeção, limpeza, transformação e modelagem de dados com o objetivo claro de obter informações úteis, informar conclusões ou apoiar a tomada de decisão. Em resumo, ela é o processo de extração de dados brutos para geração de conhecimento acionável, geralmente feito num ciclo iterativo. As fases desse processo podem ser divididas em:

1. Requisitos de Dados: a escolha de dados a serem extraídos dependem das análises que se deseja realizar. Aqui define-se a **unidade experimental**, que pode consistir de um indivíduo ou uma população deles, e as **variáveis** específicas dessa unidade, como idade e renda para uma população de pessoas.

2. Coleta de Dados: consiste na tarefa de obter os dados de diferentes fontes, como bancos de dados estruturados ou não-estruturados, sensores físicos, formulários, uma interface de programação de aplicação (API), arquivos binários ou de textos, entre muitas outras fontes.

3. Processamento e Limpeza: inclui tarefas de organizar os dados em formatos estruturados, identificar tipos, deduplicar, tratar valores faltantes, incorretos e desviantes e transformar o formato de dados para outros mais convenientes.

4. Análise Exploratória: compreende uma gama de técnicas para descrever e resumir os dados obtidos à procura de informações que ajudem entender relações entre

as variáveis e guie às técnicas a serem aplicadas nas fases posteriores. Aqui é comumente aplicadas técnicas da Estatística Descritiva e métodos gráficos.

5. Modelagem: são usados algoritmos e modelos estatísticos para extrair padrões latentes nos dados, muitas vezes não triviais de serem identificados. As técnicas de aprendizado estatístico são especialmente úteis nessa etapa.

6. Comunicação e Produto de Dados: a depender do contexto e das finalidades definidas a priori, busca-se maneiras de comunicar esses dados aos atores interessados na forma de visualizações e relatórios. Nos últimos anos, a disciplina de **Narrativa de Dados** tem se destacado para realizar essa comunicação.

A Análise de Dados, do ponto de vista da Estatística, poderia ser dividida em

1. Estatística Descritiva: utilizar medidas de resumo numéricas para os dados a fim de descrever padrões visíveis, geralmente respondendo perguntas do tipo “o que aconteceu?”.

2. Análise Exploratória: semelhante a anterior, porém empregando métodos mais flexíveis e visuais que permitam identificar padrões mais ocultos, correlações e anomalias. Ocorre num processo iterativo de formulação de perguntas, exploração e descobertas.

3. Análise Confirmatória: aplica as técnicas da inferência estatística para confirmar ou rejeitar hipóteses existentes das etapas anteriores

Parte I

Distribuições

Capítulo 1

Probabilidades

Ao observar, registrar ou extrair uma amostra de dados a partir de um fenômeno aleatório, isto é, cujo resultado não pode ser deterministicamente previsto, a Estatística, dentre outras coisas, procura entender o comportamento das frequências de ocorrência dos valores amostrados. Essas frequências são estimativas das **probabilidades** dos eventos observados. A partir de hipóteses adequadas, podemos modelar as frequências por modelos probabilísticos que, por sua vez, são objetos de estudo da Teoria das Probabilidades.

Probabilidades são frequentemente representadas como porcentagens e são muitas vezes entendidas como a frequência de um evento quando se repete o experimento um número suficiente de vezes. Por exemplo, dizer que 16% da população possui diploma de graduação significaria que se escolhermos aleatoriamente 100 pessoas dessa população, cerca de 16 delas teriam diploma de graduação. Essa abordagem é chamada de **frequentista**, sendo a mais amplamente adotada em aplicações estatísticas clássicas.

Outra abordagem para compreender probabilidades é enquanto o grau de crença numa hipótese, como ao dizer que se tem 80% de certeza em dizer que irá chover, visto as evidências do céu nublado e ventos frios. Essa é uma visão mais intuitiva e moderna de probabilidades, sendo chamada de **Bayesiana**, sendo a base da Inferência Bayesiana.

A moderna Teoria das Probabilidades é fundamentada utilizando-se conceitos da Teoria da Medida, um ramo da Análise que generaliza as noções de comprimento, área e volume para espaços abstratos associando-os a uma "medida", a partir da qual também estende-se uma Teoria de Integração para esses espaços. Probabilidades são vistas, portanto, como medidas das chances de ocorrência de um subconjunto de eventos dentro de um universo de resultados possíveis.

1.1 Noções de Medida

Nesta seção, será realizada uma breve exposição dos principais enunciados sobre a Teoria da Medida a fim de fundamentar o desenvolvimento posterior dos conceitos

associados à Teoria de Probabilidades, que, por sua vez, garante a fundamentação da teoria estatística.

1.1.1 Análise

O conceito de continuidade, estudado dentro da Análise, está atrelado à ideia de poder aproximar uma função real a um determinado valor variando suavemente seu argumento.

Definição 1.1. *Uma função $f : \mathbb{R} \to \mathbb{R}$ é contínua em $a \in \mathbb{R}$ se*

$$\forall \epsilon > 0 \, \exists \delta > 0 \, \forall x \in \mathbb{R}, |x - a| < \delta \to |f(x) - f(a)| < \epsilon$$

Outra forma equivalente de definição de continuidade é

$$\lim_{x \to a} f(x) = \lim_{x \to a^+} f(x) = \lim_{x \to a^-} f(x) = f(a).$$

Funções que não são contínuas em determinado ponto significa que, a depender de onde nos aproximamos, o valor para o qual a função converge se diferencia.

Exemplo 1.1. *A função $f(x) = x^2$ é contínua em todo ponto de seu domínio, já que*

$$\lim_{x \to a} x^2 = a^2$$

Exemplo 1.2. *Funções escadas são exemplo de funções não contínuas.*

A próxima definição é uma versão mais forte da anterior. A continuidade uniforme significa que, independente da escolha de limite de erro ϵ para o valor da função, há um único δ tal que em qualquer lugar observa-se que, se $|x-a| < \delta$, então $|f(x)-f(a)| < \epsilon$.

Definição 1.2. *Uma função $f : \mathbb{R} \to \mathbb{R}$ é uniformemente contínua se*

$$\forall \epsilon > 0 \, \exists \delta > 0 \, \forall x, a \in \mathbb{R}, |x - a| < \delta \to |f(x) - f(a)| < \epsilon$$

Uma função que não é uniformemente contínua pode ter variações muita abruptas em alguns intervalos, e mais suaves em outros.

Exemplo 1.3. *As funções* $\sin x$, $\cos x$ *e funções lineares são exemplos de funções uniformemente contínuas, pois suas taxas de variação não se tornam infinitamente grandes conforme a função se aproxima de qualquer ponto.*

Exemplo 1.4. *A função $f : (0, \infty) \to \mathbb{R}$ dada por $f(x) = 1/x$ não é uniformemente contínua, pois conforme se aproxima de* 0*, a sua variação se torna infinitamente grande.*

Um conjunto é dito compacto se toda cobertura sua por abertos admite uma subcobertura finita. Em $\mathbb{R}$, isso equivale a dizer que o conjunto é fechado e limitado (Teorema de Heine–Borel). Quando uma função é contínua em cada ponto de um compacto, então é seguro dizer que ela será uniformemente contínua ao longo de todo o conjunto.

Teorema 1.1. *Seja f uma função pontualmente contínua em X. Se X é compacto (fechado e limitado), então f é uniformemente contínua em X.*

A continuidade uniforme é uma restrição avaliada a cada par de pontos dentro de um intervalo. Já a continuidade absoluta significa que podemos tomar tantos intervalos quanto pudermos enumerar e somar seus comprimentos de forma que, a soma dos comprimentos dos intervalos no domínio levam a pequenas somas de intervalos na imagem, não estando mais estrita a pontos somente.

Definição 1.3. *Uma função f é absolutamente contínua em $[a,b]$ se para todo $\epsilon > 0$ existe $\delta > 0$ tal que, para quaisquer intervalos disjuntos*

$$(a_k, b_k) \subset [a,b]$$

tem-se

$$\sum_k (b_k - a_k) < \delta \Longrightarrow \sum_k |f(b_k) - f(a_k)| < \epsilon$$

1.1.2 Introdução à Medida

Antes de podermos medir determinados conjuntos, precisamos entender que tipos de conjuntos podem ser medidos. Com esse propósito, introduz-se o conceito de σ-álgebras, que define uma álgebra sobre uma coleção de partes de um conjunto cujas operações definem conjuntos **mensuráveis**, i.e., que podem ser medidos em certo sentido.

Definição 1.4. *Seja Ω um conjunto e $\mathscr{B} \subset \mathscr{P}(\Omega)$. O conjunto $\mathscr{B}$ é uma σ-álgebra de Ω se, e somente se,*

i $\varnothing \in \mathscr{B}$.

ii $\forall A \in \mathscr{B}, A^c \in \mathscr{B}$.

iii *Para toda sequência* $(A_i)_{i\in\mathbb{N}} \subset \mathscr{B}$, $\bigcup_{i=1}^{\infty} A_i \in \mathscr{B}$.

Se Ω é um espaço amostral, então $A \in \mathscr{B}$ é denominado evento de Ω.

O caso dos números reais será especial a nós. A **topologia usual** dos reais é a coleção de todos os conjuntos abertos de $\mathbb{R}$, que são exatamente as uniões (enumeráveis) de intervalos abertos. A σ-álgebra de Borel para $\mathbb{R}$ é a menor σ-álgebra que contém todos os abertos. Ela pode ser gerada, equivalentemente, a partir de conjuntos na forma $(-\infty, x]$, com $x \in \mathbb{R}$, pois todo intervalo aberto (a,b) é obtido deles por meio de complementos, uniões e interseções enumeráveis.

Definição 1.5. *Seja $\mathscr{G} = \{(-\infty, x] \mid x \in \mathbb{R}\}$. A σ-álgebra gerada por $\mathscr{G}$ é chamada σ-álgebra de Borel em $\mathbb{R}$ e é denotada por $\mathscr{B}(\mathbb{R})$.*

Definição 1.6. *Um conjunto é dito de medida nula se para todo $\epsilon > 0$ existe uma cobertura enumerável por intervalos $\{I_k\}_{k\in\mathbb{N}}$ tal que a soma dos comprimentos de cada intervalo I_k é menor que ϵ.*

Ao especificar um universo de elementos e as suas partes que podem ser "medidas", então chegamos a um espaço mensurável. Se encontrarmos uma função, chamada de **medida**, que satisfaça hipóteses de o vazio tem medida 0 e que a medida da soma de partes disjuntas é a soma das medidas, então essa medida, junto com o universo e a sua σ-álgebra, formam um espaço de medida.

Definição 1.7. *O par $(\Omega, \mathscr{B})$ é dito mensurável se $\mathscr{B}$ for uma σ-álgebra de Ω. A função $\mu : \mathscr{B} \to \mathbb{R}_+$ é uma medida para $(\Omega, \mathscr{B})$ se satisfaz*

i. $\mu(\varnothing) = 0$

ii. $\sigma-$*aditividade:* $\mu\left(\bigsqcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i)$

A tripla $(\Omega, \mathscr{B}, \mu)$ é chamado de espaço de medida.

Sem a restrição sobre a pré-imagem de f, haveriam conjuntos na imagem que podem ser medidos cujas contrapartes não o poderiam.

Dentre todas as medidas, a de maior destaque é a de Lebesgue, que define uma forma "canônica" de medir intervalos reais, podendo ser generalizada para medir retângulos em qualquer dimensão. Essa medida se comporta analogamente a uma régua, pois ela satisfaz que a medida do intervalo é o comprimento dele.

Definição 1.8. *A medida λ de Lebesgue para $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$ satisfaz*

$$\lambda((a, b]) = b - a$$

Outra medida importante é a de contagem, que associa cada conjunto à quantidade de elementos presentes nele, sendo um número natural quando o conjunto é finito, ou infinito quando ele não o é.

Definição 1.9. *Se a medida μ satisfaz*

$$\mu(A) = \begin{cases} |A|, & \text{se } A \text{ for finito} \\ \infty, & \text{caso contrário} \end{cases}$$

então μ é medida de contagem.

Teorema 1.2. *Se $(\Omega, \mathscr{B}, \mu)$ é uma espaço de medida e $\{A_n\}$ é uma família enumerável de elementos de $\mathscr{B}$, então*

i. ***continuidade por baixo:*** *Se $A_1 \subset A_2 \subset \ldots$, então*

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} \mu(A_n)$$

ii. ***continuidade por cima:*** *Se $A_1 \supset A_2 \supset \ldots$, então*

$$\mu\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n\to\infty} \mu(A_n)$$

iii. ***Sub-aditividade***

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n)$$

Desejamos que, quando um conjunto está contido em outro, então sua medida deve ser menor ou igual ao do conjunto que contém. Isso expressa-se no próximo Teorema.

Teorema 1.3. *Seja $(\Omega, \mathscr{B}, \mu)$ espaço de medida, e A e B elementos de $\mathscr{B}$.*

$$A \subset B \to \mu(A) \leq \mu(B)$$

Há dois tipos de medida que valem serem citadas. As medidas completas são aquelas que qualquer subconjunto de um outro que tenha medida nula também terá medida nula. Por sua vez, as σ-finitas são aquelas que permite particionar o universo em enumeráveis partes de medida finita.

Definição 1.10. *Uma medida μ para $(\Omega, \mathscr{B})$ é dita completa se*

$$\forall S \in \mathscr{B}\, \forall A\,, \mu(S) = 0 \wedge (A \subset S \to A \in \mathscr{B})$$

A medida μ é dita σ-finita se

$$\Omega = \bigcup_{n=1}^{\infty} A_n$$

com $\mu(A_n) < \infty$ para todo $n \in \mathbb{N}$.

Teorema 1.4. *A medida de Lebesgue em $\mathbb{R}$ é σ-finita. A medida de contagem em Ω é σ-finita se, e somente se, Ω é enumerável; em particular, ela não é σ-finita em $\mathbb{R}$.*

Definição 1.11. *Seja $(\Omega, \mathscr{B})$ um espaço mensurável por medidas ν e μ. Dizemos que ν é absolutamente contínua em relação a μ, denotado por $\nu \ll \mu$, se*

$$\forall A \in \mathscr{B}, \mu(A) = 0 \Longrightarrow \nu(A) = 0.$$

Funções, sob certas circuntâncias apropriadas, podem ser compreendidas como transformações de um espaço. Quando aplicamos uma função f com domínio no universo Ω de um espaço mensurável e obtemos um novo universo que pode ser medido, então essa função será mensurável caso, para todo conjunto "medível" na imagem, sua contraparte no domínio também é um conjunto que pode ser medido.

Definição 1.12. *Sejam $(\Omega, \mathbb{B})$ e $(\Omega', \mathbb{B}')$ espaços de medida. Uma função $f : \Omega \to \Omega'$ é mensurável – ou $(\mathscr{B}, \mathscr{B}')$-mensurável – se*

$$\forall B \in \mathscr{B}', f^{-1}(B) \in \mathscr{B}$$

onde f^{-1} denota a pré-imagem de f.

Teorema 1.5. *São verdadeiras as seguintes afirmações:*

i. Toda função contínua é mensurável.

ii. Se f e g são funções mensuráveis, então são mensuráveis

$$f \circ g, \quad f \cdot g, \quad \frac{f}{g}, g \neq 0$$

iii. Se $\{f_n\}$ é uma sequência de funções mensuráveis, então são mensuráveis

$$\limsup f_n, \quad \liminf f_n, \quad \sup f_n, \quad \inf f_n$$

iv. O limite pontual de uma função mensurável é mensurável.

Quando temos uma função f mensurável, pode ser desejável trabalhar como uma versão dela que se comporte tal como uma medida, mas especialmente como a medida de Lebesgue. Com esse fim, define-se a medida de Stieltjes, que mede intervalos como, por exemplo, a distância vertical entre dois pontos no gráfico de uma função real.

Definição 1.13. *Se $f : \mathbb{R} \to \mathbb{R}$ é uma função mensurável monótona crescente e contínua à direita, então a medida induzida de Stieltjes por f, denotada por μ_f, satisfaz*

$$\mu_f((a, b]) = f(b) - f(a)$$

O próximo resultado mostra uma propriedade fundamental das medidas de Stieltjes.

Teorema 1.6. *Seja μ_f a medida de Stieltjes induzida por f. A função f é absolutamente contínua se, e somente se, $\mu_f \ll \lambda$, onde λ é a medida de Lebesgue.*

1.1.3 Integral de Lebesgue

A integral de Riemann falha ao tentarmos integrar a maioria das funções. A fim de estender a integração para uma classe maior de funções, a Teoria da Medida expandiu o conceito de integral enquanto uma generalização da medida de comprimentos de comprimentos, áreas, volumes, etc. Esse desenvolvimento culminou na própria moderna Teoria de Medida, tendo como uma de suas bases a integração de Lebesgue.

Definição 1.14. *A aplicação $\phi : \Omega \to \mathbb{R}$ é uma função simples se pode ser expressa com*

$$\phi(x) = \sum_{i=1}^{n} a_i \cdot I_{A_i}(x)$$

onde $a_i \in \mathbb{R}$ e $\{A_i\}_{i=1}^n \subset \mathscr{B}(\mathbb{R})$ são dois a dois disjuntos.

As funções simples designam uma classe de funções que assumem um conjunto finito de valores. Sua importância encontra-se no Teorema a seguir, o qual enuncia que qualquer função não negativa pode ser aproximado por uma sequência de funções simples.

Teorema 1.7. *Para toda função $f \geq 0$ há uma sequência $\{\phi_i\}_{\mathbb{N}}$ não negativa e crescente de funções simples tal que $\phi \to f$ pontualmente, e uniformemente se f for limitada.*

Com isso, estamos prontos para definir a importante Integral de Lebesgue,

Definição 1.15. *Dada a medida λ de Lebesgue, a integral de Lebesgue, denotada por*

$$\int f \, d\lambda$$

satisfaz

i. Se f é simples, então

$$\int f \, d\lambda = \sum_{i=1}^{n} a_i \cdot \lambda(A_i)$$

ii. sendo f é mensurável e $\{\phi\}_{\mathbb{N}}$ tal que $\phi_n \to f$, então

$$\int f\,d\lambda = \lim_{n\to\infty} \int \phi_n\,d\lambda$$

e o limite existe e não depende da sequência $\{\phi\}_{\mathbb{N}}$.

iii. Se $f = f^+ - f^-$, onde $f^+ = \max(0, f)$ e $f^- = \max(0, -f)$, então

$$\int f\,d\lambda = \int f^+\,d\lambda - \int f^-\,d\lambda$$

desde que $\int |f|\,d\lambda < \infty$.

Teorema 1.8. *A integral de Lebesgue satisfaz*

i. ***Linearidade:***

$$\int (af + bg)\,d\lambda = a\int f\,d\lambda + b\int g\,d\lambda$$

ii. ***Monotonicidade:***

$$f \leq g \text{ q.s. } \to \int f\,d\lambda \leq \int g\,d\lambda$$

iii. ***Aditividade:*** *Se $A \cap B = \varnothing$, então*

$$\int_{A\cup B} f\,d\lambda = \int_A f\,d\lambda + \int_B f\,d\lambda$$

iv. ***Nulidade:*** *Se $f \geq 0$ mensurável,*

$$\forall A \in \mathscr{B}(\mathbb{R}), \int_A f\,d\lambda = 0 \leftrightarrow f = 0 \text{ q.s. } em\ A$$

v. ***Desigualdade de Módulo:***

$$\left|\int f\,d\lambda\right| \leq \int |f|\,d\lambda$$

vi. ***Riemann:***

$$\int_{[a,b]} f\,d\lambda = \int_a^b f(x)\,dx$$

Teorema 1.9 (Convergência Monótona)**.** *Se $\{f_n\}_{\mathbb{N}}$ é uma sequência não negativa e crescente de funções mensuráveis e $f_n \to f$ q.s. , então*

$$\lim_{n\to\infty} \int f_n\,d\lambda = \int f\,d\lambda$$

Lema 1.1 (de Fatou)**.** *Se $f_n \geq 0$ são mensuráveis, então*

$$\int \liminf f_n\,d\lambda \leq \liminf \int f_n\,d\lambda$$

Teorema 1.10. *Se $f_n \to f$ q.s. e existe $g \in L^1(\lambda)$ tal que $|f_n| \leq g$ q.s. para todo n, então*

$$\lim_{n\to\infty} \int f_n\,d\lambda = \int f\,d\lambda$$

O Teorema de Tonelli é um importante resultado do cálculo integral. Ele enuncia que dada uma função não negativa e desejamos integrá-la num espaço de medida dado como produto de outros dois, podemos integrar individualmente em relação a cada espaço individualemente de forma iterada.

Teorema 1.11. *Para $f \geq 0$ mensurável em*

$$(\Omega_1 \times \Omega_2, \mathscr{A}_1 \otimes \mathscr{A}_2, \mu_1 \otimes \mu_2)$$

vale que

$$\int \int f \, d(\mu_1 \otimes \mu_2) = \int \left(\int f \, d\mu_1 \right) d\mu_2 = \int \left(\int f \, d\mu_2 \right) d\mu_1$$

No cálculo integral multivariável tradicional, esse resulta se torna especialmente últil, pois justifica a integração iterada em cada variável de forma independente. Desse modo, enuncia-se o Teorema de Fubini:

Teorema 1.12. *Se*

$$\int |f| \, d(\mu_1 \otimes \mu_2) < \infty$$

então as integrais iteradas existem q.s. *e são iguais às integrais duplas.*

Logo, toda função integrável permite a integração (quase sempre) iterada de cada variável.

Teorema 1.13. *Seja $(\Omega, \mathscr{A}, \mu)$ espaço mensurável onde μ é de contagem, e f uma função não negativa mensurável. Para todo mensurável $A \in \mathscr{A}$,*

$$\int_A f \, d\mu = \sup \left\{ \sum_{x \in F} f(x) \mid F \subseteq A, F \text{ finito} \right\}$$

Em especial, se

$$\int_A |f| \, d\mu < \infty$$

então

$$\int_A f \, d\mu = \sum_{x \in A} f(x)$$

tal que a série à direita é absolutamente convergente.

1.1.4 Espaços L^p

Os espaços L^p são espaços funcionais de aplicações mensuráveis e integráveis. Através deles, podemos definir noção de "norma" para funções, a qual utiliza a integração em relação a uma medida.

Definição 1.16. *Para $1 \leq p \leq \infty$,*

$$L^p(\mu) = \left\{ f \text{ mensurável} \,\middle|\, \int |f|^p \, d\mu < \infty \right\}$$

e

$$\|f\|_p = \left(\int |f|^p \, d\mu \right)^{\frac{1}{p}}$$

Se $p = \infty$,

$$\|f\|_\infty = \operatorname{ess\,sup} |f|$$

O Teorema de Hölder é uma generalização da famosa Desigualdade Cauchy–Schwarz para funções em espaços L^p distos conjugados.

Teorema 1.14 (de Hölder)**.** *Sejam* $1 \leq p, q \leq \infty$ *tais que*

$$\frac{1}{p} + \frac{1}{q} = 1.$$

Então

$$\int |fg| \, d\mu \leq \|f\|_p \cdot \|g\|_q$$

Se $p = q = 2$, então o Teorema de Hölder equivale à Desigualdade de Cauchy–Schwarz. O próximo teorema generaliza a desigualdade triangular para espaços L^p.

Teorema 1.15.

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p$$

Logo, todos os espaços L^p são normados e completos (de Banach). Em especial, L^2 é um espaço de Hilbert.

Teorema 1.16. *Se* $\mu(\Omega) < \infty$ *e* $p \leq q$*, então* $L^q(\Omega) \subset L^p(\Omega)$

Teorema 1.17 (de Radon-Nikodym)**.** *Seja* $(S, \mathscr{B})$ *um espaço mensurável por medidas* μ *e* ν*. Se* μ *é* σ*-finita e* $\nu \ll \mu$*, então existe uma função mensurável não negativa* $f \in L^1(\mu)$ *tal que*

$$f = \frac{d\nu}{d\mu} \iff \forall A \in \mathscr{B}, \nu(A) = \int_A f \, d\mu$$

Ademais, se a função g satisfaz a expressão anterior, então

$$g = \frac{d\nu}{d\mu} \iff f = g \text{ q.s.}$$

Teorema 1.18. *Se* F *é uma função absolutamente contínua, então existe* $f \in L^1(\lambda)$ *tal que*

$$F(x) = F(a) + \int_a^x f \, d\lambda$$

onde dizemos que $f = F'$ q.s.

Teorema 1.19. *Se* $f = F'$ q.s. *e* f *é contínua em* x*, então* $f(x) = F'(x)$.

Definição 1.17. *Sejam* $(\Omega, \mathscr{B}, \mu)$ *um espaço de medida,* $(\Omega', \mathscr{B}')$ *um espaço mensurável e* $T : \Omega \to \Omega'$ *uma função mensurável. Dizemos que* ν *é a medida imagem obtida ao impulsionar* μ *por* T*, denotado por*

$$\nu = T \cdot \mu,$$

se

$$\forall B \in \mathscr{B}', \ \nu(B) = \mu(T^{-1}(B))$$

onde T^{-1} *denota a pré-imagem de* T.

Teorema 1.20. *Sejam $(\Omega, \mathscr{B}, \mu)$ e $(\Omega', \mathscr{B}', \nu)$ espaços de medida, onde ν é a medida imagem de μ impulsionada por $T : \Omega \to \Omega'$ mensurável. Se $f : \Omega' \to \mathbb{R}$ é mensurável e não negativa, então*

$$\int_{\Omega'} f \, d\nu = \int_{\Omega} (f \circ T) \, d\mu$$

1.2 Cálculo das Probabilidades

A Teoria de Probabilidades fundamenta-se em três princípio primitivos conhecidos como Axiomas de Kolmogorov. Dado um universo de possibilidades Ω, chamado de espaço amostral, e cujas as partes são chamadas de eventos, enuncia-se que

- **Axioma 1.** A probabilidade é uma função não negativa
- **Axioma 2.** A probabilidade do espaço amostral é 1.
- **Axioma 3.** A probabilidade de eventos disjuntos é a soma de suas respectivas probabilidades.

Podemos traduzir esses axiomas na nomenclatura de medida. O espaço amostral trata-se do universo de um espaço de medida, de sorte que os eventos são os elementos de uma σ-álgebra desse universo. A função de probabilidade é, portanto, uma medida para os eventos que pode ser interpretada como o quão provável é obter os elementos do evento num experimento aleatório. Uma vez que medidas satisfazem não negatividade e σ-aditividade por definição, para resumir os axiomas basta então impor que a medida aplicada a totalidade do universo é igual a 1.

Definição 1.18. *Um espaço de medida $\Omega, \mathscr{F}, P$ é um espaço de probabilidade se é satisfeito que*

$$P(\Omega) = 1.$$

Os elementos $A \in \mathscr{F}$ são chamados de eventos. O conjunto Ω é denominado espaço amostral.

Os Teoremas 1.1 e 1.2 nos ajudarão a facilitar a avaliação e, futuramente, a computação de probabilidades

Proposição 1.1. *Se $(\Omega, \mathscr{F}, P)$ é espaço de probabilidade, então*

i. $P(A^c) = 1 - P(A)$

ii. $P(A) \leq 1$

Demonstração. Para (i), temos que $A \cup A^c = \Omega$, então por σ-aditividade,

$$P(A) + P(A^c) = P(\Omega)$$
$$P(A^c) = P(\Omega) - P(A) = 1 - P(A)$$

A afirmação (ii) segue de (i) e da propriedade de imagem não negativade de medida:

$$P(A^c) \geq 0 \implies 1 - P(A) \geq 0 \implies P(A) \leq 1.$$

■

Proposição 1.2. *Se $(\Omega, \mathscr{F}, P)$ é espaço de probabilidade, e A e B são eventos, então*

i $P(B \cap A^c) = P(B) - P(B \cap A)$.

ii $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Demonstração. Para (i), considere primeiramente que

$$(B \cap A) \cup (B \cap A^c) = B$$

e como $(B \cap A) \cap (B \cap A^c) = \varnothing$, então podemos usar aditividade de medidas:

$$\begin{aligned} P(B \cap A) + P(B \cap A^c) &= P(B) \\ P(B \cap A^c) &= P(B) - P(B \cap A). \end{aligned}$$

Para provar (ii), usaremos a probabilidade do complementar e a afirmação (i):

$$\begin{aligned} P(A \cup B) &= 1 - P(A^c \cap B^c) \\ &= 1 - [P(A^c) - P(A^c \cap B)] \\ &= P(A) + P(A^c \cap B) \\ &= P(A) + P(B) - P(A \cap B). \end{aligned}$$

■

Para espaços amostrais enumeráveis, ao associar a cada resultado individual um número em $[0, 1]$, de modo que a soma dos pesos resulte em 1, a soma dos pesos dos resultados presentes num evento será a probabilidade desse evento.

Teorema 1.21. *Seja $\Omega = \{\omega_i\}_{\mathbb{N}}$ um conjunto enumerável, e $\mathscr{F}$ uma σ-Álgebra de Ω. Seja $\delta : \Omega \to [0, 1]$ função tal que*

$$\sum_{\omega \in \Omega} \delta(\omega) = 1.$$

Presuma também que, se $A \in \mathscr{F}$, então

$$P(A) = \sum_{\omega \in A} \delta(\omega)$$

A tripla $(\Omega, \mathscr{F}, P)$ é um espaço de probabilidade.

Demonstração. Precisamos provar que P é uma medida de probabilidade que satisfaz os Axiomas de Medida.

Não negatividade Como $\delta \geq 0$, então para todo A em $\mathscr{F}$ vale que $P(A) \geq 0$.

Probabilidade do espaço amostral satisfeito por hipótese.

Soma de eventos disjuntos seja $\{A_j\}_{\mathbb{N}}$ uma família disjunta de eventos de $\mathscr{F}$ tal que

$$A_j = \{\omega_i \mid i \in I_j\}$$

em que I_j é um conjunto de índices. Desenvolvendo,

$$P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty}\sum_{i\in I_j} \delta(\omega_i) = \sum_{j=1}^{\infty} P(A_j)$$

■

Esse resultado é útil para computar a probabilidade de uma vasta gama de experimentos aleatórios na prática. Um exemplo é o lançamento de um dado de 6 faces; se acreditamos que o dado é honesto, isto é, que o dado não é viciado em nenhuma de suas faces, então podemos associar 1/6 a cada face do dado. Se por exemplo, deseja-se saber a probabilidade de obtermos um número menor ou igual a 3, basta somar as faces que satisfazem essa condição, obtendo uma probabilidade de 0.5. Experimentos os quais acreditamos não conterem vícios são chamados de equiprováveis.

As σ-Álgebras que equivalem ao conjunto das partes do espaço amostral são chamadas de σ-Álgebra potência. Quando o espaço amostral do experimento é enumerável e a sua σ-álgebra é a potência, ocorre que cada subconjunto unitário do espaço amostral – um resultado individual – é um evento do experimento. Se o experimento é equiprovável, então todos os resultados são eventos de mesma probabilidade.

Definição 1.19. *Seja o espaço $(\Omega, \mathscr{B}, P)$ com Ω finito, $\mathscr{B} = \mathscr{P}(\Omega)$ e P definido como no Teorema 1.21. Chama-se esse espaço de equiprovável se, e somente se,*

$$\forall \omega \in \Omega, P(\omega) = \frac{1}{|\Omega|}.$$

A probabilidade de eventos em experimentos com resultados equiprováveis destaca-se por ser intuitiva de calcular. A probabilidade de evento será, simplesmente, a fração dos resultados presentes nele. Esse resultado será enunciado como Corolário do Teorema 1.21.

Corolário 1.1. *A probabilidade de um evento $A \in \mathscr{P}(\Omega)$ num espaço $(\Omega, \mathscr{P}(\Omega), P)$ equiprovável é igual a*

$$\frac{|A|}{|\Omega|}$$

Demonstração.

$$P(A) = |A| \cdot \frac{1}{|\Omega|} = \frac{|A|}{|\Omega|}$$

■

1.3 Probabilidade Condicional e Independência

Em experimentos aleatórios, um determinado evento pode ser mais ou menos frequente a depender do conhecimento da ocorrência de outro evento. Nesse caso, dizemos que um evento está condicionado a outro.

Definição 1.20. *Seja $(\Omega, \mathscr{B}, P)$ um espaço de probabilidade. Sejam E e F eventos de $\mathscr{B}$ com $P(F) \neq 0$. A probabilidade condicional do evento E dado F, denotada por $P(E|F)$, é dada por*

$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

Quando a interseção entre dois eventos é vazia, então teremos que a probabilidade condicional será 0. A probabilidade condicional induz uma forma de determinar a probabilidade do evento dado como interseção de vários outros.

Proposição 1.3 (Regra do Produto)**.** *Se $\mathscr{F} = \{E_i\}_{i=1}^n$ é uma família de eventos de um espaço de probabilidade $(\Omega, \mathscr{B}, P)$ satisfazendo*

$$P\left(\bigcap_{j<n} E_j\right) > 0,$$

então

$$P\left(\bigcap_{E\in\mathscr{F}} E\right) = \prod_{i=1}^{n} P\left(E_i \,\middle|\, \bigcap_{j<i} E_j\right)$$

Demonstração. A prova será por indução em n
Base: $n = 1$ é trivial.
Hipótese de Indução: admita que o resultado vale para uma família de n eventos. Se $|\mathscr{F}| = n + 1$, então façamos

$$\bigcap_{j<n+1} E_j = E'$$

e obtemos que

$$P\left(\bigcap_{E\in\mathscr{F}} E\right) = P(E' \cap E_{n+1}) = P(E_{n+1}|E')P(E').$$

Como a hipótese de indução vale para E', então

$$P\left(\bigcap_{E\in\mathscr{F}} E\right) = P\left(E_{n+1} \,\middle|\, \bigcap_{j<n+1} E_j\right) \cdot \prod_{i=1}^{n} P\left(E_i \,\middle|\, \bigcap_{j<i} E_j\right) = \prod_{i=1}^{n+1} P\left(E_i \,\middle|\, \bigcap_{j<i} E_j\right)$$

Uma vez que a proposição vale para $n + 1$, então vale para todo $n \in \mathbb{N}$ pelo princípio de indução. ■

Eventos independentes são aqueles cuja probabilidade de ocorrência não depende da ocorrência de outro. Isso equivale a dizer que, o conhecimento do acontecimento de um evento não muda a crença na ocorrência de outro.

Definição 1.21. *Dois eventos E e F de um espaço $(\Omega, \mathscr{B}, P)$ são independentes se, e somente se*

$$P(E \cap F) = P(E) \cdot P(F)$$

Proposição 1.4. *Se E e F são eventos independentes de $(\Omega, \mathscr{B}, P)$, então*

$$P(E|F) = P(E) \quad e \quad P(F|E) = P(F)$$

Demonstração. Por definição de probabilidade condicional,

$$P(E \cap F) = P(E|F) \cdot P(F)$$

mas como E e F são independentes por hipótese,

$$\begin{aligned} P(E) \cdot P(F) &= P(E|F) \cdot P(F) \\ P(E) &= P(E|F) \end{aligned}$$

e o mesmo pode ser mostrado analogamente para $P(F)$. ■

Proposição 1.5. *Sejam E e F eventos em $(\Omega, \mathscr{B}, P)$. Se eles são independentes, então os seguintes eventos também o são:*

1. *E e F^c*
2. *E^c e F*
3. *E^c e F^c*

Demonstração. Para (1), é verdade que

$$\begin{aligned} P(E \cap F^c) &= P(E) - P(E \cap F) \\ &= P(E)[1 - P(F)] \\ &= P(E)P(F^c) \end{aligned}$$

A expressão (2) é análoga a (1). Por fim, para expressão (3), conclua que

$$\begin{aligned} P(E^c \cap F^c) = P((E \cup F)^c) &= 1 - P(E \cup F) \\ &= 1 - P(E) - P(F) + P(E \cap F) \\ &= P(E^c) - P(F) + P(E) \cdot P(F) \\ &= P(E^c) - P(F)[1 - P(E)] \\ &= P(E^c) - P(F) \cdot P(E^c) \\ &= P(E^c)[1 - P(F)] \\ &= P(E^c) \cdot P(F^c) \end{aligned}$$

■

Teorema 1.22 (Teorema de Probabilidade Total)**.** *Seja o espaço de probabilidade $(\Omega, \mathscr{B}, P)$. Seja $\mathscr{F} = \{F_i\}_{\mathbb{N}}$, com $\mathscr{F} \subset \mathscr{B}$, uma partição de Ω. Se $E \in \mathscr{B}$, então*

$$P(E) = \sum_{F \in \mathscr{F}} P(E|F) \cdot P(F)$$

Demonstração. Para quaisquer $i, j \in \mathbb{N}$ temos que

$$(E \cap F_i) \cap (E \cap F_j) = \varnothing.$$

Com isso, podemos usar aditividade enumerável disjunta,

$$P\left(\bigcup_{F\in\mathscr{F}}(E\cap F)\right)=\sum_{F\in\mathscr{F}}P(E\cap F).$$

Em vista de que

$$\bigcup_{F\in\mathscr{F}}(E\cap F)=E\cap\Omega=E,$$

então

$$P(E)=\sum_{F\in\mathscr{F}}P(E\cap F),$$

e pela definição de probabilidade condicional,

$$P(E)=\sum_{F\in\mathscr{F}}P(E|F)\cdot P(F).$$

■

1.4 Teorema de Bayes

Teorema 1.23 (Teorema de Bayes)**.** *Seja* $(\Omega,\mathscr{B},P)$ *um espaço de probabilidade. Se* E *e* F *são eventos, então*

$$P(E|F)=P(F|E)\frac{P(E)}{P(F)}$$

Demonstração.

$$P(E|F)\cdot P(F)=P(E\cap F)=P(F|E)P(E)$$
$$P(E|F)=P(F|E)\frac{P(E)}{P(F)}$$

■

Uma interpretação para o teorema é a atualização na crença $P(E)$, chamada de **prior**, numa hipótese E dada uma nova evidência F para ela, obtendo um novo grau de crença $P(E|F)$ chamado de **posterior**. A probabilidade $P(F|E)$ é chamada de **verossimilhança**, denotando o quão verossímil é observar a evidência F considerando a hipótese E verdadeira. Por sua vez, $P(F)$ é a crença na ocorrência de F tendo em vista todas as hipóteses, que, junto com a verossimilhança, ajusta o novo grau de crença em E.

Se num dado experimento aleatório consideramos hipóteses $E_1,\ldots,E_n$ e obtemos uma evidência F, é plausível questionar em qual hipótese deveríamos depositar maior crença visto a evidência. Consideremos então o corolário:

Corolário 1.2 (Fórmula de Bayes)**.** *Seja* $\mathscr{E}=\{E_i\}_{\mathbb{N}}$ *uma partição de eventos de um espaço amostral* Ω*. Se* F *é um evento de* Ω*, então*

$$P(E_i|F)=\frac{P(F|E_i)P(E_i)}{\sum_{E\in\mathscr{E}}P(E)P(F|E)}$$

Demonstração. Segue do Teorema de Bayes e do Teorema da Probabilidade Total. ■

Logo, para cada hipótese, poderíamos utilizar a Fórmula de Bayes para computar a crença *a posteriori* nela após a evidência F, e selecionar aquela que tivesse maior probabilidade.

Capítulo 2

Variáveis Aleatórias

Variáveis aleatórias (v.a.) são representações de características numéricas de experimentos aleatórios. Exemplos são a quantidade de caras obtidas no lançamento de uma moeda, a soma dos lados de um dado, número de erros num livro, tempo até a um equipamento apresentar falha, entre muitos outros.

2.1 Variáveis Aleatórias

Apesar do nome, a definição formal desse conceito não os trata como variáveis, mas sim como funções mensuráveis (ver Definição 1.12). Logo, a variável consiste numa associação de eventos à realizações de grandezas numéricas, de modo que todo conjunto de valores pode ter a sua probabilidade medida.

Definição 2.1. *Seja $(\Omega, \mathscr{F}, P)$ um espaço de probabilidade. A aplicação $X : \Omega \to \mathbb{R}$ é uma variável aleatória se for $(\mathscr{F}, \mathscr{B}(\mathbb{R}))$-mensurável, i.e.,*

$$\forall A \in \mathscr{B}(\mathbb{R}), (X^{-1}(A) \in \mathscr{F})$$

A fim de facilitar o tratamento de variáveis aleatórias, iremos introduzir uma notação para denotar eventos de um espaço amostral a partir da variável

Definição 2.2. *Seja $(\Omega, \mathscr{F}, P)$ um espaço de probabilidade e $X : \Omega \to \mathbb{R}$ uma variável aleatória. Se $A \in \mathscr{B}(\mathbb{R})$, então o evento denotado por $\{X \in A\}$ é equivalente a $X^{-1}(A) \in \mathscr{B}$.*

Perceba que se $A \in \mathscr{B}(\mathbb{R})$, então temos três formas de denotar o mesmo evento de $\mathscr{F}$.

$$X^{-1}(A) = \{X \in A\} = \{\omega \in \Omega \mid X(\omega) \in A\}$$

Mais do que associações a características numéricas, as variáveis aleatórias transportam um espaço de probabilidade para o espaço de medida dos reais e sua topologia usual. Logo, para medir a probabilidade de obter um conjunto de valores num experimento aleatório, não necessariamene precisamos explicitar a função de probabilidade

do espaço de origem, pois podemos induzir uma nova medida de prbabilidade para $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$, obtendo, então, um novo espaço de probabilidade que consiste no espaço de resultados do experimento.

Definição 2.3. *Seja $(\Omega, \mathscr{F}, P)$ um espaço de probabilidade e $X : \Omega \to \mathbb{R}$ uma variável aleatória. A tripla $(\mathbb{R}, \mathscr{B}(\mathbb{R}), P_X)$ é o espaço de probabilidade induzido por X se para todo $A \in \mathscr{B}(\mathbb{R})$ é satisfeito*

$$P_X(A) = P(X \in A) \iff \forall A \in \mathscr{B}(\mathbb{R}),\ P_X(A) = P(X^{-1}(A))$$

Em outras palavras, P_X é a medida imagem de P impulsionada por X no espaço $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$ (ver Definição 1.17).

A especificação de variáveis aleatórias costuma vir acompanhada de um conjunto de valores chamado **suporte**, que modela a noção de valores possíveis que a variável pode assumir no experimento. Um determinado valor x está no suporte de X se qualquer conjunto de valores suficientemente próximos de x – com esse incluso – tem probabilidade não nula.

Definição 2.4. *O suporte de uma variável aleatória X é o conjunto*

$$\Omega_X = \{x \in \mathbb{R} \mid \forall \epsilon > 0,\ P(|X - x| < \epsilon) > 0\}$$

Se o suporte modela os valores possíveis, é razoável considerar que a probabilidade do próprio deve ser igual a 1.

Teorema 2.1. *Se X é uma variável aleatória com suporte Ω_X, então $P_X(\Omega_X) = 1$.*

Demonstração. Se $S = \mathbb{R} \setminus \Omega_X$, então

$$x \in S \leftrightarrow \exists a, b \in \mathbb{R}, x \in (a, b) \wedge P_X((a, b)) = 0.$$

Pelo fato de $\mathbb{Q}$ ser denso em $\mathbb{R}$, existem $p, q \in \mathbb{Q}$ tais que

i. $x \in (p, q)$

ii. $(p, q) \subset (a, b)$

iii. $P_X((p, q)) = 0$

De (i) segue que

$$S \subset \bigcup_{(p,q) \in I} (p, q),$$

onde $I \subset \mathbb{Q}^2$ é uma família enumerável de intervalos. Por (ii) e (iii) tem-se

$$P_X(S) \leq P_X\left(\bigcup_{(p,q) \in I} (p, q)\right) \leq \sum_{(p,q) \in I} P_X((p, q)) = 0.$$

Se $0 \leq P_X(S) \leq 0$, então $P_X(S) = 0$. Conclui-se que $P_X(\Omega_X) = 1$. ∎

Com isso, quando for conveniente, podemos, em vez de trabalhar com $(\mathbb{R}, \mathscr{B}(\mathbb{R}))$, usar o espaço $(\Omega_X, \mathscr{A})$, onde

$$\mathscr{A} = \{\Omega_X \cap B \mid B \in \mathscr{B}(\mathbb{R})\}$$

que é chamada de σ-álgebra traço de $\mathscr{B}(\mathbb{R})$.

Outro resultado interessante é que todo evento no espaço de resultados com probabilidade não nula contém pelo menos um elemento do suporte.

Proposição 2.1. *Seja X uma variável aleatória e $S \in \mathscr{B}(\mathbb{R})$ com $P_X(S) = 1$. Se $A \in \mathscr{B}(\mathbb{R})$ e $P(X \in A) \neq 0$, então $A \cap S \neq \varnothing$.*

Demonstração. Suponha que $A \cap S = \varnothing$, e por σ-aditividade,

$$P(A \cup S) = P(A) + P(S) = P(A) + 1$$

Mas pela Proposição 1.1,

$$P(A) + 1 \leq 1$$
$$P(A) \leq 0$$

Por não negatividade,

$$0 \leq P(A) \leq 0$$
$$P(A) = 0$$

■

Em especial, se $A = \{x\}$ for unitário e $x \notin \Omega_X$, então $P(X = x) = 0$.

2.2 Função de Distribuição Acumulada

Se para cada ponto da reta real conseguimos informar qual a probabilidade de uma variável ter realização menor ou igual a esse ponto, então temos informções de como está distribuída a probabilidade da variável. Essa função especial ajuda a caracterizar a variável e é chamada de Função de Distribuição Acumulda, ou distribuição apenas.

Definição 2.5. *Sejam Ω um espaço amostral, P uma medida de probabilidade e X uma variável aleatória. A função $F : \mathbb{R} \to \mathbb{R}$ é uma função de distribuição acumulada para X se, e somente se,*

$$F(x) = P(X \leq x)$$

Uma consequência imediata da definição é que se P_X é a medida do espaço induzido por X, então

$$F(x) = P_X((-\infty, x]).$$

Outros fatos devem ser satisfeitos para determinada função ser uma distribuição. Primeiro, ela deve ser limitada superiormente por 1 e inferiormente por 0, já que são os valores máximo e mínimo de probabilidade que um ponto pode assumir. Pelo princípio

de que $A \subset B$ implica $P(A) \leq P(B)$, então se $x < y$, teríamos $P(X \leq x) \leq P(X \leq y)$, e a distribuição é monótona. Por fim, se a partir de um ponto x nos aproximamos de um ponto a pela direita, então estamos aproximando o evento $(-\infty, x]$ do evento $(-\infty, a]$, o que significa que essa a distribuição acumulada deve ser contínua à direita, visto que o primeiro evento inclui o segundo.

Teorema 2.2. *Se $F : \mathbb{R} \to \mathbb{R}$ é uma função de distribuição acumulada de uma variável aleatória X, então*

1. $\forall x_1, x_2 \in \mathbb{R},\ (x_1 \leq x_2 \to F(x_1) \leq F(x_2))$
2. $\forall x, a \in \mathbb{R},\ (\lim_{x \to a^+} F(x) = F(a))$
3. $\lim_{x \to \infty} F(x) = 1$
4. $\lim_{x \to -\infty} F(x) = 0$

Demonstração. A afirmação (1) segue do fato de que, se $x_1 \leq x_2$, então

$$(X \leq x_1) \subset (X \leq x_2),$$

e pelo Teorema 1.3,

$$P(X \leq x_1) \leq P(X \leq x_2) \Longrightarrow F(x_1) \leq F(x_2).$$

Seguindo para a afirmação (2),

$$\lim_{x \to a^+} F(x) = \lim_{x \to a^+} P(X \leq x)$$

Se x descresce até a, então os eventos $\{X \leq x\}$, para $x > a$, formam uma sequência descrescente de eventos cuja interseção é $\{X \leq a\}$. Pela continuidade de probabilidades, temos que

$$\lim_{x \to a^+} P(X \leq x) = P\left(\lim_{x \to a^+} X \leq x\right) = P(X \leq a) = F(a)$$

Para a afirmação (3), como F é não decrescente, basta tomar $x = n \in \mathbb{N}$. Os eventos $\{X \leq n\}$ formam uma sequência crescente de eventos encaixados tal que

$$\bigcup_{n=1}^{\infty} \{X \leq n\} = \Omega$$

Novamente, pela continuidade da probabilidade,

$$\lim_{x \to \infty} F(x) = \lim_{n \to \infty} P(X \leq n) = P(\Omega) = 1$$

O mesmo argumento é replicável para (4): os eventos $\{X \leq -n\}$ formam uma sequência decrescente com

$$\bigcap_{n=1}^{\infty} \{X \leq -n\} = \varnothing,$$

de sorte que

$$\lim_{x \to -\infty} F(x) = \lim_{n \to \infty} P(X \leq -n) = P(\varnothing) = 0$$

■

Portanto, o Teorema 2.2 garante que há uma medida induzida de Steljes para a distribuição F (ver Definição 1.13). Sendo μ_F a medida de Stieltjes induzida por F, então essa equivale a medida imagem P_X.

Proposição 2.2. *Se X é variável aleatória e μ_F é a medida de Stieltjes induzida por F, então $P_X = \mu_F$.*

Demonstração. Para quaisquer $a, b \in \mathbb{R}$, temos

$$(-\infty, a] \cup (a, b] = (-\infty, b] \qquad (-\infty, a] \cap (a, b] = \varnothing$$

e por σ-aditividade

$$P_X((-\infty, a]) + P_X((a, b]) = P((-\infty, b])$$
$$P_X((a, b]) = P_X((-\infty, b]) - P_X((-\infty, a])$$
$$P_X((a, b]) = F(b) - F(a)$$

Logo,

$$P_X((a, b]) = \mu_F((a, b])$$

■

2.3 Variáveis Aleatórias Discretas

Definição 2.6. *Se X é uma variável aleatória, então X é discreta se, e somente se, existe um conjunto $S \subset \mathbb{R}$ enumerável tal que*

$$P(X \in S) = 1$$

Sob essa definição, existe um conjunto enumerável de valores cujas probabilidades pontuais são suficiente para obter a probabilidade total do espaço de probabilidade. Como vimos no Teorema 2.1, com o suporte reunindo os valores possíveis da variável, então os valores pontuais que acumulam massas de probabilidade devem estar todos reunidos nele. Isso sugere que o suporte é possivelmente um conjunto enumerável, o que é provado no Teorema a seguir.

Proposição 2.3. *Se o suporte Ω_X de uma variável aleatória X é enumerável, então X é discreta.*

Demonstração. Sendo Ω_X enumerável, então pelo Teorema 2.1 segue que X é discreta. ■

Proposição 2.4. *Toda variável discreta X com medida induzida P_X admite uma função $p_X \in L^1(\mu)$ com contradomínio em $[0, 1]$ satisfazendo*

$$p_X = \frac{d}{d\mu} P_X \iff P_X(A) = \sum_{x \in A} p_X(x)$$

onde μ é a medida de contagem.

Demonstração. ■

Temos então que toda a massa de probabilidade de realizações de uma variável discreta está concentrada num conjunto enumerável de pontos. Para essas variáveis será garantida a existência de uma função que associa a cada um desses a probabilidade concentrada nele. A essa função damos o nome de **função de massa de probabilidade**.

Definição 2.7. *Seja $X : \Omega \to \mathbb{R}$ uma v.a. discreta. A função $p_X : \mathbb{R} \to [0, 1]$ é a função de massa de probabilidade de X se, e somente se,*

$$P(X = x) = p_X(x)$$

Enunciemos agora como obter a distribuição F de uma variável aleatória discreta.

Proposição 2.5. *Se $X : \Omega \to \mathbb{R}$ é uma v.a. discreta com função de massa igual a p_X e suporte Ω_X, então a distribuição de X é*

$$F_X(x) = \sum_{\substack{a \in \Omega_X \\ a \leq x}} p_X(a)$$

Demonstração. Suponha $A = \{a \in \Omega_X \mid a \leq x\}$ e $I = (-\infty, x]$. Observe que,

$$P(X \leq x) = P(X \in I)$$

e como $A \subset I$, então por σ-aditividade,

$$P(X \leq x) = P(X \in A) + P(X \in I \setminus A)$$

Suponha por contradição que $P(X \in I \setminus A) \neq 0$, e pela proposição 2.1, $(I \setminus A) \cap \Omega_X \neq \varnothing$, o que equivale a

$$I \cap (\Omega_X \setminus A) \neq \varnothing$$

mas $\Omega_X \setminus A = \{a \in \Omega_X \mid a > x\}$, o que contradiz a hipotese anterior. Portanto,

$$P(X \leq x) = P(X \in A),$$

e pela Proposição 2.4,

$$F_X(x) = \sum_{x \in A} p_X(x),$$

que equivale a

$$F_X(x) = \sum_{\substack{a \in \Omega_X \\ a \leq x}} p_X(a).$$

■

2.4 Variáveis Aleatórias Contínuas

Variáveis aleatória discretas caracterizam-se por uma lista enumerável de pontos concentrarem massas de probabilidades. Outrossim, variáveis aleatórias contínuas são aquelas em que nenhum ponto real acumula qualquer massa de probabilidade, estando essa distribuída ao longo de suas vizinhanças. Formalmente, teremos que qualquer conjunto de pontos de medida nula (como pontos contáveis) terá probabilidade desprezível, caracterizando a medida de probabilidade da variável como absolutamente contínua em relação a medida de Lebesgue (ver Definição 1.11).

Definição 2.8. *A variável aleatória X será contínua se $P_X \ll \lambda$.*

O Teorema de Radon-Nikodym garante a existência de uma função especial – mensurável, não negativa e Lebesgue-integrável – associada a medida de probabilidade induzida P_X de X.

Proposição 2.6. *Toda variável aleatória contínua X admite uma função real mensurável não negativa $f \in L^1(\lambda)$ tal que*

$$f = \frac{d}{d\lambda} P_X$$

Demonstração. Se X é contínua, então $P_X \ll \lambda$. Como λ é σ-finita, então pelo Teorema de Radon-Nikodym existe $f \in L^1(\lambda)$ não negativa tal que

$$f = \frac{d}{d\lambda} P_X$$

■

Se interpretarmos a probabilidade como uma massa distribuída em espaço (neste caso, em $\mathbb{R}$) e que quanto maior a extensão do intervalo avaliado, maior a probabilidade da variável assumir realizações nele, então podemos interpretar a função f como uma **densidade** de probabilidade.

Definição 2.9. *Seja X uma variável aleatória contínua com medida induzida P_X. A função f que satisfaz*

$$f = \frac{d}{d\lambda} P_X \iff P_X = \int f \, d\lambda$$

é chamada de densidade de probabilidade de X.

A função de densidade pode ser então usada para medir a probabilidade de uma variável contínua assumir realizações num intervalo de valores reais. Isso é feito avaliando a integral da função sobre o intervalo desejado. A relação mais direta entre as funções de distribuição e de densidade é dada pela Proposição a seguir.

Proposição 2.7. *Se X é uma variável contínua com densidade f e distribuição F, então*

$$F(x) = \int_{-\infty}^{x} f(t) \, dt$$

Demonstração.

$$F(x) = P_X((-\infty, x]) = \int_{(-\infty,x]} f \, d\lambda = \int_{-\infty}^{x} f(t)\, dt$$

■

A distribuições de variáveis discretas tem a forma de uma função constante por partes, pois entre um ponto e outro temos um "salto" que representa a probabilidade acumulada por um dos pontos. Em contraste, como para variáveis contínuas nenhum ponto acumula massa de probabilidade, a sua distrbiuição deve variar suavemente ao longo de qualquer intervalo, ou de maneira mais forte, em qualquer conjunto disjunto de intervalso Isso caracteriza a distribuição como absolutamente contínua (ver Definição 1.3).

Proposição 2.8. *A variável X é contínua se, e somente se, sua distribuição F é absolutamente contínua.*

Demonstração. Supondo que X é contínua, então $P_X \ll \lambda$. Pela Proposição 2.2 e pelo Teorema 1.6, concluiremos que F é absolutamente contínua. Por outro lado, se F é absolutamente contínua, então $\mu_F = P_X \ll \lambda$ e, por definição, a variável X será contínua. ■

Como qualquer conjunto de pontos isolados terá probabilidade nula, então é intuitivo pensar que o intervalo $(a, b]$ terá a mesma probabilidade do que (a, b). A formalização dessas ideias é dada pelo Teorema a seguir.

Teorema 2.3. *Se X é uma variável aleatória contínua com densidade f, então para todo $x, a, b \in \mathbb{R}$*

i. $P(a < X \leq b) = \int_a^b f(t)\, dt$

ii. $P(X = x) = 0$

iii. $P(X \leq x) = P(X < x)$

iv. $P(X \geq x) = P(X > x)$

Demonstração.

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$$

e pela Proposição 2.7

$$P(a < X \leq b) = \int_{-\infty}^{b} f(t)\, dt - \int_{-\infty}^{a} f(t)\, dt = \int_a^b f(t)\, dt$$

provando (i).
Observemos agora que

$$\lambda(\{x\}) = 0 \Longrightarrow \int_{\{x\}} f \, d\lambda = 0 \Longrightarrow P(X = x) = 0$$

provando (ii).
Uma vez que

$$P(X \leq x) = P(X = x) + P(X < x) \quad \text{e} \quad P(X \geq x) = P(X = x) + P(X > x)$$

então (iii) e (iv) são consequências de (ii). ■

Proposição 2.9. *Se X é uma variável aleatória contínua com densidade f e suporte Ω_X, então*

$$\int_{\Omega_X} f \, d\lambda = \int_{\mathbb{R}} f \, \lambda = 1$$

Demonstração. Com efeito,

$$P_X(\Omega_X) = 1 \Longrightarrow \int_{\Omega_X} f \, d\lambda = 1.$$

Ademais, se $(\mathbb{R}, \mathscr{B}(\mathbb{R}), P_X)$ é o espaço de probabilidade induzido por X, então

$$P_X(\mathbb{R}) = P(\Omega) = 1 \Longrightarrow \int_{\mathbb{R}} f \, d\lambda = 1$$

■

Proposição 2.10. *Se X é uma variável contínua com densidade f e suporte Ω_X, então*

$$f = 0 \text{ q.s. } \textit{em } \mathbb{R} \setminus \Omega_X$$

Demonstração. Seja $A = \mathbb{R} \setminus \Omega_X$. Observe que

$$\int_A f \, d\lambda + \int_{\Omega_X} f \, d\lambda = \int_{\mathbb{R}} f \, d\lambda$$

e pela Proposição 2.9, conclui-se

$$\int_A f \, d\lambda = 0.$$

Como um função de densidade é mensurável e não negativa, então por nulidade da integral de Lebesgue, obtém-se que $f = 0$ q.s. em A. ■

Lema 2.1. *Seja X variável contínua com densidade f e suporte Ω_X. Se f é contínua em $x \in \mathbb{R}$, então $x \in \Omega_X$.*

Demonstração. Suponha que $0 < \epsilon < f(x)$. Por continuidade em x, existe $\delta > 0$ tal que

$$\forall a \in \mathbb{R}, |x - a| < \delta \Longrightarrow |f(x) - f(a)| < \epsilon$$

Suponha por contradição que $x \notin \Omega_X$. Com efeito, exista uma vizinhança $V = (x - \nu, x + \nu)$, com $\nu > 0$ tal que $P(X \in V) = 0$, que equivale a $f = 0$ q.s. em V. Existe, pois, $y \in V$ tal que

$$|x - y| < \delta \quad \text{e} \quad f(y) = 0$$

de modo que

$$|f(x) - f(y)| < \epsilon \Longrightarrow |f(x)| < \epsilon,$$

e sendo f densidade, $f > 0$ e $|f(x)| = f(x)$. Por conseguinte,

$$f(x) < \epsilon$$

contradizendo a afirmação que $\epsilon < f(x)$. Conclui-se que $x \in \Omega_X$. ■

Teorema 2.4. *Se X é variável aleatória com densidade f contínua em*

$$\{x \in \mathbb{R} \mid f(x) > 0\}$$

então

$$\Omega_X = \overline{\{x \in \mathbb{R} \mid f(x) > 0\}}$$

Demonstração. Seja

$$E = \{x \in \mathbb{R} \mid f(x) > 0\}.$$

Mostremos que $\Omega_X \subset \overline{E}$. Para tanto, suponha que $x \notin \overline{E}$. Existe, então, vizinhança $V = (x - \delta, x + \delta)$, com $\delta > 0$, tal que

$$V \cap E = \varnothing$$

Então para todo $a \in V$, $f(a) = 0$, o que equivale a dizer que $f = 0$ q.s. em V. Por consequência, $P(X \in V) = 0$, e $x \notin \Omega_X$.
Demonstremos agora que $\overline{E} \subset \Omega_X$. Do Lema 2.1, temos que $E \subset \Omega_X$. Resta mostrar que todo ponto de acumulação $x \notin E$ é membro de Ω_X. Se $x \in \overline{E}$, então

$$\forall \nu > 0, (x - \nu, x + \nu) \cap E \neq \varnothing.$$

Isso equivale a dizer que para toda vizinhança V de x contém pelo menos um ponto com densidade positiva e, por consequência do Lema 2.1, que é membro do suporte. Se tivéssemos $x \notin \Omega_X$, então haveria uma vizinhança U centrada em x tal que $P(X \in U) = 0$, e teríamos

$$\forall a \in U, a \notin \Omega_X$$

contradizendo a afirmação que toda vizinhança de x tem um membro do suporte. Portanto, $\overline{E} \subset \Omega_X$. ■

2.5 Transformações

Definição 2.10. *Uma transformação de uma variável aleatória X é toda função g : $\mathbb{R} \to \mathbb{R}$.*

Em experimentos aleatórios, comumente define-se variáveis aleatórias a partir de outras variáveis. Dizemos então que a variável derivada é obtida por uma transformação da variável original, consistindo da composição de uma função real mensurável, essa que, pelo Teorema 1.5, também será mensurável, sendo, então, uma variável aleatória.

Definição 2.11. *Seja X uma variável aleatória. Se g for uma transformação mensurável, então $g(X)$ é a variável aleatória definida por $g \circ X$.*

Da nossa definição, a probabilidade de uma variável $g(X)$ assumir valores num conjunto A deve ser o mesmo da imagem de valores de g aplicada sobre realizações de X pertencerem a A. De outro modo, podemos dizer que $P(g(X) \in A)$ é igual a probabilidade da pré-imagem de g em relação a A.

Proposição 2.11. *Se X é uma variável aleatória e g uma transformação mensurável, então*

$$P_X(g(X) \in A) = P(X \in g^{-1}(A))$$

Demonstração.

$$\begin{aligned} P_X(g(X) \in A) &= P_X(\{x \in \mathbb{R} \mid g(x) \in A\}) \\ &= P(X \in g^{-1}(A)) \end{aligned}$$

■

Com essa proposição, uma transformação induz um novo espaço de probabilidade $(\mathbb{R}, \mathscr{B}(\mathbb{R}), P_g)$ onde

$$P_g(A) = P_X(g^{-1}(A)) = P(X \in g^{-1}(A))$$

2.5.1 Transformação de Variáveis Discretas

Teorema 2.5. *Seja X uma variável discreta com suporte Ω_X, função de massa igual a p_X e g uma transformação mensurável de X tal que $Y = g(X)$. A variável Y é discreta e sua função de massa é dada por*

$$p_Y(y) = \sum_{x \in g^{-1}(y)} p_X(x)$$

Demonstração. Para Y ser discreto, seu suporte Ω_Y deve ser enumerável. Da Proposição 2.11 sabemos que

$$P_Y(A) > 0 \leftrightarrow P(X \in g^{-1}(A)) > 0,$$

e pela Proposição 2.1,

$$g^{-1}(A) \cap \Omega_X \neq \varnothing.$$

donde segue

$$\forall y \in \Omega_Y \exists x \in \Omega_X, (g(x) = y \wedge y \in A)$$

Logo, Ω_Y é a imagem de Ω_X sobre g, sendo, pois, enumerável.
Para a afirmação sobre a função de massa de Y, a Proposição 2.11 mostra que

$$p_Y(y) = P_X(Y = y) = P(X \in g^{-1}(y)),$$

e, pela σ-aditividade de P (os pontos fora de Ω_X têm massa nula),

$$p_Y(y) = \sum_{x \in g^{-1}(y)} p_X(x).$$

■

2.5.2 Transformação de Variáveis Contínuas

Para transformações de variáveis contínuas, concentramos-nos, primeiramente, nas transformações monótonas e bijetoras, pois essas compõem uma classe mais fácil de se analisar.

Teorema 2.6. *Seja X uma variável aleatória contínua com distribuição F_X e suporte Ω_X. Seja também $Y = g(X)$ com suporte Ω_Y, em que g é uma transformação monótona bijetora. Se g for crescente, então*

$$F_Y(y) = F_X(g^{-1}(y)).$$

Caso contrário,

$$F_Y(y) = 1 - F_X(g^{-1}(y)).$$

Demonstração. Com efeito, da Proposição 2.11 segue que,

$$F_Y(y) = P_X(Y \leq y) = P(X \leq g^{-1}((-\infty, y]).$$

A função g^{-1} tem a mesma monotonicidade de g. Se g for crescente, então

$$\{X \in g^{-1}((-\infty, y])\} = \{X \leq g^{-1}(y)\}$$

implicando em

$$F_Y(y) = F_X(g^{-1}(y)).$$

Se g for decrescente, obtém-se

$$\{X \in g^{-1}((-\infty, y])\} = \{X \geq g^{-1}(y)\}$$

e

$$F_Y(y) = P(X \geq g^{-1}(y))$$

mas pelo Teorema 2.3,

$$\begin{aligned} F_Y(y) &= P(X > g^{-1}(y)) \\ &= 1 - P(X \leq g^{-1}(y)) \\ &= 1 - F_X(g^{-1}(y)) \end{aligned}$$

■

Por sua vez, a densidade de transformações $Y = g(X)$ em casos em que a densidade de X é contínua, pode ser obtidas via a Regra da Cadeia do Cálculo Diferencial, com a condição de que a inversa de g seja também contínua em Ω_Y. Caso a densidade de X nem a inversa da transformação sejam contínuas em Ω_X e Ω_Y respectivamente, a regra da cadeia não poderia ser aplicada, complexificando a determinação da densidade de Y.

Teorema 2.7. *Seja X uma variável aleatória com f.d.p. igual a f_X. Seja $Y = g(X)$ uma variável obtida pela transformação g e com suporte Ω_Y. Se g é monótona, f_X é contínua em Ω_X e g^{-1} tem derivada contínua em Ω_Y, então a densidade f_Y de Y é dada por*

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, \text{ caso contrário.} \end{cases}$$

Demonstração. Do Teorema 1.18,

$$f_Y(y) = F'_Y(y) \text{ q.s.}$$

Se g é crescente, então

$$F_Y(y) = F_X(g^{-1}(y))$$

e, por consequência,

$$f_Y(y) = [F_X(g^{-1}(y))]' \text{ q.s.}$$

Por hipótese, g^{-1} ter derivada contínua em Ω_Y implica que g^{-1} é contínua em Ω_Y. Ademais, toda distribuição é absolutamente contínua. Pela Regra da Cadeia, obtemos então

$$f_Y(y) = F'_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y) \text{ q.s. se } y \in \Omega_Y$$

Por outro lado, se g é decrescente, então por um desenvolvimento análogo chega-se a

$$f_Y(y) = -F'_X(g^{-1}(y)) \cdot \frac{d}{dy} g^{-1}(y) \text{ q.s. se } y \in \Omega_Y$$

Como $\frac{d}{dy} g^{-1} \leq 0$ nesse caso, então podemos sintetizar esse e o caso anterior em

$$f_Y(y) = F'_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right| \text{ q.s. se } y \in \Omega_Y$$

Se $y \in \Omega_Y \implies g^{-1}(y) \in \Omega_X$ e f_X é contínua em Ω_X por hipótese, então f_X é contínua em $g^{-1}(y)$. Além disso, pela hipótese de g^{-1} ter derivada contínua em Ω_Y, então f_Y será contínua em Ω_Y, e pelo Teorema 1.19,

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right| \text{ se } y \in \Omega_Y$$

Se $y \notin \Omega_Y$, então, pelo Teorema 2.4, $f_Y(y) = 0$. ∎

O teorema 2.7 permite-nos a generalizar a obtenção da densidade de probabilidade de transformações não monótonas que podem ser decompostas em partes monótonas. Um exemplo clássico é a função $g(x) = x^2$ definida em $\mathbb{R}$. Essa função não é monótona, porém suas partes definidas separadamente em $(-\infty, 0)$ e $[0, \infty)$ serão. A densidade da variável definida pela transformação poderá, portanto, ser obtida pelo resultado a seguir

Teorema 2.8. *Seja X uma variável aleatória contínua com densidade f_X e suporte Ω_X, e seja $Y = g(X)$ a variável obtida pela transformação g. Suponha que Ω_X admita uma partição em intervalos $\{A_i\}_{i=1}^n$ e defina $g_i : A_i \to \mathbb{R}$ por $g_i(x) = g(x)$, de modo que, para todo $i \in [n]$,*

i g_i *é contínua e estritamente monótona em* A_i*, de modo que* $B_i = g_i(A_i)$ *é um intervalo e a inversa* $g_i^{-1} : B_i \to A_i$ *está bem definida;*

ii g_i^{-1} *tem derivada contínua no interior de* B_i*.*

Então uma densidade de Y *é dada por*

$$f_Y(y) = \begin{cases} \displaystyle\sum_{i\,:\,y\in B_i} f_X(g_i^{-1}(y)) \cdot \left|\frac{d}{dy} g_i^{-1}(y)\right|, & \text{se } y \in \bigcup_{i=1}^n B_i \\ 0, & \text{caso contrário.} \end{cases}$$

Demonstração. Seja $B \in \mathscr{B}(\mathbb{R})$. Como os A_i particionam Ω_X e $P(X \in \Omega_X) = 1$, temos, por σ-aditividade,

$$P(Y \in B) = \sum_{i=1}^n P(X \in A_i,\ g(X) \in B) = \sum_{i=1}^n \int_{A_i \cap g_i^{-1}(B)} f_X(x)\, dx.$$

Em cada A_i, a função g_i é uma bijeção estritamente monótona sobre B_i, cuja inversa tem derivada contínua no interior de B_i; os extremos de B_i formam um conjunto de medida nula. Logo, pela mudança de variável $x = g_i^{-1}(y)$, com $dx = \left|\frac{d}{dy} g_i^{-1}(y)\right| dy$ – o módulo leva em conta a inversão dos limites de integração quando g_i é decrescente –,

$$\int_{A_i \cap g_i^{-1}(B)} f_X(x)\, dx = \int_{B \cap B_i} f_X(g_i^{-1}(y)) \cdot \left|\frac{d}{dy} g_i^{-1}(y)\right| dy.$$

Somando em i e escrevendo I_{B_i} para a função indicadora de B_i,

$$P(Y \in B) = \int_B \sum_{i=1}^n I_{B_i}(y)\, f_X(g_i^{-1}(y)) \cdot \left|\frac{d}{dy} g_i^{-1}(y)\right| dy = \int_B f_Y(y)\, dy.$$

Como a igualdade vale para todo $B \in \mathscr{B}(\mathbb{R})$, f_Y é uma densidade de Y, que é única a menos de um conjunto de medida nula pelo Teorema de Radon-Nikodym. ■

Observação 2.1. *As imagens* B_i *não precisam coincidir. Se* $X \sim \mathscr{U}(-1, 2)$ *e* $Y = X^2$*, tomamos* $A_1 = (-1, 0)$ *e* $A_2 = [0, 2)$*, de modo que* $B_1 = (0, 1)$ *e* $B_2 = [0, 4)$*, com* $g_1^{-1}(y) = -\sqrt{y}$ *e* $g_2^{-1}(y) = \sqrt{y}$*. Assim, para* $0 < y < 1$ *há duas parcelas na soma, enquanto para* $1 \le y < 4$ *há apenas uma:*

$$f_Y(y) = \begin{cases} 2 \cdot \frac{1}{3} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{3\sqrt{y}}, & \text{se } 0 < y < 1 \\ \frac{1}{3} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{6\sqrt{y}}, & \text{se } 1 \le y < 4 \\ 0, & \text{caso contrário.} \end{cases}$$

2.6 Esperança e Momentos

A esperança de uma variável aleatória representa uma medida de centralidade dos valores dessa variável. Intuitivamente, ela é obtida ponderando-se os valores possíveis da variável por suas respectivas probabilidades, sumarizando a sua imagem a um único valor central. Na linguagem de medida, a definição formal da esperança é dada a seguir.

Definição 2.12. *Seja X uma variável aleatória e $(\Omega, \mathscr{F}, P)$ espaço de probabilidade. Define-se esperança de X, ou valor esperado, denotada por $\mathrm{E}[X]$, como*

$$\mathrm{E}[X] = \int_\Omega X \, dP$$

desde que $\int_\Omega |X| \, dP < \infty$. Caso contrário, dizemos que a esperança de X não existe.

Podemos obter o valor esperado de uma transformação de uma variável aleatória ponderando os valores da transformação pelas próprias probabilidades de suas respectivas pré-imagens, em vez da probabilidade dos valores em si, o que é útil quando não conhecemos em detalhes a distribuição de probabilidade da variável obtida pela transformação.

Teorema 2.9. *Seja X variável aleatória e $g : \mathbb{R} \to \mathbb{R}$ uma transformação mensurável. A esperança da variável $g(X)$ é dada por*

$$\mathrm{E}[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f(x) \, dx, & \text{se } X \text{ é contínua} \\ \sum_{x \in \Omega_X} g(x) P(X = x), & \text{se } X \text{ é discreta} \end{cases}$$

Demonstração. Considere o espaço de medida $(\Omega, \mathscr{F}, P)$, tal que $g(X) : \Omega \to \mathbb{R}$ e

$$\mathrm{E}[g(X)] = \int_\Omega g(X) \, dP$$

mas pelo Teorema 1.20, uma vez que $g(X) = g \circ X$, então

$$\mathrm{E}[g(X)] = \int_{\mathbb{R}} g(x) \, dP_x$$

Se X for contínua, então $f(x) = \frac{d}{d\lambda} P_X$ é densidade de X e fazendo a substituição $dP_X = f(x) d\lambda$, obtemos

$$\mathrm{E}[g(X)] = \int_{\mathbb{R}} g(x) f(x) \, d\lambda = \int_{-\infty}^{\infty} g(x) f(x) \, dx$$

Por outro lado, se X for discreta, então, pela Proposição 2.4, $p_X(x) = \frac{d}{d\mu} P_X$ é a função de massa de X, onde μ é medida de contagem, e fazendo a substituição $dP_X = p_X d\mu$, obtemos

$$\mathrm{E}[g(X)] = \int_{\mathbb{R}} g(x) p_X(x) \, d\mu = \int_{\mathbb{R} \setminus \Omega_X} g(x) p_X(x) \, d\mu + \int_{\Omega_X} g(x) p_X(x) \, d\mu$$

onde Ω_X é o suporte de X. Uma vez que,

$$\forall x \in \mathbb{R}, \, (x \notin \Omega_X \to p_X(x) = 0)$$

então

$$\mathrm{E}[g(X)] = \int_{\Omega_X} g(x) p_X(x) \, d\mu$$

e, pelo Teorema 1.13,

$$\mathrm{E}[g(X)] = \sum_{x \in \Omega_X} g(x) p_X(x)$$

■

O Teorema a seguir enuncia quatro propriedades da esperança enquanto um operador: linearidade, positividade, monotonicidade e preservação de limites. Esse resultado serve como base de cálculos utilizando-se o operador de valor esperado.

Teorema 2.10. *Seja X variável aleatória, e g_1 e g_2 transformações mensuráveis. O operador de esperança satisfaz:*

1. $\mathrm{E}[ag_1(X) + bg_2(X)] = a\mathrm{E}[g_1(X)] + b\mathrm{E}[g_2(X)]$
2. $\forall x \in \Omega_X, (g_1(x) \geq 0) \rightarrow \mathrm{E}[g_1(X)] \geq 0$
3. $\forall x \in \Omega_X,\ (g_1(x) \geq g_2(x)) \rightarrow \mathrm{E}[g_1(X)] \geq \mathrm{E}[g_2(X)]$
4. $\forall x \in \Omega_X, (a \leq g_1(x) \leq b) \rightarrow a \leq \mathrm{E}[g_1(X)] \leq b$

Demonstração. A propriedade 1 segue da linearidade dos operadores de integral, no caso contínuo, e de somatório no caso discreto. A propriedade 2 advém da nulidade para o contínuo e do fechamento dos reais não negativos sob adição nos discretos. As propriedades 3 e 4 vêm da monotonicidade das integrais e da propriedade aditiva das desigualdades. ■

Os momentos de uma variável aleatória medem diferentes aspectos da distribuição dela. A intuição advém da mecânica, em que os momentos de massa descrevem como a massa de um sistema está distribuída em torno de um ponto. Analogamente, os momentos descrevem como a probabilidade dos valores da variável estão distribuídos.

Definição 2.13. *Seja $n \in \mathbb{N}$ e X variável aleatória com esperança μ. O enésimo momento de X, denotado $\mathrm{m}_n(\mu)'$, é definido como*

$$\mathrm{m}_n(\mu)' = \mathrm{E}[X^n]$$

O enésimo momento central, denotado $\mathrm{m}_n(\mu)$, é dado por

$$\mathrm{m}_n(\mu) = \mathrm{E}[(X - \mu)^n]$$

onde $\mu = \mathrm{E}[X]$.

Cada valor de n determina um momento de uma variável, de forma que os dois primeiros possuem interpretações intuitivas:

- O primeiro momento é o "centro de massa" da distribuição, consistindo no próprio valor esperado da variável.
- O segundo é a "inércia" da variável, medindo o quão disprso estão os seus valores. Valores altos recebem pesos maiores do que os mais próximos da origem, tal modo que um pequeno segundo momento diz que as realizações estão conentradas na origem, enquanto um alto segundo momento diz que eles estão dispersos em torno dela.

Os momentos centrais descrevem a distribuição da variável em torno de seu centro de massa, ou seja, do seu valor esperado:

- O segundo momento central mede o quão dispersos os valores estão em relação ao valor esperado.
- O terceiro momento, por preservar o sinal, descreve a direção em que os valores se concentram em relação ao valores esperado: caso seja à esquerda, então ele será negativo; se à direita, então positivo; e caso a distribuição seja aproximadamente simétrica, então ele estará próximo de zero.
- O quarto momento central explica a distribuição de valores extremos, pois esses recebem pesos muito maiores do que valores mais próximos da esperança.

Na análise estatística, os principais momentos centrais usados para explicar uma variável aleatória são o segundo, terceiro e quarto, os quais podem ser normalizados – com exceção do segundo – para criarem medidas descritivas.

Definição 2.14. *Se X uma variável aleatória com esperança μ, então estão definidos:*

1. *Variância:* $\mathrm{Var}(X) = \mathrm{m}_2(\mu)$
2. *Desvio-padrão:* $\mathrm{dp}(X) = \sqrt{\mathrm{Var}(X)}$
3. *Assimetria:* $\frac{\mathrm{m}_3(\mu)}{\mathrm{dp}(X)^3}$
4. *Curtose:* $\frac{\mathrm{m}_4(\mu)}{\mathrm{dp}(X)^4} - 3$

A variância – e, por consequência, o desvio-padrão – é rotineiramente usado com mais frequência junto da esperança para descrever distribuições. Assim como o caso da esperança, nos é útil conhecer algumas propriedades da variância enquanto um operador para fins de cálculos.

Teorema 2.11. *Seja X variável aleatória com esperança μ e $a \in \mathbb{R}$. Vale que*

1. $\mathrm{Var}(X) = \mathrm{E}[X]^2 - \mu^2$
2. $\mathrm{Var}(aX) = a^2\mathrm{Var}(X)$
3. $\mathrm{Var}(X + a) = \mathrm{Var}(X)$

Demonstração. Com efeito, do Teorema 2.10 segue que

$$\begin{aligned}\mathrm{Var}(X) &= \mathrm{E}\big[(X-\mu)^2\big] \\ &= \mathrm{E}\big[X^2 - 2X\mu + \mu^2\big] \\ &= \mathrm{E}\big[X^2\big] - 2\mu\mathrm{E}[X] + \mu^2 \\ &= \mathrm{E}\big[X^2\big] - 2\mu^2 + \mu^2 \\ &= \mathrm{E}[X]^2 - \mu^2\end{aligned}$$

provando 1. Usando isso para 2,

$$\begin{aligned}\mathrm{Var}(aX) &= \mathrm{E}\big[(aX)^2\big] - \mathrm{E}[aX]^2 \\ &= \mathrm{E}\big[a^2X^2\big] - \mathrm{E}[aX]\cdot\mathrm{E}[aX] \\ &= a^2\mathrm{E}\big[X^2\big] - a^2\mathrm{E}[X]^2 \\ &= a^2\mathrm{Var}(X)\end{aligned}$$

E a aquela ainda pode ser usada para obter 3:

$$\begin{aligned}\mathrm{Var}(X+a) &= \mathrm{E}\big[(X+a)^2\big] - \mathrm{E}[X+a]^2 \\ &= \mathrm{E}\big[X^2\big] + 2a\mathrm{E}[X] + a^2 - (\mathrm{E}[X]+a)(\mathrm{E}[X]+a) \\ &= \mathrm{E}\big[X^2\big] + 2a\mathrm{E}[X] + a^2 - \mathrm{E}[X]^2 - 2a\mathrm{E}[X] - a^2 \\ &= \mathrm{E}\big[X^2\big] - \mathrm{E}[X]^2 \\ &= \mathrm{Var}(X)\end{aligned}$$

■

Uma transformação aplicável a variáveis aleatórias é aquela que subtrai a mede e divide o resultado pelo desvio-padrão, conhecida como **padronização**. O destaque para ela justifica-se pelo fato de que a variável resultante sempre terá valor esperado igual a 0 e desvio-padrão igual a 1, o que é provado na Proposição 2.12. Esse resultado é especialmente útil quando temos um conjunto de várias variáveis e queremos tratá-las na mesma escala.

Proposição 2.12. *Se X é uma variável aleatória com esperança μ e variância σ^2, então a variável definida por*

$$Z = \frac{X-\mu}{\sigma}$$

possui esperança 0 e variância 1.

Demonstração. Com efeito,

$$\mathrm{E}[Z] = \frac{1}{\sigma}\cdot\mathrm{E}[X] - \frac{\mu}{\sigma} = 0$$

enquanto que,

$$\mathrm{Var}(Z) = \mathrm{E}\left[\frac{(X-\mu)^2}{\sigma^2}\right] = \frac{\sigma^2}{\sigma^2} = 1$$

■

As funções geradoras de momentos (mgf), como seu nome sugere, são usadas para obter os momentos de uma variável aleatória. No entanto, na prática, é mais razoável utilizar a própria definição de momento para fins de computação. A sua real utilidade está em oferecer uma forma de representar todos os momentos de uma variável enquanto uma função com poderosas propriedades teóricas.

Definição 2.15. *A função geradora de momentos (mgf) da variável X é*

$$\begin{aligned}M_X &: \mathbb{R} \to \mathbb{R} \\ M_X(t) &= \mathrm{E}\big[e^{tX}\big]\end{aligned}$$

caso o valor esperado exista para t numa vizinhança de 0. *Caso contrário, dizemos que a mgf não existe.*

A presença de uma exponencial no argumento do valor esperado na definição da mgf pode ser confusa a primeira vista. A razão disso é revalada na demonstração do Teorema 2.12, o qual enuncia como obter os momentos por meio da mgf: avaliando a drivada de ordem n do gerador de momentos em torno de $t = 0$.

Teorema 2.12. *Se X uma variável aleatória cuja mgf existe, então*

$$\mathrm{E}[X^n] = \left.\frac{d^n}{dt^n} M_X(t)\right|_{t=0}.$$

Demonstração. Seja $h > 0$ tal que $M_X(t) < \infty$ para todo $|t| < h$. Mostremos, primeiramente, que

$$\mathrm{E}\Big[|X|^k e^{\tau X}\Big] < \infty \quad \text{para todo } k \in \mathbb{N} \text{ e } |\tau| < h. \tag{2.1}$$

Com efeito, tome $\epsilon > 0$ tal que $|\tau| + \epsilon < h$. Pela série de Taylor da exponencial, $e^{\epsilon|x|} \geq (\epsilon|x|)^k/k!$, de modo que

$$|x|^k \leq \frac{k!}{\epsilon^k} e^{\epsilon|x|} \leq \frac{k!}{\epsilon^k}\left(e^{\epsilon x} + e^{-\epsilon x}\right)$$

e, portanto,

$$\mathrm{E}\Big[|X|^k e^{\tau X}\Big] \leq \frac{k!}{\epsilon^k}\left(M_X(\tau+\epsilon) + M_X(\tau-\epsilon)\right) < \infty,$$

já que $|\tau \pm \epsilon| < h$.

Provemos agora, por indução em k, que $M_X^{(k)}(t) = \mathrm{E}\big[X^k e^{tX}\big]$ para todo $|t| < h$. O caso $k = 0$ é a própria definição de M_X. Suponha que a igualdade valha para k, e fixe $|t| < h$ e $\epsilon > 0$ com $|t| + \epsilon < h$. Para $0 < |s| \leq \epsilon/2$,

$$\frac{M_X^{(k)}(t+s) - M_X^{(k)}(t)}{s} = \mathrm{E}\left[X^k \cdot \frac{e^{(t+s)X} - e^{tX}}{s}\right].$$

Pelo Teorema do Valor Médio, para cada x existe ξ entre t e $t+s$ tal que

$$\frac{e^{(t+s)x} - e^{tx}}{s} = x e^{\xi x},$$

e, como $\xi \in [t - \epsilon/2, t + \epsilon/2]$ e $\xi \mapsto e^{\xi x}$ é monótona,

$$\left|x^k \cdot \frac{e^{(t+s)x} - e^{tx}}{s}\right| \leq |x|^{k+1}\left(e^{(t-\epsilon/2)x} + e^{(t+\epsilon/2)x}\right).$$

O lado direito não depende de s e, por (2.1), tem esperança finita. Além disso, o integrando converge para $X^{k+1}e^{tX}$ quando $s \to 0$. Pelo Teorema da Convergência Dominada (Teorema 1.10), aplicado ao longo de qualquer sequência $s_n \to 0$ e à medida P,

$$M_X^{(k+1)}(t) = \lim_{s\to 0} \frac{M_X^{(k)}(t+s) - M_X^{(k)}(t)}{s} = \mathrm{E}\Big[X^{k+1}e^{tX}\Big].$$

Por fim, avaliando em $t = 0$,

$$\left.\frac{d^n}{dt^n} M_X(t)\right|_{t=0} = \mathrm{E}\big[X^n e^0\big] = \mathrm{E}[X^n].$$

Note que a demonstração não supõe que X seja contínua ou discreta: ela vale para qualquer variável aleatória cuja mgf exista. ∎

O próximo resultado diz como obter a mgf de uma variável obtida por transformação afim de uma outra.

Proposição 2.13. *Se X e Y é uma variável aleatória tal que $Y = aX + b$, com a e b reais, então*

$$M_Y(t) = e^{bt} M_X(at)$$

Demonstração. Com efeito,

$$\begin{aligned} M_Y(t) &= E[e^{ty}] \\ &= \mathrm{E}\Big[e^{(at)x} \cdot e^{tb}\Big] \\ &= e^{tb} \cdot \mathrm{E}\Big[e^{(at)x}\Big] \\ &= e^{tb} \cdot M_X(at) \end{aligned}$$

■

Apesar de serem usados para descrever distribuições de variáveis aleatórias, momentos não necessariamente as definem. Em outras palavras, embora duas variáveis possuam a mesma sequência de momentos, não necessariamente elas possuem a mesma distribuição. O Teorema 2.13 estabelece algumas condições para que sequências de moementos idênticos permitem dizer que estamos tratando das mesmas distribuições.

Teorema 2.13. *Sejam X e Y variáveis aleatórias com distribuições $F_X(x)$ e $F_Y(y)$ cujos momentos existem. Valem as seguintes afirmações:*

1. *Se os suportes das variáveis são limitados, $F_X(u) = F_Y(u)$ para todo $u \in \mathbb{R}$ se, e somente se, $\mathrm{E}[X^r] = \mathrm{E}[Y^r]$ para todo inteiro r não negativo.*

2. *Se a funções geradoras de momentos das variáveis existem e $M_X(t) = M_Y(t)$ para todo t em uma vizinhança de 0, então $F_X(u) = F_Y(u)$ para todo $u \in \mathbb{R}$.*

Demonstração. Sejam f_x e f_Y as densidades de X e Y respectivamente. Utilizando-se a integração por partes para expressar $\mathrm{E}[X^n]$,

$$\mathrm{E}[X^n] = \int_{-\infty}^{\infty} u^n f_X(u)\, du = u^n F_X(u) - n \int_{-\infty}^{\infty} u^{n-1} F_X(u)\, du$$

mas supondo que $F_X(u) = F_Y(u)$, então

$$\mathrm{E}[X^n] = u^n F_Y(u) - n \int_{-\infty}^{\infty} u^{n-1} F_Y(u)\, du = \int_{-\infty}^{\infty} u^n f_Y(u)\, du = \mathrm{E}[Y^n]$$

■

Aqui é que notamos a utilidade das funções geradoras de momentos: apesar de uma sequência de momentos não ser suficiente para caracterizar uma distribuição, a convergência de geradores de momentos permite afirmar a convergência de uma distribuição.

Teorema 2.14. *Seja $(X_i)_{i=1}^n$ uma sequência de variáveis aleatórias com geradores de momentos $M_{X_i}(t)$ respectivamente. Se para todo t numa vizinhança de 0 é satisfeito que*

$$\lim_{i \to \infty} M_{X_i}(t) = M_X(t)$$

então há uma única distribuição $F_X(x)$ tal que

$$\lim_{i\to\infty} F_{X_i}(x) = F_X(x)$$

A demonstração desse Teorema está fora do escopo deste texto, pois ela baseia-se no fato de que $M_X(t)$ é Transformada de Laplace de uma única função de densidade $f(x)$. Também seria necessário mostar que, dada a convergência das transformadas, as densidades das variáveis envolvidas satisfazem determinadas hipóteses de continuidade e convergência, as quais permitem dizer que as próprias densidades convergem para a mesma função $f(x)$.

2.7 Simetria

Definição 2.16. *Uma variável X possui distribuição simétrica em torno de $x = m$ se, e somente se,*

$$\forall t \in \mathbb{R},\ P(X - m \leq t) = 1 - P(X - m < -t)$$

Observação 2.2. *Se fizémos $t = -u$, então*

$$P(X - m \leq -u) = 1 - P(X - m < u) \tag{2.2}$$

para todo $u \in \mathbb{R}$. Logo, a expressão 2.2 é uma formulação equivalente para a definição 2.16.

Observação 2.3. *Se X for variável contínua, então a definição de simetria equivale a*

$$P(X - m \leq t) = 1 - P(X - m \leq -t)$$
$$F_X(m + t) = 1 - F_X(m - t)$$

Proposição 2.14. *Se X é uma variável com distribuição simétrica em torno de m, então*

$$P(X \leq m) = P(X \geq m).$$

Demonstração. Com efeito,

$$P(X - m \leq 0) = 1 - P(X - m < 0)$$
$$P(X \leq m) = 1 - P(X < m)$$
$$P(X \leq m) - [1 - P(X < m)] = 0$$
$$P(X \leq m) - P(X \geq m) = 0$$
$$P(X \leq m) = P(X \geq m)$$

■

Definição 2.17. *A mediana m da distribuição de uma variável aleatória X satisfaz*

$$P(X \geq m) \geq \frac{1}{2} \quad e \quad P(X \leq m) \geq \frac{1}{2}$$

Proposição 2.15. *Se X possui distribuição simétrica em torno de m, então m é mediana da distribuição de X.*

Demonstração. Sabemos que

$$P(X \leq m) + P(X > m) = 1$$
$$P(X \leq m) + P(X > m) + P(X = m) = 1 + P(X = m)$$
$$P(X \leq m) + P(X \geq m) = 1 + P(X = m)$$

mas pela Proposição 2.14

$$2P(X \leq m) = 1 + P(X = m)$$

Uma vez que $P(X = m) \geq 0$, então $1 + P(X = m) \geq 1$, e

$$2P(X \leq m) \geq 1$$
$$P(X \leq m) \geq \frac{1}{2}.$$

Mais uma vez, pela Proposição 2.14,

$$P(X \geq m) \geq \frac{1}{2}$$

■

Teorema 2.15. *A variável X ter simetria em torno de m equivale a*

1. *Se X for discreta, então*

$$p_X(m + t) = p_X(m - t).$$

2. *Se X for contínua, então*

$$f_X(m + t) = f_X(m - t).$$

Demonstração. Suponha que X seja simétrica. Para provar 1, considere que

$$P(X - m \leq t) = P(X - m = t) + P(X - m < t)$$

mas, por simetria,

$$P(X - m \leq t) = 1 - P(X - m < -t)$$

de forma que

$$P(X - m = t) = 1 - [P(X - m < -t) + P(X - m < t)]$$

Analogamente, por σ-aditividade e simetria, iremos concluir que,

$$P(X - m = -t) = 1 - [P(X - m < -t) + P(X - m < t)]$$

Logo,

$$P(X - m = t) = P(X - m = -t)$$

e, como X é discreto, então

$$p_X(m + t) = p_X(m - t)$$

Para provar a afirmação 2, observe que

$$F_X(m + t) = 1 - F_X(m - t),$$

e derivando em relação a t,

$$\frac{d}{dt}F_X(m + t) = -\left[-\frac{d}{dt}F_X(m - t)\right].$$

Portanto,

$$f_X(m + t) = -[-f_X(m - t)] = f_X(m - t).$$

Agora suponha que as equações das afirmações 1 e 2 valem. Partindo de 1, temos que

$$P(X - m \leq -t) = \sum_{y \leq -t} P(X - m = y)$$

mas como para todo $t \in \mathbb{R}$ vale que $P(X - m = t) = P(X - m = -t)$, então

$$P(X - m \leq -t) = \sum_{y \leq -t} P(X - m = y) = \sum_{-y \geq t} P(X - m = -y) = P(X - m \geq t).$$

Uma vez que $P(X - m \geq t) = 1 - P(X - m < t)$, então

$$P(X - m \geq t) = 1 - P(X - m < t).$$

O que prova a simetria para o caso discreto. Direcionando agora para o caso contínuo, considere $Y = X - m$, de modo que $f_Y(y) = f_X(y + m)$. Com efeito

$$F_Y(Y \leq t) = \int_{-\infty}^{t} f_X(m + y)\, dy = 1 - \int_{t}^{\infty} f(m + y)\, dy.$$

mas supondo a afirmação 2, obtemos

$$F_Y(Y \leq t) = 1 - \int_{t}^{\infty} f(m - y)\, dy.$$

Fazendo a substituição $y = -u$ e invertendo os limites de integração ajustados à troca de variável, veremos que

$$F_Y(Y \leq t) = 1 - \int_{-\infty}^{-t} f(m + u)\, du.$$

Portanto,

$$F_Y(Y \leq t) = 1 - F_Y(-t)$$
$$F_X(m + t) = 1 - F_X(m - t)$$

■

Corolário 2.1. *Se X é contínua, tem distribuição simétrica em torno de m e sua densidade $f(x)$ é estritamente decrescente em $[m, \infty)$, então*

$$\forall x_1, x_2 \in \mathbb{R},\ x_1 \leq m \leq x_2 \text{ e } f(x_1) = f(x_2) \rightarrow \frac{x_1 + x_2}{2} = m$$

Demonstração. Suponha que $x_1 = m - a$ e $x_2 = m + b$, logo

$$f(x_1) = f(m - a) = f(m + a)$$

mas, pela hipótese $f(x_1) = f(x_2)$, temos

$$f(m + a) = f(m + b).$$

Como $a, b \geq 0$ e f é estritamente decrescente, logo injetiva, em $[m, \infty)$, segue que $a = b$ e, por conseguinte,

$$\frac{x_1 + x_2}{2} = m.$$

■

Definição 2.18. *A moda* $\text{moda}(X)$ *de uma variável aleatória X é o valor tal que*

1. *Se X é discreta, então*

$$\text{moda}(X) = \arg\max_x p_X(x)$$

2. *Se X for contínua, então*

$$\text{moda}(X) = \arg\max_x f_X(x)$$

Teorema 2.16. *Se X é uma variável aleatória cuja distribuição é simétrica em torno da mediana m, então*

1. *Se a distribuição é unimodal (isto é, possui uma única moda), então* $m = \text{moda}(X)$.
2. *Se* $\text{E}[|X|] < \infty$, *então* $m = \text{E}[X]$.

Demonstração. Seja p a função de massa de X discreta. Suponha que a moda esteja num valor x diferente de m, de modo que $x = m + a$ ou $x = m - a$. No entanto, por hipótese de simetria, do Teorema 2.15 segue que

$$p(m + a) = p(m - a),$$

implicando que a distribuição tem duas modas, logo não pode ser unimodal. O mesmo argumento é replicado para uma variável contínua substituindo a função p pela densidade f. Portanto, m é a moda da distribuição.
Consideremos agoa a transformação $Y = X - m$, tal que

$$P_X(Y \leq t) = 1 - P_X(Y \leq -t)$$
$$P_X(Y \leq t) = P_X(Y \geq -t)$$
$$P_X(Y \leq t) = P_X(-Y \leq t),$$

indicando que Y e $-Y$ tem a mesma distribuição, logo, o mesmo valor esperado. Com efeito,

$$\begin{aligned} \mathrm{E}[Y] &= \mathrm{E}[-Y] \\ \mathrm{E}[X] - m &= m - \mathrm{E}[X] \\ \mathrm{E}[X] &= m. \end{aligned}$$

■

Capítulo 3

Modelos de Distribuição de Probabilidade

Toda variável aleatória é caracterizada por uma distribuição F que contém zero ou mais parâmtros. As distribuições que contêm os mesmos parâmetros compõem uma família de funções denominadas **modelos de distribuição de probabilidade**. Na estatística, esses modelos são usados para estudar diferentes tipos de populações de forma abrangente.

Neste capítulo, serão apresentados os principais modelos de distribuição usados na modelagem estatística, compreendendo modelos discretos, contínuos

3.1 Modelos Discretos

3.1.1 Distribuição Uniforme Discreta

O primeiro e mais simples modelo de distribuição discreto é a uniforme discreta. Ela modela experimentos onde a frequência de todos os resultados são iguais, ou seja, são equiprováveis. Se $(\Omega_X, \mathscr{A}, P_X)$ é equiprovável, então a função de massa de X é dada simplesmente por

$$p_X(x) = \frac{1}{|\Omega_X|}.$$

Definição 3.1. *A variável discreta X tem distribuição uniforme discreta se sua função de massa for dada por*

$$p_X(x) = \frac{1}{|\Omega_X|}$$

onde Ω_X é o seu suporte.

Exemplo 3.1. O número de caras obtidas em 1 lançamento tem dois resultados possíveis: 0 ou 1. Se a moeda é honesta, então

$$P(X = 0) = P(X = 1) = \frac{1}{2}$$

e X tem distribuição uniforme discreta.

Exemplo 3.2. Num dado honesto, as seis faces são equiprováveis de serem sorteadas. Logo

$$P(X = k) = \frac{1}{6}$$

onde $k \in \{1, \ldots, 6\}$.

3.1.2 Distribuição Bernoulli

As variáveis Bernoulli modelam fenômenos que só possuem dois resultados possíveis: verdadero ou falso, codificados comumente como 1 e 0 respectivamente. Seja $(\Omega, \mathscr{A}, P)$ um espaço de probabilidade, e $A \in \mathscr{A}$ tal que

$$\omega \in A \to X(\omega) = 1 \quad \text{e} \quad \omega \notin A \to X(\omega) = 0.$$

Dessa forma, X equivale à função indicadora I_A. O único parâmetro p da distribuição é a probabilidade do evento A, implicando que $X = 1$ com probabilidade p e $X = 0$ com probabilidade $1 - p$.

Definição 3.2. *A variável X tem distribuição de Bernoulli com parâmetro $p \in [0, 1]$, denotada por*

$$X \sim \text{Bernoulli}(p),$$

se sua função de massa for

$$p_X(x) = p^x(1 - p)^{1-x}$$

Repetições de um experimento aleatório que resultam em *sucesso* ou *fracasso* são chamados de ensaios Bernoulli. A variável que indica se o experimento resultou num sucesso tem distribuição Bernoulli com parâmetro p, que é chamado de **taxa de sucesso** do experimento.

Exemplo 3.3. Sortear cara com uma moeda honesta é um ensaio Bernoulli com taxa de sucesso 1/2.

Proposição 3.1. *Se $X \sim \text{Bernoulli}(p)$, então*

$$\text{E}[X] = p \quad e \quad \text{Var}(X) = p(1 - p)$$

Demonstração. Com efeito,

$$\text{E}[X] = 1 \cdot p + 0 \cdot (1 - p) = p$$

Ademais, pela Proposição 2.11

$$\text{Var}(X) = p - p^2 = p(1 - p)$$

■

3.1.3 Distribuição Binomial

Essa distribuição é usada para modelar contagens de sucessos dentro de uma quantidade fixa de ensaios Bernoulli independentes, isto é, o sucesso ou fracasso de ensaio não interfere na probabilidade do resultado do próximo ensaio. Se $\{X_i\}_{i=1}^n$ é uma amostra independente com $X_i \sim \text{Bernoulli}(p)$, então a variável definida por

$$X = \sum_{i=1}^{n} X_i$$

quantificará quantos *sucessos* há nessa amostra. A probabilidade de obter $X = k$ é a probabilidade de obter k sucessos após n ensaios Bernoulli. Para qualquer sequência de ensaios $(X_i = x)_{i=1}^n$, com $x \in \{0, 1\}$, a probabilidade de haver k sucessos será

$$p^k(1-p)^{n-k}.$$

Ademais, o número de sequência em que ocorrem exatamente k sucessos é

$$\binom{n}{k},$$

e como todas elas possuem a mesma probabilidade $p^k(1-p)^{n-k}$ de ocorrer, então

$$P(X = k) = \binom{n}{k} p^k(1-p)^{n-k}$$

Definição 3.3. *A variável X terá distribuição Binomial com parâmetros n e p, denotado por $X \sim \text{Binomial}(n, p)$, se sua função de massa for*

$$p_X(k) = \binom{n}{k} p^k(1-p)^{n-k}$$

Exemplo 3.4. Uma moeda honesta é lançada 10 vezes. A probabilidade do número de caras ser 4 será

$$P(X = 4) = \binom{10}{4} 0.5^4 \cdot 0.5^6 \approx 0.21$$

Proposição 3.2. *Se $X \sim \text{Binomial}(n, p)$, então*

$$\text{E}[X] = np \quad e \quad \text{Var}(X) = np(1-p)$$

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^{n} k \cdot \binom{n}{k} p^k(1-p)^{n-k}.$$

Utilizando o fato de que

$$\binom{n}{k} = \frac{n}{k}\binom{n-1}{k-1},$$

reduzimos então a

$$E[X] = n\sum_{k=0}^{n} \binom{n-1}{k-1} p^k(1-p)^{n-k},$$

o que nos sugere realizar uma troca de variável em k para que consigamos usar o Teorema Binomial. Para tanto, realizemos que

$$n\sum_{k=0}^{n}\binom{n-1}{k-1}p^k(1-p)^{n-k} = np\sum_{k=1}^{n}\binom{n-1}{k-1}p^{k-1}(1-p)^{n-k}$$

já que somar o termo $k=0$ equivale a somar 0. Fazendo então a troca $j=k-1$, obtemos

$$E[X] = np\sum_{j=0}^{n}\binom{n-1}{j}p^j(1-p)^{(n-1)-j},$$

e pelo Teorema Binomial,

$$E[X] = np\cdot(p+1-p)^{n-1} = np$$

■

3.1.4 Distribuição Hipergeométrica

As variáveis hipergeométricas modelam a contagem de sucessos numa amostra retirada de uma população finita. A cada extração da população, o elemento extraído não é reposto, de modo que a probabilidade de se obter um novo sucesso é modificada a cada tentativa.

Considere uma população de tamanho N da qual m elementos são sucessos e $N-m$ são fracassos, e que uma amostra de tamanho n é extraída dessa população. Considere um conjunto $\{X_i\}_{i=1}^{n}$ de variáveis indicadora tais que

$$X_i = \begin{cases} 1, & \text{se a i-ésima tentativa é um sucesso} \\ 0, & \text{caso contrário} \end{cases}$$

e definamos

$$X = \sum_{i=1}^{n} X_i,$$

como o número de sucessos dentro da amostra.

Para deduzir a probabilidade de se observar $X=k$, tratemos o problema de forma combinatória. O número de amostras com k sucessos e $n-k$ fracassos é

$$\binom{m}{k}\cdot\binom{N-m}{n-k},$$

enquanto que o número total de amostras de tamanho n que podem ser obtidas dessa população é

$$\binom{N}{n}$$

Uma vez que toda amostra, sem observar o número de sucessos ou fracassos, possui a mesma probabilidade de ser sorteada, então:

$$P(X=k) = \frac{\binom{m}{k}\cdot\binom{N-m}{n-k}}{\binom{N}{n}}$$

Definição 3.4. *A variável X tem distribuição hipergeométrica com parâmetros N, m e n – $X \sim \mathrm{HG}(N, m, n)$ – se*

$$P(X = k) = \frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

com $\max\{0, n - (N - m)\} \leq k \leq \min\{n, m\}$.

Exemplo 3.5. Uma urna contém 5 bolas vermelhas e 7 verdes. Teremos então que, por exemplo, a probabilidade de que, ao selecionar 3 bolas da urna, 2 delas sejam vermelhas será

$$\frac{\binom{5}{2} \cdot \binom{7}{1}}{\binom{12}{3}} = \frac{70}{220} \approx 0.318$$

Exemplo 3.6. Considere numa fábrica são produzidos lotes com 100 peças cada. Suponha que num lote hajam 10 peças defeituosas. Ao selecionar 5 peças desse lote, a probabilidade de que ao menos uma seja defeituosa é

$$1 - P(X = 0) = 1 - \frac{\binom{90}{5} \cdot \binom{10}{0}}{\binom{100}{5}} \approx 0.416$$

Observação 3.1. Se $X \sim \mathrm{HG}(N, m, n)$ com $n = 1$, então $X \sim \mathrm{Bernoulli}(p)$ com $p = \frac{m}{N}$.

Observação 3.2. Para amostras de tamanho n retiradas de populações de tamanho N muito grandes – $N \gg n$ – é razoável aproximar a hipergeométrica por uma binomial. Suponha que o número de sucessos nessa população seja m, e definamos $p = m/N$. Na k-ésima extração, com $k \leq n$, a probabilidade p_k de se extrair um sucesso, considerando-se que se obteve u sucessos até então, é

$$p_k = \frac{Np - u}{N - k}$$

Já que $u \leq k \leq n \ll N$, então $u \ll N$ e $k \ll N$, tal que

$$p_k \approx \frac{Np - u}{N} = p - \frac{u}{N} \approx p.$$

Logo, em toda extração, temos, aproximadamente, a mesma probabilidade de se extrair um sucesso. Em outras palavras, ao extrair uma amostra de uma população muito grande, a extração sem reposição equivale, praticamente, a uma extração com reposição. Observemos também que, nesse caso

$$\mathrm{E}[X] = n\frac{Np}{N} = np \quad \text{e} \quad \mathrm{Var}(X) = np(1-p) \cdot \frac{N-n}{N-1} \approx np(1-p)$$

que são, aproximadamente, a mesma esperança e variância da variável binomial de parâmetros n e p.

3.1.5 Distribuição Geométrica

Considere o experimento aleatório que consiste na realização de ensaios Bernoulli até obter o primeiro sucesso. Desse modo, obtém-se uma amostra $(X_i = x)_{i=1}^n$ com $X_i = 0$ para $i < n$ e $X_n = 1$. Presuma que X seja a variável que represente o número de tentativas até resultar em um sucesso. Logo, se a taxa de sucesso é p, então a probabilidade de $X = n$ é

$$(1-p)^{n-1}p$$

Definição 3.5. *A variável X tem distribuição geométrica com parâmetro p se*

$$P(X = n) = (1-p)^{n-1}p$$

Observação 3.3. Uma formulação alternativa para a variável geométrica seria aquela onde a variável é o número de fracassos até o primeiro sucesso, e não o número total. Dessa forma, se X é o número de tentativas até o primeiro sucesso, então o número de fracassos é $Y = X - 1$, e a função de massa seria dada por

$$P(Y = y) = (1-p)^y p$$

Exemplo 3.7. Considere o experimento de lançar dois dados até que a soma das faces seja 4. A probabilidade de se obter esse resultado em um lançamento é 1/12. Logo, a probabilidade de que o número de vezes que os dados sejam lançados até que a soma das faces resulte no valor desejado seja 5 é

$$\left(1 - \frac{1}{12}\right)^4 \cdot \frac{1}{12} \approx 0.06$$

Proposição 3.3. *Se $X \sim \text{Geo}(p)$, então*

$$E[X] = \frac{1}{p}$$

Demonstração. Com efeito,

$$E[X] = \sum_{k=1}^{\infty} k(1-p)^{k-1}p = p\sum_{k=1}^{\infty} k(1-p)^{k-1}.$$

O somatório à esquerda é a derivada de uma série geométrica de razão $q = 1 - p$, tal que $q < 1$. Observemos que

$$\frac{d}{dq}\left(\sum_{k=0}^{\infty} q^k\right) = \frac{d}{dq}\left(\frac{1}{1-q}\right)$$

$$\sum_{k=1}^{\infty} k(1-p)^{k-1} = \frac{1}{(1-q)^2}$$

donde conclui-se

$$E[X] = \frac{p}{(1-1+p)^2} = \frac{1}{p}$$

■

Exemplo 3.8. No exemplo 3.7, o número esperado de lançamentos até que se obtenha a soma dos dados igual a 4 é 12.

Observação 3.4. A variável geométrica é dotada da propriedade "sem memória". Matematicamente, se $X \sim \text{Geo}(p)$, então temos que $P(X > s)$ dado que $X > t$ é igual a $P(X > s - t)$, com $s > t$. Isso significa que, se observamos t fracassos desde o início do experimento, então a probabilidade de observarmos mais $s - t$ fracassos é a mesma de ter recomeçar a contagem (daí a perda de memória) e obter $s - t$ fracassos. A fim de verificar, sabemos que

$$P(X > s \mid X > t) = \frac{P(X > s \text{ e } X > t)}{P(X > t)} = \frac{P(X > s)}{P(X > t)},$$

e como $P(X > k) = (1 - p)^k$, já que as k primeiras tentativas foram fracassos, então

$$P(X > s \mid X > t) = (1 - p)^{s-t} = P(X > s - t).$$

A verdade é que a variável geométrica é a única dentre as discretas com tal propriedade. Além disso, implica-se que, em experimentos nos quais conta-se o número de tentativas até o primeiro sucessos, e a probabilidade de um sucesso depende do tempo decorrido até então, a variável geométrica não pode ser aplicada.

3.1.6 Distribuição Binomial Negativa

A variável binomial negativa conta quantas ensaios Bernoulli independentes são realizados até que se acumulem um número desejado de sucessos. Suponha que os ensaios são repetidos até que se observe r sucessos, e que a taxa de sucesso é igual a p. Como o último ensaio deve ser obrigatoriamente um sucesso, então há

$$\binom{n-1}{r-1}$$

maneiras de ter se observado r sucessos ao longo de n ensaios, e cada uma delas ocorre com probabilidade

$$(1 - p)^{n-r} p^r.$$

Portanto, a probabilidade de que o número de ensaios realizados tenha sido igual a n é

$$\binom{n-1}{r-1}(1 - p)^{n-r} p^r$$

Definição 3.6. *A variável discreta X terá distribuição binomial negativa com parâmetros r e p se*

$$P(X = n) = \binom{n-1}{r-1}(1 - p)^{n-r} p^r$$

Observação 3.5. Assim como a geométrica, a variável binomial negativa tem uma formulação alternativa enquanto a contagem do número de fracassos até o r-ésimo sucesso. Se X é o número de ensaios realizados até se acumularem r sucessos, então o número de fracassos observados é $Y = X - r$, cuja função de massa é dada por

$$P(Y = y) = \binom{y + r - 1}{y} p^r (1 - p)^y.$$

Essa formulação possui algumas vantagens algébricas, como a maior facilidade de tratamento algébrico e seu suporte ser o próprio conjunto dos inteiros não negativos.

Proposição 3.4. *Se* $X \sim \text{BinNeg}(r, p)$, *então*

$$E[X] = \frac{r}{p} \quad e \quad \text{Var}(X) = \frac{r}{p^2}(1-p)$$

Demonstração. Suponha que $\{X_i = x\}_{i=1}^{r}$ seja uma amostra de variáveis tais que X_i denote o número de tentativas Bernoulli independentes após o último sucesso até se obter um novo. Com efeito, para todo $i \in [n]$, $X_i \sim \text{Geo}(p)$ e

$$X = \sum_{i=1}^{r} X_i$$

téra distribuição binomial negativa com parâmetros r e p. Pela linearidade da esperança e pela esperança de uma geométrica de parâmetro p, conclui-se que

$$E[X] = \sum_{i=1}^{r} E[X_i] = \sum_{i=1}^{r} \frac{1}{p} = \frac{r}{p}$$

■

Observação 3.6. Se usássemos a formulação da variável Y enquanto contagem de fracassos, então

$$\text{E}[X] = \text{E}[Y + r] = \text{E}[Y] + r$$

mas como $\text{E}[X] = r/p$,

$$\text{E}[Y] = \frac{r}{p} - r = \frac{r}{p}(1-p).$$

Além disso, pode-se reformular a distribuição em termos da sua própria média, ou seja, definindo uma variável binomial negativa cujo parâmetro é $\mu = r(1-p)/p$, de modo que

$$\text{Var}(Y) = \mu + \frac{1}{r}\mu^2.$$

Logo, a medida que a média cresce, a dispersão aumenta em ritmo quadrático em função dela, condição essa conhecida como **superdispersão**, a qual possui aplicações estatísticas na análise de dados.

3.1.7 Distribuição Poisson

A distrbuição de Poisson modela contagem de eventos que ocorrem dentro de um intervalo contínuo – como o tempo, uma superfície ou volume – com probabilidade praticamente desprezível. Uma de suas premissas consiste em, para intervalos pequenos, a probabilidade de ocorrência de um evento é proporcional ao tamanho do intervalo. Essa distribuição pode ser compreendida como a uma aproximação da Binomial quando $n \to \infty$.

Considere que $X \sim \text{Binomial}(n, p)$, logo

$$p_X(a) = \binom{n}{a}(1-p)^{n-a}p^a$$

Suponha que np seja igual a uma constante λ. Se tomarmos o limite da função de massa de X quando $n \to \infty$, obteremos

$$\begin{aligned}\lim_{n\to\infty} p_X(a) &= \lim_{n\to\infty} \binom{n}{a} \left(\frac{\lambda}{n}\right)^a \left(1-\frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n\to\infty} \frac{n(n-1)\dots(n-a+1)}{a!} \left(\frac{\lambda}{n}\right)^a \left(1-\frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n\to\infty} \prod_{k=1}^{a-1} \left(1-\frac{k}{n}\right) \cdot \lim_{n\to\infty} \frac{\lambda^a}{a!} \frac{(1-\lambda/n)^n}{(1-\lambda/n)^a}\end{aligned}$$

Como

$$\lim_{n\to\infty} \prod_{k=1}^{a-1} \left(1-\frac{k}{n}\right) = 1 \quad \text{e} \quad \lim_{n\to\infty} (1-\lambda/n)^a = 1$$

então,

$$\lim_{n\to\infty} p_X(a) = \lim_{n\to\infty} \frac{\lambda^a}{a!} \left(1-\frac{\lambda}{n}\right)^n$$

Usando o limite exponencial fundamental

$$\lim_{n\to\infty} \left(1-\frac{\lambda}{n}\right)^n = e^{-\lambda}$$

obtemos, por fim,

$$\lim_{n\to\infty} p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Definição 3.7. *A variável X tem distribuição de Poisson com parâmetro λ se*

$$P(X = a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

É possível mostrar, formalmente, que a distribuição de Poisson é a distribuição limite da binomial. Para tanto, utilizamos o Teorema 2.14, de formar a demonstrar que, quando $n \to \infty$, a mgf da variável binomial converge para a mgf da variável de Poisson.

Proposição 3.5. *Se $X_n \sim$ Binomial(n, p_n), com $p_n = \lambda/n$ para todo $n \in \mathbb{N}$, e $X \sim$ Poisson(λ), então*

$$\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$$

Demonstração. A função geradora de momentos da binomial X_n é dada por

$$M_{X_n}(t) = \sum_{x=0} e^{tx} \binom{n}{x} p_n^x (1-p_n)^{n-x} = \sum_{x=0} \binom{n}{x} (p_n e^t)^x (1-p_n)^{n-x},$$

e, pelo Teorema Binomial,

$$M_{X_n}(t) = (p_n e^t + 1 - p_n)^n = [1 + p_n(e^t - 1)]^n.$$

Avaliando $M_{X_n}(t)$ quando $n \to \infty$,

$$\lim_{n\to\infty} M_{X_n}(t) = \left[1 + \frac{\lambda}{n}(e^t - 1)\right]^n = e^{\lambda(e^t-1)}.$$

Resta agora verificar a mgf da variável de Poisson de parâmetro λ. Com efeito, se $X \sim \text{Poisson}(\lambda)$,

$$M_X(t) = \sum_{x=0}^{\infty} e^{tx} e^{-\lambda} \frac{\lambda^x}{x!} = \sum_{x=0}^{\infty} e^{-\lambda} \frac{(e^t\lambda)^x}{x!}.$$

Utilizando o polinômio de Taylor para a função exponencial,

$$M_X(t) = e^{-\lambda} e^{e^t\lambda} = e^{\lambda(e^t-1)}.$$

Já que $\lim_{n\to\infty} M_{X_n}(t) = M_X(t)$, então pelo Teorema 2.14,

$$\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$$

■

Mostramos, a seguir, que o parâmetro da distribuição de Poisson é a sua própria média e variância. Pela interpretação dessa distribuição como uma aproximação da Binomial, λ denota o número esperado de sucessos dentro de um número praticamente infinito de tentativas.

Proposição 3.6. *Se* $X \sim \text{Poisson}(\lambda)$, *então*

$$E[X] = \text{Var}(X) = \lambda$$

Demonstração. Com efeito,

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \end{aligned}$$

O somatório equivale ao Polinômio de Taylor de e^λ, portanto

$$E[X] = \lambda e^{-\lambda} e^{\lambda} = \lambda.$$

Para variância, temos que

$$\text{E}\big[X^2\big] = e^{-\lambda} \sum_{x=0}^{\infty} x^2 \frac{\lambda^x}{x!} = \lambda e^{-\lambda} \sum_{x=1}^{\infty} x \frac{\lambda^{x-1}}{(x-1)!}$$

Fazendo a substituição $k = x - 1$, obtemos

$$\text{E}\big[X^2\big] = \lambda e^{-\lambda} \sum_{k=0}^{\infty} (k+1) \frac{\lambda^k}{k!} = \lambda e^{-\lambda} \left(\sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} + \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \right).$$

No primeiro somatório, $\sum_{k=1}^{\infty} k \frac{\lambda^k}{k!} = \lambda \sum_{u=0}^{\infty} \frac{\lambda^u}{u!} = \lambda e^\lambda$, com $u = k - 1$; o segundo é e^λ. Temos, por fim,

$$\text{E}\big[X^2\big] = \lambda e^{-\lambda}(\lambda e^\lambda + e^\lambda) = \lambda^2 + \lambda$$

Uma vez que $\text{E}[X]^2 = \lambda^2$, então

$$\text{Var}(X) = \lambda^2 + \lambda - \lambda^2 = \lambda$$

■

3.1.8 Distribuição Zeta

A distribuição Zeta modela eventos cuja frequência é inversamente proporcional à sua posição num ranking, como frequência de palavras, população de cidades, citações de artigos científicos, entre outros. A ideia é que há poucos elementos muito frequentes, enquanto há muitos outros poucos frequentes.

Suponha que X seja a variável que indique o ranking de um evento conforme a sua posição nele tal que

$$P(X = k) \propto \frac{1}{k^s}$$

onde s indica o grau de diminuição da frequência em relação ao dacaimento no ranking. Logo, há uma constante C tal que

$$P(X = k) = \frac{C}{k^s}.$$

Temos que

$$\sum_{k=1}^{\infty} \frac{C}{k^s} = 1,$$

o que implica

$$\sum_{k=1}^{\infty} \frac{1}{k^s} = \frac{1}{C}.$$

O membro esquerdo da expressão é conhecida como a função Zeta de Riemann $\zeta(s)$. Logo

$$P(X = k) = \frac{k^{-s}}{\zeta(s)}$$

Definição 3.8. *A variável discreta X tem distribuição Zeta com parâmetro $s \in (1, \infty)$ se sua função de massa for*

$$P(X = k) = \frac{k^{-s}}{\zeta(s)},$$

onde ζ é a função Zeta de Riemann.

3.2 Distribuição Normal

Definição 3.9. *A variável contínua X tem distribuição normal com parâmetros μ e σ^2 se sua densidade for*

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}.$$

Uma variável normal será padrão caso $\mu = 0$ e $\sigma^2 = 1$.

A função de distribuição da variável normal é um caso de integral que não pode ser expressa em termos de funções elementares. No entanto, isso não a torna menos rica analiticamente. O lema a seguir mostra que, embora não possamos integrar a função de densidade para obter a função de distribuição, somos de encontrar algumas propriedades analíticas de partes da função de densidade que nos serão úteis futuramente.

Lema 3.1. *A integral definida de* $f(x) = e^{\frac{-x^2}{2}}$ *avaliada em* $(-\infty, \infty)$ *é* $\sqrt{2\pi}$.

$$\int_{-\infty}^{\infty} e^{\frac{-x^2}{2}} = \sqrt{2\pi}$$

Demonstração. Equivalentemente, podemos provar que

$$\left(\int_{-\infty}^{\infty} e^{\frac{-u^2}{2}}\, du\right)\left(\int_{-\infty}^{\infty} e^{\frac{-t^2}{2}}\, dt\right) = 2\pi.$$

Espressando o problema como uma integral dupla, tal que

$$\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} e^{\frac{-(t^2+u^2)}{2}}\, dt\, du,$$

e colocando em termos de coordenadas polares, isto é,

$$r^2 = u^2 + t^2, \quad t = r\cos\theta, \quad u = r\sin\theta,$$

obtemos

$$\int_0^{2\pi}\int_0^{\infty} re^{\frac{-r^2}{2}}\, dr\, d\theta = 2\pi\int_0^{\infty} re^{\frac{-r^2}{2}}\, dr,$$

essa que pode ser resolvida via substituição, resultando em

$$-2\pi\, e^{\frac{-r^2}{2}}\Big|_0^{\infty} = 2\pi.$$

■

Uma aplicação direta do Lema 3.1 é mostrar que a função de densidade da normal é de fato válida.

Proposição 3.7. *A função*

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

é uma função de densidade.

Demonstração. Para tanto, devemos mostrar que

$$\frac{1}{\sqrt{2\pi\sigma^2}}\int_{-\infty}^{\infty} e^{\frac{-(x-\mu)^2}{2\sigma^2}}\, dx = 1$$

Realizemos a substituição

$$z = \frac{x-\mu}{\sigma},$$

de modo que

$$\frac{1}{\sqrt{2\pi\sigma^2}}\int_{-\infty}^{\infty} e^{\frac{-(x-\mu)^2}{2\sigma^2}}\, dx = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{\frac{-z^2}{2}}\, dz = 1.$$

Resta concluir que

$$\int_{-\infty}^{\infty} e^{\frac{-z^2}{2}}\, dz = \sqrt{2\pi},$$

o que é garantido pelo Lema 3.1. ■

Quanto às transformações, toda transformação afim – um escalonamento seguido de um deslocamento – de uma variável normal resulta numa nova variável normal com parâmetros previstos.

Teorema 3.1. *Se $X \sim \text{Normal}(\mu, \sigma^2)$ e $a \neq 0$ e b são constantes, então a variável $aX + b$ é normalmente distribuída com parâmetros $a\mu + b$ e $a^2\sigma^2$.*

Demonstração. Seja $Y = g(X)$ com $g(x) = ax+b$. Como $a \neq 0$, a função g é monótona – crescente se $a > 0$ e decrescente se $a < 0$ – e bijetora de $\mathbb{R}$ em $\mathbb{R}$, com inversa

$$g^{-1}(y) = \frac{y-b}{a} \quad \text{e} \quad \frac{d}{dy}g^{-1}(y) = \frac{1}{a},$$

que tem derivada contínua em $\Omega_Y = \mathbb{R}$. Além disso, a densidade f_X da normal é contínua em $\Omega_X = \mathbb{R}$. Pelo Teorema 2.7, para todo $y \in \mathbb{R}$,

$$f_Y(y) = f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{|a|} = \frac{1}{|a|\sqrt{2\pi\sigma^2}} e^{\frac{-\left(\frac{y-b}{a}-\mu\right)^2}{2\sigma^2}}.$$

Uma vez que $|a| = \sqrt{a^2}$ e

$$\left(\frac{y-b}{a} - \mu\right)^2 = \frac{(y - a\mu - b)^2}{a^2},$$

obtemos

$$f_Y(y) = \frac{1}{\sqrt{2\pi a^2\sigma^2}} e^{\frac{-(y-(a\mu+b))^2}{2a^2\sigma^2}},$$

que é a densidade de uma variável normal com parâmetros $a\mu + b$ e $a^2\sigma^2$. Portanto, $Y \sim \text{Normal}(a\mu + b, a^2\sigma^2)$. ■

Corolário 3.1. *Se $X \sim \text{Normal}(\mu, \sigma^2)$ e $Z = \frac{X-\mu}{\sigma}$, então $Z \sim \text{Normal}(0, 1)$.*

Demonstração. Se μ_z e σ_z^2 são os parâmetros da distribuição de Z, então

$$\mu_z = \frac{1}{\sigma} \cdot \mu - \frac{\mu}{\sigma} = 0 \quad \text{e} \quad \sigma_z^2 = \left(\frac{1}{\sigma}\right)^2 \cdot \sigma^2 = 1$$

e ■

Teorema 3.2. *Se $X \sim \text{Normal}(\mu, \sigma^2)$, então*

$$\text{E}[X] = \mu \quad e \quad \text{Var}(X) = \sigma^2$$

Demonstração. Se $Z \sim \text{Normal}(0, 1)$, então

$$\text{E}[Z] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z e^{\frac{-z^2}{2}}.$$

Resolvendo por substituição $u = \frac{-z^2}{2}$, obtemos

$$\text{E}[Z] = \frac{1}{\sqrt{2\pi}} \, e^{\frac{-z^2}{2}} \Big|_{-\infty}^{\infty} = 0.$$

Por outro lado,

$$\mathrm{Var}(Z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z^2 e^{\frac{-z^2}{2}},$$

a qual pode ser resolvida usando-se integração por partes com $u = z$ e $dv = -ze^{\frac{-z^2}{2}} dz$, obtendo $v = e^{\frac{-z^2}{2}} dz$ e

$$\mathrm{Var}(Z) = -\frac{1}{\sqrt{2\pi}} \left(z^2 e^{\frac{-z^2}{2}} \Big|_{-\infty}^{\infty} - \int_{-\infty}^{\infty} e^{\frac{-z^2}{2}}\, dz \right).$$

Utilizando o Lema 3.1, encontramos que

$$\mathrm{Var}(Z) = \frac{1}{\sqrt{2\pi}} \cdot \sqrt{2\pi} = 1.$$

Então conclui-se que o Teorema vale para uma variável normal padrão. Se $X \sim \mathrm{Normal}(\mu, \sigma^2)$ e $Z = \frac{X-\mu}{\sigma}$, então, pelo Corolário 3.1, Z é normal padrão. Pelos Teoremas 2.10 e 2.11, temos que

$$\mathrm{E}[X] = \mathrm{E}[\sigma Z + \mu] = \sigma \mathrm{E}[Z] + \mu \quad \text{e} \quad \mathrm{Var}(X) = \mathrm{Var}(\sigma Z + \mu) = \sigma^2 \mathrm{Var}(Z)\,.$$

Mas como $\mathrm{E}[Z] = 0$ e $\mathrm{Var}(Z) = 1$, então

$$\mathrm{E}[X] = \mu \quad \text{e} \quad \mathrm{Var}(X) = \sigma^2$$

■

Portanto, temos que uma variável normal é caracterizada pelo seu valor esperado e por sua variância. Em conjunto com o Corolário 3.1, mostra-se que ao tomar uma variável normal, subtrair a sua média e depois a dividir pelo desvio-padrão resulta numa variável normal padrão. A utilidade desse fato é semelhante à da transformação de variáveis uniformes contínuas, vista adiante na Proposição 3.10: podemos tabelar os valores de uma única distribuição normal e usá-los para computar probabilidades relacionadas a qualquer outra distribuição normal. Esse fato é ainda mais valioso, já que a distribuição de probabilidade de variáveis normais não possui fórmula fechada como da uniforme contínua. A proposição e o Teorema a seguir nos dizem a respeito da simetria da distribuição normal.

Proposição 3.8. *A função de densidade $f(x)$ de uma variável normal padrão é uma função par, isto é,*

$$f(-x) = f(x)$$

Demonstração. Seja $X \sim \mathrm{Normal}(0, 1)$. Uma vez que

$$|-x| = |x| \implies (-x)^2 = x^2,$$

então

$$f(-x) = \frac{1}{\sqrt{2\pi}} e^{\frac{-(-x)^2}{2}} = \frac{1}{\sqrt{2\pi}} e^{\frac{-x^2}{2}} = f(x).$$

■

Teorema 3.3. *Se $F(x)$ for a função de distribuição de uma variável normal padrão, então*

$$F(-x) = 1 - F(x)$$

Demonstração. Com efeito,

$$F(-x) = \int_{-\infty}^{-x} f(u)\,du.$$

onde f é a função de densidade da normal padrão. Realizando a substituição $u = -t$, então $du = -dt$. Além disso, temos que $u \to -\infty$ implica em $t \to \infty$, enquanto que $u = -x$ nos dá $t = x$. Obtemos, por consequência,

$$F(-x) = -\int_{\infty}^{x} f(-t)\,du.$$

Pelas propriedades de integrais,

$$F(-x) = \int_{x}^{\infty} f(-t)\,du,$$

e como f é par pela Proposição 3.8, então

$$F(-x) = \int_{x}^{\infty} f(t)\,du.$$

No entanto,

$$\int_{-\infty}^{x} f(t)\,dt + \int_{x}^{\infty} = 1$$
$$\int_{x}^{\infty} f(t)\,dt = 1 - \int_{-\infty}^{x} f(t)\,dt$$
$$\int_{x}^{\infty} f(t)\,dt = 1 - F(x)$$

mostrando, enfim, que

$$F(-x) = 1 - F(x)$$

■

Com isso, temos mais uma facilidade em calcular probabilidades para variáveis normais. Não precissamos, necessarimanete, tabelar as densidades de probabilidade para valores negativos da variável, basta usar a relação de simetria usando os valores positivos.

O próximo Teorema enuncia o que De Moivre descobrira e que depois foi generalizado por Laplace: para uma amostra suficientemente grande, a contagem de sucessos tem distribuição aproximadamente normal. Isso caracteriza a aproximação da variável binomial pela variável normal.

Teorema 3.4 (de De Moivre-Laplace)**.** *Se $X \sim \text{Binomial}(n, p)$, então para quaisquer reais a e b com $a < b$ é satisfetio que*

$$\lim_{n\to\infty} P\left(a \leq \frac{X - np}{\sqrt{np(1-p)}} \leq b\right) = \Phi(b) - \Phi(a)$$

A verdade é que resultado é ainda mais geral, não se restringindo somente às distribuições binomiais. A verdade é que para qualquer distribuição, se tomamos uma amostra suficientemente grande dela e somar os seus valores, a soma deles tem distribuição aproximadamente normal. Esse o Teorema Central do Limite e a razão da importância e destaque da distribuição normal na Estatística.

3.3 Outros Modelos Contínuos

3.3.1 Uniforme Contínua

Analogamente à distribuição uniforme discreta, na distribuição uniforme contínua, todos os valores no suporte possuem a mesma densidade de probabilidade. Os parâmetros dessa distribuição definem o suporte dessa variável, e a densidade de probabilidade sobre cada valor possível é o inverso do comprimento do intervalo.

Definição 3.10. *Uma variável X tem distribição uniforme contínua com parâmetros a e b caso a sua função de densidade seja dada por*

$$f(x) = \begin{cases} \frac{1}{b-a}, & \text{se } a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases}$$

Proposição 3.9. *Se $X \sim \text{Unif}(a, b)$, então*

1. *sua função de distribuição é dado por*

$$F(x) = \begin{cases} 0, & \text{se } x < a \\ \frac{x-a}{b-a}, & \text{se } a \leq x \leq b \\ 1, & \text{se } x > b \end{cases}$$

2. $\text{E}[X] = \frac{b+a}{2}$
3. $\text{Var}(X) = \frac{(b-a)^2}{12}$

Observação 3.7. A função de distribuição da variável uniforme contínua cresce linearmente a partir de $(a, 0)$ até $(b, 1)$. Portanto, a probabilidade de um determinado intervalo $(\alpha, \beta) \subset (a, b)$ é proporcional ao tamanho do próprio intervalo:

$$F(\alpha \leq X \leq \beta) = F(\beta) - F(\alpha) = \frac{\beta - \alpha}{b - a} \propto (\beta - \alpha)$$

A próxima proposição mostra que uma determinada transformação aplicada numa variável uniforme sempre resulta na mesma variável uniforme, independente dos parâmetros da distribuição original.

Proposição 3.10. *Se $X \sim \mathscr{U}(a, b)$ e*

$$U = \frac{X - \frac{a+b}{2}}{b - a}$$

então $U \sim \mathscr{U}(-1/2, 1/2)$.

Demonstração. Se $u = g(x)$ é a transformação dada por

$$\frac{x - \frac{a+b}{2}}{b-a},$$

então ela é uma transformação monótona crescente. Pelo Teorema 2.6,

$$F_U(u) = F_X(g^{-1}(u))$$

onde $F_U(u)$ e $F_X(x)$ são as funções de distribuição de U e X respectivamente. Se $a \leq x \leq b$, então

$$F_U(u) = \frac{1}{b-a}[u(b-a) + (b+a)/2] - \frac{a}{b-a},$$

e, após algumas manipulações algébricas, chegamos a

$$F_U(u) = \frac{(b-a)u + \frac{b-a}{2}}{b-a} = u + \frac{1}{2}.$$

Para determinar os parâmetros α e β da distribuição de U, percebamos que

$$\begin{cases} \beta - \alpha = 1 \\ -\alpha = 1/2 \end{cases}$$

cuja solução é $\alpha = -1/2$ e $\beta = 1/2$, logo $U \sim \mathscr{U}(-1/2, 1/2)$. ■

Essa Proposição é útil para que programas de computador, por exemplo, possam tabelar valores para uma única distribuição uniforme e, com isso, sejam capazes de determinar valores de probabilidade para qualquer outra distribuição uniforme de forma eficiente.

3.3.2 Exponencial

A variável exponencial é rotineiramente aplicada para modelar tempos de espera entre eventos os quais ocorrem a uma taxa fixa, como chamadas telefônicas a um *call center* ou de requisições a um servidor de dados. Sua função de densidade inclui um parâmetro λ, que denota a taxa de ocorrência de eventos, de sorte que o seu inverso denota o tempo médio entre dois eventos.

Definição 3.11. *A variável X tem distribuição exponencial com parâmetro $\lambda > 0$ se sua função de densidade for dada por*

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{se } x \geq 0 \\ 0, & \text{caso contrário.} \end{cases}$$

Proposição 3.11. *Se $X \sim \text{Exp}(\lambda)$, então*

1. *Sua função de distribuição é dada por*

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & \text{se } x \geq 0 \\ 0, & \text{caso contrário.} \end{cases}$$

2. $\mathrm{E}[X] = \frac{1}{\lambda}$

3. $\mathrm{Var}(X) = \frac{1}{\lambda^2}$

Observação 3.8. A variável eponencial é a contraparte contínua da variável geométrica quanto a propriedade de sem memória. Basta observar que

$$P(X \geq s \mid X \geq t) = \frac{P(X \geq s)}{P(X \geq t)} = \frac{1 - P(X \leq s)}{1 - P(X \leq t)} = \frac{e^{-\lambda s}}{e^{-\lambda t}} = P(X \geq s - t).$$

É verdade também que a variável exponencial é a única dentre as contínuas com tal propriedade

3.3.3 Distribuição Gama

A variável com distribuição Γ é uma generalização da distribuição exponencial. A integral

$$\int_0^\infty t^{\alpha-1} e^{-t}\, dt$$

denota a função $\Gamma(\alpha)$, a qual é finita quando $\alpha > 0$. Essa função satisfaz algumas relações importantes; em particular

$$\Gamma(\alpha + 1) = \alpha\Gamma(\alpha),\ \alpha > 0.$$

Uma vez que $\Gamma(1) = 1$, então, pela relação anterior, vale que $\Gamma(n) = (n-1)!$ para todo n inteiro positivo.

Como o integrando na definição da função Γ é positivo, então segue de imadiato que

$$f(t) = \frac{t^{\alpha-1} e^{-t}}{\Gamma(\alpha)} \tag{3.1}$$

é uma função de densidade. No entanto, é possível generalizar a distribuição com uma parâmetro adicional β. Se T tem densidade igual àquela dada por 3.1 e $X = \beta T$, então define-se a distribuição Γ da maneira a seguir:

Definição 3.12. *A variável X tem distribuição Γ com parâmetros positivos α e β se sua função de densidade for dada por*

$$f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$$

onde a função $\Gamma(\alpha)$ é definida como

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t}\, dt.$$

O parâmetro α é chamado de **forma** (*shape*), pois caracteriza o pico da distribuição, enquanto que o parâmetro β é denominado **escala** (*scale*), já que influencia a dispersão dela. Percebamos também que a distribuição exponencial de taxa λ é um caso particular da distribuição Γ, onde $\alpha = 1$ e $\beta = 1/\lambda$. Com efeito,

$$f(x \mid \alpha = 1, \beta = 1/\lambda) = \frac{1}{\beta} e^{-x/\beta} = \lambda e^{-\lambda x}$$

Proposição 3.12. *Se* $X \sim \Gamma(\alpha, \beta)$*, então*

$$\mathrm{E}[X] = \alpha\beta \quad e \quad \mathrm{Var}(X) = \alpha\beta^2$$

Proposição 3.13. *Se* $t < 1/\beta$*, então a função geradora de momentos da distribuição* Γ *está definida e é determinada por*

$$M_X(t) = \left(\frac{1}{1-\beta t}\right)^{\alpha}$$

Assim como a exponencial é a contraparte contínua da variável geométrica, e a variável Γ é a contraparte contínua da variável binomial negativa. Com isso, a distribuição Γ é compreendida como a soma de variáveis exponenciais, e pode ser usada para modelar contagem de eventos até um número desejado α que ocorrem com tempo médio de intervalos iguais a β.

Proposição 3.14. *Seja* $X \sim \Gamma(\alpha, \beta)$*. Para todo* $x \in \mathbb{R}$*, se* $Y \sim \mathrm{Poisson}(x/\beta)$*, então*

$$P(X \leq x) = P(Y \geq \alpha)$$

3.3.4 Distribuição χ^2

Outra especialização da distribuição Γ é a χ^2 com n graus de liberdade, onde $\alpha = n/2$ e $\beta = 2$. Ela é uma das principais distribuiçõe utilizadas em inferência estatística, sendo usada para teste de signficância estatística de parâmetros de outras distribuições e para amostragem da distribuição normal.

Definição 3.13. *A variável* X *tem distribuição* χ^2 *com* n *graus de liberdade se sua função de densidade for dada por*

$$f(x) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}, & \text{se } x \geq 0 \\ 0, & \text{caso contrário.} \end{cases}$$

Proposição 3.15. *Se* $X \sim \chi^2(n)$*, então*

$$\mathrm{E}[X] = n \quad e \quad \mathrm{Var}(X) = 2n$$

Proposição 3.16. *Seja* $(Z_i)_{i=1}^n$ *uma sequência de variáveis aleatórias com distribuição* $\mathrm{Normal}(0, 1)$*. A variável*

$$X = \sum_{i=1}^{n} Z_i^2$$

tem distribuição χ^2 *com* n *graus de liberdade.*

3.3.5 Distribuição de Cauchy

A distribuição de Cauchy, assim como a normal, é simétrica e possui um forato de sino, porém com caudas mais pesadas. Sua função é definida a seguir:

Definição 3.14. *Uma variável aleatória X tem distribuição de Cauchy com parâmetros $\theta \in \mathbb{R}$ e $\gamma > 0$ se sua função de densidade for*

$$f(x) = \frac{1}{\pi\gamma}\left[1 + \left(\frac{x-\theta}{\gamma}\right)^2\right]^{-1}$$

Uma propriedade dessa distribuição é que seus momentos não existem. Por consequência, a função geradora de momentos dessa variável não é definida.

Proposição 3.17. *Para todos $\theta \in \mathbb{R}$ e $\gamma > 0$, se $X \sim \text{Cauchy}(\theta, \gamma)$, então*

$$\text{E}[|X|^n] = \infty$$

para todo n inteiro positivo. Em particular, $\text{E}[X^n]$ não existe para nenhum n.

Apesar da inexistência de momentos, o formato da distribuição com pico θ sugere um fato interessante. Como visto, a distribuição de Cauchy não possui média, e, na verdade, θ denota a mediana da distribuição, o que é enunciado na próxima Proposição.

Proposição 3.18. *Se $X \sim \text{Cauchy}(\theta, \gamma)$, então*

$$P(X \leq \theta) = \frac{1}{2}$$

A distrbuição de Cauchy é muito utilizada para modelar razões entre duas outras variáveis. Em verdade, é possível mostrar que a razão entre duas variáveis com distribuição normal padrão tem distribuição de Cauchy.

3.3.6 Distribuição de Weibull

A variável de Weibull é um modelo de distribuição ainda mais geral que a distribuição Γ usada para modelar tempos de vida. Além dos parâmetros de forma e escala, adiciona-se mais um parâmetro de localização, inidicando o tempo mínimo antes de uma falha poder ocorrer.

Definição 3.15. *A variável X tem distribuição de Weibull com parâmetros positivos α, β e γ se sua função de densidade for dada por*

$$f(x) = \begin{cases} \frac{\beta}{\alpha}\left(\frac{x-\gamma}{\alpha}\right)^{\beta-1} e^{-\left(\frac{x-\gamma}{\alpha}\right)^{\beta}}, & \text{se } x \geq \gamma \\ 0, & \text{caso contrário.} \end{cases}$$

Uma interpretação pode ser atribuía a cada parâmetro dessa distribuição:

- Parâmetro de forma β – Se $\beta < 1$, então a taxa de falha diminui com o tempo, a exemplo da taxas de mortalidade infantil com relação a idade. Caso $\beta = 1$, então as falhas ocorrem de maneira aleatória em todo período de tempo observado, similar à distribuição exponencial. Já se $\beta > 1$, então a taxa de falha aumenta com o tempo, como peças que se desgatam com o tempo.

- Parâmetro de escala α – modela a dispersão da distribuição no eixo do tempo, e, a medida que cresce, mais probabilidade é atribuída à valores maiores. Seu argumento representa o quantil no qual cerca de 63.2% da população terá apresentado alguma falha.

- parâmetro de localização γ – indica o tempo mínimo antes que seja possível de ocorrer uma falha. Corresponde a origem da curva de densidade no eixo do tempo.

3.3.7 Distribuição Beta

A distribuição Beta possui a propriedade de concentrar toda probabilidade num único intervalo, sendo esse, nesse caso, o intervalo $(0, 1)$. Com isso, ela é comumente aplicada para modelar proporções e taxas que se encontram no intervalo citado.

Definição 3.16. *A variável X tem distribuição beta com parâmetros positivos α e β se sua densidade for dada por*

$$f(x) = \begin{cases} \frac{1}{B(\alpha,\beta)} x^{\alpha-1}(1-x)^{\beta-1}, & \text{se } 0 < x < 1 \\ 0, & \text{caso contrário.} \end{cases}$$

onde

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1}\, dx = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

Essa distribuição também possui a característica de assumir formas totalmente distintas a depender dos valores dos parâmetros. Em síntese, temos que

- $\alpha > 1$ e $\beta = 1$ – distribuição estritamente crescente.

- $\alpha = 1$ e $\beta > 1$ – distribuição estritamente decrescente.

- $\alpha < 1$ e $\beta < 1$ – formato de "U".

- $\alpha > 1$ e $\beta > 1$ – formato unimodal.

- $\alpha = \beta$ – simétrica em torno de $1/2$ e com variância $[4(2\alpha + 1)]^{-1}$.

No último caso, a distribuição torna-se cada vez mais concentrada a medida que α cresce. Por fim, quando $\alpha = \beta = 1$, a distribuição degenera-se na uniforme no intervalo $(0, 1)$.

3.3.8 Distribuição log-normal

Quando lidando com dados assimétricos à direita (cujos distribuição concentra-se à esquerda da mediana), é muito comum aplicar a transformação $\log(x)$ para corrigir essa assimetria, pois os valores na cauda à direita são "puxados" para estarem mais próximos dos menores. Quando essa transformação leva a uma distribuição normal, então dizemos que a variável original tem distribuição log-normal.

Definição 3.17. *A variável X tem distribuição log-normal com parâmetros μ e σ^2 se sua função de densidade for dada por*

$$f(x|\mu,\sigma^2) = \begin{cases} \frac{1}{\sqrt{2\pi\sigma^2}}\frac{1}{x}e^{-(\log x-\mu)^2/(2\sigma^2)}, & \text{se } x > 0 \\ 0, & \text{caso contrário.} \end{cases}$$

Proposição 3.19. *Se* $\log X \sim \text{Normal}(\mu,\sigma^2)$, *então*

$$\text{E}[X] = e^{\mu+(\sigma^2/2)} \quad e \quad \text{Var}(X) = e^{2(\mu+\sigma^2)} - e^{2\mu+\sigma^2}$$

3.3.9 Distribuição de Laplace

A distribuição de Laplace é obtida ao espelhar a distribuição exponencial em torno da sua média. Visualmente, ela possui caudas mais pesada e longas do que a normal. Além disso, a curva da distribuição no ponto $x = \mu$ é um "bico", ou seja, a densidade não é diferenciável naquele ponto.

Definição 3.18. *A variável X tem distribuição de Laplace se sua função de densidade é dada por*

$$f(x \mid \mu,\sigma) = \frac{1}{2\sigma}e^{-|x-\mu|/\sigma}$$

Uma das aplicações da distribuição de Laplace é na seleção de atributos para uma regressão linear: adotar uma priori de Laplace para os coeficientes equivale a penalizar a soma de seus valores absolutos (penalização L^1, ou LASSO), o que tende a atribuir pesos iguais a zero às características consideradas não significativas para explicar outra variável.

Capítulo 4

Variáveis Aleatórias Multidimensionais

Capítulo 5

Simulação

Parte II

Análise Exploratória

Capítulo 6

Tipos de Dados e Gráficos

Um dos primeiros passos na exploração de uma base de dados é a identificação do tipo dos dados que estamos lidando a fim de empregar as técnicas exploratórias mais adequadas a cada caso. Os dados existem nos mais variados fomatos, como métricas, categoriais, nomes, datas, etc. Contudo, por mais diversos que sejam os formatos possíveis, normalmente os classicamos de acordo com um número limitado de tipos. Após isso, selecionamos quais técnicas usaremos para representar, apresentar e visualizar os dados, visando a identificação de padrões e a geração das primeiras hipóteses que irão guiar o resto da exploração.

6.1 Tipos e Escala de Dados

A forma comum em estatística de representar dados é por meio de matrizes retangulares chamadas de **tabelas** – ou também, devido aos softwares usados para tratá-las, de **quadro de dados** (*Dataframe*). Por padrão, sendo D um quadro de dados de dimensões $n \times p$, cada coluna de D corresponde a um **atributo**, também chamado de variável ou *feature*, e cada linha corresponde a um registro, que representa um indivíduo na amostra coletada.

Cada atributo possui um domínio de valores, que, embora possam ser os mais variados possíveis, podem ser organizados numa taxonomia simples. Os tipos de atributos são divididos em dois grande grupos: **quantitativos** e **qualitativos**. O primeiro refere-se a dados com domínio num conjunto numérico, sendo subdividido em

- **Discretos** – São atributos que assumem valores no conjunto dos números inteiros $\mathbb{Z}$, sendo, usualmente, não negativos. Geralmente, representam contagens, como número de filhos e idade em anos completos.

- **Contínuos** – O domínio do atributo é um intervalo dos números reais. Na prática, pelas limitações ontológicas de representar um número real, as realizações desses atributos limitam-se a valores aproximados. A diferença fundamental para os

discretos é que o domínio dos contínuos é não enumerável. Exemplos incluem, principalmente, medidas, como preços, alturas e pesos.

Os dados qualitativos representam uma qualidade dentro de um conjunto finito de possibilidades chamadas de fatores, sendo divididos em

- **Ordinais** – os fatores possuem uma ordem natural. Exemplos são graus de uma qualidade, como classe social (baixa, média e alta) ou severidade de um exame médico.
- **Nominais** – os fatores não possuem ordem natural, chamados de categóricos, Exemplos são grupos, como sexo ou estado cívil. Um tipo especial de variáveis nominais são as **dicotômicas**, que assume dois valores somente e de caráter antagônico: sucesso ou fracasso, positivo ou negativo, sim ou não, 0 ou 1, etc.

Alternativamente às classificações apresentadas, podemos tipificar atributos através de escalas de medição de seus valores. As escalas são similares às classificações apresentadas anteriormente, sendo elas:

- Escala Nominal – para dados nessa escala, só podemos dizer que seus valores são diferentes de outros, sendo usada para categorizar indivíduos. Um exemplo simples é o sexo de uma pessoa: feminino ou masculino. Essa escala não suporta operações matemáticas, e uma medida de centralidade comum para resumir dados nessa escala é a moda.
- Escala Ordinal – nessa escala, os valores podem ser ordenados, e podemos então dizer que, além de diferentes, um valor é maior do que o outro. Essa escala tem sua estrutura preservada por operações que mantenham a ordem. Um exemplo de variável ordinal é o nível de escolaridade: fundamental, médio e superior. Medidas de tendência central comuns para dados nessa escala são a moda e a mediana.
- Escala Intervalar - essa escala possui uma origem arbitrária e necessita de uma unidade de medida, sendo um exemplo a temperatura de um ambiente. Podemos afirmar que valores são diferentes, maiores e quão o maior em relação a outro, e transformações afim não alteram a estrutura dessa escala. Podemos utilizar medidas como média, moda e mediana.
- Escala de Razão – nessa escala, existe uma origem absoluta, e podemos dizer quantas vezes um valor maior do que outro através de razões. Um exemplo de variável nessa escala é o peso de um indivíduo. A multiplicação por uma constante positiva preserva a estrutura dessa escala, e podemos utilizar medidas como média, moda e mediana.

Em muitos casos, os atributos de um quadro de dados podem ser modelados enquanto variáveis aleatórias. É preciso, para tanto, que os atributos tenham representações numéricas válidas, especialmente no caso dos atributos qualitativos, a exemplo dos ordinais, que podem ser representados por uma enumeração de 1 até k, onde k indica o

número de fatores, e dos dicotômicos, que são podem ser simplesmente representados por 0 e 1. A modelagem por variáveis aleatórias, visa, nas tarefas de análise exploratória, explicar os atributos aplicando os resultados da teoria de distribuições de probabilidade. Com essa abordagem, pode-se explicar aspectos como frequências (absolutas relativas ou acumuladas), pontos de centralidade, dispersão, assimetria, valores atípicos, entre outros.

O espaço das linhas de um quadro de dados $D \in \mathbb{R}^{n \times p}$ representa um espaço amostral finito com probabilidade uniforme. Um atributo X é uma função que associa cada linha $i \in [n]$ de D ao valor x_i observado na coluna referente a X: $x_i = X(i)$. Com isso, X comporta-se como uma variável aleatória e pode ser represetada a partir de uma tupla de valores $(x_i)_{i=1}$ chamada de **amostra** da variável. Por fim, a composição dos atributos $\{X_i\}_{i=1}^{p}$ denota um vetor aleatório $\mathbf{X}$, o qual associa cada linha de D a p-upla dos valores observados $(x_{ij})_{j=1}^{p}$ tal que

$$(x_{ij})_{j=1}^{p} = \mathbf{X}(i) \qquad \text{e} \qquad x_{ij} = X_j(i), \text{ para } i \in [n], j \in [p]$$

Definição 6.1. Se D é um quadro de dados, a probabilidade empírica de um realização $\mathbf{x}$ de um vetor aleatório $\mathbf{X}$ é dado por

$$P_D(A) = \frac{|A|}{n}$$

onde $A = \{i \in [n] \mid \mathbf{X}(i) = \mathbf{x}\}$

Seja X um atributo de D. Denotamos por

- $X(D)$ a imagem de X, representando o conjunto dos valores distintos do atributo.
- $\{X = x\} \subset [n]$ o conjunto das linhas tais que $X(i) = x$, para $i \in [n]$.
- $D[X = x]$ o subquadro com as linhas de $\{X = x\}$.

6.2 Tabelas de Frequência

Um procedimento para entender o comportamento e distribuição dos dados consiste no uso tabelas de frequência, especialmente para variáveis qualitativas, que não podem ser resumidas por medidas de estatística descritiva a serem vistas mais adiante. Dado uma quadro D com um atributo X tal que $x \in X(D)$, chamamos de frequência

- Absoluta: o número de linhas em que se observa $X = x$;
- Relativa: a frequência absoluta de x normalizada pelo número de linhas;
- Acumulada: quantas linhas observa-se $X \leq x$.

A definição 6.2 nos dá como expressar formalmente essas grandezas.

Definição 6.2. Seja X um atributo de um quadro D com n linhas. Chamamos de

- Frequência absoluta
$$N_X(A) = |X \in A|$$
onde $A \subset X(D)$, e $N(x) = N_X(\{x\})$.

- Frequência Relativa
$$f(x) = \frac{N(x)}{n}$$
- Frequência Acumulada
$$\hat{F}(x) = |X \leq x|$$

Ao explorar um quadro de dados D com atributos discretos ou categóricos, uma tabela de frequências torna-se uma ferramenta útil para visualizar rapidamente quais valores se destacam em dado atributo X. Dedicamos a primeira coluna aos valores unitários de $X(D)$ ou agrupamentos deles, geralmente ordenados. Nas colunas seguintes constam as frequências absoluta, relativa e acumulada de cada faixa.

Exemplo 6.1. Considere um quadro D com $n = 20$ linhas, em que o atributo X registra o número de filhos de cada indivíduo, com $X(D) = \{0, 1, 2, 3, 4\}$. Contando as linhas de cada conjunto $\{X = x\}$, obtemos a tabela a seguir,

x	$N(x)$	$f(x)$	$\hat{F}(x)$
0	6	0.30	0.30
1	7	0.35	0.65
2	4	0.20	0.85
3	2	0.10	0.95
4	1	0.05	1.00
Total	20	1.00	

Por exemplo, $|X = 1| = 7$ indivíduos têm exatamente um filho, o que corresponde a $f(1) = 7/20 = 0.35$ do quadro, e $\hat{F}(1) = 0.65$ indica que 65% dos indivíduos têm no máximo um filho. A tabela evidencia que o valor mais frequente é $x = 1$ e que famílias com três ou mais filhos são raras, com $N_X(\{3, 4\}) = 3$.

No geral, para usar tabelas de frequência com dados quantitativos, discretiza-se os valores em intervalos de amplitude pré-determinada, de forma que cada intervalo passa a representar uma classe. Diferentes amplitudades para cada classe podem levar a visualizações distintas. Amplitudes pequenas levam a muitas classes, que por sua vez podem gerar perda de informação, enquanto amplitudes grandes criam poucas classes, prejudicando a tarefa de resumo. O recomendado é a criação de 5 a 15 classes de mesma amplitude.

Para dados contínuos discretizados em intervalos de amplitude Δ_i para a classe d_i, a tabela pode conter também: a densidade de frequência, dada por n_i/Δ_i, a densidade de proporção, obtida por f_i/Δ_i, Essas novas colunas podem ser usadas para construir gráficos que permitam analisar distribuição dos valores de uma variável numérica.

6.3 Gráficos

Nesta seção iremos descrever brevemente gráficos para realizar análise univariada de variáveis de acordo com o seu tipo. Para variáveis qualitativas, os gráficos são bsicamente construídos com base na tabela de frequência de cada classe, mostrando a contagem ou a frequência relativa em cada classe. Alguns exemplos incluem:

- Gráfico de Barras – uma barra é dedicada a cada classe, e o tamanho da barra é proporcional à contagem de resgistros na classe. O código 6.1 mostra a criação de tal gráfico com a base `cd_brasil` usando o pacote `ggplot2` da linguagem R.

```
library(ggplot2)

cd_brasil |>
    ggplot(aes(x = regiao)) +
        geom_bar(stat = "count")
```

Código 6.1. Gráfico de Barras

- Gráfico de Setores – construído com um círculo de raio arbitrário em que a contagem ou frequência de registros é proporcional à área do setor circular que o representa. O código 6.2 constrói o gráfico de setores correspondente à distribuição de `regiao` na base `cd_brasil`.

```
tab_regiao <- table(cd_brasil$regiao)

pie(tab_regiao, labels = names(tab_regiao))
```

Código 6.2. Gráfico de Setores

- Gráfico de Pirulito – mesmo princípio que o de barras, mas com aspecto mais simples, em que o tamanho é proporcional a uma linha vertical com um ponto no eixo do valor da contagem ou frequência. O código 6.3 mostra a construção desse gráfico com `ggplot2`, combinando `geom_segment` para a linha e `geom_point` para o ponto no topo.

```
library(ggplot2)
library(dplyr)

cd_brasil |>
    group_by(regiao) |>
    summarise(count = n()) |>
    ggplot(aes(x = regiao, y = count)) +
        geom_segment(aes(xend = regiao, y = 0, yend =
            count)) +
        geom_point(size = 3)
```

Código 6.3. Gráfico de Pirulito

Para variáveis numéricas discretas, barras e pirulito também podem funcionar se houver um número não muito grande de realizações distintas no conjunto de dados. Para variáveis contínuas, a discretização em intervalos permite gerar vários tipos de gráficos que ajudam a entender a distribuição de valores da variável, como

- Histogramas – construído também com barras com tamanho proporcional densidade – de registros ou frequência – em cada intervalo. Há várias fórmulas

para determinar o número de intervalos (*bins*), como a de Sturges, dada por $k = 1 + 3.3 \log_{10}(n)$, da raíz quadrada, com $k = \sqrt{n}$, de Scott, com $k = \frac{3.5\sigma}{\sqrt[3]{n}}$, onde σ é o desvio-padrão, ou a de Freedman-Diaconis, dada por $k = \frac{2 \cdot \text{IQR}}{\sqrt[3]{n}}$. O código 6.4 constrói o histograma da variável `temp` da base `cd_poluicao`.

```
hist(cd_poluicao$temp,
     xlab = "Temperatura",
     ylab = "Frequencia",
     border = "white",
     col = "darkblue")
```

Código 6.4. Histograma

- Ramo-e-folha – os ramos são uma coluna vertical com os valores interiros distintos assumidos pelas realizações. As folhas são as partes fracionárias, empilhadas verticalmente ou horizontalmente em seus ramos. O código 6.5 mostra a construção do diagrama para a mesma variável `temp`.

```
stem(cd_poluicao$temp, scale = .5)
```

Código 6.5. Ramo-e-folha

- Gráfico Dispersão Unidimensional – os dados são mapeados a pontos na reta correspondentes a seus valores. Valores repetidos podem ser empilhados, de modo a dar uma melhor visualização à distribuição dos dados. O código 6.6 mostra a construção desse gráfico, empilhando os pontos repetidos com a opção `method = "stack"`.

```
stripchart(cd_poluicao$temp,
           xlab = "Temperatura",
           method = "stack",
           offset = 2,
           at = 0,
           pch = 19,
           cex = 0.5,
           col = "darkblue")
```

Código 6.6. Dispersão Unidimensional

Capítulo 7

Medidas de Resumo

7.1 Medidas de Posição

Um grau maior de resumo dos dados é obtido ao computar determinadas estatísticas que sejam representativas de todo o conjunto, e não somente de agrupamentos menores, como é o caso das frequências absolutas e relativas. Para tanto, podemos utilizar algumas das medidas que explicam uma certa distribuição vistas na parte I, geralmente usadas em conjunto para evitar uma redução muito drástica dos dados. Nesta seção, veremos como obter, a partir da amostra, estimativas para medidas de posição, em especial a moda, mediana e o valor esperado.

A moda amostral é o valor mais frequente num atributo X. Desse modo, é o valor x que maximiza a probabilidade de observar $X = x$, consistindo, pois, de uma estimativa para a **moda populacional** da distribuição de X, dada na definição 2.18.

Definição 7.1. Seja X um atributo de um quadro D com n linhas. A moda amostral de X é definida por

$$\arg\max_{x \in X(D)} N(x)$$

A moda é adequada para resumir atributos qualitativos e quantitativos discretos, ao passo que, para quantitativos contínuos, ela pode ser pouco representativa devido ao grande número de possibilidades de realizações.

As estatísticas de ordem formam um arranjo ordenado de forma não decrescente dos valores observados para o atributo X.

Definição 7.2. Se X é um atributo de um quadro D com n linhas, então as estatísticas de ordem de X são a ênupla

$$(x_{(1)}, \ldots, x_{(n)})$$

dos valores de X que satisfaz

$$\forall i, j \in [n], i < j \implies x_{(i)} \leq x_{(j)}.$$

A **mediana amostral** é o valor que reside no centro das estatísticas de ordem, sendo aquele possivelmente uma dessas.

Definição 7.3. Seja X com estatísticas de ordem $(x_{(i)})_{i=1}^{n}$. Se n é par, então a mediana amostral é

$$\operatorname{med}(X) = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}.$$

Caso contrário,

$$\operatorname{med}(X) = x_{(\frac{n+1}{2})}.$$

A definição 7.3 advém da intuição de que, ao ordenar os dados e tomar o valor m que os separa em duas metades do mesmo tamanho, cerca de 50% dos dados são maiores que m, e 50% são menores. Portanto, esse valor é uma boa estimativa para a **mediana populacional**, vista na definição 2.17.

Por fim, a **média** é a média aritmética das estatísticas observadas.

Definição 7.4. Se X é um atributo de um quadro com n linhas, então sua média $\bar{X}$ é dada por

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X(i)$$

Essa definição é equivalente àquela que pondera cada $x \in X(D)$ por sua probabilidade empírica. Com isso, a média é a contraparte amostral da esperança.

Tanto a média quanto a mediana são apropriadas apenas a atributos quantitativos, com uma possível exceção àqueles que denotam uma ordenação, cuja média pode não ter uma interpretação no contexto dos dados. Caso lidemos com intervalos discretizados desses valores, então a forma de computar essas medidas é por estimativa, como, por exemplo, tomar o ponto médio de cada intervalo, e os usar para obter a média final.

7.2 Medidas de Dispersão

Além de ver onde nossos dados estão centrados, é desejável saber o quanto eles variam. Para esse fim, utilizam-se as medidas de dispersão.

Tomando a média como centro, obteremos, como medida de dispersão, o **desvio absoluto médio**, que corresponde ao erro absoluto médio cometido ao substituir todos os dados pela própria média. Isso indica se a média é uma boa medida de resumo para os dados.

Definição 7.5. Se X é um atributo dum quadro com n linhas, então o seu desvio absoluto médio é dado por

$$\operatorname{dm}(X) = \frac{1}{n}\sum_{i=1}^{n} |x_i - \bar{X}|$$

Outra candidata a medida de dispersão é a **variância amostral**. Ela pode ser interpretada, a menos do fator $\frac{n}{n-1}$, como o erro quadrático médio ao substituir todos os dados pela média.

Definição 7.6. Se X é um atributo dum quadro com $n \geq 2$ linhas, então sua variância amostral é dada por[1]

$$s_X^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{X})^2.$$

Note que $\frac{n-1}{n} s_X^2$ é a variância $\mathrm{Var}(X)$ de X sob a probabilidade empírica P_D.

Como a variância possui unidade igual ao quadrado da unidade do atributo original, sua interpretação pode ser prejudicada. Esse fato motiva o uso do desvio-padrão:

$$s_X = \sqrt{s_X^2},$$

o qual produz uma estatística na mesma unidade de medida dos dados.

O desvio absoluto médio e o desvio-padrão possuem interpretações e aplicações semelhantes ao avaliar a dispersão em torno da média. No entanto, o primeiro nos oferece uma noção mais intuitiva de dispersão, pois todos os desvios possuem o mesmo peso independentemente da magnitude. Já o desvio-padrão, uma vez que atribui pesos distintos a erros conforme a sua magnitude, é preferível quando se objetiva detectar rapidamente a presença de realizações muito distantes da média, o que pode indicar valores atípicos.

Por fim, quando se deseja comparar a variabilidade de atributos medidos em unidades ou magnitudes distintas, usa-se o **coeficiente de variação**. Se X é um atributo com média $\bar{X} > 0$, ele é dado por

$$\mathrm{CV}(X) = \frac{s_X}{\bar{X}},$$

isto é, o desvio-padrão dividido pela média, o que produz uma grandeza adimensional. Essa propriedade permite avaliar a variabilidade de um atributo de forma padronizada: para todo $c > 0$, vale $\mathrm{CV}(cX) = \mathrm{CV}(X)$, ou seja, o coeficiente não depende da unidade de medida escolhida. Ele não é, contudo, invariante por translação, de modo que só faz sentido para atributos com zero absoluto: a série $(10, 20, 30)$, em graus Celsius, tem coeficiente de variação 0.5, mas, convertida para graus Fahrenheit, tem aproximadamente 0.265. Por ser a razão entre duas medidas sensíveis a valores extremos, o coeficiente de variação também não é uma medida robusta.

7.3 Quantis

Um quantil de probabilidade p é um valor que separa a distribuição da variável X em duas partes: ao menos p de probabilidade em valores menores ou iguais a ele e ao menos $1 - p$ em valores maiores ou iguais a ele. Quando F é contínua, isso equivale a dizer que a probabilidade de X ter realização menor ou igual a ele é exatamente p.

Definição 7.7. Seja X uma variável aleatória com suporte Ω_X e função de distribuição $F(x)$. O número $q \in \mathbb{R}$ é um quantil de probabilidade $p \in (0, 1)$ da distribuição de X se

$$P(X \leq q) \geq p \quad \text{e} \quad P(X \geq q) \geq 1 - p.$$

[1] Justifica-se ter $n - 1$ no denominador em vez de n para produzir um estimador não enviesado – conceito a ser visto adiante – para a variância populacional.

Observação 7.1. Pela definição 2.17, a mediana é um quantil de probabilidade 0.5.

A mediana compõe um grupo de quantis muito utilizados no resumo de distribuições chamados **quartis**, que são os quantis de probabilidade 0.25, 0.5 e 0.75. O seu destaque deve-se ao fato de eles dividirem uma distribuição em quatro partes com mesma probabilidade, todas iguais a 25%, quando F é contínua. Analogamente, há os decis, que são os quantis de probabilidade igual a $0.1 \cdot k$, para $k \in [9]$. Outros quantis de destaque são os de 0.05 e 0.95, muito utilizados em inferência.

A determinação de quantis empíricos pode ser realizada de diferentes maneiras. Uma das mais simples é uma generalização daquela usada para a mediana apresentada na seção 7.1, chamada de interpolação.

Suponha estatísticas de ordem $(x_{(i)})_{i=1}^{n}$, com $n \geq 2$; a partir delas, queremos encontrar um quantil empírico q de probabilidade $p \in [0, 1]$. Presumiremos que $x_{(1)}$ e $x_{(n)}$ correspondem às probabilidades 0 e 1 e que as estatísticas dividem a distribuição em intervalos de mesma probabilidade, iguais a $\frac{1}{n-1}$. Assim, associamos a cada estatística $x_{(i)}$ a probabilidade

$$\forall i \in [n],\ \left(p_i = \frac{i-1}{n-1}\right),$$

de modo que $p_1 = 0$, $p_n = 1$ e $p_{i+1} - p_i = \frac{1}{n-1}$ para todo $i \in [n-1]$. O quantil empírico é obtido interpolando linearmente os pontos $(p_i, x_{(i)})$, o que continua válido quando há empates entre as estatísticas. Esse é o método padrão das funções de quantil do R e do NumPy. Suponha que $p_j \leq p < p_{j+1}$ para algum $j \in [n-1]$. Disso, segue que

$$\begin{gathered} p_j \leq p < p_{j+1} \\ (n-1)p_j + 1 \leq (n-1)p + 1 < (n-1)p_{j+1} + 1 \\ j \leq (n-1)p + 1 < j + 1. \end{gathered}$$

Fazendo $h = (n-1)p+1$, e fazendo $j = \lfloor h \rfloor$, basta interpolar linearmente as estatísticas $x_{(j)}$ e $x_{(j+1)}$ usando o fator $\gamma = h - j$, que representa o quão longe estamos de $x_{(j)}$ em direção a $x_{(j+1)}$. Desse modo,

$$q = (1-\gamma)x_{(j)} + \gamma x_{(j+1)}.$$

O caso $p = 1$ fica fora desses intervalos; nele, tomamos $j = n-1$, de modo que $\gamma = 1$ e $q = x_{(n)}$. O algoritmo 1 organiza esses passos para a determinação do quantil empírico via interpolação recebendo o vetor de observações e a probabilidade acumulada pelo quantil a ser obtido.

Além de uma medida de posição, os quantis podem ser usados para medir dispersão. O Intervalo Interquartílico (IQR) é a distância entre o primeiro e terceiro quartil, e quanto maior for sua magnitude, mais dispersa será a distribuição.

Definição 7.8. Se q_1 e q_3 são os primeiro e terceiro quartis respectivamente da distribuição da variável X, então

$$d_q = q_3 - q_1$$

é o intervalo interquartílico da distribuição.

Algoritmo 1: Método de Interpolação do Quantil Empírico

Entrada: vetor de observações $\mathbf{x}$ de tamanho $n \geq 1$ e $p \in [0, 1]$
Saída: O quantil empírico q

```
início
    s ← ordene(x);
    se n = 1 então
        retorna s[1];
    fim
    h ← (n − 1)p + 1;
    j ← min(⌊h⌋, n − 1);
    γ ← h − j;
    retorna (1 − γ)s[j] + γ · s[j + 1];
fim
```

Uma vantagem do uso dessa medida é que ela ignora os 50% mais extremos – os 25% inferiores e os 25% superiores – e preserva os 50% mais centrais, de forma a medir a dispersão típica da variável, isto é, pouco sensível a valores atípicos, desde que estes não excedam 25% dos dados em cada cauda. Ela também é considerada mais robusta para distribuições assimétricas, pois medidas como a variância e, consequentemente, o desvio-padrão são facilmente distorcidos por distribuições de cauda longa.

Os quartis também possuem outra aplicação, neste caso a construção dos diagramas de *box-plot*. Neles, usam-se caixas verticais (ou horizontais) para representar a distribuição dos dados, onde o limite inferior (ou mais à esquerda) é o primeiro quartil, e o limite superior (ou mais à direita) é o terceiro quartil. A mediana também é marcada como uma linha vertical ou horizontal a depender da orientação da caixa. Outro elemento do *box-plot* são os bigodes, segmentos que partem da caixa e terminam num traço: o inferior vai até a menor observação maior ou igual a $q_1 - 1.5\, d_q$, e o superior, até a maior observação menor ou igual a $q_3 + 1.5\, d_q$. As observações fora desse intervalo são marcadas individualmente como possíveis valores atípicos. Os *box-plot* são de grande ajuda para compreender a distribuição de um atributo, especialmente em aspectos de simetria e na detecção de valores atípicos.

7.4 Simetria e Assimetria

Entre as motivações para se estudar a assimetria ou simetria dos dados estão a constatação de

- Concentração dos dados em uma dada região de valores.
- Presença de caudas particularmente longas.
- Afastamento dos dados do centro.
- Validade de hipóteses sobre o modelo adotado para a distribuição.

Quando os dados possuem distribuição simétrica, algumas vantagens analíticas e estatísticas surgem. Por exemplo, a média se torna representativa para medir centralidade, pois essa se localiza justamente no centro da distribuição, de sorte que a variância – e o desvio-padrão – também passa a ser representativa para medir variabilidade, já que os dados estão centrados na média. Quando os dados são assimétricos, medidas de resumo como mediana e quartis são preferíveis por serem menos sensíveis à forma da distribuição. Algumas técnicas de inferência estatística, principalmente aquelas que se baseiam no uso da distribuição normal, a serem apresentadas adiante, também se aproveitam da estrutura simétrica da distribuição, facilitando a produção de algumas análises.

Seja X um atributo de um quadro com n linhas. Para medir sua assimetria, são geralmente usados os coeficientes a seguir, onde s_X denota o desvio-padrão amostral de X, com divisor $n-1$.

- Coeficiente de Assimetria de Pearson I – usado quando a distribuição é unimodal, e a moda pode ser bem definida.

$$\frac{\bar{X} - \text{moda}(X)}{s_X}$$

- Coeficiente de Assimetria de Pearson II – usado quando a distribuição não é unimodal ou a moda não pode ser bem definida, dado por

$$\frac{3\,(\bar{X} - \text{med}(X))}{s_X}$$

- Coeficiente Quartílico de Assimetria – compara as distâncias $q_3 - \text{med}(X)$ e $\text{med}(X) - q_1$, que coincidem sob simetria, medindo o quanto o primeiro e o terceiro quartil deixam de ser equidistantes da mediana

$$\frac{(q_3 - \text{med}(X)) - (\text{med}(X) - q_1)}{q_3 - q_1} = \frac{q_1 + q_3 - 2\,\text{med}(X)}{d_q},$$

  em que d_q é o intervalo interquartílico. Seu valor está em $[-1, 1]$, e o coeficiente não está definido quando $d_q = 0$.

- Coeficiente de Assimetria de Fisher – um estimador baseado no terceiro momento central multiplicado por um fator de correção para amostras pequenas

$$\frac{\sqrt{n(n-1)}}{n-2} \cdot \frac{1}{n\sigma^3} \cdot \sum_{i=1}^{n} (x_i - \bar{X})^3$$

  onde $\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{X})^2}$ é o desvio-padrão com divisor n. Ele exige $n \geq 3$ e $\sigma > 0$.

Seja c o valor de um desses coeficientes. O seu sinal indica o lado em que a cauda da distribuição é mais longa:

- $c > 0$ – assimetria positiva, também chamada de assimetria à direita, pois os dados possuem uma cauda mais longa nessa direção, enquanto seus valores concentram-se mais à esquerda, em valores mais baixos; em geral, $\bar{X} > \text{moda}(X)$.

- $c < 0$ – assimetria negativa, também chamada de assimetria à esquerda, direção na qual se estende a cauda da distribuição, enquanto os dados concentram-se em valores mais altos; em geral, $\bar{X} < \text{moda}(X)$.

- $c = 0$ – ausência de assimetria segundo o coeficiente, o que sugere, mas não garante, que a distribuição seja simétrica.

A relação entre o sinal de c e o de $\bar{X} - \text{moda}(X)$ é uma tendência típica, que vale por definição apenas no coeficiente de Pearson I. Coeficientes diferentes podem discordar em sinal nos mesmos dados. Por exemplo, para $x = (0, 10, 10, 10, 11, 11, 12, 13, 14)$, temos $\bar{X} \approx 10{,}11$, $\text{moda}(X) = 10$ e $\text{med}(X) = 11$; o coeficiente de Pearson I é positivo, o de Pearson II vale aproximadamente $-0{,}66$, o de Fisher, aproximadamente $-2{,}29$, e o quartílico é nulo.

Uma ferramenta visual para medir assimetria de dados são os **gráficos de simetria**. As estatísticas de ordem são usadas para computar pares (u_i, v_i), para $i \in [\lfloor n/2 \rfloor]$, tais que

$$u_i = \text{med}(X) - x_{(i)} \quad \text{e} \quad v_i = x_{(n-i+1)} - \text{med}(X)\,,$$

ambos não negativos. Junto desses pares, é mostrada também a reta $v = u$. Se os pontos se alinharem à reta, temos uma evidência visual de que os dados têm pouca assimetria ou são simétricos. Caso os pontos fiquem acima da reta ($v_i > u_i$), a cauda superior é mais longa, indicando assimetria à direita; caso fiquem abaixo, a assimetria é à esquerda. Os pontos com i pequeno, mais à direita no gráfico, são os que retratam as caudas.

7.5 Medidas Robustas

Tomemos o exemplo de uma base que contenha salários de funcionários de uma empresa. A média pode ser pouco representativa para descrever esses dados, pois, normalmente, há poucos funcionários que ganham altos salários, como executivos, enquanto a grande maioria dos funcionários tem uma remuneração consideravelmente mais baixa. Por consequência, a variância e o desvio-padrão também podem não ser apropriados para medir a variabilidade, pois os valores extremos podem indicar uma dispersão enquanto que os dados, na realidade, concentram-se num determinado intervalo.

A mediana e o IQR, usados para medir centralidade e dispersão respectivamente, sofrem menos influência da magnitude do dado do que a média e a variância, por exemplo. Isso se deve ao fato de que seus valores são computados utilizando somente parte dos dados, e não por uma agregação completa deles. Logo, na suspeita da presença de valores extremos e de forte assimetria, essas medidas podem ser mais apropriadas para realizar a descrição da base.

Há também outras medidas muito utilizadas para descrever dados de maneira robusta. A primeira a citar é a **média aparada**, que consiste no cálculo da média considerando apenas parte dos dados menos extremos. Para isso, decide-se por um parâmetro $\alpha \in [0, 0.5)$ e descartam-se as $\lfloor n\alpha \rfloor$ menores e as $\lfloor n\alpha \rfloor$ maiores observações.

Definição 7.9. Seja X um atributo de um quadro com n linhas e estatísticas de ordem $(x_{(i)})_{i=1}^{n}$. Dado $\alpha \in [0, 0.5)$ e $k = \lfloor n\alpha \rfloor$, a média aparada de X é

$$\bar{X}_\alpha = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} x_{(i)}.$$

Como $\alpha < 0.5$, temos $n - 2k \geq 1$, e sempre sobra ao menos uma observação. A média aparada é insensível a até k valores extremos em cada cauda, sendo, pois, mais representativa na presença deles; para $\alpha = 0$, ela coincide com a média.

Outra medida robusta, dessa vez de dispersão, é o **desvio absoluto mediano**, análogo ao desvio absoluto médio. Para o computar, basta tomar a mediana dos desvios absolutos das observações em relação à mediana do atributo:

$$\mathrm{MAD}(X) = \mathrm{med}\left\{|x_i - \mathrm{med}(X)| : i \in [n]\right\}.$$

Assim, valores extremos pouco interferem no valor final.

7.6 Implementação em R

As medidas vistas neste capítulo estão, em grande parte, disponíveis nas funções básicas da linguagem R, de modo que seu cálculo, na prática, se resume a poucas linhas de código. Ainda assim, é preciso conhecer as convenções adotadas por cada função, pois nem sempre elas coincidem com as definições apresentadas aqui – como é o caso do divisor da variância e da constante do desvio absoluto mediano. Nesta seção, veremos como computar cada uma delas, e, quando a linguagem não oferecer uma função pronta, como implementá-la a partir da definição.

Usaremos, ao longo dos exemplos, o vetor

$$x = (0, 10, 10, 10, 11, 11, 12, 13, 14),$$

o mesmo da seção de simetria, de sorte que os valores obtidos possam ser conferidos com aqueles já calculados. As saídas de cada comando são mostradas como comentários logo abaixo dele.

7.6.1 Medidas de Posição

O R não possui uma função para a moda amostral – a função `mode` retorna o modo de um objeto, como `"numeric"` ou `"character"`, e não a medida estatística. Pela definição de moda amostral, basta tomar o valor que maximiza a frequência absoluta $N(x)$, o que pode ser feito a partir da tabela de frequências produzida por `table`. Como o máximo pode não ser único, o código 7.1 retorna todos os valores que o atingem, o que deixa explícito quando a distribuição é multimodal.

```r
moda <- function(x) {
    freq <- table(x)
    as.numeric(names(freq)[freq == max(freq)])
}

x <- c(0, 10, 10, 10, 11, 11, 12, 13, 14)
moda(x)
# [1] 10
```

Código 7.1. Moda Amostral

Note que `table` converte os valores em nomes, isto é, em cadeias de caracteres, daí a necessidade de `as.numeric`; para atributos qualitativos, essa conversão deve ser omitida.

As estatísticas de ordem são obtidas com `sort`, e a mediana e a média, com `median` e `mean` respectivamente. A função `median` segue a definição 7.3, tomando a média das duas estatísticas centrais quando n é par.

```r
sort(x)
# [1]  0 10 10 10 11 11 12 13 14
median(x)
# [1] 11
mean(x)
# [1] 10.11111
```

Código 7.2. Estatísticas de Ordem, Mediana e Média

Se houver algum valor ausente no vetor, `median` e `mean` retornam `NA`, assim como `var`, `sd` e `mad`, vistas adiante; já `quantile` e `IQR` interrompem a execução com um erro. Para descartar os valores ausentes antes do cálculo, usa-se, em todas essas funções, o argumento `na.rm = TRUE`. Por outro lado, `sort` e `table` – e, portanto, a função `moda` – descartam os valores ausentes sem nenhum aviso, o que pode esconder o fato de que o valor ausente é o mais frequente do atributo.

7.6.2 Medidas de Dispersão

A variância e o desvio-padrão são dados pelas funções `var` e `sd`, ambas com divisor $n - 1$, conforme a definição de variância amostral. Caso se deseje a variância sob a probabilidade empírica, isto é, com divisor n, basta multiplicar o resultado por $\frac{n-1}{n}$. Já o desvio absoluto médio e o coeficiente de variação não possuem funções próprias, mas são escritos diretamente a partir de suas fórmulas.

```r
n <- length(x)

mean(abs(x - mean(x)))     # desvio absoluto medio
# [1] 2.320988
var(x)
# [1] 16.36111
var(x) * (n - 1) / n       # variancia com divisor n
# [1] 14.54321
```

```
sd(x)
# [1] 4.044887
sd(x) / mean(x)           # coeficiente de variacao
# [1] 0.4000438
```

Código 7.3. Medidas de Dispersão

7.6.3 Quantis

Os quantis empíricos são computados pela função `quantile`, que recebe o vetor de observações e um vetor `probs` de probabilidades. Quando este é omitido, são retornados os quartis junto do mínimo e do máximo. A função implementa nove métodos distintos de determinação de quantis, escolhidos pelo argumento `type`; o padrão, `type = 7`, é justamente o método de interpolação do algoritmo 1. O intervalo interquartílico, por sua vez, é dado por `IQR`, que usa o mesmo método.

```
quantile(x)
#   0%  25%  50%  75% 100%
#    0   10   11   12   14
quantile(x, probs = c(0.05, 0.95))
#   5%  95%
#  4.0 13.6
IQR(x)
# [1] 2
```

Código 7.4. Quantis e Intervalo Interquartílico

Para conferir a equivalência, o código 7.5 traduz o algoritmo 1 para o R. Como os vetores do R são indexados a partir de 1, a tradução é direta.

```
quantil <- function(x, p) {
    s <- sort(x)
    n <- length(s)
    if (n == 1) return(s[1])
    h <- (n - 1) * p + 1
    j <- min(floor(h), n - 1)
    gama <- h - j
    (1 - gama) * s[j] + gama * s[j + 1]
}

sapply(c(0.05, 0.25, 0.5, 0.75, 0.95), quantil, x = x)
# [1]  4.0 10.0 11.0 12.0 13.6
```

Código 7.5. Quantil Empírico por Interpolação

A função `summary`, aplicada a um vetor numérico, reúne num só comando o mínimo, os quartis, a média e o máximo, sendo um bom primeiro resumo de um atributo quantitativo. Deve-se ter cuidado, entretanto, com a função `fivenum`, que retorna as dobradiças de Tukey em vez dos quartis do método padrão; as duas coincidem no exemplo, mas diferem em geral.

```
summary(x)
#     Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#     0.00   10.00   11.00   10.11   12.00   14.00
fivenum(x)
# [1]  0 10 11 12 14
```

Código 7.6. Resumo com `summary` e `fivenum`

O *box-plot* é construído pela função `boxplot`, e os valores usados no seu desenho podem ser obtidos com `boxplot.stats`. Seu componente `out` contém as observações fora dos bigodes, isto é, os possíveis valores atípicos. Os quartis usados por essas funções também são as dobradiças de Tukey.

```
boxplot(x, horizontal = TRUE, xlab = "x")

boxplot.stats(x)$out
# [1] 0
```

Código 7.7. Box-plot e Valores Atípicos

No exemplo, $q_1 - 1.5\, d_q = 10 - 3 = 7$, e a observação 0 é a única abaixo desse limite.

7.6.4 Simetria e Assimetria

Nenhum dos coeficientes de assimetria vistos está presente nas funções básicas do R. O código 7.8 os implementa a partir das fórmulas da seção de simetria, reaproveitando a função `moda` do código 7.1. O coeficiente de Pearson I usa apenas a primeira moda retornada, pois só faz sentido quando a distribuição é unimodal.

```
pearson_1 <- function(x) (mean(x) - moda(x)[1]) / sd(x)

pearson_2 <- function(x) 3 * (mean(x) - median(x)) / sd(x)

quartilico <- function(x) {
    q <- quantile(x, c(0.25, 0.5, 0.75), names = FALSE)
    (q[1] + q[3] - 2 * q[2]) / (q[3] - q[1])
}

fisher <- function(x) {
    n <- length(x)
    sigma <- sqrt(mean((x - mean(x))^2))
    sqrt(n * (n - 1)) / (n - 2) * sum((x - mean(x))^3) /
        (n * sigma^3)
}

c(pearson_1(x), pearson_2(x), quartilico(x), fisher(x))
# [1]  0.02746952 -0.65926851  0.00000000 -2.28919119
```

Código 7.8. Coeficientes de Assimetria

Os valores reproduzem o exemplo em que os coeficientes discordam em sinal. Note que, em `fisher`, o desvio-padrão σ é calculado com divisor n, e não com `sd`. O mesmo

coeficiente é oferecido pela função `skewness` do pacote `e1071`, com o argumento `type = 2`.

Por fim, o gráfico de simetria é construído tomando os pares (u_i, v_i) a partir das estatísticas de ordem e traçando a reta $v = u$, como no código 7.9.

```
grafico_simetria <- function(x) {
    s <- sort(x)
    n <- length(s)
    m <- median(s)
    i <- seq_len(n %/% 2)
    u <- m - s[i]
    v <- s[n - i + 1] - m
    plot(u, v, pch = 19, xlab = "u", ylab = "v",
         xlim = c(0, max(u, v)), ylim = c(0, max(u, v)))
    abline(a = 0, b = 1, lty = 2)
}

grafico_simetria(x)
```

Código 7.9. Gráfico de Simetria

Para o vetor x, os pares obtidos são $(11, 3)$, $(1, 2)$, $(1, 1)$ e $(1, 0)$. O primeiro deles, que retrata as caudas, fica bem abaixo da reta, o que evidencia a cauda inferior longa causada pela observação 0.

7.6.5 Medidas Robustas

A média aparada é obtida pela própria função `mean`, por meio do argumento `trim`, que corresponde ao parâmetro α da definição de média aparada: são descartadas as $\lfloor n\alpha \rfloor$ menores e maiores observações. O desvio absoluto mediano é dado pela função `mad`, mas, por padrão, ela multiplica o resultado pela constante 1.4826, que o torna comparável ao desvio-padrão quando os dados provêm de uma distribuição normal. Para obter a medida tal como definida aqui, deve-se usar `constant = 1`.

Retomemos o exemplo dos salários com um vetor de dez salários, em milhares de reais, no qual há um único valor muito acima dos demais.

```
salario <- c(2.1, 2.3, 2.4, 2.6, 2.8, 3.0, 3.1, 3.5, 4.0,
    25.0)

c(mean(salario), median(salario), mean(salario, trim =
    0.1))
# [1] 5.0800 2.9000 2.9625
c(sd(salario), IQR(salario), mad(salario, constant = 1))
# [1] 7.02263 0.95000 0.55000
mad(salario)
# [1] 0.81543
```

Código 7.10. Medidas Robustas

A média é quase o dobro da mediana, ao passo que a média aparada com $\alpha = 0.1$, que descarta apenas a menor e a maior observação, já se aproxima desta. Da mesma

forma, o desvio-padrão é muito maior que o intervalo interquartílico e o desvio absoluto mediano, pois é dominado pelo valor 25.

7.6.6 Resumo por Grupos

Na prática, as medidas costumam ser computadas para cada nível de um atributo qualitativo do quadro, a fim de comparar as distribuições entre os grupos. O pacote `dplyr` permite fazê-lo agrupando o quadro com `group_by` e aplicando as funções vistas dentro de `summarise`, como no código 7.11. O resultado de `summarise` é um *tibble*, que arredonda os valores ao ser impresso; a conversão com `as.data.frame` serve apenas para exibi-los com mais casas decimais.

```
library(dplyr)

salarios <- data.frame(
    setor = rep(c("A", "B"), each = 6),
    salario = c(2.1, 2.4, 2.6, 2.8, 3.0, 3.1,
                2.3, 2.5, 3.5, 4.0, 4.2, 25.0)
)

salarios |>
    group_by(setor) |>
    summarise(media = mean(salario),
              mediana = median(salario),
              aparada = mean(salario, trim = 0.2),
              dp = sd(salario),
              iqr = IQR(salario),
              mad = mad(salario, constant = 1)) |>
    as.data.frame()
#   setor    media mediana aparada       dp iqr  mad
# 1     A 2.666667    2.70    2.70 0.3777124 0.5 0.30
# 2     B 6.916667    3.75    3.55 8.8925624 1.4 0.85
```

Código 7.11. Medidas de Resumo por Grupos

No setor A, as medidas clássicas e as robustas praticamente coincidem, enquanto, no setor B, a média e o desvio-padrão são inflados por um único salário, o que as medidas robustas revelam de imediato.

Capítulo 8

Transformações de Dados

8.1 Transformações Lineares

O mais simples tipo de transformação que pode ser aplicado a um atributo X quantitativo é uma transformação linear na forma $aX + b$, com $a, b \in \mathbb{R}$. Ela pode ser interpretada como um escalonamento seguido de um deslocamento. Os valores dos parâmetros a e b dependem da finalidade da exploração.

Analisemos o impacto de uma transformação linear em algumas medidas de resumo. No Teorema 2.10 vimos que a esperança é um operador linear. Como a média é a esperança de X sob a probabilidade empírica, isso implica que ela também o seja; ainda assim, a verificação direta é imediata.

Proposição 8.1. Se $Y = aX + b$ é uma transformação aplicada a um atributo X, então a média de Y é $a\bar{X} + b$.

Demonstração. Seja n o número de linhas do quadro de X.

$$\frac{1}{n}\sum_{i=1}^{n}(ax_i + b) = \frac{a}{n}\sum_{i=1}^{n} x_i + b = a\bar{X} + b$$

■

Algo análogo à transformação linear da média ocorre com a mediana.

Proposição 8.2. Se $Y = aX + b$ é uma transformação aplicada a um atributo X, então a mediana de Y é $a \cdot \mathrm{med}(X) + b$.

Demonstração. Se $a \geq 0$, então a transformação $x \mapsto ax + b$ é não decrescente, e a ordenação das estatísticas de ordem não é alterada, isto é, $y_{(k)} = ax_{(k)} + b$ para todo $k \in [n]$. Sendo n o número de linhas do quadro de X, se n é ímpar, então a mediana é

$$ax_{(\frac{n+1}{2})} + b.$$

Caso seja par,

$$\frac{(ax_{(\frac{n}{2})}+b)+(ax_{(\frac{n}{2}+1)}+b)}{2} = a\frac{(x_{(\frac{n}{2})}+x_{(\frac{n}{2}+1)})}{2}+b = a\cdot\mathrm{med}(X)+b.$$

Quando $a<0$, ocorre uma inversão na ordem das estatísticas de ordem, de modo que $y_{(k)} = ax_{(n+1-k)}+b$ para todo $k\in[n]$. Todavia, a troca de índices $k\mapsto n+1-k$ leva $\frac{n+1}{2}$ nele mesmo e permuta $\frac{n}{2}$ com $\frac{n}{2}+1$. Assim, se n é ímpar, $y_{(\frac{n+1}{2})} = ax_{(\frac{n+1}{2})}+b$, e, se n é par, as estatísticas usadas para computar a mediana de Y são as mesmas do caso anterior em ordem trocada, o que não altera a sua média aritmética. Em ambos os casos, a mediana de Y é $a\cdot\mathrm{med}(X)+b$. ■

A moda acompanha a transformação de forma ainda mais direta, pois depende apenas das frequências dos valores, e não de sua ordenação.

Proposição 8.3. Se $Y = aX+b$ é uma transformação aplicada a um atributo X e m é uma moda amostral de X, então $am+b$ é uma moda amostral de Y.

Demonstração. Se $a=0$, então Y é constante e igual a $b=am+b$, que é, pois, sua única moda. Se $a\neq 0$, então a função $x\mapsto ax+b$ é injetora, de modo que Y assume o valor $ax+b$ exatamente nas linhas em que X assume o valor x, isto é, $N_Y(\{ax+b\}) = N_X(\{x\})$ para todo $x\in X(D)$. Como m maximiza $N_X(\{x\})$, segue que $am+b$ maximiza $N_Y(\{y\})$. ■

Quando $a\neq 0$, a correspondência é uma bijeção entre as modas de X e as de Y.

A mediana é um caso particular dos quantis empíricos, e o comportamento visto acima se estende a eles, com a ressalva de que, para $a<0$, a inversão da ordem troca o quantil de probabilidade p pelo de probabilidade $1-p$. Denotaremos por $q_p(X)$ o quantil empírico de probabilidade p de X obtido pelo algoritmo 1.

Proposição 8.4. Seja $Y = aX+b$ uma transformação aplicada a um atributo X de um quadro com $n\geq 2$ linhas, e seja $p\in[0,1]$. Se $a\geq 0$, então $q_p(Y) = a\,q_p(X)+b$; se $a<0$, então $q_p(Y) = a\,q_{1-p}(X)+b$.

Demonstração. Seja $\ell_X : [1,n]\to\mathbb{R}$ a função linear por partes que liga os pontos $(k, x_{(k)})$, para $k\in[n]$, isto é,

$$\ell_X(t) = (1-(t-k))\,x_{(k)} + (t-k)\,x_{(k+1)}, \quad t\in[k,k+1].$$

Pelo algoritmo 1, com $h=(n-1)p+1$, temos $q_p(X) = \ell_X(h)$, inclusive no caso $p=1$, em que $q_1(X) = x_{(n)} = \ell_X(n)$. Defina ℓ_Y de forma análoga para Y.
Se $a\geq 0$, então $y_{(k)} = ax_{(k)}+b$, como visto na prova da proposição 8.2. As funções ℓ_Y e $a\ell_X+b$ são lineares em cada intervalo $[k,k+1]$ e coincidem nos inteiros, logo são iguais, e $q_p(Y) = \ell_Y(h) = a\,q_p(X)+b$.
Se $a<0$, então $y_{(k)} = ax_{(n+1-k)}+b$. A função $t\mapsto a\,\ell_X(n+1-t)+b$ também é linear em cada intervalo $[k,k+1]$, pois $n+1-t$ percorre o intervalo $[n-k, n+1-k]$, e vale $ax_{(n+1-k)}+b = y_{(k)}$ em cada inteiro k, de modo que $\ell_Y(t) = a\,\ell_X(n+1-t)+b$. Como $n+1-h = (n-1)(1-p)+1$, segue que

$$q_p(Y) = a\,\ell_X((n-1)(1-p)+1)+b = a\,q_{1-p}(X)+b.$$

■

Para $p = 0.5$, temos $1 - p = p$, e a proposição 8.4 recupera a proposição 8.2.

A transformação linear da variância amostral é análoga à mostrada para aquela do Teorema 2.11.

Proposição 8.5. Se $Y = aX + b$ é uma transformação aplicada a um atributo X, então $s_Y^2 = a^2 s_X^2$.

Demonstração. Se n é o número de linhas do quadro de X, então

$$\frac{1}{n-1}\sum_{i=1}^{n}(ax_i + b - (a\bar{X} + b))^2 = \frac{a^2}{n-1}\sum_{i=1}^{n}(x_i - \bar{X})^2 = a^2 s_X^2$$

■

O desvio absoluto médio, o intervalo interquartílico e o desvio absoluto mediano comportam-se da mesma maneira que o desvio-padrão: são multiplicadas por $|a|$ e não dependem do deslocamento b. Isso é esperado, pois um deslocamento move todos os dados juntos, sem alterar as distâncias entre eles, ao passo que o escalonamento multiplica todas essas distâncias por $|a|$.

Proposição 8.6. Seja $Y = aX + b$ uma transformação aplicada a um atributo X de um quadro com $n \geq 2$ linhas. Então

$$\mathrm{dm}(Y) = |a|\mathrm{dm}(X)\,, \quad s_Y = |a|\, s_X,$$
$$d_q(Y) = |a|\, d_q(X) \quad \text{e} \quad \mathrm{MAD}(Y) = |a|\,\mathrm{MAD}(X),$$

onde $d_q(X) = q_{0.75}(X) - q_{0.25}(X)$ é o intervalo interquartílico empírico.

Demonstração. Pela proposição 8.1, $y_i - \bar{Y} = a(x_i - \bar{X})$, logo

$$\mathrm{dm}(Y) = \frac{1}{n}\sum_{i=1}^{n}|a|\,|x_i - \bar{X}| = |a|\mathrm{dm}(X)\,.$$

A igualdade $s_Y = |a|\, s_X$ segue da proposição 8.5 tomando a raiz quadrada. Para o intervalo interquartílico, se $a \geq 0$, a proposição 8.4 dá

$$d_q(Y) = (a\, q_{0.75}(X) + b) - (a\, q_{0.25}(X) + b) = a\, d_q(X),$$

e, se $a < 0$, ela dá

$$d_q(Y) = (a\, q_{0.25}(X) + b) - (a\, q_{0.75}(X) + b) = -a\, d_q(X) = |a|\, d_q(X).$$

Por fim, pela proposição 8.2, $|y_i - \mathrm{med}(Y)\,| = |a|\,|x_i - \mathrm{med}(X)\,|$. Assim, os desvios absolutos de Y em relação à sua mediana são os de X multiplicados por $|a| \geq 0$, e, aplicando novamente a proposição 8.2, com coeficiente $|a|$ e deslocamento 0, obtemos $\mathrm{MAD}(Y) = |a|\,\mathrm{MAD}(X)$. ■

Como consequência, o coeficiente de variação satisfaz $\mathrm{CV}(aX) = \mathrm{CV}(X)$ para $a > 0$, mas não é preservado por deslocamentos, já que s_X não depende de b, enquanto a média depende, como já observado na seção de medidas de dispersão.

Por fim, os coeficientes de assimetria não dependem nem da escala, nem da posição dos dados, mas apenas do sentido da transformação.

Proposição 8.7. Seja $Y = aX + b$, com $a \neq 0$, uma transformação aplicada a um atributo X, e seja c um dos coeficientes de assimetria de Pearson I, Pearson II, quartílico ou de Fisher, definido para X. Então c está definido para Y, e

$$c(Y) = \frac{a}{|a|}\, c(X).$$

Demonstração. Pelas proposições 8.1, 8.2, 8.3 e 8.6, as diferenças $\bar{Y} - \text{moda}(Y)$ e $\bar{Y} - \text{med}(Y)$ são iguais às respectivas diferenças de X multiplicadas por a, ao passo que $s_Y = |a|\, s_X$, o que prova o resultado para os coeficientes de Pearson, com $s_Y > 0$ sempre que $s_X > 0$.
Para o coeficiente quartílico, se $a > 0$, a proposição 8.4 dá

$$q_{0.25}(Y) + q_{0.75}(Y) - 2\text{med}(Y) = a\left(q_{0.25}(X) + q_{0.75}(X) - 2\text{med}(X)\right);$$

se $a < 0$, os quartis trocam de papel, mas a soma $q_{0.25} + q_{0.75}$ é a mesma, e a igualdade acima continua válida. Como $d_q(Y) = |a|\, d_q(X)$, o resultado segue.
Para o coeficiente de Fisher, temos $(y_i - \bar{Y})^3 = a^3(x_i - \bar{X})^3$, e, sendo σ_X e σ_Y os desvios-padrão com divisor n de X e Y, pelo mesmo argumento da proposição 8.5, $\sigma_Y = |a|\, \sigma_X > 0$. O fator de correção depende apenas de n, logo o coeficiente de Y é o de X multiplicado por $\frac{a^3}{|a|^3} = \frac{a}{|a|}$. ■

Em particular, para $a > 0$, nenhum desses coeficientes se altera, o que formaliza a afirmação de que transformações lineares não mudam a forma da distribuição. Para $a < 0$, a distribuição é refletida, e a cauda mais longa muda de lado.

Dentre as transformações lineares mais usadas em análise exploratória está a padronização, por vezes também chamada de normalização. Ela é usada para ajustar os valores de uma sequência de atributos a uma escala comum para facilitar a comparação entre eles.

Um exemplo de padronização é a transformação $(X - \bar{X})/s_X$, definida quando $s_X > 0$, isto é, quando X não é constante. Ela produz um novo atributo com média 0 e desvio-padrão amostral igual a 1, o que segue das Proposições 8.1 e 8.5 com $a = 1/s_X$ e $b = -\bar{X}/s_X$, de forma análoga ao exposto na Proposição 2.12. Essa transformação é adequada quando o atributo se aproxima de uma distribuição normal, de modo que o atributo resultante aproximar-se-á de uma distribuição normal padrão. Também é útil quando aplicamos modelos sensíveis à escala dos atributos, como aqueles baseados em distâncias. Note, porém, que, por ser linear com $a = 1/s_X > 0$, a padronização não altera a forma da distribuição, conforme a proposição 8.7, de modo que não torna normal um atributo que não o seja. Além disso, como $\bar{X}$ e s_X não são robustos, a presença de *outliers* infla s_X e comprime os valores típicos num intervalo estreito, prejudicando a comparação entre atributos.

Uma variação robusta da padronização utiliza a mediana e o IQR no lugar da média e do desvio-padrão, respectivamente, dada por $(X - \text{med}(X))/d_q$, definida quando $d_q > 0$. Essa condição pode falhar mesmo para atributos não constantes: para $X = (0, 0, 0, 0, 1)$, o método de interpolação dá $q_{0.25}(X) = q_{0.75}(X) = 0$. Tomando $a = 1/d_q$ e $b = -\text{med}(X)\,/d_q$, o resultado é um atributo com mediana 0, pela proposição 8.2, e IQR igual a 1, pela proposição 8.6. Sua aplicação é recomendada quando os dados

possuem *outliers* que não podem ser descartados, possuem distribuição assimétrica ou cauda pesada.

Outro exemplo é a normalização min-max, que escala os valores para o intervalo $[0, 1]$, definida quando $\max X > \min X$ e dada por

$$\frac{X - \min X}{\max X - \min X}.$$

Sua vantagem sobre a padronização tradicional é que os dados são ajustados para um intervalo fixo e não negativo, porém também sofre na presença de *outliers*.

Capítulo 9

Análise de Dados de Duas Variáveis

Parte III

Inferência Clássica

Capítulo 10

Amostragem

Capítulo 11

Estimação de Parâmetros

Capítulo 12

Testes de Hipóteses

Capítulo 13

Inferência Multipopulacional

Capítulo 14

Análise de Aderência e Associação

Capítulo 15

Testes de Hipóteses Não Paramétricos

Parte IV

Regressão

Capítulo 16

Covariância e Correlação

Capítulo 17

Regressão Linear

Capítulo 18

Regressão Linear Generalizada

Parte V

Inferência Bayesiana

Capítulo 19

Paradigma Bayesiano

Capítulo 20

Inferência e Decisão

Capítulo 21

Computação Bayesiana

Parte VI

Processos Estocásticos

Capítulo 22

Introdução aos Processos Estocásticos

Capítulo 23

Cadeias de Markov

Capítulo 24

Ergodicidade

Capítulo 25

Processos de Contagem

Capítulo 26

Simulação por Processos Estocásticos

Parte VII

Séries Temporais

Capítulo 27

Fundamentos de Séries Temporais

Capítulo 28

Modelos Lineares de Séries Temporais

Capítulo 29

Modelos Integrados e Sazonais

Capítulo 30

Previsão

Capítulo 31

Métodos de Suavização

Capítulo 32

Tópicos Avançados