Estatística

J. P. S. de Sousa

Contents

0.1 Visão Geral da Estatística e Análise de Dados 4
0.1.1 Uma Breve História da Estatística 4
0.1.2 Modelos Estatísticos 5
0.1.3 Análise de Dados 5

I Distribuições **7**

1 Probabilidades **8**

2 Variáveis Aleatórias Discretas **9**

3 Variáveis Aleatórias Contínuas **10**

4 Variáveis Aleatórias Multidimensionais **11**

5 Simulação **12**

II Análise Exploratória **13**

6 Modelos e Descrição de Dados **14**
6.1 Tipos de Dados 14
6.2 Escala de Dados 15
6.3 Tabelas de Frequência 16
6.4 Gráficos 16

7 Medidas de Resumo **18**
7.1 Medidas de Posição 18
7.2 Medidas de Dispersão 19

8 Análise de Dados de Duas Variáveis **20**

III Inferência Clássica 21

9 Amostragem 22

10 Estimação de Parâmetros 23

11 Testes de Hipóteses 24

12 Inferência Multipopulacional 25

13 Análise de Aderência e Adesão 26

14 Teste de Hipótese Não Paramétricos 27

IV Regressão 28

15 Covariância e Correlação 29

16 Regressão Linear 30

17 Regressão Linear Generalizada 31

V Inferência Bayesiana 32

18 Paradigma Bayesiano 33

19 Inferência e Decisão 34

20 Computação Bayesiana 35

VI Séries Temporais 36

21 Fundamentos de Séries Temporais 37

22 Modelagem e Previsão 38

0.1 Visão Geral da Estatística e Análise de Dados

0.1.1 Uma Breve História da Estatística

A palavra estatística deriva dos termos neolatim *statisticum collegium* e italiano *statista*, que significam Colégio de Estado e Estadista respectivamente. A palavra alemã *Statistik* foi usada modernamente por Gottfried Achenwall em meados do século XVIII para designar a coleta de dados políticos, econômicos e sociais de um país, cujo equivalente em inglês era *political arithmetic*. Posteriormente, através de Sir John Sinclair e seus trabalhos no *Statistical Accounts of Scotland*, a palavra ganhou uma conotação mais ampla sobre coleta e classificação de dados.

Como vistos pelas suas raízes etimológicas, a estatística surgiu enquanto a disciplina que se preocupava com a coleta, tratamento, classificação e análise de dados sobre características político-sócio-econômicas de um país a fim de apoiar a formulação de políticas públicas.

A Estatística Matemática tem seus fundamentos no desenvolvimento da Teoria das Probabilidades, antes, com tratamento mais informal, nos trabalhos de Pierre de Fermat, Blaise Pascal e Christian Huygens no século XVII e Thomas Bayes no século XVIII. O rigor matemático também se expandiu no século XVIII com as obras *Ars Conjectandi* (1713) de Jakob Bernoulli e *The Doctrine of Chances* de Abraham Moivre (1718). A formalização matemática rigorosa das probabilidades veio ao auge com Andrei Kolmogorov no século XIX.

A disciplina estatística também tem laços com a Teoria de Erros, cujas origens remontam a *Opera Miscellanea* de Roger Cottes de 1772, e sua reedição por Thomas Simpson em 1755, que aplicou a teoria a erros de observação. A Teoria de Erros ganhou um aspecto mais analítico ainda no final do século XVIII e ao longo do XIX nas mãos de Pierre-Simon de Laplace, Joseph Louis Lagrange e Daniel Bernoulli. O seminal Método dos Mínimos Quadrados (MMQ) foi desenvolvido e publicado independentemente por Adrien-Marie Legendre, Carl Friedrich Gauss e Robert Adrain.

Com o desenvolvimento e sofisticação das técnicas estatísticas, como a amostragem, modelagem e inferência, a estatística na virada do século XIX para o XX, expandiu-se da esfera do Estado para se tornar uma disciplina aplicada em ciências naturais, sociais, administração pública e privada. Neste contexto, figuram nomes George Box, Pafnuty Chebyshev, Gertrude Cox, George Dantzig, Edward Deming, Bruno de Finetti, Sir Ronald Fisher, Sir Francis Galton, Aleksandr Lyapunov, Karl Pearson, Charles Spearman e John Tukey.

Atualmente a estatística é a disciplina central em qualquer outra área para

lidar com dados e incertezas. O avanço das técnicas computacionais viabilizaram o desenvolvimento de técnicas e aplicações estatísticas cada vez mais robustas e complexas para lidar com quantidades massivas de dados e geração de conhecimento e compreensão para diversas áreas, como economia, ciências sociais, computação, inteligência de negócios, saúde, etc.

0.1.2 Modelos Estatísticos

A estatística é um ramo da matemática aplicada e da metodologia científica que busca extrair, reduzir, analisar e modelar um conjunto de dados que amostram uma população. Para isso, são usadas principalmente as ferramentas teóricas providas pela Teoria das Probabilidades, pois entende-se que os dados originam-se de fenômenos aleatórios, e, uma vez modelados, geralmente dois objetivos visam ser cumpridos: estimar ou predizer o comportamento dos dados no futuro, ou realizar inferência, que consiste em detectar os padrões embutidos. A inferência pode ser feita por duas abordagens: a inferência dedutiva, que aceita determinadas premissas para chegar às conclusões, ou a inferência indutiva, que parte de casos particulares para generalizar.

Ainda sobre a inferência estatística, quando tenta-se modelar um determinado conjunto de dados, tentamos identificar padrões e tendências de comportamento através de modelos estatísticos. Supondo que temos um conjunto de dados D, e identificamos que conseguimos ajustar a eles um modelo M, teremos então que

$$D = M + R$$

onde R descreve a parte aleatória dos dados que não pode ser capturada pelo modelo, chamada de resíduos. Normalmente, busca-se que resíduos não devam conter nenhuma suavidade, pois isso implicaria em padrões que o modelo falhou em capturar, e mais suavização por parte de M será necessária.

0.1.3 Análise de Dados

A Análise de Dados consiste na inspeção, limpeza, transformação e modelagem de dados com o objetivo claro de obter informações úteis, informar conclusões ou apoiar a tomada de decisão. Em resumo, ela é o processo de extração de dados brutos para geração de conhecimento acionável, geralmente feito num ciclo iterativo. As fases desse processo podem ser divididas em:

1. Requisitos de Dados: a escolha de dados a serem extraídos dependem das análises que se deseja realizar. Aqui define-se a **unidade experimental**, que pode consistir de um indivíduo ou uma população deles, e as **variáveis**

específicas dessa unidade, como idade e renda para uma população de pessoas.

2. Coleta de Dados: consiste na tarefa de obter os dados de diferentes fontes, como bancos de dados estruturados ou não-estruturados, sensores físicos, formulários, uma interface de programação de aplicação (API), arquivos binários ou de textos, entre muitas outras fontes.

3. Processamento e Limpeza: inclui tarefas de organizar os dados em formatos estruturados, identificar tipos, deduplicar, tratar valores faltantes, incorretos e desviantes e transformar o formato de dados para outros mais convenientes.

4. Análise Exploratória: compreende uma gama de técnicas para descrever e resumir os dados obtidos à procura de informações que ajudem entender relações entre as variáveis e guie às técnicas a serem aplicadas nas fases posteriores. Aqui é comumente aplicadas técnicas da Estatística Descritiva e métodos gráficos.

5. Modelagem: são usados algoritmos e modelos estatísticos para extrair padrões latentes nos dados, muitas vezes não triviais de serem identificados. As técnicas de aprendizado estatístico são especialmente úteis nessa etapa.

6. Comunicação e Produto de Dados: a depender do contexto e das finalidades definidas a priori, busca-se maneiras de comunicar esses dados aos atores interessados na forma de visualizações e relatórios. Nos últimos anos, a disciplina de **Narrativa de Dados** tem se destacado para realizar essa comunicação.

A Análise de Dados, do ponto de vista da Estatística, poderia ser dividida em

1. Estatística Descritiva: utilizar medidas de resumo numéricas para os dados a fim de descrever padrões visíveis, geralmente respondendo perguntas do tipo "o que aconteceu?".

2. Análise Exploratória: semelhante a anterior, porém empregando métodos mais flexíveis e visuais que permitam identificar padrões mais ocultos, correlações e anomalias. Ocorre num processo iterativo de formulação de perguntas, exploração e descobertas.

3. Análise Confirmatória: aplica as técnicas da inferência estatística para confirmar ou rejeitar hipóteses existentes das etapas anteriores

Part I

Distribuições

Chapter 1

Probabilidades

Chapter 2

Variáveis Aleatórias Discretas

Chapter 3

Variáveis Aleatórias Contínuas

Chapter 4

Variáveis Aleatórias Multidimensionais

Chapter 5

Simulação

Part II

Análise Exploratória

Chapter 6

Modelos e Descrição de Dados

6.1 Tipos de Dados

A forma comum em estatística de representar dados é por meio de matrizes retangulares chamadas de **tabelas** ou também, modernamente devido aos softwares usados para tratá-las, **quadro de dados** (*Dataframe*). Por padrão, sendo D um quadro de dados de dimensões $m \times n$, cada coluna de D corresponde a um **atributo**, também chamado de variável ou *feature*, e cada linha corresponde a um registro, que representa um indivíduo na amostra na amostra coletada.

Cada atributo possui um domínio de valores possíveis, que embora possam ser os mais variados possíveis, podem ser organizados numa taxonomia simples. Os tipos de atributos podem ser divididos em dois grande grupos: quantitativos ou qualitativos. O primeiro refere-se a dados com domínio num conjunto numérico, sendo dividido em

Discretos: São atributos que assumem valores em subconjuntos dos números inteiros $\mathbb{Z}$, sendo que na maioria dos contextos são não negativos. Representam contagens, como número de filhos e idades.

Contínuos: O domínio do atributo é um intervalo dos números reais $\mathbb{R}$. Na prática, pelas limitações ontológicas de representar um número real, a realização desses valores se limita a valores aproximados. A diferença fundamental para os discretos é que o conjunto de valores possíveis é não enumerável. Exemplos incluem principalmente medidas, como preços, alturas e pesos.

Os dados qualitativos representam uma qualidade dentro de um conjunto finito de possibilidades chamadas de fatores, sendo dividos em

Ordinais: os fatores possuem uma ordem natural. Exemplos são graus de uma qualidade, como classe social (baixa, média e alta) ou severidade de um exame médico.

Nominais: os fatores não possuem ordem natural, sendo também chamados de categóricos, pois representam categorias. Exemplos são grupos, como sexo ou estado cívil. Um tipo especial de variáveis nominais são as dicotômicas, cujos valores possívei são apenas dois: sucesso ou fracasso, positivo ou negativo, sim ou não, 0 ou 1.

6.2 Escala de Dados

Alternativamente às classificações apresentadas, podemos tipificar atributos através de escalas de medição de seus valores. As classes são similares às classificações apresentadas anteriormente, sendo elas:

- Escala Nominal – para dados nessa escala, só podemos dizer que seus valores são diferentes de outros, sendo usada para categorizar indivíduos. Um exemplo simples é o sexo de uma pessoa: feminino ou masculino. Essa escala não suporta operações matemáticas, e uma medida de centralidade comum para resumir dados nessa escala é a moda.

- Escala Ordinal – nessa escala, os valores podem ser ordenados, e podemos então dizer que, além de diferentes, um valor é maior do que o outro. Essa escala tem sua estrutura preservada por operações que preservem a ordem. Um exemplo de variável ordinal é o nível de escolaridade: fundamental, médio e superior. Medidas de tendência central comuns para dados nessa escala são a moda e a mediana.

- Escala Intervalar - essa escala possui uma origem arbitrária e necessita de uma unidade de medida, sendo um exemplo a temperatura de um ambiente. Podemos afirmar que valores são diferentes, maiores e quão maior em relação a outro, e transformações afim – do tipo $ax + b$ – não alteram a estrutura dessa escala. Podemos utilizar medidas como média, moda e mediana.

- Escala Razão – nessa escala, existe uma origem absoluta, e podemos dizer que um valor é o quão maior do que outro através de razões. Um exemplo de variável nessa escala é o peso de um indivíduo. Transformações do tipo ax preservam a estrutura dessa escala, e podemos utilizar medidas como média, moda e mediana.

6.3 Tabelas de Frequência

Um procedimento para entender o comportamento e distribuição dos dados é por meio de tabelas de frequência, especialmente para variáveis qualitativas, que não podem ser resumidas por ser resumidas por medidas de estatística descritiva a serem vistas mais adiante. Nas tabelas de frequência constam, geralmente, três colunas: a primeira é de categorias ou intervalos de uma classe d_i, a segunda a frequência absoluta n_i de d_i, enquanto a terceira é a frequência relativa $f_i = n_i/n$, onde n é o tamanho da amostra.

Quando lidamos com intervalos de dados numéricos, a amplitude precisa ser definido a priori, e amplitudades diferentes de cada classe pode levar a visualizações distintas. Muitas classes podem levar a perda de informação, enquanto que poucas podem prejudica a tarefa de resumo. O recomendado é a criação de 5 a 15 classes de mesma amplitude.

Para dados contínuos discretizados em intervalos de amplitude Δ_i para a classe d_i,a tabela pode conter também: a densidade na classe, dada por n_i/Δ_i, a densidade de frequência, obtida por f_i/Δ_i, e a frequência acumulada, dado por

$$\sum_{k=1}^{i} f_i$$

Essas novas colunas podem ser usadas para construir gráficos que permitam analisar distribuição dos valores de uma variável numérica.

6.4 Gráficos

Nesta seção iremos descrever brevemente gráficos para realizar análise univariada de variáveis de acordo com o seu tipo. Para variáveis qualitativas, os gráficos são bsicamente construídos com base na tabela de frequência de cada classe, mostrando a contagem ou a frequência relativa em cada classe. Alguns exemplos incluem:

- Gráfico de Barras – o tamanho da barra é proporcional a contagem ou frequência de resgistros na classe
- Gráfico de Setores – construído com um círculo de raio arbitrário em que a contagem ou frequência de registros é proporcional à área do setor circular que o representa
- Gráfico de Pirulito – mesmo princípio que o de barras, mas com aspecto mais simples, em que o tamanho é proporcional a uma linha tracejada vertical com

um ponto no valor da contagem ou frequência.

Para variáveis numéricas discretas, barras e pirulito também podem funcionar se houver um número não muito grande de realizações distintas no conjunto de dados. Para variáveis contínuas, a discretização em intervalos permite gerar vários tipos de gráficos que ajudam a entender a distribuição de valores da variável, como

- Histogramas – construído também com barras com tamanho proporcional densidade – de registros ou frequência – em cada intervalo. Há várias fórmulas para determinar o número de intervalos (*bins*), como a de Sturges, dada por $k = 1 + 3.3 \log_{10}(n)$, da raíz quadrada, com $k = \sqrt{n}$, de Scott, com $k = \frac{3.5\sigma}{\sqrt[3]{n}}$, onde σ é o desvio-padrão, ou a de Freedman-Diaconis, dada por $k = \frac{2 \cdot \mathrm{IQR}}{\sqrt[3]{n}}$.
- Ramo-e-folha – os ramos são uma coluna vertical com os valores interiros distintos assumidos pelas realizações. As folhas são as partes freacionárias, empilhadas verticalmente ou horizontalmente em seus ramos.
- Gráfico Dispersão Unidimensional – os dados são mapeados a pontos na reta correspondentes a seus valores. Valores repetidos podem ser empilhados, de modo a dar uma melhor visualização à distribuição dos dados.

Chapter 7

Medidas de Resumo

7.1 Medidas de Posição

Um grau maior de resumo dos dados pode ser obtido ao se computar determinadas estatísticas numéricas que sejam representativas de todo o conjunto, e não somente de agrupamentos deles, como é o caso das frequências absolutas e relativas. As medidas a serem apresentadas são usualmente usadas em conjunto para evitar uma redução muito drástica dos dados. Em especial, as medidas de posição nos dão uma ideia de centralidade dos dados.

A primeira delas, é a moda, definida simplesmente como o valor mais frequente na distribuição. Ela pode ser facilmente estimada contando-se o valor mais frequente. Se $x_1, \ldots, x_n$ são realizações de uma variável X, então a moda é dada como

$$\text{moda}\,(X) = \arg\max_x f(x),$$

onde $f(x)$ é a frequência de x em X. A moda é adequada para atributos qualitativos e quantitativos discretos, ao passo que para quantitativos contínuos ela pode ser pouco representativa devido ao grande número de possibilidades de realizações, apesar de ter uma definição satisfatória para esse caso.

A segunda medida é a mediana, que o valor que acumula 50% da frequência acumulada da distribuição de um atributo. Para determinar a mediana de um vetor de dados X, basta ordenar as realizações do vetor; caso sua dimensão seja ímpar, então a mediana é o valor do índice $\frac{n}{2}$, ao passo que, caso seja par, a mediana é obtida como a média entre as realizações de índice $\frac{n}{2}$ e $\frac{n+1}{2}$.

Por fim, a média de um vetor de dados X é o valor $\bar{x}$ dado como

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i,$$

que é equivalente também a

$$\bar{x} = \sum_{i=1}^{n} x_i f(x_i).$$

Tanto a média quanto a mediana são apropriadas apenas à atributos quantitativos. Caso estejamos lidando com intervalos discretizados desses valores, então a forma de computar essas medidas é por estimativa.

7.2 Medidas de Dispersão

Além de ver onde nossos dados estão centrados, é desejável saber o quanto eles variam, geralmente entorno do próprio centro citado. Para esse fim, utiliza-se as medidas de dispersão. Como exemplo dessas medidas, poderiámos ter a soma dos desvios entorno da média, ou do quadrado deles para acentuar desvios maiores. No entanto, o sinal dos desvios pode ocultar sua variabilidade real, pois eles podem somar zero, além também de dificultar a comparação da variação entre dois conjuntos de dados distintos. Uma alternativa para isso, seria consederar a soma dos desvios absolutos entorno da média, apesar dessa medida ser sensível ao tamanho do próprio conjunto.

As medidas de dispersão mais simples que contornam os problemas ditos anteriormente são o desvio médio e a variância, dados como

$$\mathrm{dm}\,(X) = \frac{1}{n}\sum_{i=1}^{n} |x_i - \bar{x}| \quad e \quad \mathrm{Var}\,(X) = \frac{1}{n}\sum_{i=1}^{n} |x_i - \bar{x}|^2.$$

Como a variância possui unidade igual ao quadrado da unidade do atributo original, então sua interpretação pode ser prejudicada. Dessa forma, define-se o desvio padrão:

$$\mathrm{dp}\,(X) = \sqrt{\mathrm{Var}\,(X)},$$

que é equivalente ao "erro" cometido ao se subtituir cada observação pela média.

Chapter 8

Análise de Dados de Duas Variáveis

Part III

Inferência Clássica

Chapter 9

Amostragem

Chapter 10

Estimação de Parâmetros

Chapter 11

Testes de Hipóteses

Chapter 12

Inferência Multipopulacional

Chapter 13

Análise de Aderência e Adesão

Chapter 14

Teste de Hipótese Não Paramétricos

Part IV

Regressão

Chapter 15

Covariância e Correlação

Chapter 16

Regressão Linear

Chapter 17

Regressão Linear Generalizada

Part V

Inferência Bayesiana

Chapter 18

Paradigma Bayesiano

Chapter 19

Inferência e Decisão

Chapter 20

Computação Bayesiana

Part VI

Séries Temporais

Chapter 21

Fundamentos de Séries Temporais

Chapter 22

Modelagem e Previsão