

Estatística

J. P. S. de Sousa

o.1 Visão Geral da Estatística e Análise de Dados

o.1.1 Uma Breve História da Estatística

A palavra estatística deriva dos termos neolatim *statisticum collegium* e italiano *statista*, que significam Colégio de Estado e Estadista respectivamente. A palavra alemã *Statistik* foi usada modernamente por Gottfried Achenwall em meados do século XVIII para designar a coleta de dados políticos, econômicos e sociais de um país, cujo equivalente em inglês era *political arithmetic*. Posteriormente, através de Sir John Sinclair e seus trabalhos no *Statistical Accounts of Scotland*, a palavra ganhou uma conotação mais ampla sobre coleta e classificação de dados.

Como vistos pelas suas raízes etimológicas, a estatística surgiu enquanto a disciplina que se preocupava com a coleta, tratamento, classificação e análise de dados sobre características político-sócio-econômicas de um país a fim de apoiar a formulação de políticas públicas.

A Estatística Matemática tem seus fundamentos no desenvolvimento da Teoria das Probabilidades, antes, com tratamento mais informal, nos trabalhos de Pierre de Fermat, Blaise Pascal e Christian Huygens no século XVII e Thomas Bayes no século XVIII. O rigor matemático também se expandiu no século XVIII com as obras *Ars Conjectandi* (1713) de Jakob Bernoulli e *The Doctrine of Chances* de Abraham Moivre (1718). A formalização matemática rigorosa das probabilidades veio ao auge com Andrei Kolmogorov no século XIX.

A disciplina estatística também tem laços com a Teoria de Erros, cujas origens remontam a *Opera Miscellanea* de Roger Cotes de 1772, e sua reedição por Thomas Simpson em 1755, que aplicou a teoria a erros de observação. A Teoria de Erros ganhou um aspecto mais analítico ainda no final do século XVIII e ao longo do XIX nas mãos de Pierre-Simon de Laplace, Joseph Louis Lagrange e Daniel Bernoulli. O seminal Método dos Mínimos Quadrados (MMQ) foi desenvolvido e publicado independentemente por Adrien-Marie Legendre, Carl Friedrich Gauss e Robert Adrain.

Com o desenvolvimento e sofisticação das técnicas estatísticas, como a amostragem, modelagem e inferência, a estatística na virada do século XIX para o XX, expandiu-se da esfera do Estado para se tornar uma disciplina aplicada em ciências naturais, sociais, administração pública e privada. Neste contexto, figuram nomes George Box, Pafnuty Chebyshev, Gertrude Cox, George Dantzig, Edward Deming, Bruno de Finetti, Sir Ronald Fisher, Sir Francis Galton, Aleksandr Lyapunov, Karl Pearson, Charles Spearman e John Tukey.

Atualmente a estatística é a disciplina central em qualquer outra área para lidar com dados e incertezas. O avanço das técnicas computacionais viabilizaram o desenvolvimento de técnicas e aplicações estatísticas cada vez mais robustas e complexas para lidar com quantidades massivas de dados e geração de conhecimento e compreensão para diversas

áreas, como economia, ciências sociais, computação, inteligência de negócios, saúde, etc.

o.1.2 Modelos Estatísticos

A estatística é um ramo da matemática aplicada e da metodologia científica que busca extrair, reduzir, analisar e modelar um conjunto de dados que amostram uma população. Para isso, são usadas principalmente as ferramentas teóricas providas pela Teoria das Probabilidades, pois entende-se que os dados originam-se de fenômenos aleatórios, e, uma vez modelados, geralmente dois objetivos visam ser cumpridos: estimar ou prever o comportamento dos dados no futuro, ou realizar inferência, que consiste em detectar os padrões embutidos. A inferência pode ser feita por duas abordagens: a inferência dedutiva, que aceita determinadas premissas para chegar às conclusões, ou a inferência indutiva, que parte de casos particulares para generalizar.

Ainda sobre a inferência estatística, quando tenta-se modelar um determinado conjunto de dados, tentamos identificar padrões e tendências de comportamento através de modelos estatísticos. Supondo que temos um conjunto de dados D , e identificamos que conseguimos ajustar a eles um modelo M , teremos então que

$$D = M + R$$

onde R descreve a parte aleatória dos dados que não pode ser capturada pelo modelo, chamada de resíduos. Normalmente, busca-se que resíduos não devam conter nenhuma suavidade, pois isso implicaria em padrões que o modelo falhou em capturar, e mais suavização por parte de M será necessária.

o.1.3 Análise de Dados

A Análise de Dados consiste na inspeção, limpeza, transformação e modelagem de dados com o objetivo claro de obter informações úteis, informar conclusões ou apoiar a tomada de decisão. Em resumo, ela é o processo de extração de dados brutos para geração de conhecimento acionável, geralmente feito num ciclo iterativo. As fases desse processo podem ser divididas em:

1. Requisitos de Dados: a escolha de dados a serem extraídos dependem das análises que se deseja realizar. Aqui define-se a **unidade experimental**, que pode consistir de um indivíduo ou uma população deles, e as **variáveis** específicas dessa unidade, como idade e renda para uma população de pessoas.
2. Coleta de Dados: consiste na tarefa de obter os dados de diferentes fontes, como bancos de dados estruturados ou não-estruturados, sensores físicos, formulários, uma interface de programação de aplicação (API), arquivos binários ou de textos, entre muitas outras fontes.

3. **Processamento e Limpeza:** inclui tarefas de organizar os dados em formatos estruturados, identificar tipos, deduplicar, tratar valores faltantes, incorretos e desviantes e transformar o formato de dados para outros mais convenientes.
4. **Análise Exploratória:** compreende uma gama de técnicas para descrever e resumir os dados obtidos à procura de informações que ajudem entender relações entre as variáveis e guie às técnicas a serem aplicadas nas fases posteriores. Aqui é comumente aplicadas técnicas da Estatística Descritiva e métodos gráficos.
5. **Modelagem:** são usados algoritmos e modelos estatísticos para extrair padrões latentes nos dados, muitas vezes não triviais de serem identificados. As técnicas de aprendizado estatístico são especialmente úteis nessa etapa.
6. **Comunicação e Produto de Dados:** a depender do contexto e das finalidades definidas a priori, busca-se maneiras de comunicar esses dados aos atores interessados na forma de visualizações e relatórios. Nos últimos anos, a disciplina de **Narrativa de Dados** tem se destacado para realizar essa comunicação.

A Análise de Dados, do ponto de vista da Estatística, poderia ser dividida em

1. **Estatística Descritiva:** utilizar medidas de resumo numéricas para os dados a fim de descrever padrões visíveis, geralmente respondendo perguntas do tipo “o que aconteceu?”.
2. **Análise Exploratória:** semelhante a anterior, porém empregando métodos mais flexíveis e visuais que permitam identificar padrões mais ocultos, correlações e anomalias. Ocorre num processo iterativo de formulação de perguntas, exploração e descobertas.
3. **Análise Conformatória:** aplica as técnicas da inferência estatística para confirmar ou rejeitar hipóteses existentes das etapas anteriores

Contents

o.1	Visão Geral da Estatística e Análise de Dados	2
o.1.1	Uma Breve História da Estatística	2
o.1.2	Modelos Estatísticos	3
o.1.3	Análise de Dados	3
I	Distribuições	8
1	Probabilidades	9
1.1	Probabilidades	9
1.1.1	A Teoria de Probabilidades	9
1.1.2	σ -Álgebras	10
1.1.3	Axiomas de Kolmogorov	11
1.2	Cálculo das Probabilidades	11
1.3	Probabilidade Condicional e Independência	13
1.4	Teorema de Bayes	16
2	Variáveis Aleatórias	18
2.1	Variáveis Aleatórias	18
2.2	Função de Distribuição Acumulada	19
2.3	Variáveis Aleatórias Discretas	20
2.4	Variáveis Aleatórias Contínuas	22
2.5	Transformações	23
2.5.1	Transformação de Variáveis Discretas	24
2.5.2	Transformação de Variáveis Contínuas	25
2.6	Esperança de Variáveis Discretas	26
2.7	Modelos de Distribuição Discreta	28
2.7.1	Distribuição Bernoulli	28
2.7.2	Distribuição Binomial	29
2.7.3	Distribuição Geométrica	31
2.7.4	Distribuição Binomial Negativa	32

2.7.5	Distribuição Hipergeométrica	33
2.7.6	Distribuição de Poisson	35
3	Variáveis Aleatórias Contínuas	37
4	Variáveis Aleatórias Multidimensionais	38
5	Simulação	39
II	Análise Exploratória	40
6	Modelos e Descrição de Dados	41
6.1	Tipos de Dados	41
6.2	Escala de Dados	42
6.3	Tabelas de Frequência	42
6.4	Gráficos	43
7	Medidas de Resumo	45
7.1	Medidas de Posição	45
7.2	Medidas de Dispersão	46
8	Análise de Dados de Duas Variáveis	47
III	Inferência Clássica	48
9	Amostragem	49
10	Estimação de Parâmetros	50
11	Testes de Hipóteses	51
12	Inferência Multipopulacional	52
13	Análise de Aderência e Adesão	53
14	Teste de Hipótese Não Paramétricos	54
IV	Regressão	55
15	Covariância e Correlação	56

<i>CONTENTS</i>	7
16 Regressão Linear	57
17 Regressão Linear Generalizada	58
V Inferência Bayesiana	59
18 Paradigma Bayesiano	60
19 Inferência e Decisão	61
20 Computação Bayesiana	62
VI Séries Temporais	63
21 Fundamentos de Séries Temporais	64
22 Modelagem e Previsão	65

Part I

Distribuições

Chapter 1

Probabilidades

1.1 Probabilidades

1.1.1 A Teoria de Probabilidades

Ao observar, registrar ou extrair uma amostra de dados a partir de um fenômeno aleatório, isto é, cujo resultado não pode ser deterministicamente previsto, a Estatística, dentre outras coisas, procura entender o comportamento das frequências de ocorrência dos valores amostrados. Essas frequências são estimativas das **probabilidades** dos eventos observados. A partir de hipóteses adequadas, podemos modelar as frequências por modelos probabilísticos que, por sua vez, são objetos de estudo da Teoria das Probabilidades.

A Teoria de Probabilidades encontra seus fundamentos em alguns campos da matemática pura, tais como a Matemática Discreta, Análise e Teoria da Medida. No entanto, neste texto, estaremos mais interessados na visão da teoria para aplicações estatísticas, como a já a modelagem de frequências e estimação de parâmetros de modelos.

Probabilidades são frequentemente representadas como porcentagens e são muitas vezes entendidas como a frequência de um evento quando se repete o experimento um número suficiente de vezes. Por exemplo, dizer que 16% da população possui diploma de graduação significaria que se escolhermos aleatoriamente 100 pessoas dessa população, cerca de 16 delas teriam diploma de graduação. Essa abordagem é chamada de **frequentista**, sendo a mais amplamente adotada em aplicações estatísticas clássicas.

Outra abordagem para compreender probabilidades é enquanto o grau de crença numa hipótese, como ao dizer que se tem 80% de certeza em dizer que irá chover, visto as evidências do céu nublado e ventos frios. Essa é uma visão mais intuitiva e moderna de probabilidades, sendo chamada de **Bayesiana**, sendo a base da Inferência Bayesiana.

1.1.2 σ -Álgebras

A noção primitiva que iremos usar como base será de experimento ou fenômeno aleatório, que modela qualquer fenômeno cujos resultados são conhecidos, porém podem ser distintos apesar da repetição de condições iniciais.

Definição 1.1. O espaço amostral Ω de um experimento aleatório é o conjunto de todos os resultados possíveis do experimento.

Alguns subconjuntos de um espaço amostral compõem um **evento** do experimento aleatório. Intuitivamente, para serem “bem-comportados”, os eventos devem satisfazer algumas regras que possibilitem determinar outros eventos “bem comportados”. Formalmente, os eventos devem compor uma σ -Álgebra.

Definição 1.2. Seja Ω um conjunto e $\mathcal{B} \subset \mathcal{P}(\Omega)$. O conjunto $\mathcal{B}$ é uma σ -Álgebra de Ω se, e somente se,

$$\text{i } \emptyset \in \mathcal{B}.$$

$$\text{ii } \forall A \in \mathcal{B}, A^c \in \mathcal{B}.$$

$$\text{iii } \forall A \in \mathcal{B}, \bigcup_{i=1}^{\infty} A_i \in \mathcal{B}.$$

Se Ω é um espaço amostral, então $A \in \mathcal{B}$ é denominado evento de Ω .

Em resumo, (i) diz que a ausência de resultados é um evento, (ii) afirma que os resultados possíveis que não estão num determinado evento compõem um evento, e (iii) afirma que a reunião de uma lista – possivelmente infinita – de eventos forma um evento.

Proposição 1.1. Se $\mathcal{B}$ é uma σ -Álgebra do espaço amostral Ω , e $\{A_1, A_2, \dots\} \subset \mathcal{B}$, então

$$\bigcap_{i=1}^{\infty} A_i \in \mathcal{B}$$

Demonstração.

$$\bigcup_{i=1}^{\infty} A_i^c \in \mathcal{B} \iff \left(\bigcap_{i=1}^{\infty} A_i \right)^c \in \mathcal{B}$$

o que leva a

$$\bigcap_{i=1}^{\infty} A_i \in \mathcal{B}$$

■

1.1.3 Axiomas de Kolmogorov

Para cada evento de um espaço amostral podemos associar uma probabilidade, que consiste numa medida do evento. Iremos requerer que essa medida seja não negativa e no máximo 1, de modo a se adequar a nossa intuição de probabilidade como um número entre 0 e 1. Além disso, se esperamos que o experimento tenha algum evento, então é razoável presumir que a probabilidade do próprio espaço amostral é igual a 1.

Definição 1.3 (Axiomas de Kolmogorov). Seja $\mathcal{B}$ uma σ -Álgebra de um conjunto Ω . Uma medida de probabilidade $P : \mathcal{B} \rightarrow \mathbb{R}$ satisfaz:

- i $\forall E \in \mathcal{B}, P(E) \geq 0$
- 1. $P(\Omega) = 1$
- 2. Se $\{E_1, E_2, \dots\}$ são eventos disjuntos em Ω , então

$$P\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} P(E_i)$$

Num experimento aleatório, dados os resultados conhecidos, as coleções desses resultados que compõem eventos e uma medida da probabilidade desses eventos, obtemos, então, o espaço de probabilidade do experimento.

Definição 1.4. A tripla $(\Omega, \mathcal{B}, P)$ é um espaço de probabilidade se, e somente se,

- i Ω é um espaço amostral
- ii $\mathcal{B}$ é uma σ -Álgebra de Ω
- iii $P : \mathcal{B} \rightarrow \mathbb{R}$ é uma medida de probabilidade.

1.2 Cálculo das Probabilidades

Para espaços amostrais enumeráveis, ao associar a cada resultado individual um número em $[0, 1]$, então a soma dos pesos dos resultados presentes num evento é a probabilidade desse evento.

Teorema 1.1. Seja $\Omega = \{\omega_i\}_{i \in \mathbb{N}}$ um espaço amostral enumerável, e $\mathcal{B}$ uma σ -Álgebra de Ω . Seja $(p_i)_{i \in \mathbb{N}}$ uma sequência de números não negativos cuja soma é 1. Presuma também que, se $A \in \mathcal{B}$, então

$$P(A) = \sum_{\omega_i \in A} p_i.$$

A tripla $(\Omega, \mathcal{B}, P)$ é um espaço de probabilidade.

Demonstração. Precisamos provar que P é uma medida de probabilidade que satisfaz os Axiomas de Kolmogorov.

Não negatividade a soma de números não negativos é não negativa, então para todo A em $\mathcal{B}$ vale que $P(A) \geq 0$.

Probabilidade do espaço amostral A série $\sum_{i=1}^{\infty}$ deve coincidir com a probabilidade de Ω , série essa que será igual a 1 por hipótese.

Soma de eventos disjuntos Seja $\{A_j\}_{j \in \mathbb{N}}$ uma família disjunta de eventos de $\mathcal{B}$ tal que

$$A_j = \{\omega_i \mid i \in I_j\}$$

em que I_j é um conjunto de índices. Tão logo obtemos

$$P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} \sum_{i \in I_j} p_{ji} = \sum_{j=1}^{\infty} P(A_j)$$

■

Esse resultado é útil para computar a probabilidade de uma vasta gama de experimentos aleatórios na prática. Um exemplo é o lançamento de um dado de 6 faces; se acreditamos que o dado é honesto, isto é, que o dado não é viciado em nenhuma de suas faces, então podemos associar $1/6$ a cada face do dado. Se por exemplo, deseja-se saber a probabilidade de obtermos um número menor ou igual a 3, basta somar as faces que satisfazem essa condição, obtendo uma probabilidade de 0.5. Experimentos os quais acreditamos não conterem vícios são chamados de equiprováveis.

As σ -Álgebras que equivalem ao conjunto das partes do espaço amostral são chamadas de σ -Álgebra potência. Quando o espaço amostral do experimento é enumerável, ocorre que cada subconjunto unitário do espaço amostral – um resultado individual – é um evento do experimento. Se o experimento é equiprovável, então todos os resultados são eventos de mesma probabilidade.

Definição 1.5. Seja o espaço $(\Omega, \mathcal{B}, P)$ com Ω finito, $\mathcal{B} = \mathcal{P}(\Omega)$ e P definido como no Teorema 1.1. Chama-se esse espaço de equiprovável se, e somente se,

$$\forall i \in [n], P(\omega_i) = \frac{1}{n}$$

onde $n = |\Omega|$.

A probabilidade de eventos em experimentos com resultados equiprováveis destaca-se por ser intuitiva de calcular. A probabilidade de evento será, simplesmente, a fração dos resultados presentes nele. Esse resultado será enunciado como Corolário do Teorema 1.1.

Corolário 1.1. A probabilidade de um evento $A \in \mathcal{P}(\Omega)$ num espaço $(\Omega, \mathcal{P}(\Omega), P)$ equiprovável é igual a

$$\frac{|A|}{|\Omega|}$$

Demonstração.

$$P(A) = |A| \cdot \frac{1}{|\Omega|} = \frac{|A|}{|\Omega|}$$

■

1.3 Probabilidade Condicional e Independência

A probabilidade condicional representa o conceito de probabilidade de um evento tal que é conhecida a ocorrência de outro; como se tivéssemos reduzido o espaço amostral a um conjunto menor de resultados possíveis. Outra interpretação possível é aquela tal que associamos uma probabilidade a um evento tendo o conhecimento de uma evidência sobre ele.

Definição 1.6. Sejam E e F eventos num espaço amostral Ω . A probabilidade condicional do evento E dado F , denotada por $P(E|F)$, é dada por

$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

A probabilidade condicional induz uma forma de determinar a probabilidade do evento dado como interseção de vários outros.

Proposição 1.1 (Regra do Produto). Se $\mathcal{F} = \{E_1, \dots, E_n\}$ uma família de eventos de Ω , então

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = \prod_{i=1}^n P\left(E_i \mid \bigcap_{j < i} E_j\right)$$

Demonstração. A prova será por indução em n

Base: $n = 1$ é trivial.

Hipótese de Indução: admita que o resultado vale para uma família de n eventos. Se $|\mathcal{F}| = n + 1$, então fazemos

$$\bigcap_{j < n+1} E_j = E'$$

e obtemos que

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P(E' \cap E_n) = P(E_n|E')P(E').$$

Como a hipótese de indução vale para E' , então

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P\left(E_n \left| \bigcap_{j < n+1} E_j \right.\right) \cdot \prod_{i=1}^n P\left(E_i \left| \bigcap_{j < i} E_j \right.\right) = \prod_{i=1}^{n+1} P\left(E_i \left| \bigcap_{j < i} E_j \right.\right)$$

Uma vez que a proposição vale para $n + 1$, então vale para todo $n \in \mathbb{N}$ pelo princípio de indução. ■

Eventos independentes são aqueles cuja probabilidade de ocorrência não depende da ocorrência de outro. Isso equivale a dizer que, o conhecimento do acontecimento de um evento não muda a crença na ocorrência de outro.

Definição 1.7. Dois eventos E e F dum espaço amostral Ω são independentes se, e somente se

$$P(E \cap F) = P(E) \cdot P(F)$$

Proposição 1.2. Se E e F são eventos independentes de Ω , então

$$P(E|F) = P(E) \quad e \quad P(F|E) = P(F)$$

Demonstração. Por definição de probabilidade condicional,

$$P(E \cap F) = P(E|F) \cdot P(F)$$

mas como E e F são independentes por hipótese,

$$\begin{aligned} P(E) \cdot P(F) &= P(E|F) \cdot P(F) \\ P(E) &= P(E|F) \end{aligned}$$

e o mesmo pode ser mostrado analogamente para $P(F)$. ■

Proposição 1.3. Sejam E e F eventos em Ω . Se eles são independentes, então os seguintes eventos também o são:

1. E^c e F
2. E e F^c
3. E^c e F^c

Demonstração. (1) É verdade que

$$(E \cap F) \cap (E \cap F^c) = \emptyset$$

e também que

$$(E \cap F) \cup (E \cap F^c) = E$$

então

$$P(E \cap F) + P(E \cap F^c) = P(E)$$

donde segue que

$$\begin{aligned} P(E \cap F^c) &= P(E) - P(E \cap F) = P(E) - P(E)P(F) = P(E) \cdot [1 - P(F)] \\ P(E \cap F^c) &= P(E) \cdot P(F^c) \end{aligned}$$

A expressão (2) é análoga a (1). Por fim, para expressão (3), conclua que

$$\begin{aligned} P(E^c \cap F^c) &= P((E \cup F)^c) = 1 - P(E \cup F) \\ &= 1 - P(E) - P(F) + P(E \cap F) \\ &= P(E^c) - P(F) + P(E) \cdot P(F) \\ &= P(E^c) - P(F)[1 - P(E)] \\ &= P(E^c) - P(F) \cdot P(E^c) \\ &= P(E^c)[1 - P(F)] \\ &= P(E^c) \cdot P(F^c) \end{aligned}$$

■

Teorema 1.1 (Teorema de Probabilidade Total). Seja Ω um espaço amostral e $\mathcal{F} = \{F_1, \dots, F_n\}$ uma partição de Ω . Se E é um evento de Ω , então

$$P(E) = \sum_{F \in \mathcal{F}} P(E) \cdot P(E|F)$$

Demonstração. Para quaisquer $i, j \in [n]$ temos que

$$(E \cap F_i) \cap (E \cap F_j) = \emptyset.$$

Com isso,

$$P\left(\bigcup_{F \in \mathcal{F}} E \cap F_i\right) = \sum_{F \in \mathcal{F}} P(E \cap F)$$

Em vista de que

$$\bigcup_{F \in \mathcal{F}} E \cap F_i = E \cap \Omega = E,$$

então

$$P(E) = \sum_{F \in \mathcal{F}} P(E \cap F),$$

e pela Proposição 1.3, conclui-se que

$$P(E) = \sum_{F \in \mathcal{F}} P(E) \cdot P(E|F).$$

■

1.4 Teorema de Bayes

Teorema 1.2 (Teorema de Bayes). Se E e F são eventos de um espaço amostral Ω , então

$$P(E|F) = P(F|E) \frac{P(E)}{P(F)}$$

Demonstração.

$$\begin{aligned} P(E|F) \cdot P(F) &= P(E \cap F) = P(F|E)P(E) \\ P(E|F) &= P(F|E) \frac{P(E)}{P(F)} \end{aligned}$$

■

Uma interpretação para o teorema é a atualização na crença $P(E)$, chamada de **prior**, numa hipótese E dada uma nova evidência F para ela, obtendo um novo grau de crença $P(E|F)$ chamado de **posterior**. A probabilidade $P(F|E)$ é chamada de **verossimilhança**, denotando o quão verossímil é observar a evidência F considerando a hipótese E verdadeira. Por sua vez, $P(F)$ é a crença na ocorrência de F tendo em vista todas as hipóteses, que, junto com a verossimilhança, ajusta o novo grau de crença em E .

Se num dado experimento aleatório consideramos hipóteses $E_1, \dots, E_n$ e obtemos uma evidência F , é plausível questionar em qual hipótese deveríamos depositar maior crença visto a evidência. Consideremos então o corolário:

Corolário 1.2 (Fórmula de Bayes). Seja $\mathcal{E} = \{E_1, \dots, E_n\}$ uma partição de um espaço amostral Ω . Se E é um evento de Ω , então

$$P(E_i|F) = \frac{P(F|E_i)P(E_i)}{\sum_{E \in \mathcal{E}} P(E)P(F|E)}$$

Demonstração. Segue do Teorema de Bayes e do Teorema da Probabilidade Total. ■

Logo, para cada hipótese, poderíamos utilizar a Fórmula de Bayes para computar a crença *a posteriori* nela após a evidência F , e selecionar aquela que tivesse maior probabilidade.

Chapter 2

Variáveis Aleatórias

2.1 Variáveis Aleatórias

Variáveis aleatórias (v.a.) são representações de características numéricas de experimentos aleatórios. Exemplos são a quantidade de caras obtidas no lançamento de uma moeda, a soma dos lados de um dado, número de erros num livro, tempo até a um equipamento apresentar falha, entre muitos outros. As v.a.'s podem ser formalizadas como funções que associam cada resultado do espaço amostral a um número real.

Definição 2.1. Se Ω é um espaço amostral, então uma variável aleatória X é uma aplicação de Ω em $\mathbb{R}$.

Introduzamos uma forma que nos permite definir eventos a partir de variáveis aleatórias e os valores que elas mapeiam um determinado resultado no espaço amostral.

Definição 2.2. Seja $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. Se $A \subset \mathbb{R}$, então o evento denotado por $\{X \in A\}$ é equivalente a

$$\{\omega \in \Omega \mid X(\omega) \in A\}$$

Um caso especial dessa forma de definir eventos por meio de variáveis são as realizações, que representam os casos em que queremos dizer qual foi o valor ao qual a variável mapeou o resultado do experimento aleatório.

Definição 2.3. Seja $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. Chamamos de realização de X igual a x o evento definido por $\{\omega \in \Omega \mid X(\omega) = x\}$.

Muitos outros predicados podem ser úteis para sintetizar eventos em termos dos valores assumidos por uma variável. Por exemplo, para dizer que uma variável X teve real-

ização menor do que x , então representamos por $\{X < x\}$. Ou que a realização de X está no intervalo $[a, b]$, denotamos por $\{X \in [a, b]\}$.

O conjunto dos valores cuja probabilidade da realização é não nula é chamado de suporte. Por exemplo, no lançamento de um dado, as realizações possíveis são os inteiros de 1 a 6, enquanto os demais inteiros tem probabilidade nula. Coletando dados sobre o peso corporal de uma população, o suporte é, em tese, qualquer valor positivo.

Definição 2.4. Seja $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. O suporte de X é o conjunto

$$\Omega_X = \{x \in \mathbb{R} \mid \forall a, b \in \mathbb{R}, (x \in (a, b) \rightarrow P(X \in (a, b)) > 0)\}$$

2.2 Função de Distribuição Acumulada

A função de distribuição acumulada (FDA) informa, para cada ponto na reta real, a probabilidade de que a variável assuma um valor menor ou igual ao do ponto.

Definição 2.5. Seja $X : \Omega \rightarrow \mathbb{R}$ e $F : \mathbb{R} \rightarrow \mathbb{R}$. A função F é uma função de distribuição acumulada para X se, e somente se,

$$P(X \leq x) = F(x)$$

Para uma dada função ser de distribuição acumulada, é necessário e suficiente que ela cumpra alguns requisitos: ser não decrescente, ser contínua à direita e convergir para 0 e 1 no sentido de $-\infty$ e ∞ respectivamente.

Teorema 2.1. Se $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de distribuição acumulada de uma variável aleatória X , então

1. $\forall x_1, x_2 \in \mathbb{R}, (x_1 \leq x_2 \rightarrow F(x_1) \leq F(x_2))$
2. $\forall x, a \in \mathbb{R}, (\lim_{x \rightarrow a^+} F(x) = F(a))$
3. $\lim_{x \rightarrow \infty} F(x) = 1$
4. $\lim_{x \rightarrow -\infty} F(x) = 0$

Demonstração. A afirmação (1) segue do fato de que, se $x_1 \leq x_2$, então

$$(X \leq x_1) \subset (X \leq x_2)$$

logo

$$P(X = x_1) \leq P(X = x_2) \implies F(x_1) \leq F(x_2).$$

Seguindo para a afirmação (2),

$$\lim_{x \rightarrow a^-} F(x) = \lim_{x \rightarrow a^+} P(X \leq x)$$

Se x decresce até a , então os eventos $\{X \leq x\}$, para $x > a$, formam uma sequência decrescente de eventos cuja interseção é $\{X \leq a\}$. Pela continuidade de probabilidades, temos que

$$\lim_{x \rightarrow a^+} P(X \leq x) = P\left(\lim_{x \rightarrow a^+} X \leq x\right) = P(X \leq a) = F(a)$$

Para as afirmações (3) e (4), considere a sequência de intervalos encaixados

$$I_1 \subset I_2 \subset \dots$$

com extremos inferiores e superiores a_i e b_i respectivamente com $i \in \mathbb{N}$. Os eventos $\{X \leq b_i\}$ formam uma sequência crescente de eventos encaixados tal que

$$\lim_{n \rightarrow \infty} \{X \leq b_n\} = \{X \leq \infty\}$$

Novamente, pela continuidade da probabilidade,

$$\lim_{x \rightarrow \infty} F(x) = \lim_{x \rightarrow \infty} P(X \leq x) = P\left(\lim_{x \rightarrow \infty} X \leq x\right) = P(X \leq \infty) = 1$$

O argumento é replicável para (4): a sequência de eventos $\{X \leq a_i\}$ converge para $\{X \leq -\infty\}$, de sorte que

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{x \rightarrow -\infty} P(X \leq x) = P\left(\lim_{x \rightarrow -\infty} X \leq x\right) = P(X \leq -\infty) = 0$$

■

2.3 Variáveis Aleatórias Discretas

Definição 2.6. Se X é uma variável aleatória, então X é discreta se, e somente se, seu suporte seja enumerável.

Definição 2.7. Seja $X : \Omega \rightarrow \mathbb{R}$ uma v.a. discreta. A função $p_X : \mathbb{R} \rightarrow \mathbb{R}$ é a função de massa de probabilidade de X se, e somente se,

$$P(X = x) = p_X(x)$$

Proposição 2.1. Seja $X : \Omega \rightarrow \mathbb{R}$ uma v.a. discreta com f.m.p. igual a p_X e suporte Ω_X . Se $A \subset \Omega_X$, então

$$P(X \in A) = \sum_{a \in A} p_X(a)$$

Demonstração. Como Ω_x é enumerável, então A também é. Presuma que $A = \{a_1, a_2, \dots\}$ seja uma ordenação de A , de modo que

$$P(X \in A) = P(X \in \{a_1, a_2, \dots\}) = P\left(X \in \bigcup_{a \in A} \{a\}\right),$$

portanto,

$$P(X \in A) = \sum_{a \in A} P(X = a) = \sum_{a \in A} p_X(a)$$

■

Pela definição de variáveis discretas, então digamos que $\{x_1, x_2, \dots\}$ seja uma ordenação de Ω_X de tal modo

$$F(X) = \begin{cases} 0, & \text{se } x < x_1 \\ F(x_1), & \text{se } x_1 \leq x < x_2 \\ \vdots & \\ F(x_i), & \text{se } x_i \leq x < x_{i+1} \\ \vdots & \end{cases}.$$

A função F é, pois, uma função constante por partes que sempre incluem a extremidade esquerda de seu domínio devido à propriedade necessária de uma FDA sempre ser contínua à direita. Uma vez que

$$\begin{aligned} P(X = x_i) &= P(X \leq x_i) - P(X < x_i) \\ P(X = x_i) &= F(x_i) - \lim_{x \rightarrow x_i^-} F(x) \\ P(X = x_i) &= F(x_i) - F(x_{i-1}), \end{aligned}$$

então $p_X(x_i)$ é o salto entre duas partes consecutivas da FDA de X .

Exemplos de variáveis aleatórias discretas incluem

- Número de caras obtidas em 10 lançamentos.
- Soma dos lados obtidos no lançamento de dados.
- Número de clientes em uma loja em um dia.

No primeiro exemplo, as realizações possíveis são os inteiros de 0 a 10. Nos dois seguintes, são todos os naturais. Todos esses são conjunto enumeráveis, cujos pontos isoladamente concentram massa de probabilidade, isto é, um valor efetivo de probabilidade associado à ao evento da variável de ter realização naquele ponto.

2.4 Variáveis Aleatórias Contínuas

Definição 2.8. Seja X uma variável aleatória com FDA igual a $F(x)$. A variável será contínua se, e somente se,

$$F(x) = \int_{-\infty}^x f(u) du$$

As variáveis contínuas, diferentes das discretas, não permitem uma boa definição de uma função para a probabilidade de realização da variável em um ponto. Isso porque a probabilidade de uma variável contínua ter realização em um ponto $x \in \mathbb{R}$ é sempre igual a zero.

Teorema 2.2. Se X é uma variável aleatória contínua, então

$$\forall x \in \mathbb{R}, (P(X = x) = 0)$$

Demonstração. Sejam $a, b \in \mathbb{R}$ tal que $a < b$. Disso temos,

$$\begin{aligned} P(X = a) &= P(X \leq a) - P(X < a) \\ &= F(a) - \lim_{x \rightarrow a^-} F(a) \end{aligned}$$

já que a definição de variável contínua implica que $F(x)$ é contínua, então

$$\begin{aligned} P(X = a) &= F(a) - \lim_{x \rightarrow a^-} F(x) \\ &= F(a) - F(a) \\ &= 0 \end{aligned}$$

■

Dessa maneira, a análise da probabilidade de uma realização x para uma variável contínua X somente pode ocorrer em vizinhanças de x , mas nunca pontualmente. Chamamos a probabilidade de X ter realização num intervalo de **densidade do intervalo**.

Definição 2.9. Seja X uma variável aleatória contínua. A função $f : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de densidade para X se, e somente se,

$$F(x) = \int_{-\infty}^x f(x) dx$$

Proposição 2.2. Se X é uma variável aleatória contínua, então

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Demonstração. Com efeito

$$\int_{-\infty}^{\infty} f(x)dx = \lim_{x \rightarrow \infty} F(x) - \lim_{x \rightarrow -\infty} F(x) = 1 - 0 = 1$$

■

Exemplos de variáveis aleatórias contínuas são

Exemplos de variáveis aleatórias contínuas

- Tempos de espera em algum serviço.
- Peso ou altura de pessoas numa população.
- Temperatura ao longo de um ano.

Essas variáveis variam de forma contínua num intervalo de valores, de forma que não possível haver valores que concentrem uma massa de probabilidade, sendo essa totalmente dispersada pelo intervalo. Em vista disso, a probabilidade de que a variável tenha um valor específico é zero, o que nos leva ao conceito de densidade de probabilidade sobre intervalos de valores.

2.5 Transformações

Definição 2.10. Uma transformação de uma variável aleatória $X : \Omega \rightarrow \mathbb{R}$ com imagem $\mathcal{X}$ é toda função $f : \mathcal{X} \rightarrow \mathbb{R}$.

Toda transformação define uma nova variável aleatória. Isso porque a função composta $f \circ X : \Omega \rightarrow \mathbb{R}$ é, por definição, uma variável aleatória.

Definição 2.11. Se $X : \Omega \rightarrow \mathbb{R}$ é uma variável aleatória e f é uma transformação de X , então $f(X)$ equivale à variável definida por

$$f \circ X$$

A transformação não necessariamente é bijetora, o que nos leva a ter de tratar sobre a sua distribuição de probabilidade a partir da distribuição de X com um pouco mais de cuidado. Antes de tudo, iremos definir uma generalização de uma função inversa para f .

Definição 2.12. Se $f : D \rightarrow \mathbb{R}$ é uma função real, então $f^\dagger : \mathcal{P}(\mathbb{R}) \rightarrow \mathcal{P}(D)$ é tal que

$$f^\dagger(A) = \{x \in D \mid f(x) \in A\}.$$

Em especial, se $y \in \mathbb{R}$, então

$$f^\dagger(y) = f^\dagger(\{y\})$$

Proposição 2.3. Seja X uma variável aleatória, f uma transformação e $A \subset \mathbb{R}$.

$$P(f(X) \in A) = P(X \in f^\dagger(A))$$

Demonstração.

$$\begin{aligned} P(f(X) \in A) &= P(\{x \in \mathbb{R} \mid f(x) \in A\}) \\ &= P(X \in f^\dagger(A)) \end{aligned}$$

■

2.5.1 Transformação de Variáveis Discretas

Teorema 2.3. Seja X uma variável discreta com suporte Ω_X , f.m.p. igual a p_X , f uma transformação de X e $Y = f(X)$. A variável Y é discreta e sua f.m.p é dada por

$$p_Y(y) = \sum_{x \in f^\dagger(y)} p_X(x)$$

Demonstração. De 2.3 sabemos que

$$P(Y \in A) > 0 \iff P(X \in f^\dagger(A)) > 0,$$

o que ocorre também se, e somente se, $A \cap \Omega_X \neq \emptyset$. Essa afirmação é verdade somente quando há $x \in \mathbb{R}$ que satisfaz $f(x) \in A$ e $x \in \Omega_X$. Portanto, $y \in \Omega_Y$ ocorre somente quando $y = f(x)$ e $x \in \Omega_X$, ou seja, Ω_Y é a imagem de Ω_X sobre f , sendo, pois, enumerável.

O resultado sobre a f.m.p. de Y segue do fato de que

$$p_Y(y) = P(Y = y) = P(X \in f^\dagger(y))$$

e pela proposição 2.1, temos que

$$p_Y(y) = \sum_{x \in f^\dagger(y)} p_X(x)$$

■

2.5.2 Transformação de Variáveis Contínuas

Para transformações de variáveis contínuas, concentramos-nos, primeiramente, nas transformações monótonas, pois essas são bijetoras, e compõem casos mais simples para se analisar.

É possível obter a FDA de uma transformação monótona $Y = g(X)$ de uma variável X apenas em termos da própria FDA de X e da inversa da transformação.

Teorema 2.4. Seja X uma variável aleatória com FDA igual a F_X e suporte Ω_X . Seja também $Y = g(X)$ uma transformação monótona com suporte Ω_Y . Se g for crescente, então

$$\forall x \in \Omega_X \forall y \in \Omega_Y, F_Y(y) = F_X(g^{-1}(y)).$$

Se for decrescente, então

$$\forall x \in \Omega_X \forall y \in \Omega_Y, F_Y(y) = 1 - F_X(g^{-1}(y)).$$

Demonstração. Com efeito,

$$F_Y(y) = P(Y \leq y) = P(X \leq g^{-1}(y))$$

Sendo g monótona crescente, g^{-1} também será, de modo que

$$F_Y(y) = P(\{x \in \mathcal{X} \mid x \leq g^{-1}(y)\}) = \int_{-\infty}^{g^{-1}(y)} f(x) dx = F_X(g^{-1}(y))$$

■

Por sua vez, a densidade de transformações $Y = g(X)$ em casos em que a densidade de X é contínua, pode ser obtidas via a Regra da Cadeia do Cálculo Diferencial, com a condição de que a inversa de g seja também contínua em Ω_Y . Caso a densidade de X nem a inversa da transformação sejam contínuas em Ω_X e Ω_Y respectivamente, a regra da cadeia não poderia ser aplicada, complexificando a determinação da densidade de Y .

Teorema 2.5. Seja X uma variável aleatória com f.d.p. igual a f_X . Seja $Y = g(X)$ uma variável obtida pela transformação g e com suporte Ω_Y . Se g é monótona, f_X é contínua em Ω_X e g^{-1} tem derivada contínua em Ω_Y , então a f.d.p. de Y é dada por

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, & \text{caso contrário.} \end{cases}$$

O teorema 2.5 permite-nos a generalizar a obtenção da densidade de probabilidade de transformações não monótonas que podem ser decompostas em partes monótonas. Um exemplo clássico é a função $g(x) = x^2$ definida em $\mathbb{R}$. Essa função não é monótona, porém suas partes definidas separadamente em $(-\infty, 0)$ e $[0, \infty)$ serão. A densidade da variável definida pela transformação poderá, portanto, ser obtida pelo resultado a seguir

Teorema 2.6. Seja X uma variável aleatória com f.d.p. igual a f_X . Seja $Y = g(X)$ uma variável obtida pela transformação g e com suporte Ω_Y . Se Ω_X admite partição $\{A_1, \dots, A_n\}$ sendo possível definir a família de funções $\{g_i : A_i \rightarrow \mathbb{R}\}_{i \in [n]}$ tal que

- i $g_i(x) = g(x)$
- ii $g_i(x)$ é monótona em A_i
- iii Ω_Y é o mesmo para todo $i \in [n]$.
- iv g_i^{-1} tem derivada contínua em Ω_Y para todo $i \in [n]$.

e f_X contínua em cada A_i , então a f.d.p. de Y é dada por

$$f_Y(y) = \begin{cases} \sum_{i=1}^n f_X(g_i^{-1}(y)) \cdot \left| \frac{d}{dy} g_i^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, & \text{caso contrário.} \end{cases}$$

2.6 Esperança de Variáveis Discretas

A esperança de uma variável aleatória é definida matematicamente como a média ponderada dos valores assumidos por essa variável. Uma interpretação para esperança é que ela é o valor médio de todas as realizações da variável ao se repetir o experimento aleatório um número infinito de vezes. Essa interpretação será justificada posteriormente com a **Lei dos Grandes Números**.

Definição 2.13. Seja X uma v.a. discreta com f.m.p. p_X . A esperança $E[X]$ de X é definida tal como

$$E[X] = \sum_{x \in \Omega_X} x \cdot p_X(x)$$

A partir do conhecimento da distribuição dos valores de uma variável, é possível ter conhecimento da distribuição dos valores de uma função aplicada sobre essa variável. Se $X : \Omega \rightarrow \mathbb{R}$ e $f : \mathbb{R} \rightarrow \mathbb{R}$, então $f(X) = f \circ X$ é uma variável aleatória por definição. Digamos que $f(X) = Y$, então a massa de probabilidade $Y = y$ será a soma das probabilidades de $X = x$ tal que $x \in \Omega_X$ tem y como imagem em f , já que as realizações de uma v.a. são sempre disjuntas.

$$P(Y = y) = \sum_{\substack{x \in \Omega_X \\ f(x)=y}} P(X = x)$$

Tão logo conhecendo a distribuição de $f(X)$ a partir da distribuição de X , então poderemos expressar a esperança de $f(X)$ em termos da própria f.m.p. de X .

Proposição 2.4. Seja X uma v.a. discreta com f.m.p. p_X , e $f : \mathbb{R} \rightarrow \mathbb{R}$ uma função. A esperança da variável aleatória definida por $f(X) = f \circ X$ é dada por

$$E[f(X)] = \sum_{x \in \Omega_X} f(x) \cdot p_X(x)$$

Demonstração. Seja Ω_f o suporte de $f(X)$ e p_f a sua f.m.p.. Temos que

$$\begin{aligned} \sum_{x \in \Omega_X} f(x) \cdot p_X(x) &= \sum_{y \in \Omega_f} \sum_{\substack{x \in \Omega_x \\ f(x)=y}} y \cdot p_X(x) \\ &= \sum_{y \in \Omega_f} y \sum_{\substack{x \in \Omega_x \\ f(x)=y}} p_X(x) \end{aligned}$$

Fixando y , observamos que

$$p_f(y) = \sum_{\substack{x \in \Omega_x \\ f(x)=y}} p_X(x).$$

Logo

$$E[f(X)] = \sum_{y \in \Omega_f} y \cdot p_f(y).$$

■

A esperança satisfaz as propriedades de linearidade. Isso significa que, se uma v.a. é definida como uma constante, como produto de uma v.a. por uma constante ou como a soma de outras duas v.a.'s, podemos facilmente obter a esperança da variável derivada a partir das variáveis que a compõe. Ressaltemos que constantes podem ser vistas como v.a.'s com suporte unitário.

Proposição 2.5. Sejam X e Y variáveis aleatórias. A esperança satisfaz:

1. se X tem suporte unitário igual a $\{c\}$, então $E[X] = c$.
2. $E[\lambda X] = \lambda E[X]$.
3. $E[X + Y] = E[X] + E[Y]$.

Demonstração. Para (1), basta observar que $E[X] = c \cdot 1 = c$.

Para (2), usemos a definição de esperança:

$$E[\lambda X] = \sum_{x \in \Omega_X} \lambda x \cdot p_X(x) = \lambda \sum_{x \in \Omega_X} x \cdot p_X(x) = \lambda E[X].$$

Para provar (3), temos que

$$E[X + Y] = \sum_{x \in \Omega_X} \sum_{y \in \Omega_Y} (x + y)P(X = x, Y = y),$$

e expandindo,

$$E[X + Y] = \sum_{x \in \Omega_X} x \sum_{y \in \Omega_Y} P(X = x, Y = y) + \sum_{y \in \Omega_Y} y \sum_{x \in \Omega_X} P(X = x, Y = y). \quad (2.1)$$

Já que

$$\sum_{y \in \Omega_Y} P(X = x, Y = y) = \sum_{y \in \Omega_Y} P(X = x|Y = y)P(Y = y),$$

então pelo Teorema da Probabilidade Total,

$$\sum_{y \in \Omega_Y} P(X = x, Y = y) = P(X = x)$$

e, de forma análoga,

$$\sum_{x \in \Omega_X} P(X = x, Y = y) = P(Y = y),$$

então podemos simplificar a expressão 2.1 para

$$E[X + Y] = \sum_{x \in \Omega_X} x \cdot P(X = x) + \sum_{y \in \Omega_Y} y \cdot P(Y = y),$$

e, finalmente

$$E[X + Y] = E[X] + E[Y]$$

■

2.7 Modelos de Distribuição Discreta

Muitas características de fenômenos aleatórios podem ser modelados como variáveis aleatórias discretas, como determinar se o lançamento de uma moeda deu cara, quantas pessoas possuem diploma numa população de tamanho conhecido, quantas bolas de- vemos sortear de uma urna até que obtenhamos a que contém a cor desejada, etc.

2.7.1 Distribuição Bernoulli

A distribuição Bernoulli modela experimentos que só podem ter dois resultados possíveis: *sucesso* ou *fracasso*. Seu único parâmetro é a probabilidade p de obter *sucesso* no experimento. Dessa forma, podemos particionar o espaço amostral em dois eventos disjuntos:

$X = 0$ e $X = 1$. O primeiro é aquele cujos resultados são *fracassos*, obtidos com probabilidade $1 - p$, enquanto que no segundo são aqueles cujos resultados são *sucessos*, que ocorre com probabilidade p .

Definição 2.1. Suponha que Ω seja um espaço amostral e $\mathcal{P} = \{F, S\}$ uma partição de Ω . A variável X tem distribuição Bernoulli de parâmetro p , denotado por $X \sim \text{Bernoulli}(p)$, se, e somente se, X é a função indicadora de um membro de $\mathcal{P}$ e

$$P(X = 1) = p.$$

Da definição formal de uma distribuição Bernoulli, segue que seu suporte é o conjunto $\{0, 1\}$. Se $S \subset \Omega$ reúne os *sucessos*, então podemos escrever

$$P(S) = p \quad \text{e} \quad P(F) = 1 - p$$

e, caso Ω seja equiprovável, então

$$p = \frac{|S|}{|\Omega|}$$

Proposição 2.2. A f.m.p. da distribuição Bernoulli de parâmetro p é dada por

$$p_X(x) = p^x(1 - p)^{1-x}$$

Demonstração. Temos que

$$P(X = x) = \begin{cases} p, & \text{se } x = 1 \\ 1 - p, & \text{se } x = 0 \end{cases}$$

que equivale à fórmula desejada. ■

A esperança de uma Bernoulli é dada como

$$E[X] = 1 \cdot p + 0 \cdot (1 - p) = p.$$

Conclui-se que a taxa de sucessos é a própria probabilidade de obter um sucesso no experimento.

2.7.2 Distribuição Binomial

A distribuição binomial é uma versão mais generalizada da Bernoulli, modelando quantos sucessos são obtidos num experimento que consiste de n tentativas Bernoulli independentes, isto é, uma tentativa não altera no resultado da outra. Exemplo inclui quantas caras obtemos ao lançar uma moeda 10 vezes. Os parâmetros dessa distribuição são o

número de tentativas n e o número de sucessos p . Seu suporte será igual aos inteiros de 0 a n .

Cada uma das n tentativas Bernoulli são v.a.'s $X_k \sim \text{Bernoulli}(p)$, com $k \in [n]$, independentes. Logo, a probabilidade de um evento $(X_k = x_k)_{k \in [n]}$ com a sucessos, tendo fixado o valor de cada x_k , deve ser igual a

$$P((X_k = x_k)_{k \in [n]}) = \prod_{k=1}^n P(X_k = x_k),$$

mas como há a resultados $x_k = 1$, e $n - a$ resultados $x_k = 0$, então

$$P((X_k = x_k)_{k \in [n]}) = \prod_{k=1}^n P(X_k = x_k) = p^a (1 - p)^{n-a}$$

Como cada uma das sequências de resultados com a sucessos são mutuamente exclusivas, então

$$P(X = a) = m \cdot p^a (1 - p)^{n-a},$$

onde m é o número de sequências com a sucessos dentre n , que equivale a escolher a tentativas para serem sucessos dentre n possíveis, logo

$$P(X = a) = \binom{n}{a} \cdot p^a (1 - p)^{n-a}$$

Definição 2.3. $X \sim \text{Binomial}(n, p) \longleftrightarrow p_X(a) = \binom{n}{a} p^a (1 - p)^{n-a}$

Se a taxa de sucesso de cada ensaio Bernoulli é p , então podemos intuir que o número esperado de sucessos em n ensaios deverá ser a fração p do total dos ensaios, ou seja que o valor esperado seja np .

Proposição 2.4. Se $X \sim \text{Binomial}(n, p)$, então $E[x] = np$.

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^n k \cdot \binom{n}{k} p^k (1 - p)^{n-k}.$$

Utilizando o fato de que

$$\binom{n}{k} = \frac{n}{k} \binom{n-1}{k-1},$$

reduzimos então a

$$E[X] = n \sum_{k=0}^n \binom{n-1}{k-1} p^k (1 - p)^{n-k},$$

o que nos sugere realizar uma troca de variável em k para que consigamos usar o Teorema Binomial. Para tanto, realizemos que

$$n \sum_{k=0}^n \binom{n-1}{k-1} p^k (1-p)^{n-k} = np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} (1-p)^{n-k}$$

já que somar o termo $k = 0$ equivale a somar o. Fazendo então a troca $j = k - 1$, obtemos

$$E[X] = np \sum_{j=0}^n \binom{n-1}{j} p^j (1-p)^{(n-1)-j},$$

e pelo Teorema Binomial,

$$E[X] = np \cdot (p + 1 - p)^{n-1} = np$$

■

2.7.3 Distribuição Geométrica

Uma variável geométrica modela experimentos que consistem na repetição de ensaios Bernoulli independentes até que se obtenha o primeiro sucesso. Um exemplo é repetir o lançamento de uma moeda até obter coroa. Para obter a função de massa de probabilidade dessa variável para uma realização n , basta encontrar a probabilidade de obter $n - 1$ fracassos consecutivos seguidos de um sucesso. Desse modo, se $(X_k = x_k)_{k \in [n]}$ é uma sucessão de n ensaios Bernoulli independentes com parâmetro p , então

$$P((X_k = x_k)_{k \in \mathbb{N}}) = \prod_{k=1}^n P(X_k = x_k),$$

mas como os $n - 1$ valores de x_k são fracassos (iguais a o) obtidos com probabilidade $1 - p$, e $x_n = 1$ é obtido com probabilidade p , então

$$P((X_k = x_k)_{k \in \mathbb{N}}) = (1 - p)^{n-1} p$$

Definição 2.5.

$$X \sim Geo(p) \iff p_X(n) = (1 - p)^{n-1} p$$

O número esperada de ensaios realizados num experimento até obter o primeiro sucesso é o valor esperado da variável geométrica.

Proposição 2.6. Se $X \sim Geo(p)$, então

$$E[X] = \frac{1}{p}$$

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^{\infty} k(1-p)^{k-1}p = p \sum_{k=0}^{\infty} k(1-p)^{k-1}.$$

O somatório à esquerda é a derivada de uma série geométrica de razão $q = 1 - p$, tal que $q < 1$. Observemos que

$$\begin{aligned} \frac{d}{dq} \left(\sum_{k=0}^{\infty} q^k \right) &= \frac{d}{dq} \left(\frac{1}{1-q} \right) \\ \sum_{k=0}^{\infty} k(1-p)^{k-1} &= \frac{1}{(1-q)^2} \end{aligned}$$

donde conclui-se

$$E[X] = \frac{p}{(1-p)^2} = \frac{1}{p}$$

■

2.7.4 Distribuição Binomial Negativa

A distribuição binomial negativa é similar à geométrica: invés de repetir os ensaios Bernoulli independentes até o obter o primeiro sucesso, os ensaios são repetidos até que se acumulem r sucessos, sendo esse total um novo parâmetro da distribuição. A dedução da f.m.p. para esse modelo de probabilidade é análogo ao da Binomial e da Geométrica; fixando uma sequência $((X_k = x_k)_{k \in [n]})$ de ensaios Bernoulli independentes com parâmetro p , temos que a probabilidade de uma sequência será

$$\prod_{k=1}^n P(X_k = x_k),$$

de sorte que, sendo r ensaios com $x_k = 1$ e $n - r$ ensaios com $x_k = 0$, então

$$\prod_{k=1}^n P(X_k = x_k) = (1-p)^{n-r} p^r.$$

Visto que cada sequência de ensaios é mutualmente exclusiva, então a probabilidade de obter acumular n ensaios até obter r tentativas equivale ao total de escolhas de r ensaios para fixar $x_k = 1$ dentre n possíveis, logo

$$\binom{n}{r} (1-p)^{n-r} p^r$$

Definição 2.7.

$$X \sim \text{BinNeg}(r, p) \longleftrightarrow p_X(n) = \binom{n}{r} (1-p)^{n-r} p^r$$

Uma binomial negativa pode ser vista como a sucessão de várias geométricas. Desse modo, o valor esperado de uma binomial negativa deve ser igual ao valor esperado da soma das geométricas que a compõe.

Proposição 2.8. Se $X \sim \text{BinNeg}(r, p)$, então

$$E[X] = \frac{r}{p}$$

Demonstração. Suponha que $(X_i)_{i \in [r]}$ denote a variável que determina quantos ensaios Bernoulli foram realizados até se obter um sucesso desde o último. Com efeito, a variável $X_i \sim \text{Geo}(p)$ para todo $i \in [r]$. Além disso, temos que

$$X = \sum_{i=1}^r X_i$$

Pela linearidade da esperança, conclui-se que

$$E[X] = \sum_{i=1}^r E[X_i] = \sum_{i=1}^r \frac{1}{p} = \frac{r}{p}$$

■

2.7.5 Distribuição Hipergeométrica

A distribuição hipergeométrica modela amostragens de tamanho n de um espaço amostral equiprovável de tamanho N , em que m dos resultados possíveis são considerados sucessos. Um exemplo clássico são bolas numa urna, das quais m são azuis, e as demais vermelhas. A urna é nosso espaço amostral, as m bolas azuis são os resultados que representam sucessos possíveis, caso realizássemos um sorteio de n bolas da urna, a variável que nos dá o número de bolas azuis sorteadas é hipergeométrica.

Para obter a função de distribuição para a situação sendo modelada, considere uma população de tamanho N , com m indivíduos pertencentes ao evento de sucessos, e uma amostra de tamanho n dessa população. Para obter a probabilidade de obter k indivíduos na amostra que sejam sucessos, supondo que os indivíduos na população são equiprováveis, podemos utilizar a proposição 1.1, considerando Ω como o universo das amostras, e E as

amostras que possuem k indivíduos considerados sucessos. O número de amostras possíveis equivale a selecionar n indivíduos de N possíveis

$$|\Omega| = \binom{N}{n}.$$

Por sua vez, o número de amostras com k sucessos equivale ao selecionar k indivíduos dos m que são sucessos e selecionar outros $n - k$ com que não pertencem a esse grupo dos $N - m$ restantes. Por conseguinte

$$|E| = \binom{m}{k} \cdot \binom{N-m}{n-k}$$

e a probabilidade de uma amostra conter k sucessos será

$$\frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

Definição 2.9.

$$X \sim \text{HG}(N, m, n) \longleftrightarrow p_X(k) = \frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

A média de uma hipergeométrica pode ser facilmente obtida pelo seguinte raciocínio: suponha que já tenhamos selecionado a amostra de tamanho n e temos o conhecimento *a priori* de que a população N continha m sucessos, implicando que a probabilidade que cada indivíduo da amostra selecionada tenha probabilidade m/N de ser um sucesso. Considerando que cada indivíduo na amostra é um ensaio Bernoulli de parâmetro m/N , então a média de sucessos deve ser igual a $\frac{nm}{N}$.

Proposição 2.10. Se $X \sim \text{HG}(N, m, n)$, então

$$E[X] = n \frac{m}{N}$$

Demonstração. Presuma que a amostra de tamanho n obtida seja a sequência de eventos $(X_k = x_k)_{k \in [n]}$, em que $X_k : \Omega \rightarrow \{0, 1\}$ é a variável indicadora do conjunto dos sucessos S . Como $|S| = m$ e $|\Omega| = N$, então

$$P(S) = \frac{m}{N}$$

e X_k equivale a uma v.a. Bernoulli de parâmetro m/N . Logo, o número de sucessos na amostra é uma variável binomial com parâmetros n e m/N , e sua média será

$$E[X] = n \frac{m}{N}$$

■

2.7.6 Distribuição de Poisson

A distribuição de Poisson modela contagem de eventos que ocorrem dentro de um intervalo contínuo – como o tempo, uma superfície ou volume – com probabilidade praticamente desprezível. Essa distribuição pode ser compreendida como a uma aproximação da Binomial quando $n \rightarrow \infty$.

Considere que $X \sim \text{Binomial}(n, p)$, logo

$$p_X(a) = \binom{n}{a} (1-p)^{n-a} p^a$$

Se tomarmos o limite da f.m.p. de X quando $n \rightarrow \infty$ e denotamos np por λ , então

$$\begin{aligned} \lim_{n \rightarrow \infty} p_X(a) &= \lim_{n \rightarrow \infty} \binom{n}{a} \left(\frac{\lambda}{n}\right)^a \left(1 - \frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n \rightarrow \infty} \frac{n(n-1) \dots (n-a+1)}{a!} \left(\frac{\lambda}{n}\right)^a \left(1 - \frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n \rightarrow \infty} \prod_{k=1}^{a-1} \left(1 - \frac{k}{n}\right) \cdot \lim_{n \rightarrow \infty} \frac{\lambda^a (1 - \lambda/n)^n}{a! (1 - \lambda/n)^a} \end{aligned}$$

Como

$$\lim_{n \rightarrow \infty} \prod_{k=1}^{a-1} \left(1 - \frac{k}{n}\right) = 1 \quad \text{e} \quad \lim_{n \rightarrow \infty} 1 - (\lambda/n)^a = 1$$

então,

$$\lim_{n \rightarrow \infty} p_X(a) = \lim_{n \rightarrow \infty} \frac{\lambda^a}{a!} \left(1 - \frac{\lambda}{n}\right)^n$$

Usando o limite exponencial fundamental

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

obtemos, por fim,

$$\lim_{n \rightarrow \infty} p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Definição 2.11.

$$X \sim \text{Poisson}(\lambda) \longleftrightarrow p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Proposição 2.12. Se $X \sim \text{Poisson}(\lambda)$, então

$$E[X] = \lambda$$

Demonstração. Com efeito,

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \end{aligned}$$

O somatório equivale ao Polinômio de Taylor de e^λ , portanto

$$E[X] = \lambda e^{-\lambda} e^\lambda = \lambda$$

■

Chapter 3

Variáveis Aleatórias Contínuas

Chapter 4

Variáveis Aleatórias Multidimensionais

Chapter 5

Simulação

Part II

Análise Exploratória

Chapter 6

Modelos e Descrição de Dados

6.1 Tipos de Dados

A forma comum em estatística de representar dados é por meio de matrizes retangulares chamadas de **tabelas** ou também, modernamente devido aos softwares usados para tratá-las, **quadro de dados** (*Dataframe*). Por padrão, sendo D um quadro de dados de dimensões $m \times n$, cada coluna de D corresponde a um **atributo**, também chamado de variável ou *feature*, e cada linha corresponde a um registro, que representa um indivíduo na amostra na amostra coletada.

Cada atributo possui um domínio de valores possíveis, que embora possam ser os mais variados possíveis, podem ser organizados numa taxonomia simples. Os tipos de atributos podem ser divididos em dois grande grupos: quantitativos ou qualitativos. O primeiro refere-se a dados com domínio num conjunto numérico, sendo dividido em

Discretos: São atributos que assumem valores em subconjuntos dos números inteiros $\mathbb{Z}$, sendo que na maioria dos contextos são não negativos. Representam contagens, como número de filhos e idades.

Contínuos: O domínio do atributo é um intervalo dos números reais $\mathbb{R}$. Na prática, pelas limitações ontológicas de representar um número real, a realização desses valores se limita a valores aproximados. A diferença fundamental para os discretos é que o conjunto de valores possíveis é não enumerável. Exemplos incluem principalmente medidas, como preços, alturas e pesos.

Os dados qualitativos representam uma qualidade dentro de um conjunto finito de possibilidades chamadas de fatores, sendo divididos em

Ordinais: os fatores possuem uma ordem natural. Exemplos são graus de uma qualidade, como classe social (baixa, média e alta) ou severidade de um exame médico.

Nominais: os fatores não possuem ordem natural, sendo também chamados de categóricos, pois representam categorias. Exemplos são grupos, como sexo ou estado civil. Um tipo especial de variáveis nominais são as dicotômicas, cujos valores possíveis são apenas dois: sucesso ou fracasso, positivo ou negativo, sim ou não, 0 ou 1.

6.2 Escala de Dados

Alternativamente às classificações apresentadas, podemos tipificar atributos através de escalas de medição de seus valores. As classes são similares às classificações apresentadas anteriormente, sendo elas:

- Escala Nominal – para dados nessa escala, só podemos dizer que seus valores são diferentes de outros, sendo usada para categorizar indivíduos. Um exemplo simples é o sexo de uma pessoa: feminino ou masculino. Essa escala não suporta operações matemáticas, e uma medida de centralidade comum para resumir dados nessa escala é a moda.
- Escala Ordinal – nessa escala, os valores podem ser ordenados, e podemos então dizer que, além de diferentes, um valor é maior do que o outro. Essa escala tem sua estrutura preservada por operações que preservem a ordem. Um exemplo de variável ordinal é o nível de escolaridade: fundamental, médio e superior. Medidas de tendência central comuns para dados nessa escala são a moda e a mediana.
- Escala Intervalar - essa escala possui uma origem arbitrária e necessita de uma unidade de medida, sendo um exemplo a temperatura de um ambiente. Podemos afirmar que valores são diferentes, maiores e quão maior em relação a outro, e transformações afim – do tipo $ax + b$ – não alteram a estrutura dessa escala. Podemos utilizar medidas como média, moda e mediana.
- Escala Razão – nessa escala, existe uma origem absoluta, e podemos dizer que um valor é o quão maior do que outro através de razões. Um exemplo de variável nessa escala é o peso de um indivíduo. Transformações do tipo ax preservam a estrutura dessa escala, e podemos utilizar medidas como média, moda e mediana.

6.3 Tabelas de Frequência

Um procedimento para entender o comportamento e distribuição dos dados é por meio de tabelas de frequência, especialmente para variáveis qualitativas, que não podem

ser resumidas por ser resumidas por medidas de estatística descritiva a serem vistas mais adiante. Nas tabelas de frequência constam, geralmente, três colunas: a primeira é de categorias ou intervalos de uma classe d_i , a segunda a frequência absoluta n_i de d_i , enquanto a terceira é a frequência relativa $f_i = n_i/n$, onde n é o tamanho da amostra.

Quando lidamos com intervalos de dados numéricos, a amplitude precisa ser definido a priori, e amplitudes diferentes de cada classe pode levar a visualizações distintas. Muitas classes podem levar a perda de informação, enquanto que poucas podem prejudica a tarefa de resumo. O recomendado é a criação de 5 a 15 classes de mesma amplitude.

Para dados contínuos discretizados em intervalos de amplitude Δ_i para a classe d_i , a tabela pode conter também: a densidade na classe, dada por n_i/Δ_i , a densidade de frequência, obtida por f_i/Δ_i , e a frequência acumulada, dado por

$$\sum_{k=1}^i f_k$$

Essas novas colunas podem ser usadas para construir gráficos que permitam analisar distribuição dos valores de uma variável numérica.

6.4 Gráficos

Nesta seção iremos descrever brevemente gráficos para realizar análise univariada de variáveis de acordo com o seu tipo. Para variáveis qualitativas, os gráficos são basicamente construídos com base na tabela de frequência de cada classe, mostrando a contagem ou a frequência relativa em cada classe. Alguns exemplos incluem:

- Gráfico de Barras – o tamanho da barra é proporcional a contagem ou frequência de registros na classe
- Gráfico de Setores – construído com um círculo de raio arbitrário em que a contagem ou frequência de registros é proporcional à área do setor circular que o representa
- Gráfico de Pirulito – mesmo princípio que o de barras, mas com aspecto mais simples, em que o tamanho é proporcional a uma linha tracejada vertical com um ponto no valor da contagem ou frequência.

Para variáveis numéricas discretas, barras e pirulito também podem funcionar se houver um número não muito grande de realizações distintas no conjunto de dados. Para variáveis contínuas, a discretização em intervalos permite gerar vários tipos de gráficos que ajudam a entender a distribuição de valores da variável, como

- Histogramas – construído também com barras com tamanho proporcional densidade – de registros ou frequência – em cada intervalo. Há várias fórmulas para determinar

o número de intervalos (*bins*), como a de Sturges, dada por $k = 1 + 3.3 \log_{10}(n)$, da raiz quadrada, com $k = \sqrt{n}$, de Scott, com $k = \frac{3.5\sigma}{\sqrt[3]{n}}$, onde σ é o desvio-padrão, ou a de Freedman-Diaconis, dada por $k = \frac{2 \cdot \text{IQR}}{\sqrt[3]{n}}$.

- Ramo-e-folha – os ramos são uma coluna vertical com os valores inteiros distintos assumidos pelas realizações. As folhas são as partes fracionárias, empilhadas verticalmente ou horizontalmente em seus ramos.
- Gráfico Dispersão Unidimensional – os dados são mapeados a pontos na reta correspondentes a seus valores. Valores repetidos podem ser empilhados, de modo a dar uma melhor visualização à distribuição dos dados.

Chapter 7

Medidas de Resumo

7.1 Medidas de Posição

Um grau maior de resumo dos dados pode ser obtido ao se computar determinadas estatísticas numéricas que sejam representativas de todo o conjunto, e não somente de agrupamentos deles, como é o caso das frequências absolutas e relativas. As medidas a serem apresentadas são usualmente usadas em conjunto para evitar uma redução muito drástica dos dados. Em especial, as medidas de posição nos dão uma ideia de centralidade dos dados.

A primeira delas, é a moda, definida simplesmente como o valor mais frequente na distribuição. Ela pode ser facilmente estimada contando-se o valor mais frequente. Se $x_1, \dots, x_n$ são realizações de uma variável X , então a moda é dada como

$$\text{moda}(X) = \arg \max_x f(x),$$

onde $f(x)$ é a frequência de x em X . A moda é adequada para atributos qualitativos e quantitativos discretos, ao passo que para quantitativos contínuos ela pode ser pouco representativa devido ao grande número de possibilidades de realizações, apesar de ter uma definição satisfatória para esse caso.

A segunda medida é a mediana, que o valor que acumula 50% da frequência acumulada da distribuição de um atributo. Para determinar a mediana de um vetor de dados X , basta ordenar as realizações do vetor; caso sua dimensão seja ímpar, então a mediana é o valor do índice $\frac{n}{2}$, ao passo que, caso seja par, a mediana é obtida como a média entre as realizações de índice $\frac{n}{2}$ e $\frac{n+1}{2}$.

Por fim, a média de um vetor de dados X é o valor $\bar{x}$ dado como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

que é equivalente também a

$$\bar{x} = \sum_{i=1}^n x_i f(x_i).$$

Tanto a média quanto a mediana são apropriadas apenas à atributos quantitativos. Caso estejamos lidando com intervalos discretizados desses valores, então a forma de computar essas medidas é por estimativa.

7.2 Medidas de Dispersão

Além de ver onde nossos dados estão centrados, é desejável saber o quanto eles variam, geralmente entorno do próprio centro citado. Para esse fim, utiliza-se as medidas de dispersão. Como exemplo dessas medidas, poderíamos ter a soma dos desvios entorno da média, ou do quadrado deles para acentuar desvios maiores. No entanto, o sinal dos desvios pode ocultar sua variabilidade real, pois eles podem somar zero, além também de dificultar a comparação da variação entre dois conjuntos de dados distintos. Uma alternativa para isso, seria considerar a soma dos desvios absolutos entorno da média, apesar dessa medida ser sensível ao tamanho do próprio conjunto.

As medidas de dispersão mais simples que contornam os problemas ditos anteriormente são o desvio médio e a variância, dados como

$$\text{dm}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad e \quad \text{Var}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|^2.$$

Como a variância possui unidade igual ao quadrado da unidade do atributo original, então sua interpretação pode ser prejudicada. Dessa forma, define-se o desvio padrão:

$$\text{dp}(X) = \sqrt{\text{Var}(X)},$$

que é equivalente ao “erro” cometido ao se substituir cada observação pela média.

Chapter 8

Análise de Dados de Duas Variáveis

Part III

Inferência Clássica

Chapter 9

Amostragem

Chapter 10

Estimação de Parâmetros

Chapter 11

Testes de Hipóteses

Chapter 12

Inferência Multipopulacional

Chapter 13

Análise de Aderência e Adesão

Chapter 14

Teste de Hipótese Não Paramétricos

Part IV

Regressão

Chapter 15

Covariância e Correlação

Chapter 16

Regressão Linear

Chapter 17

Regressão Linear Generalizada

Part V

Inferência Bayesiana

Chapter 18

Paradigma Bayesiano

Chapter 19

Inferência e Decisão

Chapter 20

Computação Bayesiana

Part VI

Séries Temporais

Chapter 21

Fundamentos de Séries Temporais

Chapter 22

Modelagem e Previsão