

Estatística

J. P. S. de Sousa

0.1 Visão Geral da Estatística e Análise de Dados

0.1.1 Uma Breve História da Estatística

A palavra estatística deriva dos termos neolatim *statisticum collegium* e italiano *statista*, que significam Colégio de Estado e Estadista respectivamente. A palavra alemã *Statistik* foi usada modernamente por Gottfried Achenwall em meados do século XVIII para designar a coleta de dados políticos, econômicos e sociais de um país, cujo equivalente em inglês era *political arithmetic*. Posteriormente, através de Sir John Sinclair e seus trabalhos no *Statistical Accounts of Scotland*, a palavra ganhou uma conotação mais ampla sobre coleta e classificação de dados.

Como vistos pelas suas raízes etimológicas, a estatística surgiu enquanto a disciplina que se preocupava com a coleta, tratamento, classificação e análise de dados sobre características político-sócio-econômicas de um país a fim de apoiar a formulação de políticas públicas.

A Estatística Matemática tem seus fundamentos no desenvolvimento da Teoria das Probabilidades, antes, com tratamento mais informal, nos trabalhos de Pierre de Fermat, Blaise Pascal e Christian Huygens no século XVII e Thomas Bayes no século XVIII. O rigor matemático também se expandiu no século XVIII com as obras *Ars Conjectandi* (1713) de Jakob Bernoulli e *The Doctrine of Chances* de Abraham Moivre (1718). A formalização matemática rigorosa das probabilidades veio ao auge com Andrei Kolmogorov no século XIX.

A disciplina estatística também tem laços com a Teoria de Erros, cujas origens remontam a *Opera Miscellanea* de Roger Cotes de 1772, e sua reedição por Thomas Simpson em 1755, que aplicou a teoria a erros de observação. A Teoria de Erros ganhou um aspecto mais analítico ainda no final do século XVIII e ao longo do XIX nas mãos de Pierre-Simon de Laplace, Joseph Louis Lagrange e Daniel Bernoulli. O seminal Método dos Mínimos Quadrados (MMQ) foi desenvolvido e publicado independentemente por Adrien-Marie Legendre, Carl Friedrich Gauss e Robert Adrain.

Com o desenvolvimento e sofisticação das técnicas estatísticas, como a amostragem, modelagem e inferência, a estatística na virada do século XIX para o XX, expandiu-se da esfera do Estado para se tornar uma disciplina aplicada em ciências naturais, sociais, administração pública e privada. Neste contexto, figuram nomes George Box, Pafnuty Chebyshev, Gertrude Cox, George Dantzig, Edward Deming, Bruno de Finetti, Sir Ronald Fisher, Sir Francis Galton, Aleksandr Lyapunov, Karl Pearson, Charles Spearman e John Tukey.

Atualmente a estatística é a disciplina central em qualquer outra área para

lidar com dados e incertezas. O avanço das técnicas computacionais viabilizaram o desenvolvimento de técnicas e aplicações estatísticas cada vez mais robustas e complexas para lidar com quantidades massivas de dados e geração de conhecimento e compreensão para diversas áreas, como economia, ciências sociais, computação, inteligência de negócios, saúde, etc.

0.1.2 Modelos Estatísticos

A estatística é um ramo da matemática aplicada e da metodologia científica que busca extrair, reduzir, analisar e modelar um conjunto de dados que amostram uma população. Para isso, são usadas principalmente as ferramentas teóricas providas pela Teoria das Probabilidades, pois entende-se que os dados originam-se de fenômenos aleatórios, e, uma vez modelados, geralmente dois objetivos visam ser cumpridos: estimar ou prever o comportamento dos dados no futuro, ou realizar inferência, que consiste em detectar os padrões embutidos. A inferência pode ser feita por duas abordagens: a inferência dedutiva, que aceita determinadas premissas para chegar às conclusões, ou a inferência indutiva, que parte de casos particulares para generalizar.

Ainda sobre a inferência estatística, quando tenta-se modelar um determinado conjunto de dados, tentamos identificar padrões e tendências de comportamento através de modelos estatísticos. Supondo que temos um conjunto de dados D , e identificamos que conseguimos ajustar a eles um modelo M , teremos então que

$$D = M + R$$

onde R descreve a parte aleatória dos dados que não pode ser capturada pelo modelo, chamada de resíduos. Normalmente, busca-se que resíduos não devam conter nenhuma suavidade, pois isso implicaria em padrões que o modelo falhou em capturar, e mais suavização por parte de M será necessária.

0.1.3 Análise de Dados

A Análise de Dados consiste na inspeção, limpeza, transformação e modelagem de dados com o objetivo claro de obter informações úteis, informar conclusões ou apoiar a tomada de decisão. Em resumo, ela é o processo de extração de dados brutos para geração de conhecimento acionável, geralmente feito num ciclo iterativo. As fases desse processo podem ser divididas em:

1. Requisitos de Dados: a escolha de dados a serem extraídos dependem das análises que se deseja realizar. Aqui define-se a **unidade experimental**, que pode consistir de um indivíduo ou uma população deles, e as **variáveis**

específicas dessa unidade, como idade e renda para uma população de pessoas.

2. Coleta de Dados: consiste na tarefa de obter os dados de diferentes fontes, como bancos de dados estruturados ou não-estruturados, sensores físicos, formulários, uma interface de programação de aplicação (API), arquivos binários ou de textos, entre muitas outras fontes.
3. Processamento e Limpeza: inclui tarefas de organizar os dados em formatos estruturados, identificar tipos, deduplicar, tratar valores faltantes, incorretos e desviantes e transformar o formato de dados para outros mais convenientes.
4. Análise Exploratória: compreende uma gama de técnicas para descrever e resumir os dados obtidos à procura de informações que ajudem entender relações entre as variáveis e guie às técnicas a serem aplicadas nas fases posteriores. Aqui é comumente aplicadas técnicas da Estatística Descritiva e métodos gráficos.
5. Modelagem: são usados algoritmos e modelos estatísticos para extrair padrões latentes nos dados, muitas vezes não triviais de serem identificados. As técnicas de aprendizado estatístico são especialmente úteis nessa etapa.
6. Comunicação e Produto de Dados: a depender do contexto e das finalidades definidas a priori, busca-se maneiras de comunicar esses dados aos atores interessados na forma de visualizações e relatórios. Nos últimos anos, a disciplina de **Narrativa de Dados** tem se destacado para realizar essa comunicação.

A Análise de Dados, do ponto de vista da Estatística, poderia ser dividida em

1. Estatística Descritiva: utilizar medidas de resumo numéricas para os dados a fim de descrever padrões visíveis, geralmente respondendo perguntas do tipo “o que aconteceu?”.
2. Análise Exploratória: semelhante a anterior, porém empregando métodos mais flexíveis e visuais que permitam identificar padrões mais ocultos, correlações e anomalias. Ocorre num processo iterativo de formulação de perguntas, exploração e descobertas.
3. Análise Confirmatória: aplica as técnicas da inferência estatística para confirmar ou rejeitar hipóteses existentes das etapas anteriores

Contents

0.1	Visão Geral da Estatística e Análise de Dados	2
0.1.1	Uma Breve História da Estatística	2
0.1.2	Modelos Estatísticos	3
0.1.3	Análise de Dados	3
I	Distribuições	8
1	Probabilidades	9
1.1	Probabilidades	9
1.1.1	Fundamentos de Probabilidade	9
1.1.2	Axiomas de Probabilidade	10
1.1.3	Eventos Equiprováveis	10
1.1.4	Probabilidade como Função Contínua em um Conjunto . . .	12
1.2	Probabilidade Condicional e Independência	12
1.3	Teorema de Bayes	15
2	Variáveis Aleatórias Discretas	17
3	Variáveis Aleatórias Contínuas	18
4	Variáveis Aleatórias Multidimensionais	19
5	Simulação	20
II	Análise Exploratória	21
6	Modelos e Descrição de Dados	22
6.1	Tipos de Dados	22
6.2	Escala de Dados	23
6.3	Tabelas de Frequência	24

6.4	Gráficos	24
7	Medidas de Resumo	26
7.1	Medidas de Posição	26
7.2	Medidas de Dispersão	27
8	Análise de Dados de Duas Variáveis	28
III	Inferência Clássica	29
9	Amostragem	30
10	Estimação de Parâmetros	31
11	Testes de Hipóteses	32
12	Inferência Multipopulacional	33
13	Análise de Aderência e Adesão	34
14	Teste de Hipótese Não Paramétricos	35
IV	Regressão	36
15	Covariância e Correlação	37
16	Regressão Linear	38
17	Regressão Linear Generalizada	39
V	Inferência Bayesiana	40
18	Paradigma Bayesiano	41
19	Inferência e Decisão	42
20	Computação Bayesiana	43

<i>CONTENTS</i>	7
VI Séries Temporais	44
21 Fundamentos de Séries Temporais	45
22 Modelagem e Previsão	46

Part I

Distribuições

Chapter 1

Probabilidades

1.1 Probabilidades

1.1.1 Fundamentos de Probabilidade

Ao observar, registrar ou extrair uma amostra de dados a partir de um fenômeno aleatório, isto é, cujo resultado não pode ser deterministicamente previsto, a Estatística, dentre outras coisas, procura entender a frequência de ocorrência dos valores amostrados, que nos dão diversas opções de como analisar seu comportamento. Essas frequências são estimativas das **probabilidades** dos eventos observados. A partir de hipóteses adequadas, podemos modelar as frequências por modelos probabilísticos que, por sua vez, são objetos de estudo da Teoria das Probabilidades.

A Teoria de Probabilidades encontra seus fundamentos em alguns campos da matemática pura, tais como Matemática Discreta, Análise e Teoria da Medida. No entanto, neste texto, estaremos mais interessados na visão da teoria para aplicações estatísticas, como a já citada modelagem de frequências e estimação de parâmetros.

A noção primitiva que iremos usar como base será de experimento ou fenômeno aleatório, que modela qualquer fenômeno cujos resultados são conhecidos, porém que podem ser distintos apesar da repetição de condições iniciais. Com isso, daremos a definição do espaço amostral

1.1.2 Axiomas de Probabilidade

Definição 1.1. *O espaço amostral Ω de um experimento aleatório é o conjunto de todos os resultados possíveis do experimento. Um subconjunto de Ω é chamado de evento.*

Com isso, temos a definição de probabilidade de um resultado, ou subconjunto de resultados.

Definição 1.2. *A probabilidade $P(E)$ de um evento E num espaço amostral Ω satisfaz:*

1. $P(E) \in [0, 1]$
2. $P(\Omega) = 1$
3. *Se $E_1, \dots, E_n$ são eventos disjuntos em Ω , também ditos mutualmente exclusivos, então*

$$P\left(\bigcup_{i=1}^n E_i\right) = \sum_{i=1}^n P(E_i)$$

Probabilidades são frequentemente representadas como porcentagens e são muitas vezes entendidas como a frequência de um evento quando se repete o experimento um número suficiente de vezes. Por exemplo, dizer que 16% da população possui diploma de graduação significaria que se escolhermos aleatoriamente 100 pessoas dessa população, cerca de 16 delas teriam diploma de graduação. Essa abordagem é chamada de **frequentista**, sendo a mais amplamente adotada em aplicações estatísticas clássicas.

Outra abordagem para compreender probabilidades é enquanto o grau de crença numa hipótese, como ao dizer que se tem 80% de certeza em dizer que irá chover, visto as evidências do céu nublado e ventos frios. Essa é uma visão mais intuitiva e moderna de probabilidades, sendo chamada de **Bayesiana**, sendo a base da Inferência Bayesiana.

1.1.3 Eventos Equiprováveis

Numa noção intuitiva de que quando o evento não possui vícios, os seus resultados são ditos como equiprováveis, como os lados de um dado ou as faces de uma moeda honestos.

Definição 1.3. *Um evento $E \subset \Omega$ é equiprovável se, e somente se, todo subconjunto unitário de E possui a mesma probabilidade.*

Proposição 1.1. *A probabilidade de um evento E num espaço Ω equiprovável é igual a*

$$\frac{|E|}{|\Omega|}$$

Demonstração. Com efeito, temos que

$$P(E_1) = \dots = P(E_n)$$

em que E_i são eventos unitários de Ω , tal que $|\Omega| = n$. Como eles são disjuntos, então a soma de suas probabilidades deve ser igual a 1, ou seja,

$$\forall i \in [n], \left(P(E_i) = \frac{1}{n} \right).$$

Segue que

$$P(E) = |E| \cdot \frac{1}{n} = \frac{|E|}{|\Omega|}$$

■

Corolário 1.1. *Se $\mathcal{F} = \{E_1, \dots, E_m\}$ é uma família de eventos quaisquer dum espaço Ω equiprovável, então*

$$P\left(\bigcup_{E \in \mathcal{F}} E\right) = \sum_{k=1}^m (-1)^{k+1} \sum_{D \in \mathcal{P}(\mathcal{F}) \wedge |D|=k} P\left(\bigcap_{E \in D} E\right)$$

Demonstração. A cardinalidade da união dos conjuntos de $\mathcal{F}$ é dado pelo Princípio da Exclusão e Inclusão, ou seja

$$\left| \bigcup_{E \in \mathcal{F}} E \right| = \sum_{k=1}^m (-1)^{k+1} \sum_{D \in \mathcal{P}(\mathcal{F}) \wedge |D|=k} \left| \bigcap_{E \in D} E \right|$$

Dividindo a expressão acima por $n = |\Omega|$ obtém-se a probabilidade da união dos conjuntos de $\mathcal{F}$. Contudo, uma vez que a interseção de eventos é um evento, então podemos obter a probabilidade da união como

$$P\left(\bigcup_{E \in \mathcal{F}} E\right) = \sum_{k=1}^m (-1)^{k+1} \sum_{D \in \mathcal{P}(\mathcal{F}) \wedge |D|=k} \frac{1}{n} \left| \bigcap_{E \in D} E \right|$$

que equivale a expressão desejada.

■

1.1.4 Probabilidade como Função Contínua em um Conjunto

Definição 1.4. Uma sequência $E_{i \in \mathbb{N}}$ é encaixado se

$$E_1 \subset E_2 \subset \dots$$

ou

$$E_1 \supset E_2 \supset \dots$$

O primeiro caso é chamado de crescente, enquanto o segundo de decrescente.

Proposição 1.2. Se $E_{i \in \mathbb{N}}$ eventos encaixados crescentes, então

$$\lim_{n \rightarrow \infty} P(E_n) = P\left(\lim_{n \rightarrow \infty} E_n\right)$$

Demonstração. . ■

1.2 Probabilidade Condicional e Independência

A probabilidade condicional representa o conceito de probabilidade de um evento tal que é conhecida a ocorrência de outro; como se tivéssemos reduzido o espaço amostral a um conjunto menor de resultados possíveis. Outra interpretação possível é aquela tal que associamos uma probabilidade a um evento tendo o conhecimento de uma evidência sobre ele.

Definição 1.5. Sejam E e F eventos num espaço amostral Ω . A probabilidade condicional do evento E dado F , denotada por $P(E|F)$, é dada por

$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

A probabilidade condicional induz uma forma de determinar a probabilidade do evento dado como interseção de vários outros.

Proposição 1.3 (Regra do Produto). Se $\mathcal{F} = \{E_1, \dots, E_n\}$ uma família de eventos de Ω , então

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = \prod_{i=1}^n P\left(E_i \mid \bigcap_{j < i} E_j\right)$$

Demonstração. A prova será por indução em n

Base: $n = 1$ é trivial.

Hipótese de Indução: admita que o resultado vale para uma família de n eventos. Se $|\mathcal{F}| = n + 1$, então façamos

$$\bigcap_{j < n+1} E_j = E'$$

e obtemos que

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P(E' \cap E_n) = P(E_n|E')P(E').$$

Como a hipótese de indução vale para E' , então

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P\left(E_n \mid \bigcap_{j < n+1} E_j\right) \cdot \prod_{i=1}^n P\left(E_i \mid \bigcap_{j < i} E_j\right) = \prod_{i=1}^{n+1} P\left(E_i \mid \bigcap_{j < i} E_j\right)$$

Uma vez que a proposição vale para $n+1$, então vale para todo $n \in \mathbb{N}$ pelo princípio de indução. ■

Eventos independentes são aqueles cuja probabilidade de ocorrência não depende da ocorrência de outro. Isso equivale a dizer que, o conhecimento do acontecimento de um evento não muda a crença na ocorrência de outro.

Definição 1.6. *Dois eventos E e F dum espaço amostral Ω são independentes se, e somente se*

$$P(E \cap F) = P(E) \cdot P(F)$$

Proposição 1.4. *Se E e F são eventos independentes de Ω , então*

$$P(E|F) = P(E) \quad e \quad P(F|E) = P(F)$$

Demonstração. Por definição de probabilidade condicional,

$$P(E \cap F) = P(E|F) \cdot P(F)$$

mas como E e F são independentes por hipótese,

$$\begin{aligned} P(E) \cdot P(F) &= P(E|F) \cdot P(F) \\ P(E) &= P(E|F) \end{aligned}$$

e o mesmo pode ser mostrado analogamente para $P(F)$. ■

Proposição 1.5. *Sejam E e F eventos em Ω . Se eles são independentes, então os seguintes eventos também o são:*

1. E^c e F
2. E e F^c
3. E^c e F^c

Demonstração. (1) É verdade que

$$(E \cap F) \cap (E \cap F^c) = \emptyset$$

e também que

$$(E \cap F) \cup (E \cap F^c) = E$$

então

$$P(E \cap F) + P(E \cap F^c) = P(E)$$

donde segue que

$$\begin{aligned} P(E \cap F^c) &= P(E) - P(E \cap F) = P(E) - P(E)P(F) = P(E) \cdot [1 - P(F)] \\ P(E \cap F^c) &= P(E) \cdot P(F^c) \end{aligned}$$

A expressão (2) é análoga a (1). Por fim, para expressão (3), conclua que

$$\begin{aligned} P(E^c \cap F^c) &= P((E \cup F)^c) = 1 - P(E \cup F) \\ &= 1 - P(E) - P(F) + P(E \cap F) \\ &= P(E^c) - P(F) + P(E) \cdot P(F) \\ &= P(E^c) - P(F)[1 - P(E)] \\ &= P(E^c) - P(F) \cdot P(E^c) \\ &= P(E^c)[1 - P(F)] \\ &= P(E^c) \cdot P(F^c) \end{aligned}$$

■

Teorema 1.1 (Teorema de Probabilidade Total). *Seja Ω um espaço amostral e $\mathcal{F} = \{F_1, \dots, F_n\}$ uma partição de Ω . Se E é um evento de Ω , então*

$$P(E) = \sum_{F \in \mathcal{F}} P(E) \cdot P(E|F)$$

Demonstração. Para quaisquer $i, j \in [n]$ temos que

$$(E \cap F_i) \cap (E \cap F_j) = \emptyset.$$

Com isso,

$$P\left(\bigcup_{F \in \mathcal{F}} E \cap F_i\right) = \sum_{F \in \mathcal{F}} P(E \cap F)$$

Em vista de que

$$\bigcup_{F \in \mathcal{F}} E \cap F_i = E \cap \Omega = E,$$

então

$$P(E) = \sum_{F \in \mathcal{F}} P(E \cap F),$$

e pela Proposição 1.5, conclui-se que

$$P(E) = \sum_{F \in \mathcal{F}} P(E) \cdot P(E|F).$$

■

1.3 Teorema de Bayes

Teorema 1.2 (Teorema de Bayes). *Se E e F são eventos de um espaço amostral Ω , então*

$$P(E|F) = P(F|E) \frac{P(E)}{P(F)}$$

Demonstração.

$$P(E|F) \cdot P(F) = P(E \cap F) = P(F|E)P(E)$$

$$P(E|F) = P(F|E) \frac{P(E)}{P(F)}$$

■

Uma interpretação para o teorema é a atualização na crença $P(E)$, chamada de **prior**, numa hipótese E dada uma nova evidência F para ela, obtendo um novo grau de crença $P(E|F)$ chamado de **posterior**. A probabilidade $P(F|E)$ é chamada de **verossimilhança**, denotando o quão verossímil é observar a evidência F considerando a hipótese E verdadeira. Por sua vez, $P(F)$ é a crença na ocorrência de F tendo em vista todas as hipóteses, que, junto com a verossimilhança, ajusta o novo grau de crença em E .

Se num dado experimento aleatório consideramos hipóteses $E_1, \dots, E_n$ e obtemos uma evidência F , é plausível questionar em qual hipótese deveríamos depositar maior crença visto a evidência. Consideremos então o corolário:

Corolário 1.2 (Fórmula de Bayes). *Seja $\mathcal{E} = \{E_1, \dots, E_n\}$ uma partição de um espaço amostral Ω . Se E é um evento de Ω , então*

$$P(E_i|F) = \frac{P(F|E_i)P(E_i)}{\sum_{E \in \mathcal{E}} P(E)P(F|E)}$$

Demonstração. Segue do Teorema de Bayes e do Teorema da Probabilidade Total. ■

Logo, para cada hipótese, poderíamos utilizar a Fórmula de Bayes para computar a crença *a posteriori* nela após a evidência F , e selecionar aquela que tivesse maior probabilidade.

Chapter 2

Variáveis Aleatórias Discretas

Chapter 3

Variáveis Aleatórias Contínuas

Chapter 4

Variáveis Aleatórias Multidimensionais

Chapter 5

Simulação

Part II

Análise Exploratória

Chapter 6

Modelos e Descrição de Dados

6.1 Tipos de Dados

A forma comum em estatística de representar dados é por meio de matrizes retangulares chamadas de **tabelas** ou também, modernamente devido aos softwares usados para tratá-las, **quadro de dados** (*Dataframe*). Por padrão, sendo D um quadro de dados de dimensões $m \times n$, cada coluna de D corresponde a um **atributo**, também chamado de variável ou *feature*, e cada linha corresponde a um registro, que representa um indivíduo na amostra na amostra coletada.

Cada atributo possui um domínio de valores possíveis, que embora possam ser os mais variados possíveis, podem ser organizados numa taxonomia simples. Os tipos de atributos podem ser divididos em dois grande grupos: quantitativos ou qualitativos. O primeiro refere-se a dados com domínio num conjunto numérico, sendo dividido em

Discretos: São atributos que assumem valores em subconjuntos dos números inteiros $\mathbb{Z}$, sendo que na maioria dos contextos são não negativos. Representam contagens, como número de filhos e idades.

Contínuos: O domínio do atributo é um intervalo dos números reais $\mathbb{R}$. Na prática, pelas limitações ontológicas de representar um número real, a realização desses valores se limita a valores aproximados. A diferença fundamental para os discretos é que o conjunto de valores possíveis é não enumerável. Exemplos incluem principalmente medidas, como preços, alturas e pesos.

Os dados qualitativos representam uma qualidade dentro de um conjunto finito de possibilidades chamadas de fatores, sendo divididos em

Ordinais: os fatores possuem uma ordem natural. Exemplos são graus de uma qualidade, como classe social (baixa, média e alta) ou severidade de um exame médico.

Nominais: os fatores não possuem ordem natural, sendo também chamados de categóricos, pois representam categorias. Exemplos são grupos, como sexo ou estado civil. Um tipo especial de variáveis nominais são as dicotômicas, cujos valores possíveis são apenas dois: sucesso ou fracasso, positivo ou negativo, sim ou não, 0 ou 1.

6.2 Escala de Dados

Alternativamente às classificações apresentadas, podemos tipificar atributos através de escalas de medição de seus valores. As classes são similares às classificações apresentadas anteriormente, sendo elas:

- Escala Nominal – para dados nessa escala, só podemos dizer que seus valores são diferentes de outros, sendo usada para categorizar indivíduos. Um exemplo simples é o sexo de uma pessoa: feminino ou masculino. Essa escala não suporta operações matemáticas, e uma medida de centralidade comum para resumir dados nessa escala é a moda.
- Escala Ordinal – nessa escala, os valores podem ser ordenados, e podemos então dizer que, além de diferentes, um valor é maior do que o outro. Essa escala tem sua estrutura preservada por operações que preservem a ordem. Um exemplo de variável ordinal é o nível de escolaridade: fundamental, médio e superior. Medidas de tendência central comuns para dados nessa escala são a moda e a mediana.
- Escala Intervalar - essa escala possui uma origem arbitrária e necessita de uma unidade de medida, sendo um exemplo a temperatura de um ambiente. Podemos afirmar que valores são diferentes, maiores e quão maior em relação a outro, e transformações afim – do tipo $ax + b$ – não alteram a estrutura dessa escala. Podemos utilizar medidas como média, moda e mediana.
- Escala Razão – nessa escala, existe uma origem absoluta, e podemos dizer que um valor é o quão maior do que outro através de razões. Um exemplo de variável nessa escala é o peso de um indivíduo. Transformações do tipo ax preservam a estrutura dessa escala, e podemos utilizar medidas como média, moda e mediana.

6.3 Tabelas de Frequência

Um procedimento para entender o comportamento e distribuição dos dados é por meio de tabelas de frequência, especialmente para variáveis qualitativas, que não podem ser resumidas por ser resumidas por medidas de estatística descritiva a serem vistas mais adiante. Nas tabelas de frequência constam, geralmente, três colunas: a primeira é de categorias ou intervalos de uma classe d_i , a segunda a frequência absoluta n_i de d_i , enquanto a terceira é a frequência relativa $f_i = n_i/n$, onde n é o tamanho da amostra.

Quando lidamos com intervalos de dados numéricos, a amplitude precisa ser definido a priori, e amplitudes diferentes de cada classe pode levar a visualizações distintas. Muitas classes podem levar a perda de informação, enquanto que poucas podem prejudica a tarefa de resumo. O recomendado é a criação de 5 a 15 classes de mesma amplitude.

Para dados contínuos discretizados em intervalos de amplitude Δ_i para a classe d_i , a tabela pode conter também: a densidade na classe, dada por n_i/Δ_i , a densidade de frequência, obtida por f_i/Δ_i , e a frequência acumulada, dado por

$$\sum_{k=1}^i f_k$$

Essas novas colunas podem ser usadas para construir gráficos que permitam analisar distribuição dos valores de uma variável numérica.

6.4 Gráficos

Nesta seção iremos descrever brevemente gráficos para realizar análise univariada de variáveis de acordo com o seu tipo. Para variáveis qualitativas, os gráficos são bsicamente construídos com base na tabela de frequência de cada classe, mostrando a contagem ou a frequência relativa em cada classe. Alguns exemplos incluem:

- Gráfico de Barras – o tamanho da barra é proporcional a contagem ou frequência de registros na classe
- Gráfico de Setores – construído com um círculo de raio arbitrário em que a contagem ou frequência de registros é proporcional à área do setor circular que o representa
- Gráfico de Pirulito – mesmo princípio que o de barras, mas com aspecto mais simples, em que o tamanho é proporcional a uma linha tracejada vertical com

um ponto no valor da contagem ou frequência.

Para variáveis numéricas discretas, barras e pirulito também podem funcionar se houver um número não muito grande de realizações distintas no conjunto de dados. Para variáveis contínuas, a discretização em intervalos permite gerar vários tipos de gráficos que ajudam a entender a distribuição de valores da variável, como

- Histogramas – construído também com barras com tamanho proporcional densidade – de registros ou frequência – em cada intervalo. Há várias fórmulas para determinar o número de intervalos (*bins*), como a de Sturges, dada por $k = 1 + 3.3 \log_{10}(n)$, da raiz quadrada, com $k = \sqrt{n}$, de Scott, com $k = \frac{3.5\sigma}{\sqrt[3]{n}}$, onde σ é o desvio-padrão, ou a de Freedman-Diaconis, dada por $k = \frac{2 \cdot \text{IQR}}{\sqrt[3]{n}}$.
- Ramo-e-folha – os ramos são uma coluna vertical com os valores inteiros distintos assumidos pelas realizações. As folhas são as partes fracionárias, empilhadas verticalmente ou horizontalmente em seus ramos.
- Gráfico Dispersão Unidimensional – os dados são mapeados a pontos na reta correspondentes a seus valores. Valores repetidos podem ser empilhados, de modo a dar uma melhor visualização à distribuição dos dados.

Chapter 7

Medidas de Resumo

7.1 Medidas de Posição

Um grau maior de resumo dos dados pode ser obtido ao se computar determinadas estatísticas numéricas que sejam representativas de todo o conjunto, e não somente de agrupamentos deles, como é o caso das frequências absolutas e relativas. As medidas a serem apresentadas são usualmente usadas em conjunto para evitar uma redução muito drástica dos dados. Em especial, as medidas de posição nos dão uma ideia de centralidade dos dados.

A primeira delas, é a moda, definida simplesmente como o valor mais frequente na distribuição. Ela pode ser facilmente estimada contando-se o valor mais frequente. Se $x_1, \dots, x_n$ são realizações de uma variável X , então a moda é dada como

$$\text{moda}(X) = \arg \max_x f(x),$$

onde $f(x)$ é a frequência de x em X . A moda é adequada para atributos qualitativos e quantitativos discretos, ao passo que para quantitativos contínuos ela pode ser pouco representativa devido ao grande número de possibilidades de realizações, apesar de ter uma definição satisfatória para esse caso.

A segunda medida é a mediana, que o valor que acumula 50% da frequência acumulada da distribuição de um atributo. Para determinar a mediana de um vetor de dados X , basta ordenar as realizações do vetor; caso sua dimensão seja ímpar, então a mediana é o valor do índice $\frac{n}{2}$, ao passo que, caso seja par, a mediana é obtida como a média entre as realizações de índice $\frac{n}{2}$ e $\frac{n+1}{2}$.

Por fim, a média de um vetor de dados X é o valor $\bar{x}$ dado como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

que é equivalente também a

$$\bar{x} = \sum_{i=1}^n x_i f(x_i).$$

Tanto a média quanto a mediana são apropriadas apenas à atributos quantitativos. Caso estejamos lidando com intervalos discretizados desses valores, então a forma de computar essas medidas é por estimativa.

7.2 Medidas de Dispersão

Além de ver onde nossos dados estão centrados, é desejável saber o quanto eles variam, geralmente entorno do próprio centro citado. Para esse fim, utiliza-se as medidas de dispersão. Como exemplo dessas medidas, poderíamos ter a soma dos desvios entorno da média, ou do quadrado deles para acentuar desvios maiores. No entanto, o sinal dos desvios pode ocultar sua variabilidade real, pois eles podem somar zero, além também de dificultar a comparação da variação entre dois conjuntos de dados distintos. Uma alternativa para isso, seria consederar a soma dos desvios absolutos entorno da média, apesar dessa medida ser sensível ao tamanho do próprio conjunto.

As medidas de dispersão mais simples que contornam os problemas ditos anteriormente são o desvio médio e a variância, dados como

$$\text{dm}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad e \quad \text{Var}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|^2.$$

Como a variância possui unidade igual ao quadrado da unidade do atributo original, então sua interpretação pode ser prejudicada. Dessa forma, define-se o desvio padrão:

$$\text{dp}(X) = \sqrt{\text{Var}(X)},$$

que é equivalente ao “erro” cometido ao se substituir cada observação pela média.

Chapter 8

Análise de Dados de Duas Variáveis

Part III

Inferência Clássica

Chapter 9

Amostragem

Chapter 10

Estimação de Parâmetros

Chapter 11

Testes de Hipóteses

Chapter 12

Inferência Multipopulacional

Chapter 13

Análise de Aderência e Adesão

Chapter 14

Teste de Hipótese Não Paramétricos

Part IV

Regressão

Chapter 15

Covariância e Correlação

Chapter 16

Regressão Linear

Chapter 17

Regressão Linear Generalizada

Part V

Inferência Bayesiana

Chapter 18

Paradigma Bayesiano

Chapter 19

Inferência e Decisão

Chapter 20

Computação Bayesiana

Part VI

Séries Temporais

Chapter 21

Fundamentos de Séries Temporais

Chapter 22

Modelagem e Previsão