
Estatística

Uma introdução à teoria e à prática

J. P. S. DE SOUSA

Visão Geral da Estatística e Análise de Dados

Uma Breve História da Estatística

A palavra estatística deriva dos termos neolatim *statisticum collegium* e italiano *statista*, que significam Colégio de Estado e Estadista respectivamente. A palavra alemã *Statistik* foi usada modernamente por Gottfried Achenwall em meados do século XVIII para designar a coleta de dados políticos, econômicos e sociais de um país, cujo equivalente em inglês era *political arithmetic*. Posteriormente, através de Sir John Sinclair e seus trabalhos no *Statistical Accounts of Scotland*, a palavra ganhou uma conotação mais ampla sobre coleta e classificação de dados.

Como vistos pelas suas raízes etimológicas, a estatística surgiu enquanto a disciplina que se preocupava com a coleta, tratamento, classificação e análise de dados sobre características político-sócio-econômicas de um país a fim de apoiar a formulação de políticas públicas.

A Estatística Matemática tem seus fundamentos no desenvolvimento da Teoria das Probabilidades, antes, com tratamento mais informal, nos trabalhos de Pierre de Fermat, Blaise Pascal e Christian Huygens no século XVII e Thomas Bayes no século XVIII. O rigor matemático também se expandiu no século XVIII com as obras *Ars Conjectandi* (1713) de Jakob Bernoulli e *The Doctrine of Chances* de Abraham Moivre (1718). A formalização matemática rigorosa das probabilidades veio ao auge com Andrei Kolmogorov no século XIX.

A disciplina estatística também tem laços com a Teoria de Erros, cujas origens remontam a *Opera Miscellanea* de Roger Cotes de 1772, e sua reedição por Thomas Simpson em 1755, que aplicou a teoria a erros de observação. A Teoria de Erros ganhou um aspecto mais analítico ainda no final do século XVIII e ao longo do XIX nas mãos de Pierre-Simon de Laplace, Joseph Louis Lagrange e Daniel Bernoulli. O seminal Método dos Mínimos Quadrados (MMQ) foi desenvolvido e publicado independentemente por Adrien-Marie Legendre, Carl Friedrich Gauss e Robert Adrain.

Com o desenvolvimento e sofisticação das técnicas estatísticas, como a amostragem, modelagem e inferência, a estatística na virada do século XIX para o XX, expandiu-se da esfera do Estado para se tornar uma disciplina aplicada em ciências naturais, sociais, administração pública e privada. Neste contexto, figuram nomes George Box, Pafnuty Chebyshev, Gertrude Cox, George Dantzig, Edward Deming, Bruno de Finetti, Sir Ronald Fisher, Sir Francis Galton, Aleksandr Lyapunov, Karl Pearson, Charles Spearman e John Tukey.

Atualmente a estatística é a disciplina central em qualquer outra área para lidar com dados e incertezas. O avanço das técnicas computacionais viabilizaram o desenvolvimento de técnicas e aplicações estatísticas cada vez mais robustas e complexas para lidar com quantidades massivas de dados e geração de conhecimento e compreensão para diversas áreas, como economia, ciências sociais, computação, inteligência de negócios, saúde, etc.

Modelos Estatísticos

A estatística é um ramo da matemática aplicada e da metodologia científica que busca extrair, reduzir, analisar e modelar um conjunto de dados que amostram uma população. Para isso, são usadas principalmente as ferramentas teóricas providas pela Teoria das Probabilidades, pois entende-se que os dados originam-se de fenômenos aleatórios, e, uma vez modelados, geralmente dois objetivos visam ser cumpridos: estimar ou prever o comportamento dos dados no futuro, ou realizar inferência, que consiste em detectar os padrões embutidos. A inferência pode ser feita por duas abordagens: a inferência dedutiva, que aceita determinadas premissas para chegar às conclusões, ou a inferência indutiva, que parte de casos particulares para generalizar.

Ainda sobre a inferência estatística, quando tenta-se modelar um determinado conjunto de dados, tentamos identificar padrões e tendências de comportamento através de modelos estatísticos. Supondo que temos um conjunto de dados D , e identificamos que conseguimos ajustar a eles um modelo M , teremos então que

$$D = M + R$$

onde R descreve a parte aleatória dos dados que não pode ser capturada pelo modelo, chamada de resíduos. Normalmente, busca-se que resíduos não devam conter nenhuma suavidade, pois isso implicaria em padrões que o modelo falhou em capturar, e mais suavização por parte de M será necessária.

Análise de Dados

A Análise de Dados consiste na inspeção, limpeza, transformação e modelagem de dados com o objetivo claro de obter informações úteis, informar conclusões ou apoiar a tomada de decisão. Em resumo, ela é o processo de extração de dados brutos para geração de conhecimento acionável, geralmente feito num ciclo iterativo. As fases desse processo podem ser divididas em:

1. **Requisitos de Dados:** a escolha de dados a serem extraídos dependem das análises que se deseja realizar. Aqui define-se a **unidade experimental**, que pode consistir de um indivíduo ou uma população deles, e as **variáveis** específicas dessa unidade, como idade e renda para uma população de pessoas.
2. **Coleta de Dados:** consiste na tarefa de obter os dados de diferentes fontes, como bancos de dados estruturados ou não-estruturados, sensores físicos, formulários, uma interface de programação de aplicação (API), arquivos binários ou de textos, entre muitas outras fontes.
3. **Processamento e Limpeza:** inclui tarefas de organizar os dados em formatos estruturados, identificar tipos, deduplicar, tratar valores faltantes, incorretos e desviantes e transformar o formato de dados para outros mais convenientes.
4. **Análise Exploratória:** compreende uma gama de técnicas para descrever e resumir os dados obtidos à procura de informações que ajudem entender relações entre as variáveis e guie às técnicas a serem aplicadas nas fases posteriores. Aqui é comumente aplicadas técnicas da Estatística Descritiva e métodos gráficos.
5. **Modelagem:** são usados algoritmos e modelos estatísticos para extrair padrões latentes nos dados, muitas vezes não triviais de serem identificados. As técnicas de aprendizado estatístico são especialmente úteis nessa etapa.
6. **Comunicação e Produto de Dados:** a depender do contexto e das finalidades definidas a priori, busca-se maneiras de comunicar esses dados aos atores interessados na forma de visualizações e relatórios. Nos últimos anos, a disciplina de **Narrativa de Dados** tem se destacado para realizar essa comunicação.

A Análise de Dados, do ponto de vista da Estatística, poderia ser dividida em

1. **Estatística Descritiva:** utilizar medidas de resumo numéricas para os dados a fim de descrever padrões visíveis, geralmente respondendo perguntas do tipo “o que aconteceu?”.
2. **Análise Exploratória:** semelhante a anterior, porém empregando métodos mais flexíveis e visuais que permitam identificar padrões mais ocultos, correlações e anomalias. Ocorre num processo iterativo de formulação de perguntas, exploração e descobertas.
3. **Análise Confirmatória:** aplica as técnicas da inferência estatística para confirmar ou rejeitar hipóteses existentes das etapas anteriores

Sumário

I	Distribuições	1
1	Probabilidades	2
1.1	Noções de Medida	2
1.1.1	Adendos de Análise	2
1.1.2	Introdução à Medida	3
1.1.3	Integral de Lebesgue	5
1.1.4	Espaços L^p	6
1.1.5	Teorema de Radon-Nikodym	6
1.2	Cálculo das Probabilidades	7
1.3	Probabilidade Condicional e Independência	8
1.4	Teorema de Bayes	10
2	Variáveis Aleatórias	12
2.1	Variáveis Aleatórias	12
2.2	Função de Distribuição Acumulada	13
2.3	Variáveis Aleatórias Discretas	14
2.4	Variáveis Aleatórias Contínuas	16
2.5	Transformações	18
2.5.1	Transformação de Variáveis Discretas	18
2.5.2	Transformação de Variáveis Contínuas	19
2.6	Esperança de Variáveis Discretas	20
3	Modelos de Distribuição de Probabilidade	22
3.1	Modelos de Distribuição Discreta	22
3.1.1	Distribuição Bernoulli	22
3.1.2	Distribuição Binomial	23
3.1.3	Distribuição Geométrica	24
3.1.4	Distribuição Binomial Negativa	24
3.1.5	Distribuição Hipergeométrica	25
3.1.6	Distribuição de Poisson	26
4	Variáveis Aleatórias Multidimensionais	28
5	Simulação	29
II	Análise Exploratória	30
6	Modelos e Descrição de Dados	31

6.1	Tipos de Dados	31
6.2	Escala de Dados	31
6.3	Tabelas de Frequência	32
6.4	Gráficos	32
7	Medidas de Resumo	34
7.1	Medidas de Posição	34
7.2	Medidas de Dispersão	34
8	Análise de Dados de Duas Variáveis	36
III	Inferência Clássica	37
9	Amostragem	38
10	Estimação de Parâmetros	39
11	Testes de Hipóteses	40
12	Inferência Multipopulacional	41
13	Análise de Aderência e Adesão	42
14	Teste de Hipótese Não Paramétricos	43
IV	Regressão	44
15	Covariância e Correlação	45
16	Regressão Linear	46
17	Regressão Linear Generalizada	47
V	Inferência Bayesiana	48
18	Paradigma Bayesiano	49
19	Inferência e Decisão	50
20	Computação Bayesiana	51
VI	Séries Temporais	52
21	Fundamentos de Séries Temporais	53
22	Modelagem e Previsão	54

PARTE I

DISTRIBUIÇÕES

Probabilidades

Ao observar, registrar ou extrair uma amostra de dados a partir de um fenômeno aleatório, isto é, cujo resultado não pode ser deterministicamente previsto, a Estatística, dentre outras coisas, procura entender o comportamento das frequências de ocorrência dos valores amostrados. Essas frequências são estimativas das **probabilidades** dos eventos observados. A partir de hipóteses adequadas, podemos modelar as frequências por modelos probabilísticos que, por sua vez, são objetos de estudo da Teoria das Probabilidades.

Probabilidades são frequentemente representadas como porcentagens e são muitas vezes entendidas como a frequência de um evento quando se repete o experimento um número suficiente de vezes. Por exemplo, dizer que 16% da população possui diploma de graduação significaria que se escolhermos aleatoriamente 100 pessoas dessa população, cerca de 16 delas teriam diploma de graduação. Essa abordagem é chamada de **frequentista**, sendo a mais amplamente adotada em aplicações estatísticas clássicas.

Outra abordagem para compreender probabilidades é enquanto o grau de crença numa hipótese, como ao dizer que se tem 80% de certeza em dizer que irá chover, visto as evidências do céu nublado e ventos frios. Essa é uma visão mais intuitiva e moderna de probabilidades, sendo chamada de **Bayesiana**, sendo a base da Inferência Bayesiana.

A moderna Teoria das Probabilidades é fundamenta utilizando-se conceitos da Teoria da Medida, um ramo da Análise que generaliza as noções de comprimento, área e volume para espaços abstratos associando-os a uma “medida”, a partir da qual também estende-se uma Teoria de Integração para esses espaços. Probabilidades são vistas, portanto, como medidas das chances de ocorrência de um subconjunto de eventos dentro de um universo de resultados possíveis.

1.1 Noções de Medida

Nesta seção, será realizada uma breve exposição dos principais enunciados sobre medida a fim de somente fundamentar o desenvolvimento posterior dos conceitos associados à Teoria de Probabilidades, que, por sua vez, garante a fundamentação da teoria e prática estatística.

1.1.1 Adendos de Análise

O conceito de continuidade, estudado dentro da Análise, está atrelado à ideia de poder aproximar uma função real a um determinado valor variando suavemente seu argumento.

Definição 1.1. *Um função $f : \mathbb{R} \rightarrow \mathbb{R}$ é uniformemente contínua em $a \in \mathbb{R}$ se*

$$\forall \epsilon > 0 \exists \delta \in \mathbb{R} \forall x \in \mathbb{R}, |x - a| < \delta \rightarrow |f(x) - f(a)| < \epsilon$$

Outra forma equivalente de definição de continuidade é

$$\lim_{x \rightarrow a^-} f(x) = \lim_{x \rightarrow a^+} f(x) = \lim_{x \rightarrow a} f(x) = f(a).$$

Funções que não são contínuas em determinado ponto significa que, a depender de onde nos aproximamos, o valor para o qual a função converge se diferencia.

Exemplo 1.1. A função $f(x) = x^2$ é contínua em todo ponto de seu domínio, já que

$$\lim_{x \rightarrow a} x^2 = a^2$$

Exemplo 1.2. Funções escadas são exemplo de funções não contínuas.

A próxima definição é uma versão mais forte da anterior. A continuidade uniforme significa que, independente da escolha de limite de erro ϵ para o valor da função, há um único δ tal que em qualquer lugar observa-se que, se $|x - a| < \delta$, então $|f(x) - f(a)| < \epsilon$.

Definição 1.2. Uma função $f : \mathbb{R} \rightarrow \mathbb{R}$ é uniformemente contínua se

$$\forall \epsilon > 0 \exists \delta \in \mathbb{R} \forall x, a \in \mathbb{R}, |x - a| < \delta \rightarrow |f(x) - f(a)| < \epsilon$$

Uma função que não é uniformemente contínua pode ter variações muito abruptas em alguns intervalos, e mais suaves em outros.

Exemplo 1.3. As funções $\sin x$, $\cos x$ e funções lineares são exemplos de absolutamente contínuas, pois suas taxas de variação não se tornam infinitamente grandes conforme a função se aproxima de qualquer ponto.

Exemplo 1.4. A função $f(x) = 1/x$ não é uniformemente contínua, pois conforme se aproxima de 0, a sua variação se torna infinitamente grande.

Teorema 1.1. Seja f uma função pontualmente contínua em X . Se X é compacto (fechado e limitado), então f é uniformemente contínua em X .

Definição 1.3. Uma função f é absolutamente contínua em $[a, b]$ se para todo $\epsilon > 0$ existe $\delta \in \mathbb{R}$ tal que, para quaisquer intervalos disjuntos

$$(a_k, b_k) \subset [a, b]$$

tem-se

$$\sum_k (b_k - a_k) < \delta \implies \sum_k |f(b_k) - f(a_k)| < \epsilon$$

1.1.2 Introdução à Medida

Antes de podermos medir determinados conjuntos, precisamos entender que tipos de conjuntos podem ser medidos. Com esse propósito, introduz-se o conceito de σ -álgebras, que define uma álgebra sobre uma coleção de partes de um conjunto cujas operações definem conjuntos **mensuráveis**.

Definição 1.4. Seja Ω um conjunto e $\mathcal{B} \subset \mathcal{P}(\Omega)$. O conjunto $\mathcal{B}$ é uma σ -álgebra de Ω se, e somente se,

$$i. \emptyset \in \mathcal{B}.$$

$$ii. \forall A \in \mathcal{B}, A^c \in \mathcal{B}.$$

$$iii. \forall A \in \mathcal{B}, \bigcup_{i=1}^{\infty} A_i \in \mathcal{B}.$$

Se Ω é um espaço amostral, então $A \in \mathcal{B}$ é denominado evento de Ω .

Definição 1.1. Seja $\mathcal{G} = \{(-\infty, x] \mid x \in \mathbb{R}\}$. A σ -álgebra gerada por $\mathcal{G}$ é chamada σ -álgebra de Borel em $\mathbb{R}$ e é denotada por $\mathcal{B}(\mathbb{R})$.

Definição 1.5. Um conjunto é dito de medida nula se para todo $\epsilon > 0$ existe uma cobertura enumerável $\{I_k\}_1^n$ tal que a soma dos comprimentos de cada intervalo I_k é menor que ϵ .

Definição 1.6. O par $(\Omega, \mathcal{B})$ é dito mensurável se $\mathcal{B}$ for uma σ -álgebra de Ω . A função $\mu : \mathcal{B} \rightarrow [0, +\infty)$ é uma medida para $(\Omega, \mathcal{B})$ se satisfaz

$$i. \mu(\emptyset) = 0$$

$$ii. \sigma\text{-aditividade: } \mu(\bigsqcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mu(A_i)$$

A tripla $(\Omega, \mathcal{B}, \mu)$ é chamado de espaço de medida.

Teorema 1.2. Dados espaços mensuráveis $(\Omega, \mathcal{B})$ e $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, uma função real $f : \Omega \rightarrow \mathbb{R}$ é mensurável se, e somente, se

$$\forall x \in \mathbb{R}, f^{-1}((-\infty, x]) \in \mathcal{B}.$$

Definição 1.7. A medida λ de Lebesgue para $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ satisfaz

$$\lambda((a, b]) = b - a$$

Teorema 1.3. Se $(\Omega, \mathcal{B}, \mu)$ é um espaço de medida e $\{A_n\}$ é uma família enumerável de elementos de $\mathcal{B}$, então

i. *continuidade por baixo:* Se $A_1 \subset A_2 \subset \dots$, então

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow \infty} \mu(A_n)$$

ii. *continuidade por cima:* Se $A_1 \supset A_2 \supset \dots$, então

$$\mu\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow \infty} \mu(A_n)$$

iii. *Sub-aditividade*

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu(A_n)$$

Teorema 1.4. Seja $(\Omega, \mathcal{B}, \mu)$ espaço de medida, e A e B elementos de $\mathcal{B}$.

$$A \subset B \rightarrow \mu(A) \leq \mu(B)$$

Definição 1.8. Uma medida μ para $(\Omega, \mathcal{B})$ é dita completa se

$$\forall S \in \mathcal{B} \forall A, \mu(S) = 0 \wedge (A \subset S \rightarrow A \in \mathcal{B})$$

A medida μ é dita σ -finita se

$$\Omega = \bigcup_{n=1}^{\infty} A_n$$

com $\mu(A_n) < \infty$ para todo $n \in \mathbb{N}$.

Teorema 1.5. A medida de Lebesgue é σ -finita.

Definição 1.9. Seja $(\Omega, \mathcal{B})$ um espaço mensurável por medidas ν e μ . Dizemos que ν é absolutamente contínua em relação a μ , denotado por $\nu \ll \mu$, se

$$\forall A \in \mathcal{B}, \mu(A) = 0 \implies \nu(A) = 0.$$

Definição 1.10. Sejam $(\Omega, \mathcal{B})$ e $(\Omega', \mathcal{B}')$ espaços de medida. Uma função $f : \Omega \rightarrow \Omega'$ é mensurável – ou $(\mathcal{B}, \mathcal{B}')$ -mensurável – se

$$\forall B \in \mathcal{B}', f^{-1}(B) \in \mathcal{B}$$

onde f^{-1} denota a pré-imagem de f .

Teorema 1.6. São verdadeiras as seguintes afirmações:

i. Toda função contínua é mensurável.

ii. Se f e g são funções mensuráveis, então são mensuráveis

$$f \circ g, \quad f \cdot g, \quad \frac{f}{g}, g \neq 0$$

iii. Se $\{f_n\}$ é uma sequência de funções mensuráveis, então são mensuráveis

$$\limsup f_n, \quad \liminf f_n, \quad \sup f_n, \quad \inf f_n$$

iv. O limite pontual de uma função mensurável é mensurável.

Definição 1.11. Se $f : \mathbb{R} \rightarrow \mathbb{R}$ é uma função mensurável monótona crescente e contínua à direita, então a medida induzida de Stieltjes por f , denotada por μ_f , satisfaz

$$\mu_f((a, b]) = f(b) - f(a)$$

Teorema 1.7. Seja μ_f a medida de Stieltjes induzida por f . A função f é absolutamente contínua se, e somente se, $\mu_f \ll \lambda$, onde λ é a medida de Lebesgue.

1.1.3 Integral de Lebesgue

Definição 1.12. A aplicação $\phi : \Omega \rightarrow \mathbb{R}$ é uma função simples se pode ser expressa com

$$\phi(x) = \sum_{i=1}^n a_i \cdot I_{A_i}(x)$$

onde $a_i \in \mathbb{R}$ e $\{A_i\}_1^n \subset \mathcal{B}(\mathbb{R})$ são dois a dois disjuntos.

Teorema 1.8. Para toda função $f \geq 0$ há uma sequência $\{\phi_i\}_{\mathbb{N}}$ não negativa e monótona de funções simples tal que $\phi \rightarrow f$ pontualmente, e uniformemente se f for limitada.

Definição 1.13. Dada a medida λ de Lebesgue, a integral de Lebesgue, denotada por

$$\int f d\lambda$$

satisfaz

i. Se f é simples, então

$$\int f d\lambda = \sum_{i=1}^n a_i \cdot \lambda(A_i)$$

ii. sendo f é mensurável e $\{\phi\}_{\mathbb{N}}$ tal que $\phi_n \rightarrow f$, então

$$\int f d\lambda = \lim_{n \rightarrow \infty} \int \phi_n d\lambda$$

e o limite existe e não depende da sequência $\{\phi\}_{\mathbb{N}}$.

iii. Se $f = f^+ - f^-$, onde $f^+ = \max(0, f)$ e $f^- = \max(0, -f)$, então

$$\int f d\lambda = \int f^+ d\lambda + \int f^- d\lambda$$

desde que $\int |f| d\lambda < \infty$.

Teorema 1.9. A integral de Lebesgue satisfaz

i. **Linearidade:**

$$\int (af + bg) d\lambda = a \int f d\lambda + b \int g d\lambda$$

ii. **Monotonicidade:**

$$f \leq g \text{ q.s.} \rightarrow \int f d\lambda \leq \int g d\lambda$$

iii. **Aditividade:** Se $A \cap B = \emptyset$, então

$$\int_{A \cup B} f d\lambda = \int_A f d\lambda + \int_B f d\lambda$$

iv. **Nulidade:** Se $f \geq 0$ mensurável,

$$\forall A \in \mathcal{B}(\mathbb{R}), \int_A f d\lambda = 0 \leftrightarrow f = 0 \text{ q.s. em } A$$

v. **Desigualdade de Módulo:**

$$\left| \int f d\lambda \right| \leq \int |f| d\lambda$$

vi. **Riemann:**

$$\int_{[a,b]} f d\lambda = \int_a^b f(x) dx$$

Teorema 1.10 (Convergência Monótona). Se $\{f_n\}_{\mathbb{N}}$ é uma sequência não negativa e monótona de funções mensuráveis e $f_n \rightarrow f$ q.s., então

$$\lim_{n \rightarrow \infty} \int f_n d\lambda = \int f d\lambda$$

Lema 1.1 (de Fatou). Se $f_n \leq 0$ são mensuráveis, então

$$\int \liminf f_n d\lambda \leq \liminf \int f_n d\lambda$$

Teorema 1.11. Se $f_n \rightarrow f$ q.s. e existe $g \in L^1(\lambda)$ tal que $|f_n| \leq g$ q.s. para todo n , então

$$\lim_{n \rightarrow \infty} \int f_n d\lambda = \int f d\lambda$$

Teorema 1.12. Para $f \leq 0$ mensurável em

$$(\Omega_1 \times \Omega_2, \mathcal{A}_1 \otimes \mathcal{A}_2, \mu_1 \otimes \mu_2)$$

vale que

$$\int \int f d(\mu_1 \otimes \mu_2) = \int (f d\mu_1) d\mu_2 = \int (f d\mu_2) d\mu_1$$

Teorema 1.13. Se

$$\int |f| d(\mu_1 \otimes \mu_2) < \infty$$

então as integrais iteradas existem q.s. e são iguais às integrais duplas.

1.1.4 Espaços L^p

Definição 1.14. Para $1 \leq p \leq \infty$,

$$L^p(\mu) = \left\{ f \text{ mensurável} \mid \int |f|^p d\mu < \infty \right\}$$

e

$$\|f\|_p = \left(\int |f|^p d\mu \right)^{\frac{1}{p}}$$

Se $p = \infty$,

$$\|f\|_\infty = \text{ess sup } |f|$$

Teorema 1.14 (de Hölder).

$$\int (fg) d\mu = \|f\|_p \cdot \|g\|_q$$

onde

$$\frac{1}{p} + \frac{1}{q} = 1.$$

Se $p = q = 2$, então o Teorema de Hölder equivale à Desigualdade de Cauchy-Schwartz.

Teorema 1.15.

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p$$

Logo, todos os espaços L^p são normados e completos (de Banach). Em especial, L^2 é um espaço de Hilbert.

Teorema 1.16. Se $\mu(\Omega) < \infty$ e $p \leq q$, então $L^p(\Omega) \subset L^q(\Omega)$

1.1.5 Teorema de Radon-Nikodym

Teorema 1.17 (de Radon-Nikodym). Seja $(S, \mathcal{B})$ um espaço mensurável por medidas μ e ν . Se μ é σ -finita e $\nu \ll \mu$, então existe uma função mensurável não negativa $f \in L^1(\mu)$ tal que

$$f = \frac{d\nu}{d\mu}$$

Ademais, se a função g satisfaz a expressão anterior, então

$$g = \frac{d\nu}{d\mu} \iff f = g \text{ q.s.}$$

1.2 Cálculo das Probabilidades

Definição 1.15. Um espaço de medida $\Omega, \mathcal{F}, P$ é um espaço de probabilidade se é satisfeito que

$$P(\Omega) = 1.$$

Os elementos $A \in \mathcal{F}$ são chamados de eventos. O conjunto Ω é denominado espaço amostral.

Teorema 1.18. Se $(\Omega, \mathcal{F}, P)$ é espaço de probabilidade, então

$$i. P(A^c) = 1 - P(A)$$

$$ii. P(A) \leq 1$$

Demonstração. Para (i), temos que $A \cup A^c = \Omega$, então por σ -aditividade,

$$\begin{aligned} P(A) + P(A^c) &= P(\Omega) \\ P(A^c) &= P(\Omega) - P(A) = 1 - P(A) \end{aligned}$$

A afirmação (ii) segue de (i) e da propriedade de imagem não negativa de medida:

$$P(A^c) \geq 0 \implies 1 - P(A) \geq 0 \implies P(A) \leq 1.$$

■

Teorema 1.19. Se $(\Omega, \mathcal{F}, P)$ é espaço de probabilidade, e A e B são eventos, então

$$i. P(B \cap A^c) = P(B) - P(B \cap A).$$

$$ii. P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Demonstração. Para (i), considere primeiramente que

$$(B \cap A) \cup (B \cap A^c) = B$$

e como $(B \cap A) \cap (B \cap A^c) = \emptyset$, então podemos usar aditividade de medidas:

$$\begin{aligned} P(B \cap A) + P(B \cap A^c) &= P(B) \\ P(B \cap A^c) &= P(B) - P(B \cap A). \end{aligned}$$

Para provar (ii), usaremos a probabilidade do complementar e a afirmação (i):

$$\begin{aligned} P(A \cup B) &= 1 - P(A^c \cap B^c) \\ &= 1 - [P(A^c) - P(A^c \cap B)] \\ &= P(A) + P(A^c \cap B) \\ &= P(A) + P(B) - P(A \cap B). \end{aligned}$$

■

Para espaços amostrais enumeráveis, ao associar a cada resultado individual um número em $[0, 1]$, de modo que a soma dos pesos resulte em 1, a soma dos pesos dos resultados presentes num evento será a probabilidade desse evento.

Teorema 1.20. Seja $\Omega = \{\omega_i\}_{\mathbb{N}}$ um conjunto enumerável, e $\mathcal{F}$ uma σ -Álgebra de Ω . Seja $\delta : \Omega \rightarrow [0, 1]$ função tal que

$$\sum_{\omega \in \Omega} \delta(\omega) = 1.$$

Presuma também que, se $A \in \mathcal{F}$, então

$$P(A) = \sum_{\omega \in A} \delta(\omega)$$

A tripla $(\Omega, \mathcal{F}, P)$ é um espaço de probabilidade.

Demonstração. Precisamos provar que P é uma medida de probabilidade que satisfaz os Axiomas de Medida.

Não negatividade Como $\delta \geq 0$, então para todo A em $\mathcal{F}$ vale que $P(A) \geq 0$.

Probabilidade do espaço amostral satisfeito por hipótese.

Soma de eventos disjuntos seja $\{A_j\}_{j \in \mathbb{N}}$ uma família disjunta de eventos de $\mathcal{F}$ tal que

$$A_j = \{\omega_i \mid i \in I_j\}$$

em que I_j é um conjunto de índices. Desenvolvendo,

$$P\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} \sum_{i \in I_j} \delta(\omega_i) = \sum_{j=1}^{\infty} P(A_j)$$

■

Esse resultado é útil para computar a probabilidade de uma vasta gama de experimentos aleatórios na prática. Um exemplo é o lançamento de um dado de 6 faces; se acreditamos que o dado é honesto, isto é, que o dado não é viciado em nenhuma de suas faces, então podemos associar $1/6$ a cada face do dado. Se por exemplo, deseja-se saber a probabilidade de obtermos um número menor ou igual a 3, basta somar as faces que satisfazem essa condição, obtendo uma probabilidade de 0.5. Experimentos os quais acreditamos não conterem vícios são chamados de equiprováveis.

As σ -Álgebras que equivalem ao conjunto das partes do espaço amostral são chamadas de σ -Álgebra potência. Quando o espaço amostral do experimento é enumerável e a sua σ -álgebra é a potência, ocorre que cada subconjunto unitário do espaço amostral – um resultado individual – é um evento do experimento. Se o experimento é equiprovável, então todos os resultados são eventos de mesma probabilidade.

Definição 1.16. Seja o espaço $(\Omega, \mathcal{B}, P)$ com Ω finito, $\mathcal{B} = \mathcal{P}(\Omega)$ e P definido como no Teorema 1.20. Chama-se esse espaço de equiprovável se, e somente se,

$$\forall \omega \in \Omega, P(\omega) = \frac{1}{|\Omega|}.$$

A probabilidade de eventos em experimentos com resultados equiprováveis destaca-se por ser intuitiva de calcular. A probabilidade de evento será, simplesmente, a fração dos resultados presentes nele. Esse resultado será enunciado como Corolário do Teorema 1.20.

Corolário 1.1. A probabilidade de um evento $A \in \mathcal{P}(\Omega)$ num espaço $(\Omega, \mathcal{P}(\Omega), P)$ equiprovável é igual a

$$\frac{|A|}{|\Omega|}$$

Demonstração.

$$P(A) = |A| \cdot \frac{1}{|\Omega|} = \frac{|A|}{|\Omega|}$$

■

1.3 Probabilidade Condicional e Independência

Em experimentos aleatórios, um determinado evento pode ser mais ou menos frequente a depender do conhecimento da ocorrência de outro evento. Nesse caso, dizemos que um evento está condicionado a outro.

Definição 1.17. Seja $(\Omega, \mathcal{B}, P)$ um espaço de probabilidade. Sejam E e F eventos de $\mathcal{B}$ com $P(F) \neq 0$. A probabilidade condicional do evento E dado F , denotada por $P(E|F)$, é dada por

$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

Quando a interseção entre dois eventos é vazia, então teremos que a probabilidade condicional será 0. A probabilidade condicional induz uma forma de determinar a probabilidade do evento dado como interseção de vários outros.

Proposição 1.1 (Regra do Produto). *Seja $\mathcal{F} = \{E_i\}_n$ uma família de eventos disjuntos de um espaço de probabilidade $(\Omega, \mathcal{B}, P)$.*

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = \prod_{i=1}^n P\left(E_i \mid \bigcap_{j<i} E_j\right)$$

Demonstração. A prova será por indução em n

Base: $n = 1$ é trivial.

Hipótese de Indução: admita que o resultado vale para uma família de n eventos. Se $|\mathcal{F}| = n + 1$, então façamos

$$\bigcap_{j<n+1} E_j = E'$$

e obtemos que

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P(E' \cap E_n) = P(E_n | E')P(E').$$

Como a hipótese de indução vale para E' , então

$$P\left(\bigcap_{E \in \mathcal{F}} E\right) = P\left(E_n \mid \bigcap_{j<n+1} E_j\right) \cdot \prod_{i=1}^n P\left(E_i \mid \bigcap_{j<i} E_j\right) = \prod_{i=1}^{n+1} P\left(E_i \mid \bigcap_{j<i} E_j\right)$$

Uma vez que a proposição vale para $n + 1$, então vale para todo $n \in \mathbb{N}$ pelo princípio de indução. ■

Eventos independentes são aqueles cuja probabilidade de ocorrência não depende da ocorrência de outro. Isso equivale a dizer que, o conhecimento do acontecimento de um evento não muda a crença na ocorrência de outro.

Definição 1.18. *Dois eventos E e F de um espaço $(\Omega, \mathcal{B}, P)$ são independentes se, e somente se*

$$P(E \cap F) = P(E) \cdot P(F)$$

Proposição 1.2. *Se E e F são eventos independentes de $(\Omega, \mathcal{B}, P)$, então*

$$P(E|F) = P(E) \quad e \quad P(F|E) = P(F)$$

Demonstração. Por definição de probabilidade condicional,

$$P(E \cap F) = P(E|F) \cdot P(F)$$

mas como E e F são independentes por hipótese,

$$\begin{aligned} P(E) \cdot P(F) &= P(E|F) \cdot P(F) \\ P(E) &= P(E|F) \end{aligned}$$

e o mesmo pode ser mostrado analogamente para $P(F)$. ■

Proposição 1.3. *Sejam E e F eventos em $(\Omega, \mathcal{B}, P)$. Se eles são independentes, então os seguintes eventos também o são:*

1. E e F^c
2. E^c e F
3. E^c e F^c

Demonstração. Para (1), é verdade que

$$\begin{aligned} P(E \cap F^c) &= P(E) - P(E \cap F) \\ &= P(E)[1 - P(F)] \\ &= P(E)P(F^c) \end{aligned}$$

A expressão (2) é análoga a (1). Por fim, para expressão (3), conclua que

$$\begin{aligned}
 P(E^c \cap F^c) &= P((E \cup F)^c) = 1 - P(E \cup F) \\
 &= 1 - P(E) - P(F) + P(E \cap F) \\
 &= P(E^c) - P(F) + P(E) \cdot P(F) \\
 &= P(E^c) - P(F)[1 - P(E)] \\
 &= P(E^c) - P(F) \cdot P(E^c) \\
 &= P(E^c)[1 - P(F)] \\
 &= P(E^c) \cdot P(F^c)
 \end{aligned}$$

■

Teorema 1.21 (Teorema de Probabilidade Total). *Seja o espaço de probabilidade $(\Omega, \mathcal{B}, P)$. Seja $\mathcal{F} = \{F_i\}_{i \in \mathbb{N}}$, com $\mathcal{F} \subset \mathcal{B}$, uma partição de Ω . Se $E \in \mathcal{B}$, então*

$$P(E) = \sum_{F \in \mathcal{F}} P(E|F) \cdot P(F)$$

Demonstração. Para quaisquer $i, j \in \mathbb{N}$ temos que

$$(E \cap F_i) \cap (E \cap F_j) = \emptyset.$$

Com isso, podemos usar aditividade enumerável disjunta,

$$P\left(\bigcup_{F \in \mathcal{F}} (E \cap F)\right) = \sum_{F \in \mathcal{F}} P(E \cap F).$$

Em vista de que

$$\bigcup_{F \in \mathcal{F}} (E \cap F) = E \cap \Omega = E,$$

então

$$P(E) = \sum_{F \in \mathcal{F}} P(E \cap F),$$

e pela definição de probabilidade condicional,

$$P(E) = \sum_{F \in \mathcal{F}} P(E|F) \cdot P(F).$$

■

1.4 Teorema de Bayes

Teorema 1.22 (Teorema de Bayes). *Seja $(\Omega, \mathcal{B}, P)$ um espaço de probabilidade. Se E e F são eventos, então*

$$P(E|F) = P(F|E) \frac{P(E)}{P(F)}$$

Demonstração.

$$\begin{aligned}
 P(E|F) \cdot P(F) &= P(E \cap F) = P(F \cap E) = P(F|E)P(E) \\
 P(E|F) &= P(F|E) \frac{P(E)}{P(F)}
 \end{aligned}$$

■

Uma interpretação para o teorema é a atualização na crença $P(E)$, chamada de **prior**, numa hipótese E dada uma nova evidência F para ela, obtendo um novo grau de crença $P(E|F)$ chamado de **posterior**. A probabilidade $P(F|E)$ é chamada de **verossimilhança**, denotando o quão verossímil é observar a evidência F considerando a hipótese E verdadeira. Por sua vez, $P(F)$ é a crença na ocorrência de F tendo em vista todas as hipóteses, que, junto com a verossimilhança, ajusta o novo grau de crença em E .

Se num dado experimento aleatório consideramos hipóteses $E_1, \dots, E_n$ e obtemos uma evidência F , é plausível questionar em qual hipótese deveríamos depositar maior crença visto a evidência. Consideremos então o corolário:

Corolário 1.2 (Fórmula de Bayes). *Seja $\mathcal{E} = \{E_i\}_{i \in \mathbb{N}}$ uma partição de eventos de um espaço amostral Ω . Se F é um evento de Ω , então*

$$P(E_i|F) = \frac{P(F|E_i)P(E_i)}{\sum_{E \in \mathcal{E}} P(E)P(F|E)}$$

Demonstração. Segue do Teorema de Bayes e do Teorema da Probabilidade Total. ■

Logo, para cada hipótese, poderíamos utilizar a Fórmula de Bayes para computar a crença *a posteriori* nela após a evidência F , e selecionar aquela que tivesse maior probabilidade.

Variáveis Aleatórias

Variáveis aleatórias (v.a.) são representações de características numéricas de experimentos aleatórios. Exemplos são a quantidade de caras obtidas no lançamento de uma moeda, a soma dos lados de um dado, número de erros num livro, tempo até a um equipamento apresentar falha, entre muitos outros.

2.1 Variáveis Aleatórias

Definição 2.1. Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade. A aplicação $X : \Omega \rightarrow \mathbb{R}$ é uma variável aleatória se for $(\mathcal{F}, \mathcal{B}(\mathbb{R}))$ -mensurável, i.e.,

$$\forall A \in \mathcal{B}(\mathbb{R}), (X^{-1}(A) \in \mathcal{F})$$

A fim de facilitar o tratamento de variáveis aleatórias, iremos introduzir uma notação para denotar eventos de um espaço amostral a partir da variável

Definição 2.2. Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade e $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. Se $A \in \mathcal{B}(\mathbb{R})$, então o evento denotado por $\{X \in A\}$ é equivalente a $X^{-1}(A) \in \mathcal{B}$.

Perceba que se $A \in \mathcal{B}(\mathbb{R})$, então temos três formas de denotar o mesmo evento de $\mathcal{F}$.

$$X^{-1}(A) = \{X \in A\} = \{\omega \in \Omega \mid X(\omega) \in A\}$$

Definição 2.3. Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade e $X : \Omega \rightarrow \mathbb{R}$ uma variável aleatória. A tripla $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_X)$ é o espaço de probabilidade induzido por X se para todo $A \in \mathcal{B}(\mathbb{R})$ é satisfeito

$$P_X(A) = P(X \in A)$$

Definição 2.4. O suporte de uma variável aleatória X é o conjunto

$$\Omega_X = \{x \in \mathbb{R} \mid \forall \epsilon > 0, P(x - \epsilon < X < x + \epsilon) > 0\}$$

Teorema 2.1. Se X é uma variável aleatória com suporte Ω_X , então $P_X(\Omega_X) = 1$.

Demonstração. Se $S = \mathbb{R} \setminus \Omega_X$, então

$$x \in S \leftrightarrow \exists a, b \in \mathbb{R}, x \in (a, b) \wedge P_X((a, b)) = 0.$$

Pelo fato de $\mathbb{Q}$ ser denso em $\mathbb{R}$, existem $p, q \in \mathbb{Q}$ tais que

- i. $x \in (p, q)$
- ii. $(p, q) \subset (a, b)$
- iii. $P_X((p, q)) = 0$

De (i) segue que

$$S \subset \bigcup_{(p,q) \in I} (p,q),$$

onde $I \subset \mathbb{Q}^2$ é uma família enumerável de intervalos. Por (ii) e (iii) tem-se

$$P_X(S) \leq P_X \left(\bigcup_{(p,q) \in I} (p,q) \right) \leq \sum_{(p,q) \in I} P_X((p,q)) = 0.$$

Se $0 \leq P_X(S) \leq 0$, então $P_X(S) = 0$. Conclui-se que $P_X(\Omega_X) = 1$. ■

Proposição 2.1. *Seja X uma variável aleatória e $S \in \mathcal{B}(\mathbb{R})$ com $P_X(S) = 1$. Se $A \in \mathcal{B}(\mathbb{R})$ e $P(X \in A) \neq 0$, então $A \cap S \neq \emptyset$.*

Demonstração. Suponha que $A \cap S = \emptyset$, e por σ -aditividade,

$$P(A \cup S) = P(A) + P(S) = P(A) + 1$$

Mas pelo Teorema 1.18,

$$\begin{aligned} P(A) + 1 &\leq 1 \\ P(A) &\leq 0 \end{aligned}$$

Por não negatividade,

$$\begin{aligned} 0 &\leq P(A) \leq 0 \\ P(A) &= 0 \end{aligned}$$

■

2.2 Função de Distribuição Acumulada

Do Teorema 1.2, temos que se X é uma variável aleatória e $(\Omega, \mathcal{F}, P)$ espaço de medida, então $\{X \leq x\} \in \mathcal{F}$ para todo $x \in \mathbb{R}$. Esse fato permite-nos definir uma função que informa, para cada ponto na reta real, a probabilidade de uma variável ter realização menor igual a daquele ponto. Isso equivale a probabilidade que é acumulada por aquele ponto. Essa função é chamada de **Função de Distribuição Acumulada**, ou distribuição apenas.

Definição 2.5. *Sejam Ω um espaço amostral e P uma medida de um espaço de probabilidade e X uma variável aleatória. A função $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de distribuição acumulada para X se, e somente se,*

$$F(x) = P(X \leq x)$$

Um consequência imediata da definição é que se P_X é a medida do espaço induzido por X , então

$$F(x) = P_X((-\infty, x]).$$

Outros fatos devem ser satisfeitos para determinada função ser de probabilidade acumulada. Temos que $F(x)$ equivale a uma medida de probabilidade, então ela deve ser limitada superiormente por 1 e inferiormente por 0. Pelo princípio de que $A \subset B$ implica $P(A) \leq P(B)$, então se $x < y$, teríamos $P(X \leq x) \leq P(X \leq y)$, e a FDA é monótona. Por fim, se a partir de um ponto x nos aproximamos de um ponto a pela direita, então estamos aproximando o evento $(-\infty, x]$ do evento $(-\infty, a]$, o que significa que essa a distribuição acumulada deve ser contínua à direita, visto que o primeiro evento inclui o segundo.

Teorema 2.2. *Se $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função de distribuição acumulada de uma variável aleatória X , então*

1. $\forall x_1, x_2 \in \mathbb{R}, (x_1 \leq x_2 \rightarrow F(x_1) \leq F(x_2))$
2. $\forall x, a \in \mathbb{R}, (\lim_{x \rightarrow a^+} F(x) = F(a))$
3. $\lim_{x \rightarrow \infty} F(x) = 1$

$$4. \lim_{x \rightarrow -\infty} F(x) = 0$$

Demonstração. A afirmação (1) segue do fato de que, se $x_1 \leq x_2$, então

$$(X \leq x_1) \subset (X \leq x_2),$$

e pelo Teorema 1.4,

$$P(X \leq x_1) \leq P(X \leq x_2) \implies F(x_1) \leq F(x_2).$$

Seguindo para a afirmação (2),

$$\lim_{x \rightarrow a^+} F(x) = \lim_{x \rightarrow a^+} P(X \leq x)$$

Se x decresce até a , então os eventos $\{X \leq x\}$, para $x > a$, formam uma sequência decrescente de eventos cuja interseção é $\{X \leq a\}$. Pela continuidade de probabilidades, temos que

$$\lim_{x \rightarrow a^+} P(X \leq x) = P\left(\lim_{x \rightarrow a^+} X \leq x\right) = P(X \leq a) = F(a)$$

Para as afirmações (3) e (4), considere a sequência de intervalos encaixados

$$I_1 \subset I_2 \subset \dots$$

com extremos inferiores e superiores a_i e b_i respectivamente com $i \in \mathbb{N}$. Os eventos $\{X \leq b_i\}$ formam uma sequência crescente de eventos encaixados tal que

$$\lim_{n \rightarrow \infty} \{X \leq b_n\} = \{X \leq \infty\}$$

Novamente, pela continuidade da probabilidade,

$$\lim_{x \rightarrow \infty} F(x) = \lim_{x \rightarrow \infty} P(X \leq x) = P(X \leq \infty) = P(\mathbb{R}) = 1$$

O mesmo argumento é replicável para (4): a sequência de eventos $\{X \leq a_i\}$ converge para $\{X \leq -\infty\}$, de sorte que

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{x \rightarrow -\infty} P(X \leq x) = P(X \leq -\infty) = P(\emptyset) = 0$$

■

Proposição 2.2. Se X é variável aleatória e μ_F é a medida de Stieltjes induzida por F , então $P_X = \mu_F$.

Demonstração. Para quaisquer $a, b \in \mathbb{R}$, temos

$$(-\infty, a] \cup (a, b] = (-\infty, b] \quad (-\infty, a] \cap (a, b] = \emptyset$$

e por σ -aditividade

$$\begin{aligned} P_X((-\infty, a]) + P_X((a, b]) &= P_X((-\infty, b]) \\ P_X((a, b]) &= P_X((-\infty, b]) - P_X((-\infty, a]) \\ P_X((a, b]) &= F(b) - F(a) \end{aligned}$$

Logo,

$$P_X((a, b]) = \mu_F((a, b])$$

■

2.3 Variáveis Aleatórias Discretas

Definição 2.6. Se X é uma variável aleatória, então X é discreta se, e somente se, existe um conjunto $S \subset \mathbb{R}$ enumerável tal que

$$P(X \in S) = 1$$

Teorema 2.3. O suporte Ω_X de uma variável aleatória X é enumerável se, e somente se, X é enumerável.

Demonstração. Sendo Ω_X enumerável, então pelo Teorema 2.1 segue que X é discreta. Por outro lado, supondo X discreta, então seja S tal que $P_X(S) = 1$. Sendo $x \in \Omega_X$, então

$$\forall \epsilon > 0, P(|X - x| < \epsilon) > 0$$

mas se $x \notin S$, segue da Proposição 2.1 que

$$\forall \epsilon > 0, S \cap (x - \epsilon, x + \epsilon) \neq \emptyset,$$

concluindo-se que todo ponto em $\Omega_X \setminus S$ é de acumulação em S . Definamos

$$A = S \cup \{x \in \mathbb{R} \setminus S \mid x \text{ é ponto de acumulação de } S\}$$

donde teremos $\Omega_X \subset A$. Como S é enumerável, então o conjunto de seus pontos de acumulação também será, assim como A . Uma vez que Ω_X é subconjunto de um enumerável, então ele próprio é enumerável. ■

Definição 2.7. Seja $X : \Omega \rightarrow \mathbb{R}$ uma v.a. discreta. A função $p_X : \mathbb{R} \rightarrow [0, 1]$ é a função de massa de probabilidade de X se, e somente se,

$$P(X = x) = p_X(x)$$

Proposição 2.3. Seja $(\Omega, \mathcal{F}, P)$ um espaço de probabilidade e seja X uma variável aleatória discreta tal que $P(X \in S) = 1$, onde $S \subset \mathbb{R}$. Defina

$$\begin{aligned} p_X : \mathbb{R} &\rightarrow [0, 1] \\ x &\mapsto P(X = x) \end{aligned}$$

Então a aplicação

$$\begin{aligned} \mu_X : \mathcal{P}(S) &\rightarrow [0, 1] \\ A &\mapsto \sum_{x \in A} p_X(x) \end{aligned}$$

é uma medida de probabilidade em $(S, \mathcal{P}(S))$.

Demonstração. Para todo $A \subset S$,

$$\mu_X(A) = \sum_{x \in A} p_X(x) = \sum_{x \in A} P(X = x).$$

Como os eventos $\{X = x\}$, com $x \in A$, são dois a dois disjuntos, segue da σ -aditividade de P que

$$\mu_X(A) = P(X \in A).$$

Em particular,

$$\mu_X(S) = P(X \in S) = 1.$$

Logo, μ_X é uma medida de probabilidade em $(S, \mathcal{P}(S))$. ■

Lema 2.1. Se X é variável discreta e $A \in \mathcal{B}(\mathbb{R})$ é enumerável, então

$$P(X \in A) = \sum_{x \in A} p_X(x)$$

Demonstração. Por σ -aditividade,

$$P(X \in A) = \sum_{x \in A} P(X = x) = \sum_{x \in A} p_X(x)$$

■

Proposição 2.4. Se $X : \Omega \rightarrow \mathbb{R}$ é uma v.a. discreta com função de massa igual a p_X e suporte Ω_X , então a distribuição de X é

$$F_X(x) = \sum_{\substack{a \in \Omega_X \\ a \leq x}} p_X(a)$$

Demonstração. Suponha $A = \{a \in \Omega_X \mid a \leq x\}$ e $I = (-\infty, x]$. Observe que,

$$P(X \leq x) = P(X \in I)$$

e como $A \subset I$, então por σ -aditividade,

$$P(X \leq x) = P(X \in A) + P(X \in I \setminus A)$$

Suponha por contradição que $P(X \in I \setminus A) \neq 0$, e pela proposição 2.1, $(I \setminus A) \cap \Omega_X \neq \emptyset$, o que equivale a

$$I \cap (\Omega_X \setminus A) \neq \emptyset$$

mas $\Omega_X \setminus A = \{a \in \Omega_X \mid a > x\}$, o que contradiz a hipótese anterior. Portanto,

$$P(X \leq x) = P(X \in A),$$

e pelo lema 2.1,

$$F_X(x) = \sum_{x \in A} p_X(x),$$

que equivale a

$$F_X(x) = \sum_{\substack{a \in \Omega_X \\ a \leq x}} p_X(a).$$

■

Com isso, se $S = \{x \in \mathbb{R} \mid p_X(x) > 0\} \subseteq \Omega_X$, então seja $\{x_i\}_{i \in \mathbb{N}}$ uma ordenação de S de tal modo

$$F(x) = \begin{cases} 0, & \text{se } x < x_1 \\ F(x_1), & \text{se } x_1 \leq x < x_2 \\ \vdots & \\ F(x_i), & \text{se } x_i \leq x < x_{i+1} \\ \vdots & \end{cases}.$$

A função F é, pois, uma função constante por partes que sempre incluem a extremidade esquerda de seu domínio devido à propriedade necessária de uma distribuição sempre ser contínua à direita. Uma vez que

$$\begin{aligned} P(X = x_i) &= P(X \leq x_i) - P(X < x_i) \\ P(X = x_i) &= F(x_i) - \lim_{x \rightarrow x_i^-} F(x) \\ P(X = x_i) &= F(x_i) - F(x_{i-1}), \end{aligned}$$

então $p_X(x_i)$ é o salto entre duas partes consecutivas da distribuição de X .

2.4 Variáveis Aleatórias Contínuas

Definição 2.8. A variável aleatória X será contínua se $P_X \ll \lambda$.

Proposição 2.5. Toda variável aleatória contínua X admite uma função real mensurável não negativa $f \in L^1(\lambda)$ tal que

$$f = \frac{d}{d\lambda} P_X$$

Demonstração. Se X é contínua, então $P_X \ll \lambda$. Como λ é σ -finita, então pelo Teorema de Radon-Nikodym existe $f \in L^1(\lambda)$ não negativa tal que

$$f = \frac{d}{d\lambda} P_X$$

■

Definição 2.9. Seja X uma variável aleatória contínua com medida induzida P_X . A função

$$f = \frac{d}{d\lambda} P_X$$

é chamada de densidade de probabilidade de X .

Proposição 2.6. Se X é uma variável contínua com densidade f e distribuição F , então

$$F(x) = \int_{-\infty}^x f(t) dt$$

Demonstração.

$$F(x) = P_X((-\infty, x]) = \int_{(-\infty, x]} f d\lambda = \int_{-\infty}^x f(t) dt$$

■

Proposição 2.7. A variável X é contínua se, e somente se, sua distribuição F é absolutamente contínua.

Demonstração. Supondo que X é contínua, então $P_X \ll \lambda$. Pela Proposição 2.2 e pelo Teorema 1.7, concluiremos que F é absolutamente contínua. Por outro lado, se F é absolutamente contínua, então $\mu_F = P_X \ll \lambda$ e, por definição, a variável X será contínua. ■

Teorema 2.4. Se X é uma variável aleatória contínua com densidade f , então para todo $x, a, b \in \mathbb{R}$

$$i. P(a < X \leq b) = \int_a^b f(t) dt$$

$$ii. P(X = x) = 0$$

$$iii. P(X \leq x) = P(X < x)$$

$$iv. P(X \geq x) = P(X > x)$$

Demonstração.

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$$

e pela Proposição 2.6

$$P(a < X \leq b) = \int_{-\infty}^b f(t) dt - \int_{-\infty}^a f(t) dt = \int_a^b f(t) dt$$

provando (i).

A afirmação (ii) é consequência direta,

$$P(X = x) = \int_x^x f(t) dt = 0.$$

Uma vez que

$$P(X \leq x) = P(X = x) + P(X < x) \quad \text{e} \quad P(X \geq x) = P(X = x) + P(X > x)$$

então (iii) e (iv) são consequências de (ii). ■

Proposição 2.8. Se X é uma variável aleatória contínua com densidade f e suporte Ω_X , então

$$\int_{\Omega_X} f d\lambda = \int_{\mathbb{R}} f \lambda = 1$$

Demonstração. Com efeito,

$$P_X(\Omega_X) = 1 \implies \int_{\Omega_X} f d\lambda = 1.$$

Ademais, se $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_X)$ é o espaço de probabilidade induzido por X , então

$$P_X(\mathbb{R}) = P(\Omega) = 1 \implies \int_{\mathbb{R}} f d\lambda = 1$$

■

Proposição 2.9. Se X é uma variável contínua com densidade f e suporte Ω_X , então

$$f = 0 \text{ q.s. em } \mathbb{R} \setminus \Omega_X$$

Demonstração. Seja $A = \mathbb{R} \setminus \Omega_X$. Observe que

$$\int_A f d\lambda + \int_{\Omega_X} f d\lambda = \int_{\mathbb{R}} f d\lambda$$

e pela Proposição 2.8, conclui-se

$$\int_A f d\lambda = 0.$$

Como uma função de densidade é mensurável e não negativa, então por nulidade da integral de Lebesgue, obtém-se que $f = 0$ q.s. em A . ■

2.5 Transformações

Definição 2.10. Uma transformação de uma variável aleatória X com imagem $\mathcal{X}$ é toda função $f : \mathcal{X} \rightarrow \mathbb{R}$.

Definição 2.11. Se $X : \Omega \rightarrow \mathbb{R}$ é uma variável aleatória e f é uma transformação de X , então $f(X) = f \circ X$ é uma variável aleatória se, e somente se,

Proposição 2.10. Seja X uma variável aleatória, f uma transformação e $A \in \mathcal{B}(\mathbb{R})$.

$$P_X(f(X) \in A) = P(X \in f^{-1}(A))$$

Demonstração.

$$\begin{aligned} P_X(f(X) \in A) &= P_X(\{x \in \mathbb{R} \mid f(x) \in A\}) \\ &= P(X \in f^{-1}(A)) \end{aligned}$$

■

Com essa proposição, uma transformação induz um novo espaço de probabilidade $(\mathbb{R}, \mathcal{B}(\mathbb{R}), P_f)$ onde

$$P_f(A) = P_X(f^{-1}(A)) = P(X \in f^{-1}(A))$$

2.5.1 Transformação de Variáveis Discretas

Teorema 2.5. Seja X uma variável discreta com suporte Ω_X , FMP igual a p_X , f uma transformação de X e $Y = f(X)$. A variável Y é discreta e sua FMP é dada por

$$p_Y(y) = \sum_{x \in f^{-1}(y)} p_X(x)$$

Demonstração. De 2.10 sabemos que

$$P(Y \in A) > 0 \iff P(X \in f^{-1}(A)) > 0,$$

o que ocorre também se, e somente se, $A \cap \Omega_Y \neq \emptyset$. Essa afirmação é verdade somente quando há $x \in \mathbb{R}$ que satisfaz $f(x) \in A$ e $x \in \Omega_X$. Portanto, $y \in \Omega_Y$ ocorre somente quando $y = f(x)$ e $x \in \Omega_X$, ou seja, Ω_Y é a imagem de Ω_X sobre f , sendo, pois, enumerável.

O resultado sobre a FMP de Y segue do fato de que

$$p_Y(y) = P(Y = y) = P(X \in f^{-1}(y))$$

e temos que

$$p_Y(y) = \sum_{x \in f^{-1}(y)} p_X(x)$$

■

2.5.2 Transformação de Variáveis Contínuas

Para transformações de variáveis contínuas, concentramos-nos, primeiramente, nas transformações monótonas, pois essas são bijetoras, e compõem casos mais simples para se analisar.

É possível obter a FDA de uma transformação monótona $Y = g(X)$ de uma variável X apenas em termos da própria FDA de X e da inversa da transformação.

Teorema 2.6. *Seja X uma variável aleatória com FDA igual a F_X e suporte Ω_X . Seja também $Y = g(X)$ uma transformação monótona com suporte Ω_Y . Se g for crescente, então*

$$\forall x \in \Omega_X \forall y \in \Omega_Y, F_Y(y) = F_X(g^{-1}(y)).$$

Se for decrescente, então

$$\forall x \in \Omega_X \forall y \in \Omega_Y, F_Y(y) = 1 - F_X(g^{-1}(y)).$$

Demonstração. Com efeito,

$$F_Y(y) = P(Y \leq y) = P(X \leq g^{-1}(-\infty, y))$$

Sendo g monótona crescente crescente, g^{-1} também será, de modo que

$$F_Y(y) = P(\{x \in \mathcal{X} \mid x \leq g^{-1}(y)\}) = \int_{-\infty}^{g^{-1}(y)} f_X(x) dx = F_X(g^{-1}(y))$$

■

Por sua vez, a densidade de transformações $Y = g(X)$ em casos em que a densidade de X é contínua, pode ser obtidas via a Regra da Cadeia do Cálculo Diferencial, com a condição de que a inversa de g seja também contínua em Ω_Y . Caso a densidade de X nem a inversa da transformação sejam contínuas em Ω_X e Ω_Y respectivamente, a regra da cadeia não poderia ser aplicada, complexificando a determinação da densidade de Y .

Teorema 2.7. *Seja X uma variável aleatória com f.d.p. igual a f_X . Seja $Y = g(X)$ uma variável obtida pela transformação g e com suporte Ω_Y . Se g é monótona, f_X é contínua em Ω_X e g^{-1} tem derivada contínua em Ω_Y , então a f.d.p. de Y é dada por*

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, & \text{caso contrário.} \end{cases}$$

O teorema 2.7 permite-nos a generalizar a obtenção da densidade de probabilidade de transformações não monótonas que podem ser decompostas em partes monótonas. Um exemplo clássico é a função $g(x) = x^2$ definida em $\mathbb{R}$. Essa função não é monótona, porém suas partes definidas separadamente em $(-\infty, 0)$ e $[0, \infty)$ serão. A densidade da variável definida pela transformação poderá, portanto, ser obtida pelo resultado a seguir

Teorema 2.8. *Seja X uma variável aleatória com f.d.p. igual a f_X . Seja $Y = g(X)$ uma variável obtida pela transformação g e com suporte Ω_Y . Se Ω_X admite partição $\{A_1, \dots, A_n\}$ sendo possível definir a família de funções $\{g_i : A_i \rightarrow \mathbb{R}\}_{i \in [n]}$ tal que*

$$i \quad g_i(x) = g(x)$$

$$ii \quad g_i(x) \text{ é monótona em } A_i$$

$$iii \quad \Omega_Y \text{ é o mesmo para todo } i \in [n].$$

$$iv \quad g_i^{-1} \text{ tem derivada contínua em } \Omega_Y \text{ para todo } i \in [n].$$

e f_X contínua em cada A_i , então a f.d.p. de Y é dada por

$$f_Y(y) = \begin{cases} \sum_{i=1}^n f_X(g_i^{-1}(y)) \cdot \left| \frac{d}{dy} g_i^{-1}(y) \right|, & \text{se } y \in \Omega_Y \\ 0, & \text{caso contrário.} \end{cases}$$

2.6 Esperança de Variáveis Discretas

A esperança de uma variável aleatória é definida matematicamente como a média ponderada dos valores assumidos por essa variável. Uma interpretação para esperança é que ela é o valor médio de todas as realizações da variável ao se repetir o experimento aleatório um número infinito de vezes. Essa interpretação será justificada posteriormente com a **Lei dos Grandes Números**.

Definição 2.12. *Seja X uma v.a. discreta com f.m.p. p_X . A esperança $E[X]$ de X é definida tal como*

$$E[X] = \sum_{x \in \Omega_X} x \cdot p_X(x)$$

A partir do conhecimento da distribuição dos valores de uma variável, é possível ter conhecimento da distribuição dos valores de uma função aplicada sobre essa variável. Se $X : \Omega \rightarrow \mathbb{R}$ e $f : \mathbb{R} \rightarrow \mathbb{R}$, então $f(X) = f \circ X$ é uma variável aleatória por definição. Digamos que $f(X) = Y$, então a massa de probabilidade $Y = y$ será a soma das probabilidades de $X = x$ tal que $x \in \Omega_X$ tem y como imagem em f , já que as realizações de uma v.a. são sempre disjuntas.

$$P(Y = y) = \sum_{\substack{x \in \Omega_X \\ f(x)=y}} P(X = x)$$

Tão logo conhecendo a distribuição de $f(X)$ a partir da distribuição de X , então poderemos expressar a esperança de $f(X)$ em termos da própria f.m.p. de X .

Proposição 2.11. *Seja X uma v.a. discreta com f.m.p. p_X , e $f : \mathbb{R} \rightarrow \mathbb{R}$ uma função. A esperança da variável aleatória definida por $f(X) = f \circ X$ é dada por*

$$E[f(X)] = \sum_{x \in \Omega_X} f(x) \cdot p_X(x)$$

Demonstração. Seja Ω_f o suporte de $f(X)$ e p_f a sua f.m.p.. Temos que

$$\begin{aligned} \sum_{x \in \Omega_X} f(x) \cdot p_X(x) &= \sum_{y \in \Omega_f} \sum_{\substack{x \in \Omega_X \\ f(x)=y}} y \cdot p_X(x) \\ &= \sum_{y \in \Omega_f} y \sum_{\substack{x \in \Omega_X \\ f(x)=y}} p_X(x) \end{aligned}$$

Fixando y , observamos que

$$p_f(y) = \sum_{\substack{x \in \Omega_X \\ f(x)=y}} p_X(x).$$

Logo

$$E[f(X)] = \sum_{y \in \Omega_f} y \cdot p_f(y).$$

■

A esperança satisfaz as propriedades de linearidade. Isso significa que, se uma v.a. é definida como uma constante, como produto de uma v.a. por uma constante ou como a soma de outras duas v.a.'s, podemos facilmente obter a esperança da variável derivada a partir das variáveis que a compõe. Ressaltemos que constantes podem ser vistas como v.a.'s com suporte unitário.

Proposição 2.12. *Sejam X e Y variáveis aleatórias. A esperança satisfaz:*

1. *se X tem suporte unitário igual a $\{c\}$, então $E[X] = c$.*
2. $E[\lambda X] = \lambda E[X]$.
3. $E[X + Y] = E[X] + E[Y]$.

Demonstração. Para (1), basta observar que $E[X] = c \cdot 1 = c$.

Para (2), usemos a definição de esperança:

$$E[\lambda X] = \sum_{x \in \Omega_X} \lambda x \cdot p_X(x) = \lambda \sum_{x \in \Omega_X} x \cdot p_X(x) = \lambda E[X].$$

Para provar (3), temos que

$$E[X + Y] = \sum_{x \in \Omega_X} \sum_{y \in \Omega_Y} (x + y) P(X = x, Y = y),$$

e expandindo,

$$E[X + Y] = \sum_{x \in \Omega_X} x \sum_{y \in \Omega_Y} P(X = x, Y = y) + \sum_{y \in \Omega_Y} y \sum_{x \in \Omega_X} P(X = x, Y = y). \quad (2.1)$$

Já que

$$\sum_{y \in \Omega_Y} P(X = x, Y = y) = \sum_{y \in \Omega_Y} P(X = x | Y = y) P(Y = y),$$

então pelo Teorema da Probabilidade Total,

$$\sum_{y \in \Omega_Y} P(X = x, Y = y) = P(X = x)$$

e, de forma análoga,

$$\sum_{x \in \Omega_X} P(X = x, Y = y) = P(Y = y),$$

então podemos simplificar a expressão 2.1 para

$$E[X + Y] = \sum_{x \in \Omega_X} x \cdot P(X = x) + \sum_{y \in \Omega_Y} y \cdot P(Y = y),$$

e, finalmente

$$E[X + Y] = E[X] + E[Y]$$

■

Modelos de Distribuição de Probabilidade

3.1 Modelos de Distribuição Discreta

Muitas características de fenômenos aleatórios podem ser modelados como variáveis aleatórias discretas, como determinar se o lançamento de uma moeda deu cara, quantas pessoas possuem diploma numa população de tamanho conhecido, quantas bolas devemos sortear de uma urna até que obtenhamos a que contém a cor desejada, etc.

3.1.1 Distribuição Bernoulli

A distribuição Bernoulli modela experimentos que só podem ter dois resultados possíveis: *sucesso* ou *fracasso*. Seu único parâmetro é a probabilidade p de obter *sucesso* no experimento. Dessa forma, podemos particionar o espaço amostral em dois eventos disjuntos: $X = 0$ e $X = 1$. O primeiro é aquele cujos resultados são *fracassos*, obtidos com probabilidade $1 - p$, enquanto que no segundo são aqueles cujos resultados são *sucessos*, que ocorre com probabilidade p .

Definição 3.1. Suponha que Ω seja um espaço amostral e $\mathcal{P} = \{F, S\}$ uma partição de Ω . A variável X tem distribuição Bernoulli de parâmetro p , denotado por $X \sim \text{Bernoulli}(p)$, se, e somente se, X é a função indicadora de um membro de $\mathcal{P}$ e

$$P(X = 1) = p.$$

Da definição formal de uma distribuição Bernoulli, segue que seu suporte é o conjunto $\{0, 1\}$. Se $S \subset \Omega$ reúne os *sucessos*, então podemos escrever

$$P(S) = p \quad \text{e} \quad P(F) = 1 - p$$

e, caso Ω seja equiprovável, então

$$p = \frac{|S|}{|\Omega|}$$

Proposição 3.2. A f.m.p. da distribuição Bernoulli de parâmetro p é dada por

$$p_X(x) = p^x(1 - p)^{1-x}$$

Demonstração. Temos que

$$P(X = x) = \begin{cases} p, & \text{se } x = 1 \\ 1 - p, & \text{se } x = 0 \end{cases}$$

que equivale à fórmula desejada. ■

A esperança de uma Bernoulli é dada como

$$E[X] = 1 \cdot p + 0 \cdot (1 - p) = p.$$

Conclui-se que a taxa de sucessos é a própria probabilidade de obter um sucesso no experimento.

3.1.2 Distribuição Binomial

A distribuição binomial é uma versão mais generalizada da Bernoulli, modelando quantos sucessos são obtidos num experimento que consiste de n tentativas Bernoulli independentes, isto é, uma tentativa não altera no resultado da outra. Exemplo inclui quantas caras obtemos ao lançar uma moeda 10 vezes. Os parâmetros dessa distribuição são o número de tentativas n e o número de sucessos p . Seu suporte será igual aos inteiros de 0 a n .

Cada uma das n tentativas Bernoulli são v.a.'s $X_k \sim \text{Bernoulli}(p)$, com $k \in [n]$, independentes. Logo, a probabilidade de um evento $(X_k = x_k)_{k \in [n]}$ com a sucessos, tendo fixado o valor de cada x_k , deve ser igual a

$$P((X_k = x_k)_{k \in [n]}) = \prod_{k=1}^n P(X_k = x_k),$$

mas como há a resultados $x_k = 1$, e $n - a$ resultados $x_k = 0$, então

$$P((X_k = x_k)_{k \in [n]}) = \prod_{k=1}^n P(X_k = x_k) = p^a (1 - p)^{n-a}$$

Como cada uma das sequências de resultados com a sucessos são mutuamente exclusivas, então

$$P(X = a) = m \cdot p^a (1 - p)^{n-a},$$

onde m é o número de sequências com a sucessos dentre n , que equivale a escolher a tentativas para serem sucessos dentre n possíveis, logo

$$P(X = a) = \binom{n}{a} \cdot p^a (1 - p)^{n-a}$$

Definição 3.3. $X \sim \text{Binomial}(n, p) \iff p_X(a) = \binom{n}{a} p^a (1 - p)^{n-a}$

Se a taxa de sucesso de cada ensaio Bernoulli é p , então podemos intuir que o número esperado de sucessos em n ensaios deverá ser a fração p do total dos ensaios, ou seja que o valor esperado seja np .

Proposição 3.4. Se $X \sim \text{Binomial}(n, p)$, então $E[X] = np$.

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^n k \cdot \binom{n}{k} p^k (1 - p)^{n-k}.$$

Utilizando o fato de que

$$\binom{n}{k} = \frac{n}{k} \binom{n-1}{k-1},$$

reduzimos então a

$$E[X] = n \sum_{k=0}^n \binom{n-1}{k-1} p^k (1 - p)^{n-k},$$

o que nos sugere realizar uma troca de variável em k para que consigamos usar o Teorema Binomial. Para tanto, realizemos que

$$n \sum_{k=0}^n \binom{n-1}{k-1} p^k (1 - p)^{n-k} = np \sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} (1 - p)^{n-k}$$

já que somar o termo $k = 0$ equivale a somar 0. Fazendo então a troca $j = k - 1$, obtemos

$$E[X] = np \sum_{j=0}^{n-1} \binom{n-1}{j} p^j (1 - p)^{(n-1)-j},$$

e pelo Teorema Binomial,

$$E[X] = np \cdot (p + 1 - p)^{n-1} = np$$

■

3.1.3 Distribuição Geométrica

Uma variável geométrica modela experimentos que consistem na repetição de ensaios Bernoulli independentes até que se obtenha o primeiro sucesso. Um exemplo é repetir o lançamento de uma moeda até obter coroa. Para obter a função de massa de probabilidade dessa variável para uma realização n , basta encontrar a probabilidade de obter $n - 1$ fracassos consecutivos seguidos de um sucesso. Desse modo, se $(X_k = x_k)_{k \in [n]}$ é uma sucessão de n ensaios Bernoulli independentes com parâmetro p , então

$$P((X_k = x_k)_{k \in \mathbb{N}}) = \prod_{k=1}^n P(X_k = x_k),$$

mas como os $n - 1$ valores de x_k são fracassos (iguais a 0) obtidos com probabilidade $1 - p$, e $x_n = 1$ é obtido com probabilidade p , então

$$P((X_k = x_k)_{k \in \mathbb{N}}) = (1 - p)^{n-1} p$$

Definição 3.5.

$$X \sim \text{Geo}(p) \longleftrightarrow p_X(n) = (1 - p)^{n-1} p$$

O número esperada de ensaios realizados num experimento até obter o primeiro sucesso é o valor esperado da variável geométrica.

Proposição 3.6. Se $X \sim \text{Geo}(p)$, então

$$E[X] = \frac{1}{p}$$

Demonstração. Com efeito,

$$E[X] = \sum_{k=0}^{\infty} k(1 - p)^{k-1} p = p \sum_{k=0}^{\infty} k(1 - p)^{k-1}.$$

O somatório à esquerda é a derivada de uma série geométrica de razão $q = 1 - p$, tal que $q < 1$. Observemos que

$$\begin{aligned} \frac{d}{dq} \left(\sum_{k=0}^{\infty} q^k \right) &= \frac{d}{dq} \left(\frac{1}{1 - q} \right) \\ \sum_{k=0}^{\infty} k(1 - p)^{k-1} &= \frac{1}{(1 - q)^2} \end{aligned}$$

donde conclui-se

$$E[X] = \frac{p}{(1 - 1 + p)^2} = \frac{1}{p}$$

■

3.1.4 Distribuição Binomial Negativa

A distribuição binomial negativa é similar à geométrica: invés de repetir os ensaios Bernoulli independentes até o obter o primeiro sucesso, os ensaios são repetidos até que se acumulem r sucessos, sendo esse total um novo parâmetro da distribuição. A dedução da f.m.p. para esse modelo de probabilidade é análogo ao da Binomial e da Geométrica; fixando uma sequência $((X_k = x_k)_{k \in [n]})$ de ensaios Bernoulli independentes com parâmetro p , temos que a probabilidade de uma sequência será

$$\prod_{k=1}^n P(X_k = x_k),$$

de sorte que, sendo r ensaios com $x_k = 1$ e $n - r$ ensaios com $x_k = 0$, então

$$\prod_{k=1}^n P(X_k = x_k) = (1 - p)^{n-r} p^r.$$

Visto que cada sequência de ensaios é mutualmente exclusiva, então a probabilidade de obter acumular n ensaios até obter r tentativas equivale ao total de escolhas de r ensaios para fixar $x_k = 1$ dentre n possíveis, logo

$$\binom{n}{r} (1 - p)^{n-r} p^r$$

Definição 3.7.

$$X \sim \text{BinNeg}(r, p) \longleftrightarrow p_X(n) = \binom{n}{r} (1-p)^{n-r} p^r$$

Uma binomial negativa pode ser vista como a sucessão de várias geométricas. Desse modo, o valor esperado de uma binomial negativa deve ser igual ao valor esperado da soma das geométricas que a compõe.

Proposição 3.8. Se $X \sim \text{BinNeg}(r, p)$, então

$$E[X] = \frac{r}{p}$$

Demonstração. Suponha que $(X_i)_{i \in [r]}$ denote a variável que determina quantos ensaios Bernoulli foram realizados até se obter um sucesso desde o último. Com efeito, a variável $X_i \sim \text{Geo}(p)$ para todo $i \in [r]$. Além disso, temos que

$$X = \sum_{i=1}^r X_i$$

Pela linearidade da esperança, conclui-se que

$$E[X] = \sum_{i=1}^r E[X_i] = \sum_{i=1}^r \frac{1}{p} = \frac{r}{p}$$

■

3.1.5 Distribuição Hipergeométrica

A distribuição hipergeométrica modela amostragens de tamanho n de um espaço amostral equiprovável de tamanho N , em que m dos resultados possíveis são considerados sucessos. Um exemplo clássico são bolas numa urna, das quais m são azuis, e as demais vermelhas. A urna é nosso espaço amostral, as m bolas azuis são os resultados que representam sucessos possíveis, caso realizássemos um sorteio de n bolas da urna, a variável que nos dá o número de bolas azuis sorteadas é hipergeométrica.

Para obter a função de distribuição para a situação sendo modelada, considere uma população de tamanho N , com m indivíduos pertencentes ao evento de sucessos, e uma amostra de tamanho n dessa população. Para obter a probabilidade de obter k indivíduos na amostra que sejam sucessos, supondo que os indivíduos na população são equiprováveis, podemos utilizar a proposição 1.1, considerando Ω como o universo das amostras, e E as amostras que possuem k indivíduos considerados sucessos. O número de amostras possíveis equivale a selecionar n indivíduos de N possíveis

$$|\Omega| = \binom{N}{n}.$$

Por sua vez, o número de amostras com k sucessos equivale ao selecionar k indivíduos dos m que são sucessos e selecionar outros $n - k$ com que não pertencem a esse grupo dos $N - m$ restantes. Por conseguinte

$$|E| = \binom{m}{k} \cdot \binom{N-m}{n-k}$$

e a probabilidade de uma amostra conter k sucessos será

$$\frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

Definição 3.9.

$$X \sim \text{HG}(N, m, n) \longleftrightarrow p_X(k) = \frac{\binom{m}{k} \cdot \binom{N-m}{n-k}}{\binom{N}{n}}$$

A média de uma hipergeométrica pode ser facilmente obtida pelo seguinte raciocínio: suponha que já tenhamos selecionado a amostra de tamanho n e temos o conhecimento *a priori* de que a população N continha m sucessos, implicando que a probabilidade que cada indivíduo da amostra selecionada tenha probabilidade m/N de ser um sucesso. Considerando que cada indivíduo na amostra é um ensaio Bernoulli de parâmetro m/N , então a média de sucessos deve ser igual a $\frac{nm}{N}$.

Proposição 3.10. Se $X \sim \text{HG}(N, m, n)$, então

$$E[X] = n \frac{m}{N}$$

Demonstração. Presuma que a amostra de tamanho n obtida seja a sequência de eventos $(X_k = x_k)_{k \in [n]}$, em que $X_k : \Omega \rightarrow \{0, 1\}$ é a variável indicadora do conjunto dos sucessos S . Como $|S| = m$ e $|\Omega| = N$, então

$$P(S) = \frac{m}{N}$$

e X_k equivale a uma v.a. Bernoulli de parâmetro m/N . Logo, o número de sucessos na amostra é uma variável binomial com parâmetros n e n/N , e sua média será

$$E[X] = n \frac{m}{N}$$

■

3.1.6 Distribuição de Poisson

A distribuição de Poisson modela contagem de eventos que ocorrem dentro de um intervalo contínuo – como o tempo, uma superfície ou volume – com probabilidade praticamente desprezível. Essa distribuição pode ser compreendida como a uma aproximação da Binomial quando $n \rightarrow \infty$.

Considere que $X \sim \text{Binomial}(n, p)$, logo

$$p_X(a) = \binom{n}{a} (1-p)^{n-a} p^a$$

Se tomarmos o limite da f.m.p. de X quando $n \rightarrow \infty$ e denotamos np por λ , então

$$\begin{aligned} \lim_{n \rightarrow \infty} p_X(a) &= \lim_{n \rightarrow \infty} \binom{n}{a} \left(\frac{\lambda}{n}\right)^a \left(1 - \frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n \rightarrow \infty} \frac{n(n-1) \dots (n-a+1)}{a!} \left(\frac{\lambda}{n}\right)^a \left(1 - \frac{\lambda}{n}\right)^{n-a} \\ &= \lim_{n \rightarrow \infty} \prod_{k=1}^{a-1} \left(1 - \frac{k}{n}\right) \cdot \lim_{n \rightarrow \infty} \frac{\lambda^a (1 - \lambda/n)^n}{a! (1 - \lambda/n)^a} \end{aligned}$$

Como

$$\lim_{n \rightarrow \infty} \prod_{k=1}^{a-1} \left(1 - \frac{k}{n}\right) = 1 \quad \text{e} \quad \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

então,

$$\lim_{n \rightarrow \infty} p_X(a) = \lim_{n \rightarrow \infty} \frac{\lambda^a}{a!} \left(1 - \frac{\lambda}{n}\right)^n$$

Usando o limite exponencial fundamental

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

obtemos, por fim,

$$\lim_{n \rightarrow \infty} p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Definição 3.11.

$$X \sim \text{Poisson}(\lambda) \iff p_X(a) = e^{-\lambda} \frac{\lambda^a}{a!}$$

Proposição 3.12. Se $X \sim \text{Poisson}(\lambda)$, então

$$E[X] = \lambda$$

Demonstração. Com efeito,

$$\begin{aligned} E[X] &= \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \end{aligned}$$

O somatório equivale ao Polinômio de Taylor de e^λ , portanto

$$E[X] = \lambda e^{-\lambda} e^\lambda = \lambda$$

■

Variáveis Aleatórias Multidimensionais

Simulação

PARTE II

ANÁLISE EXPLORATÓRIA

Modelos e Descrição de Dados

6.1 Tipos de Dados

A forma comum em estatística de representar dados é por meio de matrizes retangulares chamadas de **tabelas** ou também, modernamente devido aos softwares usados para tratá-las, **quadro de dados** (*Dataframe*). Por padrão, sendo D um quadro de dados de dimensões $m \times n$, cada coluna de D corresponde a um **atributo**, também chamado de variável ou *feature*, e cada linha corresponde a um registro, que representa um indivíduo na amostra na amostra coletada.

Cada atributo possui um domínio de valores possíveis, que embora possam ser os mais variados possíveis, podem ser organizados numa taxonomia simples. Os tipos de atributos podem ser divididos em dois grande grupos: quantitativos ou qualitativos. O primeiro refere-se a dados com domínio num conjunto numérico, sendo dividido em

Discretos: São atributos que assumem valores em subconjuntos dos números inteiros $\mathbb{Z}$, sendo que na maioria dos contextos são não negativos. Representam contagens, como número de filhos e idades.

Contínuos: O domínio do atributo é um intervalo dos números reais $\mathbb{R}$. Na prática, pelas limitações ontológicas de representar um número real, a realização desses valores se limita a valores aproximados. A diferença fundamental para os discretos é que o conjunto de valores possíveis é não enumerável. Exemplos incluem principalmente medidas, como preços, alturas e pesos.

Os dados qualitativos representam uma qualidade dentro de um conjunto finito de possibilidades chamadas de fatores, sendo divididos em

Ordinais: os fatores possuem uma ordem natural. Exemplos são graus de uma qualidade, como classe social (baixa, média e alta) ou severidade de um exame médico.

Nominais: os fatores não possuem ordem natural, sendo também chamados de categóricos, pois representam categorias. Exemplos são grupos, como sexo ou estado civil. Um tipo especial de variáveis nominais são as dicotômicas, cujos valores possíveis são apenas dois: sucesso ou fracasso, positivo ou negativo, sim ou não, 0 ou 1.

6.2 Escala de Dados

Alternativamente às classificações apresentadas, podemos tipificar atributos através de escalas de medição de seus valores. As classes são similares às classificações apresentadas anteriormente, sendo elas:

- Escala Nominal – para dados nessa escala, só podemos dizer que seus valores são diferentes de outros, sendo usada para categorizar indivíduos. Um exemplo simples é o sexo de uma pessoa: feminino ou masculino. Essa escala não suporta operações matemáticas, e uma medida de centralidade comum para resumir dados nessa escala é a moda.

- Escala Ordinal – nessa escala, os valores podem ser ordenados, e podemos então dizer que, além de diferentes, um valor é maior do que o outro. Essa escala tem sua estrutura preservada por operações que preservem a ordem. Um exemplo de variável ordinal é o nível de escolaridade: fundamental, médio e superior. Medidas de tendência central comuns para dados nessa escala são a moda e a mediana.
- Escala Intervalar - essa escala possui uma origem arbitrária e necessita de uma unidade de medida, sendo um exemplo a temperatura de um ambiente. Podemos afirmar que valores são diferentes, maiores e quão maior em relação a outro, e transformações afim – do tipo $ax + b$ – não alteram a estrutura dessa escala. Podemos utilizar medidas como média, moda e mediana.
- Escala Razão – nessa escala, existe uma origem absoluta, e podemos dizer que um valor é o quão maior do que outro através de razões. Um exemplo de variável nessa escala é o peso de um indivíduo. Transformações do tipo ax preservam a estrutura dessa escala, e podemos utilizar medidas como média, moda e mediana.

6.3 Tabelas de Frequência

Um procedimento para entender o comportamento e distribuição dos dados é por meio de tabelas de frequência, especialmente para variáveis qualitativas, que não podem ser resumidas por serem resumidas por medidas de estatística descritiva a serem vistas mais adiante. Nas tabelas de frequência constam, geralmente, três colunas: a primeira é de categorias ou intervalos de uma classe d_i , a segunda a frequência absoluta n_i de d_i , enquanto a terceira é a frequência relativa $f_i = n_i/n$, onde n é o tamanho da amostra.

Quando lidamos com intervalos de dados numéricos, a amplitude precisa ser definido a priori, e amplitudes diferentes de cada classe pode levar a visualizações distintas. Muitas classes podem levar a perda de informação, enquanto que poucas podem prejudicar a tarefa de resumo. O recomendado é a criação de 5 a 15 classes de mesma amplitude.

Para dados contínuos discretizados em intervalos de amplitude Δ_i para a classe d_i , a tabela pode conter também: a densidade na classe, dada por n_i/Δ_i , a densidade de frequência, obtida por f_i/Δ_i , e a frequência acumulada, dado por

$$\sum_{k=1}^i f_k$$

Essas novas colunas podem ser usadas para construir gráficos que permitam analisar distribuição dos valores de uma variável numérica.

6.4 Gráficos

Nesta seção iremos descrever brevemente gráficos para realizar análise univariada de variáveis de acordo com o seu tipo. Para variáveis qualitativas, os gráficos são basicamente construídos com base na tabela de frequência de cada classe, mostrando a contagem ou a frequência relativa em cada classe. Alguns exemplos incluem:

- Gráfico de Barras – o tamanho da barra é proporcional a contagem ou frequência de registros na classe
- Gráfico de Setores – construído com um círculo de raio arbitrário em que a contagem ou frequência de registros é proporcional à área do setor circular que o representa
- Gráfico de Pirulito – mesmo princípio que o de barras, mas com aspecto mais simples, em que o tamanho é proporcional a uma linha tracejada vertical com um ponto no valor da contagem ou frequência.

Para variáveis numéricas discretas, barras e pirulito também podem funcionar se houver um número não muito grande de realizações distintas no conjunto de dados. Para variáveis contínuas, a discretização em intervalos permite gerar vários tipos de gráficos que ajudam a entender a distribuição de valores da variável, como

- Histogramas – construído também com barras com tamanho proporcional densidade – de registros ou frequência – em cada intervalo. Há várias fórmulas para determinar o número de intervalos (*bins*), como a de Sturges, dada por $k = 1 + 3.3 \log_{10}(n)$, da raiz quadrada, com $k = \sqrt{n}$, de Scott, com $k = \frac{3.5\sigma}{\sqrt[3]{n}}$, onde σ é o desvio-padrão, ou a de Freedman-Diaconis, dada por $k = \frac{2 \cdot \text{IQR}}{\sqrt[3]{n}}$.

- Ramo-e-folha – os ramos são uma coluna vertical com os valores inteiros distintos assumidos pelas realizações. As folhas são as partes fracionárias, empilhadas verticalmente ou horizontalmente em seus ramos.
- Gráfico Dispersão Unidimensional – os dados são mapeados a pontos na reta correspondentes a seus valores. Valores repetidos podem ser empilhados, de modo a dar uma melhor visualização à distribuição dos dados.

Medidas de Resumo

7.1 Medidas de Posição

Um grau maior de resumo dos dados pode ser obtido ao se computar determinadas estatísticas numéricas que sejam representativas de todo o conjunto, e não somente de agrupamentos deles, como é o caso das frequências absolutas e relativas. As medidas a serem apresentadas são usualmente usadas em conjunto para evitar uma redução muito drástica dos dados. Em especial, as medidas de posição nos dão uma ideia de centralidade dos dados.

A primeira delas, é a moda, definida simplesmente como o valor mais frequente na distribuição. Ela pode ser facilmente estimada contando-se o valor mais frequente. Se $x_1, \dots, x_n$ são realizações de uma variável X , então a moda é dada como

$$\text{moda}(X) = \arg \max_x f(x),$$

onde $f(x)$ é a frequência de x em X . A moda é adequada para atributos qualitativos e quantitativos discretos, ao passo que para quantitativos contínuos ela pode ser pouco representativa devido ao grande número de possibilidades de realizações, apesar de ter uma definição satisfatória para esse caso.

A segunda medida é a mediana, que o valor que acumula 50% da frequência acumulada da distribuição de um atributo. Para determinar a mediana de um vetor de dados X , basta ordenar as realizações do vetor; caso sua dimensão seja ímpar, então a mediana é o valor do índice $\frac{n}{2}$, ao passo que, caso seja par, a mediana é obtida como a média entre as realizações de índice $\frac{n}{2}$ e $\frac{n+1}{2}$.

Por fim, a média de um vetor de dados X é o valor $\bar{x}$ dado como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

que é equivalente também a

$$\bar{x} = \sum_{i=1}^n x_i f(x_i).$$

Tanto a média quanto a mediana são apropriadas apenas à atributos quantitativos. Caso estejamos lidando com intervalos discretizados desses valores, então a forma de computar essas medidas é por estimativa.

7.2 Medidas de Dispersão

Além de ver onde nossos dados estão centrados, é desejável saber o quanto eles variam, geralmente entorno do próprio centro citado. Para esse fim, utiliza-se as medidas de dispersão. Como exemplo dessas medidas, poderíamos ter a soma dos desvios entorno da média, ou do quadrado deles para acentuar desvios maiores. No entanto, o sinal dos desvios pode ocultar sua variabilidade real, pois eles podem somar zero, além também de dificultar a comparação da variação entre dois conjuntos de dados distintos. Uma alternativa para isso, seria consederar a soma dos desvios absolutos entorno da média, apesar dessa medida ser sensível ao tamanho do próprio conjunto.

As medidas de dispersão mais simples que contornam os problemas ditos anteriormente são o desvio médio e a variância, dados como

$$\text{dm}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad e \quad \text{Var}(X) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|^2.$$

Como a variância possui unidade igual ao quadrado da unidade do atributo original, então sua interpretação pode ser prejudicada. Dessa forma, define-se o desvio padrão:

$$\text{dp}(X) = \sqrt{\text{Var}(X)},$$

que é equivalente ao “erro” cometido ao se substituir cada observação pela média.

Análise de Dados de Duas Variáveis

PARTE III

INFERÊNCIA CLÁSSICA

Amostragem

Estimação de Parâmetros

Testes de Hipóteses

Inferência Multipopulacional

Análise de Aderência e Adesão

Teste de Hipótese Não Paramétricos

PARTE IV

REGRESSÃO

Covariância e Correlação

Regressão Linear

Regressão Linear Generalizada

PARTE V

INFERÊNCIA BAYESIANA

Paradigma Bayesiano

Inferência e Decisão

Computação Bayesiana

PARTE VI

SÉRIES TEMPORAIS

Fundamentos de Séries Temporais

Modelagem e Previsão
